

Análisis de Series de Tiempo

Benjamín Oliva Vázquez Jaime Vázquez Alamilla
Omar Alfaro Rivera Marcos Emiliano Pérez Caullieres
Luis Gerardo Ruíz González

julio de 2026


Índice general

Análisis de Series de Tiempo	7
Presentación	7
1 Introducción	9
1.1 Sobre estas notas	9
1.2 Estructura del libro	9
1.3 Prerrequisitos	10
1.4 Software: R	11
1.5 Convenciones notacionales	12
1.6 Por qué estudiar el análisis de series de tiempo en economía . . .	12
2 Introducción al Análisis de Series de Tiempo y Elementos de Ecuaciones en Diferencia	15
2.1 La naturaleza de los datos de Series de Tiempo	15
2.2 Ejemplos y aplicaciones de las Series de Tiempo	16
2.3 Ecuaciones en Diferencia para procesos deterministas	24
2.4 Operador de rezago L	43
2.5 De las Ecuaciones en Diferencia a los Procesos Estocásticos . . .	46
3 Procesos Estacionarios y Modelos Univariados	49
3.1 Definición de ergodicidad y estacionariedad	49
3.2 Función de autocorrelación	55
3.3 Procesos estacionarios univariados	61
3.4 Procesos Autorregresivos (AR)	63

3.5	Procesos de Medias Móviles (MA)	88
3.6	Procesos ARMA(p, q) y ARIMA(p, d, q)	95
3.7	Función de Autocorrelación Parcial	100
3.8	Selección de las constantes p, q, d en un AR(p), un MA(q), un ARMA(p, q) o un ARIMA(p, d, q)	103
3.9	Pronósticos	110
3.10	Desestacionalización y filtrado de Series	116
3.11	Resumen del capítulo	126
4	Procesos No Estacionarios Univariados	127
4.1	Definición y formas de No Estacionariedad	127
4.2	Simulación: Caminata Aleatoria vs. Proceso Estacionario	130
4.3	Pruebas de Raíces Unitarias	132
4.4	Resumen y Guía de Decisión	148
5	Causalidad de Granger, Modelos Multivariados de Vectores Au- torregresivos y de Cointegración, Modelos ARDL y Filtro Mul- tivariado	151
5.1	Causalidad de Granger	152
5.2	Definición y representación del Sistema o Modelo de Vectores Autorregresivos (VAR(p))	156
5.3	Análisis de Impulso-Respuesta	172
5.4	Identificación de los Choques Estructurales en los Modelos VAR	181
5.5	Cointegración	191
5.6	Modelos ARDL	208
5.7	Filtro Kalman	215
5.8	Resumen del capítulo	233
6	Modelos Univariados y Multivariados de Volatilidad	235
6.1	Motivación	235
6.2	Modelos ARCH y GARCH Univariados	242
6.3	Extensiones: asimetría y GARCH en media	259
6.4	Modelos ARCH y GARCH Multivariados	260
6.5	Pruebas para detectar efectos ARCH	261
6.6	Resumen del capítulo	262

7 Modelos de Datos Panel, Panel VAR y otros Modelos No Lineales	265
7.1 Modelos de Datos Panel y Panel VAR	265
7.2 Ejemplos: Panel VAR(p)	286
7.3 Cointegración	297
7.4 Modelos No Lineales	302
7.5 Ejemplo: Modelos de Cambio de Régimen (TAR)	306
7.6 Resumen del capítulo	321
Bibliografía	323

Análisis de Series de Tiempo



Presentación

Estas notas corresponden al curso de **Análisis de Series de Tiempo** de la Facultad de Economía de la Universidad Nacional Autónoma de México (UNAM) y al curso de **Econometría II** del Tecnológico de Monterrey, Campus Santa Fe. Están orientadas a estudiantes de licenciatura con conocimientos previos de econometría y probabilidad, y tienen como objetivo ofrecer una introducción rigurosa pero accesible a los principales modelos de series de tiempo, tanto desde la perspectiva teórica y de matemática formal como computacional.

El material cubre los siguientes temas:

1. Ecuaciones en diferencia y su relación con los procesos estocásticos.
2. Procesos estacionarios y modelos univariados (AR, MA, ARMA, ARIMA).
3. Pruebas de raíz unitaria y procesos no estacionarios.

4. Modelos multivariados: VAR, cointegración, VEC y ARDL.
5. Modelos de volatilidad: ARCH y GARCH univariados y multivariados.
6. Datos en panel y modelos no lineales de cambio de régimen.

Todos los ejemplos se implementan en **R** utilizando paquetes especializados (`forecast`, `urca`, `vars`, `rugarch`, `plm`, entre otros). El código está disponible en el repositorio de GitHub junto con las bases de datos empleadas.

Este es un trabajo en proceso de mejora continua. Para comentarios o correcciones escribir a: benjov@ciencias.unam.mx o omarxalpha@gmail.com.

Recurso	Enlace
Sitio web	https://benjov.github.io/Series-Tiempo/
Repositorio (código y datos)	https://github.com/benjov/Series-Tiempo
Versión PDF	https://github.com/benjov/Series-Tiempo/blob/main/docs/Notas-Series-Tiempo.pdf

Capítulo 1

Introducción

1.1 Sobre estas notas

Estas notas son un resumen, una síntesis comparativa y, en algunos casos, una interpretación propia de los libros de texto de Brooks (2019), Cowpertwait y Metcalfe (2009), Guerrero (2003), Enders (2015), Franses y van Dijk (2000), Kirchgässner, Wolters y Hassler (2013), Levendis (2023), Lütkepohl (2005), Neusser (2025), Wei (2019), entre otros. En algunos casos se incorporan artículos de investigación y otra información adicional para efectos de dar contexto al tema analizado (ver sección de Bibliografía para mayores detalles).

El objetivo de este documento es proporcionar un conjunto de apuntes que sirvan de apoyo para las clases de Análisis de Series de Tiempo en la Facultad de Economía de la UNAM y de Econometría II del Tecnológico de Monterrey, Campus Santa Fe. Por esta razón, no deben considerarse como notas exhaustivas ni como un sustituto de la clase, los laboratorios y la lectura de los textos recomendados en clase. Es deseable que los alumnos aporten sus observaciones y correcciones; los comentarios a estas notas son siempre bienvenidos y agradecidos.

Para cualquier comentario o aclaración escribir a los correos benjov@ciencias.unam.mx o omarxalpha@gmail.com.

1.2 Estructura del libro

En estas notas se estudian los temas que típicamente se incluyen en un curso estándar de análisis de series de tiempo, además de algunos tópicos adicionales. Los capítulos están organizados de la siguiente manera:

Capítulo 2. Elementos de Ecuaciones en Diferencia — Se presentan los conceptos fundamentales de las ecuaciones en diferencia, herramienta matemática central para modelar la dinámica de las series de tiempo. Se introduce la notación del operador de rezagos y se estudian las condiciones de estabilidad de procesos lineales basados en ecuaciones en diferencia.

Capítulo 3. Procesos Estacionarios y Modelos Univariados — Se definen formalmente los conceptos de estacionariedad y ergodicidad. Se estudian los modelos autorregresivos $AR(p)$, de medias móviles $MA(q)$, mixtos $ARMA(p, q)$, y su extensión integrada $ARIMA(p, d, q)$. Se incluyen también modelos con variables exógenas $ARIMAX$ y procedimientos de desestacionalización, así como la extensión $SARIMAX$.

Capítulo 4. Procesos No Estacionarios Univariados — Se estudian los procesos con raíz unitaria y las principales pruebas estadísticas para detectarlos: Dickey-Fuller, Dickey-Fuller Aumentada (ADF) y Phillips-Perron, entre otras. Se analiza la diferencia entre tendencia determinística y tendencia estocástica. Finalmente, se introducen pruebas de detección de raíz unitaria bajo escenarios de cambio estructural.

Capítulo 5. Modelos Multivariados: VAR y Cointegración — Se extiende el análisis univariado de series al caso de múltiples series o vector de series. Se presentan la causalidad de Granger, los Vectores Autorregresivos (VAR) y su identificación estructural, el análisis de cointegración de Engle-Granger y Johansen, los Modelos de Corrección de Error (VEC), los modelos de rezagos distribuidos autorregresivos ($ARDL$) y el filtro de Kalman con su representación estado-espacio.

Capítulo 6. Modelos de Volatilidad — Se introducen los modelos que capturan heterocedasticidad condicional: $ARCH(q)$, $GARCH(p, q)$, sus extensiones asimétricas (TGARCH y EGARCH), el GARCH en media y las versiones multivariadas ($M-ARCH$ y $M-GARCH$). Se discute su aplicación a datos financieros de alta frecuencia y otras aplicaciones en el ámbito de la economía.

Capítulo 7. Modelos de Datos Panel y Modelos No Lineales — Se aborda el análisis de datos panel con dimensión temporal, incluyendo pruebas de raíz unitaria y cointegración en panel, el estimador de diferencias en diferencias y los modelos Panel-VAR. Se introduce también la modelación no lineal mediante modelos de cambio de régimen (TAR, STAR y Markov-Switching).

1.3 Prerrequisitos

Estas notas asumen que el lector tiene conocimientos previos de:

- **Probabilidad y estadística:** variables aleatorias, distribuciones de probabilidad, esperanza matemática, varianza y covarianza, métodos de estimación, y pruebas de hipótesis para medias y varianzas.

- **Econometría básica:** regresión lineal por Mínimos Cuadrados Ordinarios (MCO), pruebas de hipótesis simples y conjuntas, problemas de autocorrelación y heterocedasticidad.
- **Álgebra lineal:** operaciones con matrices, valores y vectores propios.
- **Cálculo:** derivadas e integrales básicas.

El dominio de R a nivel introductorio es deseable, aunque no indispensable para seguir los ejemplos. La Sección 1.4 ofrece una guía de los paquetes empleados a lo largo del texto.

1.4 Software: R

Todos los ejemplos y ejercicios en estas notas están programados en **R** (R Core Team, 2023), un entorno de software libre para cómputo estadístico y gráficos. R puede descargarse gratuitamente desde <https://cran.r-project.org>. Se recomienda también instalar **RStudio** como entorno de desarrollo integrado (IDE, por sus siglas en inglés), disponible en <https://posit.co/downloads>.

Los paquetes de R utilizados con mayor frecuencia a lo largo de estas notas son:

Paquete	Propósito principal
<code>readxl</code>	Importación de datos desde archivos Excel
<code>ggplot2</code>	Visualización de datos
<code>forecast</code>	Modelación y pronóstico de series de tiempo (ARIMA, etc.)
<code>tseries</code>	Pruebas de raíz unitaria (ADF, KPSS, etc.)
<code>urca</code>	Pruebas de raíz unitaria y cointegración
<code>vars</code>	Estimación de modelos VAR y VEC
<code>rugarch</code>	Modelos GARCH univariados
<code>rmgarch</code>	Modelos GARCH multivariados
<code>plm</code>	Modelos de datos panel
<code>MSwM</code>	Modelos de cambio de régimen (Markov-Switching)

Para instalar todos los paquetes necesarios en una sola instrucción:

```
install.packages( c( "readxl", "ggplot2", "forecast", "tseries",
  ↪ "urca", "vars", "rugarch", "rmgarch", "plm", "MSwM" ) )
```

Los datos empleados en los ejemplos están disponibles en la carpeta BD/ del repositorio del proyecto en GitHub: <https://github.com/benjov/Series-Tiempo/tree/main/BD>.

1.5 Convenciones notacionales

A lo largo del texto se usan las siguientes convenciones:

- Las series de tiempo se denotan con letras mayúsculas: X_t, Y_t, Z_t .
- Los parámetros poblacionales se denotan con letras griegas: $\alpha, \beta, \phi, \theta$.
- El operador de rezagos se denota con L , de modo que $L^k X_t = X_{t-k}$.
- El operador de primeras diferencias se denota con Δ , de modo que $\Delta X_t = X_t - X_{t-1}$.
- $E[\cdot]$ denota la esperanza matemática (o valor esperado).
- $\text{Var}(\cdot)$ y $\text{Cov}(\cdot, \cdot)$ denotan la varianza y covarianza, respectivamente.
- Las ecuaciones numeradas se referencian como, por ejemplo, la ecuación (3.2).

1.6 Por qué estudiar el análisis de series de tiempo en economía

El análisis de series de tiempo es una herramienta fundamental en la investigación empírica, ya que permite describir y modelar de manera estadísticamente coherente la evolución de una o varias variables a lo largo del tiempo. En economía, está estrechamente relacionado con la macroeconomía y las finanzas, áreas que estudian modelos dinámicos.

En la literatura, existen dos enfoques principales. El primero es descriptivo: utiliza estadísticas como la media, la varianza y la covarianza para identificar regularidades observables en los datos. El segundo busca representar el mecanismo interno que genera los datos. Como en economía este mecanismo suele ser desconocido, se recurre a clases amplias de modelos, especialmente los modelos autorregresivos de medias móviles, conocidos como ARMA, cuyos parámetros se estiman a partir de los datos observados.

Las regularidades encontradas, ya sea mediante estadísticas descriptivas o modelos específicos, son importantes porque permiten contrastar teorías económicas, respaldarlas o descubrir nuevos patrones. Una idea central del análisis de series de tiempo es que las regularidades observadas en una muestra pueden extenderse hacia el futuro. De ahí surge una de sus aplicaciones principales y fundamentales para la economía: la predicción.

A diferencia de los datos de corte transversal, en los que las observaciones se asumen independientes entre sí, las series de tiempo exhiben *dependencia temporal*: el valor de una variable en el período t está correlacionado con sus valores pasados. Esta dependencia, conocida como autocorrelación, invalida los supuestos del modelo de regresión clásico y exige herramientas específicas. Al mismo tiempo, la dependencia temporal es precisamente la que hace posible el

pronóstico: si el presente contiene información sistemática sobre el futuro, es posible aprovecharla para anticipar la trayectoria de la variable de interés.

Las aplicaciones en economía son numerosas. En macroeconomía, el análisis de las fluctuaciones del Producto Interno Bruto (PIB), la inflación, el tipo de cambio y la tasa de desempleo requiere metodologías que capten tanto tendencias de largo plazo como ciclos de corto plazo y componentes estacionales. En finanzas, los modelos de series de tiempo se utilizan para estimar la volatilidad de los rendimientos de activos, evaluar el riesgo de carteras de inversión y construir estrategias de cobertura. En política económica, los bancos centrales y las instituciones gubernamentales emplean estos modelos para generar proyecciones de variables clave y evaluar el impacto de sus intervenciones.

En términos generales, el análisis de series de tiempo persigue tres objetivos: (i) *descripción*, que consiste en caracterizar las propiedades estadísticas de la serie —su tendencia, estacionalidad, ciclos y estructura de correlación serial—; (ii) *modelación*, que busca identificar y estimar el proceso estocástico generador de los datos, de modo que el modelo capte fielmente la dinámica observada; y (iii) *pronóstico*, que utiliza el modelo estimado para generar predicciones de valores futuros de la serie. Estos tres objetivos no son excluyentes: la descripción orienta la elección del modelo, y un modelo bien especificado es a la vez una herramienta poderosa de pronóstico.

Capítulo 2

Introducción al Análisis de Series de Tiempo y Elementos de Ecuaciones en Diferencia

2.1 La naturaleza de los datos de Series de Tiempo

El análisis de series de tiempo tiene muchas aplicaciones en diversos campos de la ciencia. Por ejemplo, en la economía continuamente se está expuesto a información recopilada de los mercados financieros, indicadores de empleo, índices o indicadores del nivel de producción, índices de precios, etc. En otros campos de las ciencias sociales se emplea el análisis de series de tiempo para analizar la evolución de la población, los nacimientos, o el número de personas con matrículas escolares. Finalmente, en las ciencias exactas se pueden encontrar casos como los de un epidemiólogo que puede estar interesado en el número de casos de influenza observados en algún periodo de tiempo dado y si a estos se les puede asociar con algún tipo de estacionalidad o si se trata del inicio de un fenómeno atípico.

La primera aproximación que se suele tener a las series de tiempo es mediante el examen de datos puestos en una gráfica, en la cual uno de los ejes es el tiempo y el otro es el valor tomado por la variable. No obstante, en este tipo de exámenes existen dos enfoques. Por un lado, existe el enfoque de la importancia del tiempo, el cual consiste en reconocer cómo lo que sucede hoy es afectado por lo que pasó ayer o, en general, en periodos pasados, o cómo lo que pasa

hoy afectará los eventos futuros. Por otro lado, existe el enfoque del análisis frecuentista o de frecuencia, mediante el cual se busca reconocer la importancia que tienen para los investigadores los ciclos –por ejemplo, ciclos estacionales, momentos de crisis económicas, etc.–.

2.2 Ejemplos y aplicaciones de las Series de Tiempo

Un primer ejemplo que puede ilustrar la presencia de los dos tipos de enfoques antes mencionados es la Figura 2.1. En esta figura se muestra la evolución del Indicador Global de la Actividad Económica (IGAE) en su versión global o del total de la economía y en su versión únicamente para las actividades primarias entre enero de 2002 y mayo de 2025.

```
library(readxl)

Base_1 <- read_excel("BD/Base_1_TimeSeries.xlsx")
IGAE_2013 <- ts(Base_1$IGAE_2013, start = 2002, freq = 12)
IGAE_PRIM_2013 <- ts(Base_1$IGAE_PRIM_2013, start = 2002, freq =
  ↪ 12)
ICC <- ts(Base_1$ICC, start = 2002, freq = 12)
ICC_LAG <- ts(Base_1$ICC_LAG, start = 2002, freq = 12)
IPC_BMV <- ts(Base_1$IPC_BMV, start = 2002, freq = 12)
TDC <- ts(Base_1$TDC, start = 2002, freq = 12)

plot(IGAE_2013, type = "l", lwd = 1, col = "red", ylab =
  ↪ "Índice",
      xlab = "Tiempo", ylim = c(60,160))
par(new = T)
# Indicador Global de la Actividad Económica, Act. Prim., base
  ↪ 2008
plot(IGAE_PRIM_2013, type = "l", lwd = 1, col = "blue",
      ylab = "Índice", xlab = "Tiempo", ylim = c(60,160))
# Leyenda
legend("topleft", c("IGAE","IGAE Act. Prim."), cex = 0.8,
      lty = 1:1, col = c("red", "blue"))

par(new = F)
```

Como se puede observar, el IGAE del total de la economía muestra, principalmente, que el enfoque del tiempo es más relevante. Es decir, que existe cierta persistencia en el indicador, lo que significa que la economía crece en razón del




Figura 2.1: Indicador Global de Actividad Económica (IGAE) Global y para las Actividades Primarias (2008=100), Ene.2002 - May.2025

crecimiento reportado en períodos pasados. No obstante, lo que no podemos reconocer es que los eventos futuros tienen un efecto en el desempeño de la economía hoy día. Así, no es común observar cambios abruptos del indicador, salvo por la crisis global de 2008 y la reciente crisis causada por la COVID-19.

Por el contrario, el IGAE de las actividades primarias muestra una presencia significativa de la importancia de la frecuencia. No pasa desapercibido que existen muchos ciclos en la evolución del indicador. Algo que suena común en las actividades primarias, cuya producción depende de eventos que son cíclicos y que están asociados con el clima u otros factores determinantes de la oferta de productos agrícolas. Otro factor que puede influir en el indicador son elementos de demanda, más que los de oferta. Por ejemplo, el consumo de alimentos típicos de algunas temporadas del año.

Como segundo ejemplo, en la Figura 2.2 se ilustra la evolución reciente del índice de Confianza del Consumidor (ICC) en dos de sus versiones: i) el Índice global y ii) el Índice de confianza de los consumidores cuando estos consideran la situación actual de la economía en relación con el año anterior.

```
plot(ICC, type = "l", lwd = 1, col = "red", ylab = "Índice",
     xlab = "Tiempo", ylim = c(29, 50))
# Comando que indica a R que sin borrar la grafica anterior,
# grafique la siguiente.
par(new = T)
# Índice ¿Cómo considera usted la situación económica del país
# hoy en día comparada con la de hace 12 meses?, base enero 2003
plot(ICC_LAG, type = "l", lwd = 1, col = "blue", ylab = "Índice",
     xlab = "Tiempo", ylim = c(29,50))
# Leyenda
legend("bottomleft", c("ICC","ICC lag"), cex = 0.8, lty = 1:1,
     col = c("red", "blue"))
```

```
par(new = F)
```

Destacamos que el ICC mide las expectativas de los consumidores en razón de la información pasada y de la esperada, según dichos consumidores. Así, es probable que las dos series de tiempo exhiban un gran peso para los eventos pasados, pero a la vez, un componente –probablemente menor– del componente de frecuencia. Esto último en razón de que los consumidores suelen considerar en sus expectativas de consumo los períodos cíclicos de la economía: temporadas navideñas, pagos de colegiaturas, etc. Este segundo ejemplo también ilustra que la confianza del consumidor no necesariamente está directamente correlacionada con el desempeño de la economía.




Figura 2.2: Índice de Confianza del Consumidor (ICC): General y resultado de ¿Cómo considera usted la situación económica del país hoy en día comparada con la de hace 12 meses? (puntos), Ene.2002-May.2025

Como tercer ejemplo se muestra la evolución de dos series. La Figura 2.3 ilustra el comportamiento reciente de dos indicadores que son referencia para los inversionistas. Por un lado, se ubica el índice de Precios y Cotizaciones de la BMV (IPC), el cual refleja el valor de las acciones de empresas que cotizan en la BMV y el volumen de acciones comercializadas, en conjunto. En el mundo de las finanzas se ha interpretado que el IPC refleja el rendimiento del capital promedio invertido en las empresas que cotizan en la BMV.

```
par(mfrow=c(1,2))

# Índice de Precios y Cotizaciones de la Bolsa Mexicana de
# Valores
plot(IPC_BMV, type = "l", lwd = 1, col = "red", ylab = "Índice",
     xlab = "Tiempo", main = "Índice de Precios y \nCotizaciones
     ↪ BMV")
# Tipo de Cambio para Solventar Obligaciones en Moneda Extranjera
plot(TDC, type = "l", lwd = 1, col = "blue", ylab = "Pesos por
     ↪ Dólar",
     xlab = "Tiempo", main = "Tipo de Cambio")
```




Figura 2.3: Índice de Precios y Cotizaciones de la Bolsa Mexicana de Valores (panel izquierdo) y Tipo de Cambio para Solventar Obligaciones en Moneda Extranjera, pesos por dólar (panel derecho), Ene.2002-May.2025

```
par(mfrow=c(1,1))
```

Por otro lado, en la Figura 2.3 se presenta la evolución del Tipo de Cambio (TDC) –indicador financiero que se suele utilizar como medio de reserva de valor–. Esto, en razón de que el TDC es conocido como un instrumento que en momentos de crisis toma valores contracíclicos de la economía mexicana. No obstante, ambos indicadores no son comparables. Para hacerlos comparables en la Figura 2.4 se presentan en versión índice con una base en el primer mes de la muestra.

```
IPC_BMV_I <- 100*IPC_BMV/IPC_BMV[1]
TDC_I <- 100*TDC/TDC[1]
# Índice del Índice de Precios y Cotizaciones de la Bolsa
  ↳ Mexicana
# de Valores
plot(IPC_BMV_I, type = "l", lwd = 1, col = "red", ylab =
  ↳ "Índice",
      xlab = "Tiempo", ylim = c(80,740))
# Comando que indica a R que sin borrar la grafica anterior,
# grafique la siguiente.
par(new = T)
# Índice del Tipo de Cambio para Solventar Obligaciones en
# Moneda Extranjera
plot(TDC_I, type = "l", lwd = 1, col = "blue", ylab = "Índice",
      xlab = "Tiempo", ylim = c(80,740))
# Leyenda
legend("topleft", c("Índice del IPC","Índice del TDC"), cex =
  ↳ 0.8,
      lty = 1:1, col = c("red", "blue"))
```

```
par(new = F)
```

En la perspectiva de la Figura 2.4 se puede apreciar que el TDC no es tan rentable, ya que una inversión en la BMV mediante el IPC, en el largo plazo, muestra más rendimientos. Asimismo, la Figura 2.4 ilustra que en ambas series se observa un dominio de la condición de tiempo y no uno de la frecuencia. Es decir, tanto el IPC como el TDC no responden a condiciones como ciclos o temporadas que sí son observables en actividades económicas como las primarias.

Finalmente, la Figura 2.5 ilustra una característica que también resulta de gran interés en el análisis de series de tiempo: los datos de alta frecuencia y de comportamiento no regular. En la Figura 2.5 se muestran las diferencias logarítmicas de las series de IGAE de la actividad total, el IPC y el TDC.




Figura 2.4: Índice del índice de Precios y Cotizaciones de la Bolsa Mexicana de Valores e Índice del Tipo de Cambio para Solventar Obligaciones en Moneda Extranjera (ambos, enero de 2002 = 100), pesos por dólar, Ene.2002-May.2025

```

par(mfrow=c(3,1))
# Indicador Global de la Actividad Económica, base 2008
plot(diff(log(IGAE_2013), lag = 1), type = "l", lwd = 1,
     col = "darkred", ylab = "Var. %", xlab = "Tiempo",
     main = "Indicador Global de la Actividad Económica")
# Índice de Precios y Cotizaciones de la Bolsa Mexicana de
  ↪ Valores
plot(diff(log(IPC_BMV), lag = 1), type = "l", lwd = 1,
     col = "darkgreen", ylab = "Var. %", xlab = "Tiempo",
     main = "Índice de Precios y Cotizaciones BMV")
# Tipo de Cambio para Solventar Obligaciones en Moneda Extranjera
plot(diff(log(TDC), lag = 1), type = "l", lwd = 1,
     col = "darkblue", ylab = "Var. %", xlab = "Tiempo",
     main = "Tipo de Cambio")

```




Figura 2.5: Tasas de crecimiento mensuales (diferencias logarítmicas) del Indicador Global de la Actividad Económica, el Índice de Precios y Cotizaciones de la Bolsa Mexicana de Valores y el Tipo de Cambio para Solventar Obligaciones en Moneda Extranjera, Ene.2002-May.2025

```

par(mfrow=c(1,1))

```

Dichas diferencias se pueden interpretar como una tasa de crecimiento de las

series por las siguientes razones. Consideremos una serie de tiempo dada por y_t , cuya versión logarítmica es $\ln(y_t)$. De esta forma, la diferencia logarítmica está dada por la ecuación (2.1):

$$\Delta \ln(y_t) = \ln(y_t) - \ln(y_{t-1}) = \ln\left(\frac{y_t}{y_{t-1}}\right) \quad (2.1)$$

Ahora bien, si retomamos la definición de tasa de crecimiento (TC) de una serie de tiempo y_t entre el periodo t y $t - 1$ podemos obtener que:

$$TC = \frac{y_t - y_{t-1}}{y_{t-1}} = \frac{y_t}{y_{t-1}} - 1 \quad (2.2)$$

De esta forma, si tomamos el logaritmo de la expresión de la ecuación (2.2) obtenemos la siguiente aproximación:

$$\frac{y_t}{y_{t-1}} - 1 \approx \ln\left(\frac{y_t}{y_{t-1}}\right) = \ln(y_t) - \ln(y_{t-1}) \quad (2.3)$$

La aproximación de la ecuación (2.3) es válida cuando los valores de y_t y y_{t-1} son muy parecidos, es decir, cuando las variaciones entre periodos son suficientemente pequeñas (se deriva de que $\ln(1 + x) \approx x$ cuando x es cercano a cero). Dicho de otra forma: para tasas de crecimiento pequeñas, la diferencia logarítmica de la ecuación (2.1) es una buena aproximación de la tasa de crecimiento de la serie.

En la Figura 2.5 se reportan las diferencias logarítmicas del IGAE, el IPC y el TDC, todas interpretables como una medida de distintos tipos de rendimientos. Es decir, un inversionista promedio (suponiendo que solo puede invertir en la actividad económica, en la bolsa o en el dólar) puede comparar cuál de las tres alternativas le resulta más redituable en función de sus preferencias.

Nótese que la dinámica de las variaciones de cada una de las series es significativamente diferente. Destaca que el TDC es una de las variables que, en general, no muestra grandes cambios a lo largo del tiempo. No obstante, se han observado cambios radicales, cuando menos en el año 2008 y durante la pandemia de COVID-19. Esta situación también se ha observado para el IPC. En cambio, el IGAE muestra un comportamiento más estable o estacionario –concepto que abordaremos más adelante–.

2.3 Ecuaciones en Diferencia para procesos deterministas

En las secciones previas se hizo una introducción al concepto de series de tiempo. En esta sección se pretende desarrollar la construcción de los procesos generadores de datos de las series de tiempo. En un sentido más formal, se expondrá

que las series de tiempo se pueden considerar como una secuencia de variables aleatorias.

Para tales efectos, se desarrollará una introducción al concepto de ecuaciones en diferencia. Así, las preguntas que se pretende responder son:

1. ¿Cuál es la solución de la ecuación en diferencia que se estudia?
2. ¿Cuáles son las condiciones para que un proceso estocástico, representado mediante una ecuación en diferencia, llegue a alcanzar un punto de equilibrio en el largo plazo?

El término de *ecuación en diferencia* sirve para denominar un proceso similar o equivalente dentro de las ecuaciones diferenciales, dentro del cual se consideran a un conjunto de variables que están en función del tiempo. Así, si consideramos al tiempo como una variable continua, es decir, consideramos una variable $Z(t)$, podemos expresar las siguientes expresiones para la ecuación diferencial:

$$\frac{dZ(t)}{dt}; \frac{d^2Z(t)}{dt^2}; \dots; \frac{d^kZ(t)}{dt^k} \quad (2.4)$$

Por otro lado, suponiendo el caso del tiempo en forma discreta, es decir, con $t = \dots, -2, -1, 0, 1, 2, \dots$, el comportamiento de la serie de variables dada por Z_t se puede expresar como:

$$\Delta Z_t; \Delta^2 Z_t; \dots; \Delta^k Z_t \quad (2.5)$$

Observemos que una forma técnicamente más correcta es escribir las expresiones anteriores como:

$$\frac{\Delta Z_t}{\Delta t}; \frac{\Delta^2 Z_t}{\Delta t^2}; \dots; \frac{\Delta^k Z_t}{\Delta t^k} \quad (2.6)$$

No obstante, no pasa desapercibido que $\Delta t = 1$, por lo que resultan equivalentes ambos conjuntos de expresiones (2.5) y (2.6).

2.3.1 Ecuaciones en Diferencia Lineales de Primer Orden

El primer caso que se suele estudiar en relación con las Ecuaciones en Diferencia es el de las Ecuaciones en Diferencia Lineales de Primer Orden. Al respecto, al igual que en el caso continuo, las variaciones de la variable Z_t se pueden expresar como se ilustra en el siguiente ejemplo. Consideremos la siguiente ecuación:

$$Z_t = a_0 + a_1 Z_{t-1} \quad (2.7)$$

Donde, $t = \dots, -2, -1, 0, 1, 2, \dots$, y a_0 y $a_1 \neq 0$ son números reales constantes. De (2.7) podemos reagrupar los términos y obtener una forma de ecuación en diferencia:

$$Z_t - a_1 Z_{t-1} = a_0 \quad (2.8)$$

Ahora denotemos a $LZ_t = Z_{t-1}$, es decir, mediante el operador L se puede rezagar una variable dada—entendiendo como rezago a tomar el valor de Z en el período $t - 1$ —. En general, podemos decir que el operador tiene dos propiedades, la primera es que es lineal —en el sentido de que abre sumas y saca escalares— como se muestra en la siguiente expresión para el caso de un (1) rezago:

$$L(\alpha Z_t + \beta) = \alpha Z_{t-1} + \beta \quad (2.9)$$

Donde $\alpha, \beta \in \mathbb{R}$ y $\alpha, \beta \neq 0$. Otro resultado implícito en esta primera propiedad es que el operador rezago aplicado a cualquier escalar dará como resultado el escalar, puesto que este es una constante sin importar el momento t en el cual se encuentre la variable Z .

La segunda propiedad del operador es que se puede aplicar de forma consecutiva a una misma variable. Es decir, $L(Z_{t-1}) = LLZ_t = L^2Z_t$, por lo que en general tendremos: $L^p Z_t = Z_{t-p}$ (con $p \in \mathbb{Z}$). Así, en el caso de p rezagos la propiedad de linealidad del operador rezago será:

$$L^p(\alpha Z_t + \beta) = \alpha Z_{t-p} + \beta \quad (2.10)$$

Dicho lo anterior, podemos escribir la solución general de (2.8) como:

$$\begin{aligned} Z_t - a_1 LZ_t &= a_0 \\ (1 - a_1 L)Z_t &= a_0 \\ Z_t &= a_0 \frac{1}{1 - a_1 L} + sa_1^t \\ Z_t &= a_0 \frac{1}{1 - a_1} + sa_1^t \end{aligned} \quad (2.11)$$

Donde $a_1 \neq 1$ y $t = \dots, -2, -1, 0, 1, 2, \dots$. Nótese que la aplicación del operador rezago L a la constante a_1 dará como resultado el valor de la misma constante, ya que ésta no depende del momento t en el cual observemos a la variable Z_t . En la ecuación (2.11) se adiciona un término sa_1^t que permite ubicar la trayectoria inicial de la solución de la ecuación. El componente no significa un cambio respecto de la ecuación (2.8) original, ya que si buscáramos reconstruir esta ecuación tendríamos:

$$\begin{aligned} (1 - a_1 L)sa_1^t &= sa_1^t - a_1 sLa_1^t \\ &= sa_1^t - a_1 sa_1^{t-1} \\ &= sa_1^t - sa_1^t \\ &= 0 \end{aligned}$$

La ecuación (2.11) se suele interpretar como la solución de largo plazo. Ahora demostraremos por qué es cierta la ecuación y discutiremos algunas condiciones que se deben observar en esta solución para que sea una solución convergente.

No obstante, primero discutiremos un método indirecto e incompleto para demostrar el resultado. Dicho método es conocido como el método iterativo. Plantearemos las siguientes ecuaciones particulares donde suponemos la existencia del valor inicial Z_0 del proceso:

$$Z_1 = a_0 + a_1 Z_0$$

$$\begin{aligned} Z_2 &= a_0 + a_1 Z_1 \\ &= a_0 + a_1(a_0 + a_1 Z_0) \\ &= a_0 + a_0 a_1 + a_1^2 Z_0 \\ &= a_0(1 + a_1) + a_1^2 Z_0 \end{aligned}$$

$$\begin{aligned} Z_3 &= a_0 + a_1 Z_2 \\ &= a_0 + a_1(a_0 + a_0 a_1 + a_1^2 Z_0) \\ &= a_0 + a_0 a_1 + a_0 a_1^2 + a_1^3 Z_0 \\ &= a_0(1 + a_1 + a_1^2) + a_1^3 Z_0 \end{aligned}$$

De lo anterior se puede inferir que el método iterativo convergerá hacia una expresión como la siguiente en el momento t :

$$\begin{aligned} Z_t &= a_0 + a_1 Z_{t-1} \\ &= a_0(1 + a_1 + a_1^2 + \dots + a_1^{t-1}) + a_1^t Z_0 \\ &= a_0 \sum_{i=0}^{t-1} a_1^i + a_1^t Z_0 \end{aligned} \tag{2.12}$$

Donde, es necesario que en la ecuación (2.12) se cumpla que $|a_1| < 1$ para que la suma sea convergente –más adelante detallaremos esta afirmación–. A este tipo de ecuaciones se les puede denominar como lineales. Esto en razón de que ningún término de la variable Z aparece elevado a ninguna potencia distinta a 1. También, son de primer orden, ya que el rezago de la variable Z es sólo de un período.

En adelante trabajaremos con ecuaciones en las que la variable Z se encuentra rezagada en cualquiera de los siguientes casos:

$$Z_t, Z_{t-1}, Z_{t-2}, Z_{t-3}, \dots, Z_{t-p}, \dots \tag{2.13}$$

Por lo que diremos que en adelante el texto versará sobre ecuaciones en diferencia lineales y de cualquier orden $p \in \mathbb{N}$.

Retomemos la ecuación (2.12) y consideremos la parte de la suma de los términos a_1^t , a la cual buscaremos dar una expresión más compacta. Definamos:

$$S_{t-1} = \sum_{i=0}^{t-1} a_1^i \quad (2.14)$$

Multipliquemos ahora S_{t-1} por a_1 :

$$\begin{aligned} a_1 S_{t-1} &= a_1 \sum_{i=0}^{t-1} a_1^i \\ &= a_1(1 + a_1 + a_1^2 + \dots + a_1^{t-1}) \\ &= a_1 + a_1^2 + a_1^3 + \dots + a_1^t \end{aligned} \quad (2.15)$$

Restando la ecuación (2.15) de la ecuación (2.14), la mayoría de los términos se cancelan entre sí:

$$\begin{aligned} S_{t-1} - a_1 S_{t-1} &= (1 + a_1 + a_1^2 + \dots + a_1^{t-1}) - (a_1 + a_1^2 + a_1^3 + \dots + a_1^t) \\ (1 - a_1) S_{t-1} &= 1 - a_1^t \end{aligned}$$

Así, podemos concluir que:

$$S_{t-1} = \frac{1 - a_1^t}{1 - a_1} \quad (2.16)$$

Conjuntando este último resultado de la ecuación (2.16) con la ecuación (2.12) tenemos la siguiente solución por el método de iteración:

$$Z_t = a_0 \left(\frac{1 - a_1^t}{1 - a_1} \right) + a_1^t Z_0 \quad (2.17)$$

De esta forma, la ecuación (2.17) es una solución de la Ecuación en Diferencia planteada en la ecuación (2.7). Esta solución aún no es general, en el sentido de que sea válida para cualquier tipo de proceso: convergente o divergente. Dicha convergencia o divergencia estará determinada por el parámetro a_1 . No debe pasar desapercibido que cuando $t \rightarrow \infty$ o cuando la muestra es muy grande (lo que es equivalente), podemos decir que la solución solo puede converger a la siguiente expresión cuando se considera que $|a_1| < 1$:

$$Z_t = a_0 \left(\frac{1}{1 - a_1} \right) \quad (2.18)$$

Retomemos ahora el caso general descrito en la ecuación (2.11) y determinemos una solución general en la cual $a_1 \neq 1$ y $t = \dots, -2, -1, 0, 1, 2, \dots$. Para ello,

observemos que el siguiente componente en la ecuación mencionada se puede interpretar como la suma infinita de términos descritos como:

$$\begin{aligned}\frac{1}{1-a_1} &= 1 + a_1 + a_1^2 + \dots + a_1^t + \dots \\ &= \sum_{i=0}^{\infty} a_1^i\end{aligned}\tag{2.19}$$

Donde claramente es necesario que $|a_1| < 1$. Por lo tanto, sólo faltaría determinar el valor de la constante s en la ecuación (2.11) de la siguiente forma, supongamos que observamos el proceso en el momento inicial, por lo que es posible determinar el valor de la constante conociendo el valor inicial del proceso como sigue:

$$Z_0 = a_0 \frac{1}{1-a_1} + s\tag{2.20}$$

De la ecuación (2.20) tenemos que:

$$s = Z_0 - a_0 \frac{1}{1-a_1}\tag{2.21}$$

Así, juntando la ecuación (2.11) y la ecuación (2.21) tenemos la expresión:

$$Z_t = a_0 \frac{1-a_1^t}{1-a_1} + a_1^t Z_0\tag{2.22}$$

No debe pasar desapercibido que esta solución es la misma que la mostrada en la ecuación (2.17): ambos caminos —el método iterativo y el uso del operador rezago— conducen a la misma solución general. En ambos casos la solución converge a la expresión de la ecuación (2.18) bajo la misma condición de convergencia $|a_1| < 1$. Para ilustrar estas ecuaciones, veamos algunos ejemplos al respecto.

Ejemplo. Consideremos que tenemos un proceso Z_t que es descrito por una ecuación en diferencia lineal de primer orden dada por:

$$Z_t = 2 + 0.9Z_{t-1}\tag{2.23}$$

Siguiendo la expresión mostrada en la ecuación (2.22), obtenemos la expresión:

$$Z_t = 2 \left(\frac{1-0.9^t}{1-0.9} \right) + 0.9^t Z_0\tag{2.24}$$

Donde asumiremos que el valor inicial es $Z_0 = 10$ y que la expresión debe converger al valor de 20, cuando t es muy grande o tiende a infinito.

Ejemplo. De forma similar, tomemos otro ejemplo en el cual asumimos la siguiente expresión:

$$Z_t = 2 - 0.5Z_{t-1} \quad (2.25)$$

Siguiendo la expresión mostrada en la ecuación (2.22), obtenemos:

$$Z_t = 2 \left(\frac{1 - (-0.5)^t}{1 + 0.5} \right) + (-0.5)^t Z_0 \quad (2.26)$$

Donde asumiremos que el valor inicial es $Z_0 = 10$ y que la ecuación converge al valor de 1.333333..., cuando t es muy grande o tiende a infinito. Ahora simularemos el comportamiento de ambos procesos; los resultados se muestran en el Cuadro 2.1. Notemos que el segundo proceso converge de una forma más rápida que el primero. Los resultados del Cuadro 2.1 se ilustran en las Figuras 2.6 y 2.7.

```
library(knitr)
library(tidyverse)
library(kableExtra)

Tiempo = c(0:100)
Zt = rep(NA, 101)
Zt2 = rep(NA, 101)
Zt[1] = 10
Zt2[1] = 10

for (i in c(2:101)){
  Zt[i] = 2+0.9*Zt[i-1]
  Zt2[i] = 2 - 0.5*Zt2[i-1]
}
lista = c(1:16, 97:101)
Tiempo1 = Tiempo[lista]
Zt1=Zt[lista]
Zt21=Zt2[lista]

tabla1 = data.frame(Tiempo1, Zt1, Zt21)
colnames(tabla1) <- c("Tiempo", "$Z_t =2+0.9Z_{t-1}$",
"$Z_t = 2-0.5Z_{t-1}$")

kable(tabla1,
      caption = "Dos ejemplos de Ecuaciones Lineales de Primer
↪ Orden",
      format = "pandoc") %>%
kable_styling(font_size = 10)
```

Cuadro 2.1: Dos ejemplos de Ecuaciones Lineales de Primer Orden

Tiempo	$Z_t = 2 + 0.9Z_{t-1}$	$Z_t = 2 - 0.5Z_{t-1}$
0	10.00000	10.000000
1	11.00000	-3.000000
2	11.90000	3.500000
3	12.71000	0.250000
4	13.43900	1.875000
5	14.09510	1.062500
6	14.68559	1.468750
7	15.21703	1.265625
8	15.69533	1.367188
9	16.12580	1.316406
10	16.51322	1.341797
11	16.86189	1.329102
12	17.17570	1.335449
13	17.45813	1.332275
14	17.71232	1.333862
15	17.94109	1.333069
96	19.99960	1.333333
97	19.99964	1.333333
98	19.99967	1.333333
99	19.99970	1.333333
100	19.99973	1.333333

```
tabla <- data.frame( Tiempo, Zt, Zt2 )

ggplot( data = tabla , aes(x = Tiempo, y = Zt) )+
  geom_line(col="blue4") +
  geom_point(col= "blue4") +
  labs(y=expression(Z[t]))
```

```
ggplot(data = tabla , aes(x = Tiempo, y=Zt2)) +
  geom_line(col="red4") +
  geom_point(col= "red4") +
  labs(y=expression(Z[t]))
```

2.3.2 Ecuaciones en Diferencia Lineales de Segundo Orden y de orden superior

Como un segundo caso a estudiar se ubica el caso de las Ecuaciones en Diferencia Lineales de Segundo Orden y, en su caso, de orden superior. Primero, sea una




Figura 2.6: Evolución del proceso dado por $Z_t = 2 + 0.9Z_{t-1}$




Figura 2.7: Evolución del proceso dado por $Z_t = 2 - 0.5Z_{t-1}$

ecuación como la siguiente, la cual es lineal y de segundo orden, ya que tiene asociado un término de Z_t rezagado dos periodos:

$$Z_t = a_0 + a_1 Z_{t-1} + a_2 Z_{t-2} \quad (2.27)$$

Donde $t = \dots, -2, -1, 0, 1, 2, \dots$ y $a_1, a_2 \neq 0$. Reordenando la ecuación (2.27) podemos escribir:

$$\begin{aligned} Z_t - a_1 Z_{t-1} - a_2 Z_{t-2} &= a_0 \\ Z_t - a_1 L Z_t - a_2 L^2 Z_t &= a_0 \\ (1 - a_1 L - a_2 L^2) Z_t &= a_0 \end{aligned} \quad (2.28)$$

Así, la solución general propuesta para la ecuación (2.28) es la siguiente, la cual es una forma análoga a una Ecuación Lineal en Diferencia de Primer Orden:

$$Z_t = \frac{a_0}{1 - a_1 - a_2} + s_1 g_1^t + s_2 g_2^t \quad (2.29)$$

En donde s_1 y s_2 son constantes que se determinan mediante dos condiciones iniciales –por lo que para resolver este tipo de ecuaciones requerimos conocer dos condiciones iniciales–. Los valores de g_1 y g_2 están relacionados con los coeficientes a_1 y a_2 , de esta forma:

$$a_1 = g_1 + g_2 \quad (2.30)$$

$$a_2 = -g_1 g_2 \quad (2.31)$$

Lo anterior surge del siguiente procedimiento y recordando que siempre es posible descomponer una ecuación cuadrática en expresiones como las siguientes:

$$\begin{aligned} (1 - a_1 L - a_2 L^2) &= (1 - g_1 L)(1 - g_2 L) \\ &= 1 - g_1 L - g_2 L + g_1 g_2 L^2 \\ &= 1 - (g_1 + g_2)L + g_1 g_2 L^2 \end{aligned} \quad (2.32)$$

Donde se observa la equivalencia mostrada en las ecuaciones (2.30) y (2.31). Así, considerando la ecuación (2.29) tenemos que:

$$\begin{aligned} (1 - a_1 L - a_2 L^2) Z_t &= (1 - g_1 L)(1 - g_2 L) Z_t \\ &= a_0 + (1 - g_1 L)(1 - g_2 L) s_1 g_1^t \\ &\quad + (1 - g_1 L)(1 - g_2 L) s_2 g_2^t \end{aligned} \quad (2.33)$$

Por lo tanto, para que la ecuación (2.29) sea efectivamente una solución general, se requiere que se cumpla lo siguiente:

$$(1 - g_1 L)(1 - g_2 L) s_1 g_1^t + (1 - g_1 L)(1 - g_2 L) s_2 g_2^t = 0 \quad (2.34)$$

O, escrito de otra forma:

$$(1 - g_1 L)s_1 g_1^t = (1 - g_2 L)s_2 g_2^t = 0 \quad (2.35)$$

Ahora determinemos cuáles son los valores g_1 y g_2 dados los valores a_1 y a_2 que nos permitan determinar si el proceso será convergente. Para ello debemos resolver la siguiente ecuación que se deriva de la ecuación (2.32):

$$1 - a_1 x - a_2 x^2 = (1 - g_1 x)(1 - g_2 x) = 0 \quad (2.36)$$

Donde, claramente existen dos raíces: $x_1 = g_1^{-1}$ y $x_2 = g_2^{-1}$. Así, la solución estará dada por las raíces de la ecuación característica:

$$\begin{aligned} 1 - a_1 x - a_2 x^2 &= 0 \\ a_2 x^2 + a_1 x - 1 &= 0 \end{aligned} \quad (2.37)$$

Cuya solución es:

$$x = \frac{-a_1 \pm \sqrt{a_1^2 + 4a_2}}{2a_2} \quad (2.38)$$

Es importante distinguir tres diferentes casos en relación con las raíces que surgen como solución de la ecuación (2.37), estos son:

Caso I. Si $a_1^2 + 4a_2 > 0$, la ecuación (2.37) proporcionará dos valores de raíces reales y distintos, eso es $x_1 = g_1^{-1} \neq x_2 = g_2^{-1}$. Si por ahora suponemos que $|g_1| < 1$ y que $|g_2| < 1$, entonces tendremos que:

$$\begin{aligned} (1 - g_1 L)^{-1}(1 - g_2 L)^{-1}a_0 &= \left(\sum_{j=0}^{\infty} g_1^j L^j \right) \left(\sum_{j=0}^{\infty} g_2^j L^j \right) a_0 \\ &= \left(\sum_{j=0}^{\infty} g_1^j \right) \left(\sum_{j=0}^{\infty} g_2^j \right) a_0 \\ &= \frac{a_0}{(1 - g_1)(1 - g_2)} \\ &= \frac{a_0}{1 - a_1 - a_2} \end{aligned} \quad (2.39)$$

Esto último es el punto de equilibrio de la ecuación (2.29); considerando que $|g_1| < 1$ y que $|g_2| < 1$ —notemos que los demás casos son divergentes, ya que la suma anterior no convergería—. De esta forma, la solución de la ecuación estará dada por:

$$\lim_{t \rightarrow \infty} Z_t = \frac{a_0}{1 - a_1 - a_2} \quad (2.40)$$

Caso II. Si $a_1^2 + 4a_2 < 0$ en la ecuación (2.37), entonces las raíces serán números complejos conjugados, es decir:

$$g_i^{-1} = a \pm ib \quad (2.41)$$

$$g_i = u \pm iv \quad (2.42)$$

Dichas raíces las podemos escribir en coordenadas polares como:

$$g_1 = re^{i\theta} = r(\cos(\theta) + i\sen(\theta)) \quad (2.43)$$

$$g_2 = re^{-i\theta} = r(\cos(\theta) - i\sen(\theta)) \quad (2.44)$$

Donde: $r = \sqrt{u^2 + v^2}$, a esta expresión también se le conoce como módulo. Alternativamente, podemos escribir que $r = \sqrt{g_1 g_2}$. La única condición es que $r < 1$ para que el proceso descrito en la ecuación (2.29) sea convergente.

Al igual que en el **Caso I**, el punto de equilibrio de la ecuación se debería ubicar alrededor de la ecuación (2.40), siempre que $r < 1$, por lo que el factor que determina la convergencia es el módulo, ya que si el módulo es mayor a 1, el proceso será divergente, pero si es menor a 1 convergerá a (2.40). Para ilustrar, el caso contrario es divergente puesto que representa trayectorias senoidales (oscilatorias) que sólo pueden converger si a medida que pasa el tiempo las ondas son menos amplias.

Analicemos la solución:

$$Z_t = \frac{a_0}{1 - a_1 - a_2} + s_1 g_1^t + s_2 g_2^t$$

Donde s_1 y s_2 las determinamos usando las condiciones iniciales al solucionar:

$$\begin{aligned} Z_0 &= \frac{a_0}{1 - a_1 - a_2} + s_1 g_1^0 + s_2 g_2^0 \\ Z_1 &= \frac{a_0}{1 - a_1 - a_2} + s_1 g_1^1 + s_2 g_2^1 \end{aligned}$$

Donde, una vez encontradas las g_1 y g_2 , las incógnitas son s_1 y s_2 . Para determinar g_1 y g_2 realizamos el siguiente procedimiento. Partimos de la ecuación:

$$1 - a_1 x - a_2 x^2 = 0$$

Al factorizar notamos que:

$$(1 - g_1 x)(1 - g_2 x) = 0$$

De lo anterior debe quedar claro que:

$$\begin{aligned} x_1 &= g_1^{-1} \\ x_2 &= g_2^{-1} \end{aligned}$$

Donde g_1 y g_2 se determinan:

$$x = \frac{-a_1 \pm \sqrt{a_1^2 + 4a_2}}{2a_2}$$

Asumiendo que se obtienen números complejos:

$$\begin{aligned} x_1 &= g_1^{-1} = u + iv \\ x_2 &= g_2^{-1} = u - iv \end{aligned}$$

Las cuales se pueden reescribir en coordenadas polares:

$$\begin{aligned} g_1^{-1} &= se^{i\theta} = s[\cos(\theta) + i\text{sen}(\theta)] \\ g_2^{-1} &= se^{-i\theta} = s[\cos(\theta) - i\text{sen}(\theta)] \\ s &= \sqrt{u^2 + v^2} = \sqrt{g_1^{-1} \cdot g_2^{-1}} \\ \cos(\theta) &= \frac{u}{s} \\ \text{sen}(\theta) &= \frac{v}{s} \end{aligned}$$

Recuerde que: $r = s^{-1} = \sqrt{g_1 \cdot g_2}$, de esta forma:

$$\begin{aligned} g_1 &= r[\cos(\theta) - i\text{sen}(\theta)] \\ g_2 &= r[\cos(\theta) + i\text{sen}(\theta)] \end{aligned}$$

Retomemos nuestra solución original:

$$\begin{aligned} Z_t &= \frac{a_0}{1 - a_1 - a_2} + s_1 g_1^t + s_2 g_2^t \\ &= \frac{a_0}{1 - a_1 - a_2} + s_1 r^t [\cos(\theta) - i\text{sen}(\theta)]^t + s_2 r^t [\cos(\theta) + i\text{sen}(\theta)]^t \\ &= \frac{a_0}{1 - a_1 - a_2} + s_1 r^t (e^{-i\theta})^t + s_2 r^t (e^{i\theta})^t \\ &= \frac{a_0}{1 - a_1 - a_2} + s_1 r^t (e^{-it\theta}) + s_2 r^t (e^{it\theta}) \\ &= \frac{a_0}{1 - a_1 - a_2} + s_1 r^t [\cos(\theta t) - i\text{sen}(\theta t)] + s_2 r^t [\cos(\theta t) + i\text{sen}(\theta t)] \\ &= \frac{a_0}{1 - a_1 - a_2} + r^t [(s_1 + s_2)\cos(\theta t) + i(s_2 - s_1)\text{sen}(\theta t)] \\ &= \frac{a_0}{1 - a_1 - a_2} + r^t [A\cos(\theta t) + B\text{sen}(\theta t)] \end{aligned}$$

Donde $A = s_1 + s_2$ y $B = i(s_2 - s_1)$ son constantes, y la convergencia está definida por r : si $r > 1$ el proceso diverge, y converge si $r < 1$. Nótese que para

que Z_t sea real, s_1 y s_2 deben ser conjugados complejos, es decir, $s_2 = \bar{s}_1$. Si escribimos $s_1 = p - iq$ con $p, q \in \mathbb{R}$, entonces $A = s_1 + s_2 = 2p$ y $B = i(s_2 - s_1) = i(2iq) = -2q$, ambos reales, lo que garantiza que $Z_t \in \mathbb{R}$. Finalmente, el ángulo θ se recupera de las relaciones anteriores:

$$\theta = \cos^{-1} \left(\frac{u}{s} \right) = \sin^{-1} \left(\frac{v}{s} \right)$$

Caso III. Ahora revisemos el caso en el que $a_1^2 + 4a_2 = 0$, de esta forma las raíces serán idénticas:

$$g = g_1^{-1} = g_2^{-1} = \frac{-a_1}{2a_2} \quad (2.45)$$

Así, el punto de equilibrio será dado por la solución descrita como:

$$\begin{aligned} (1 - gL)^2 Z_t &= a_0 \\ Z_t &= \frac{a_0}{(1 - gL)^2} + s_1 g^t + s_2 t g^t \\ &= a_0 \sum_{j=0}^{\infty} (1 + j) g^j + s_1 g^t + s_2 t g^t \end{aligned} \quad (2.46)$$

Para verificar que $t g^t$ es solución independiente de g^t en la parte homogénea, aplicamos el operador $(1 - gL)^2$ directamente:

$$\begin{aligned} (1 - gL)^2 (t g^t) &= (1 - gL) [t g^t - g(t - 1) g^{t-1}] \\ &= (1 - gL) [t g^t - (t - 1) g^t] \\ &= (1 - gL) g^t \\ &= g^t - g \cdot g^{t-1} = 0 \end{aligned}$$

Por lo tanto, $t g^t$ satisface la ecuación homogénea y constituye una solución linealmente independiente de g^t , lo que justifica la forma de la solución general en el caso de raíces repetidas.

La expansión en serie de la solución particular $\frac{a_0}{(1 - gL)^2}$ es resultado del siguiente procedimiento. Sea:

$$f(g) = \frac{1}{(1 - g)} = \sum_{j=0}^{\infty} g^j$$

Por lo que si hacemos la primera derivada de la expresión anterior tenemos que:

$$\begin{aligned} f'(g) &= \frac{1}{(1 - g)^2} \\ &= \sum_{j=0}^{\infty} j g^{j-1} \\ &= 0 + g^0 + 2g^1 + 3g^2 + \dots \\ &= \sum_{j=0}^{\infty} (1 + j) g^j \end{aligned}$$

Ahora veamos un ejemplo de una Ecuación Lineal en Diferencia de Segundo Orden. Supongamos la ecuación y el desarrollo siguientes:

$$\begin{aligned} Z_t &= 3 + 0.9Z_{t-1} - 0.2Z_{t-2} \\ (1 - 0.9L + 0.2L^2)Z_t &= 3 \end{aligned}$$

La solución dada por una ecuación similar a la expresión (2.37), obtendríamos la solución dada por las ecuaciones equivalentes a:

$$\begin{aligned} 1 - 0.9x + 0.2x^2 &= 0 \\ -0.2x^2 + 0.9x - 1 &= 0 \end{aligned}$$

De donde las raíces del polinomio característico $x_1 = g_1^{-1}$ y $x_2 = g_2^{-1}$ se obtienen de la expresión dada por:

$$\begin{aligned} x &= \frac{-0.9 \pm \sqrt{0.81 + (4)(-0.2)}}{(2)(-0.2)} \\ &= \frac{-0.9 \pm 0.1}{-0.4} \end{aligned}$$

Dado que el componente $a_1^2 + 4a_2$ es positivo, obtendremos dos raíces reales. Las raíces estarán dadas por $x_1 = 2.5$ y $x_2 = 2.0$, de lo cual podemos determinar que $g_1 = 0.4$ y $g_2 = 0.5$. De esta forma tenemos que $|g_1| < 1$ y $|g_2| < 1$, así la ecuación converge a la expresión dada por las siguientes expresiones:

$$\begin{aligned} Z_t &= \frac{3}{1 - 0.9L + 0.2L^2} + s_1(0.4)^t + s_2(0.5)^t \\ &= \frac{3}{1 - 0.9 + 0.2} + s_1(0.4)^t + s_2(0.5)^t \\ &= \frac{3}{(1 - 0.4)(1 - 0.5)} + s_1(0.4)^t + s_2(0.5)^t \end{aligned}$$

Al final, la ecuación que describe la solución general será:

$$Z_t = 10 + s_1(0.4)^t + s_2(0.5)^t \quad (2.47)$$

Para determinar los valores de s_1 y s_2 necesitamos obtener dos valores iniciales de la ecuación. Para lo cual iniciaremos con $t = 0$ y, luego, obtenemos el valor de $t = 1$, y consideremos el valor de $Z_0 = 0$ y $Z_1 = 50$:

$$\begin{aligned} Z_0 &= 10 + s_1(0.4)^0 + s_2(0.5)^0 \\ 0 &= 10 + s_1 + s_2 \\ Z_1 &= 10 + s_1(0.4)^1 + s_2(0.5)^1 \\ 50 &= 10 + 0.4s_1 + 0.5s_2 \end{aligned}$$

Por lo que la solución es: $s_1 = -450$ y $s_2 = 440$, de donde podemos expresar la ecuación como:

$$Z_t = 10 - 450(0.4)^t + 440(0.5)^t \quad (2.48)$$

La ecuación (2.48) anterior convergerá al valor de 10 cuando $t \rightarrow \infty$. Para ilustrar la trayectoria de esta ecuación tomemos un cuadro similar al de los ejemplos anteriores. En el Cuadro 2.2 y la Figura 2.8 mostramos los resultados de la trayectoria para 100 períodos.

```
t = ts(c(0:100))

Zt = 10-450*(0.4^t)+440*(0.5^t)

tabla_2 <- data.frame( t, Zt)

lista = c(1:16, 97:101)
t1 = t[lista]
Zt1=Zt[lista]

tabla1 = data.frame(t1, Zt1)
colnames(tabla1) <- c("Tiempo", "$Z_t")
# =10-450(0.4)^t+440(0.5)^t$")

kable(tabla1,
      caption = "Un ejemplo de Ecuación de Segundo Orden",
      format = "pandoc")%>%
kable_styling(font_size = 10)
```

Cuadro 2.2: Un ejemplo de Ecuación de Segundo Orden

Tiempo	$Z_t = 10 - 450(0.4)^t + 440(0.5)^t$
0	0.00000
1	50.00000
2	48.00000
3	36.20000
4	25.98000
5	19.14200
6	15.03180
7	12.70022
8	11.42384
9	10.74141
10	10.38250
11	10.19597

Tiempo	$Z_t = 10 - 450(0.4)^t + 440(0.5)^t$
12	10.09987
13	10.05069
14	10.02565
15	10.01294
96	10.00000
97	10.00000
98	10.00000
99	10.00000
100	10.00000

```
ggplot(data = tabla_2, aes(x = t, y=Zt)) +
  geom_line(col="green4") +
  geom_point(col= "green4") +
  labs(y=expression(Z[t]))
```




Figura 2.8: Evolución del proceso dado por $Z_t = 3 + 0.9Z_{t-1} - 0.2Z_{t-2}$

Finalmente, discutiremos la solución para las Ecuaciones Lineales en Diferencia de Orden p , donde $p \geq 2$. En general, una ecuación de este tipo se puede escribir como:

$$Z_t = a_0 + a_1 Z_{t-1} + a_2 Z_{t-2} + \dots + a_p Z_{t-p} \quad (2.49)$$

Donde $t = \dots, -2, -1, 0, 1, 2, \dots$ y $a_p \neq 0$. La ecuación (2.49) se puede escribir

como:

$$\begin{aligned} Z_t - a_1 Z_{t-1} - a_2 Z_{t-2} - \dots - a_p Z_{t-p} &= a_0 \\ Z_t - a_1 L Z_t - a_2 L^2 Z_t - \dots - a_p L^p Z_t &= a_0 \\ (1 - a_1 L - a_2 L^2 - \dots - a_p L^p) Z_t &= a_0 \end{aligned} \quad (2.50)$$

Por el Teorema Fundamental del Álgebra¹ es posible escribir la ecuación (2.50) como:

$$(1 - g_1 L)(1 - g_2 L) \dots (1 - g_p L) Z_t = a_0 \quad (2.51)$$

Utilizando la ecuación (2.50) y la ecuación (2.51) tenemos que la solución general de una ecuación como la descrita en (2.49) se puede escribir como:

$$Z_t = \frac{a_0}{1 - a_1 - a_2 - \dots - a_p} + s_1 g_1^t + s_2 g_2^t + \dots + s_p g_p^t \quad (2.52)$$

$$Z_t = \frac{a_0}{(1 - g_1)(1 - g_2) \dots (1 - g_p)} + s_1 g_1^t + s_2 g_2^t + \dots + s_p g_p^t \quad (2.53)$$

Donde $s_1, s_2, \dots, s_p$ son constantes que se determinan utilizando p valores particulares de Z_t , y la solución general descrita en las ecuaciones (2.52) y (2.53) implica encontrar p raíces: $x_1 = g_1^{-1}, x_2 = g_2^{-1}, \dots, x_p = g_p^{-1}$ de los siguientes polinomios equivalentes:

$$(1 - g_1 x)(1 - g_2 x) \dots (1 - g_p x) = 0 \quad (2.54)$$

$$1 - a_1 x - a_2 x^2 - \dots - a_p x^p = 0 \quad (2.55)$$

$$a_p x^p + \dots + a_2 x^2 + a_1 x - 1 = 0 \quad (2.56)$$

Antes de plantear la solución general, analicemos una solución particular cuando un conjunto de las p raíces, digamos un total de m , son iguales, es decir, cuando

¹El Teorema Fundamental del Álgebra establece que todo polinomio de grado $p \geq 1$ con coeficientes en $\mathbb{C}$ tiene exactamente p raíces en $\mathbb{C}$, contadas con multiplicidad. En particular, garantiza que el polinomio $1 - a_1 L - a_2 L^2 - \dots - a_p L^p$ puede factorizarse en exactamente p factores lineales de la forma $(1 - g_i L)$.

sucede que $g_1 = g_2 = \dots = g_m = g$ (con $1 < m \leq p$). En este caso la solución general en la ecuación (2.53) se escribe como:

$$Z_t = \frac{a_0}{(1-g)^m(1-g_{m+1}) \dots (1-g_p)} + s_1 g^t + s_2 t g^t + \dots + s_m t^{m-1} g^t + s_{m+1} g_{m+1}^t + \dots + s_p g_p^t \quad (2.57)$$

Definamos:

$$f(g) = \frac{1}{1-g} = \sum_{j=0}^{\infty} g^j \quad (2.58)$$

Si retomamos el método descrito párrafos arriba tenemos las siguientes expresiones. Cuando $m = 2$:

$$f'(g) = \frac{1}{(1-g)^2} = \sum_{j=0}^{\infty} j g^{j-1} = \sum_{j=0}^{\infty} (1+j) g^j$$

En el otro extremo, cuando $m = p$, la derivada de orden $p-1$ es $f^{(p-1)}(g) = (p-1)! / (1-g)^p$, por lo que:

$$\frac{1}{(1-g)^p} = \frac{f^{(p-1)}(g)}{(p-1)!} = \sum_{j=0}^{\infty} \frac{(p-1+j)(p-2+j) \dots (2+j)(1+j)}{(p-1)!} g^j \quad (2.59)$$

Así, en el extremo cuando $m = p$ la solución general podría estar dada por:

$$Z_t = a_0 \sum_{j=0}^{\infty} \frac{(p-1+j)(p-2+j) \dots (2+j)(1+j)}{(p-1)!} g^j + g^t \sum_{i=1}^p s_i t^{i-1} \quad (2.60)$$

Donde $|g| < 1$, $t = \dots, -2, -1, 0, 1, 2, \dots$. Para finalizar esta sección, plantearemos la expresión del polinomio característico que nos permitirá hacer el análisis de convergencia de los procesos. Partamos de que la ecuación (2.56) se puede escribir como:

$$(x^{-1})^p - a_1(x^{-1})^{p-1} - a_2(x^{-1})^{p-2} - \dots - a_p = 0 \quad (2.61)$$

La ecuación (2.61) permite interpretar las raíces del polinomio característico de forma directa ya que $x_1^{-1} = g_1$, $x_2^{-1} = g_2$, ..., $x_p^{-1} = g_p$. La condición exacta de convergencia del proceso descrito en la ecuación (2.49) es que todas las raíces g_i tengan módulo estrictamente menor que uno, como se expresa en la ecuación (2.62):

$$|g_i| < 1 \quad (2.62)$$

Para todo $i = 1, 2, \dots, p$ –cuando la raíz es real, el módulo es su valor absoluto; cuando es compleja, $g_i = u \pm iv$, el módulo es $\sqrt{u^2 + v^2}$ –. En la práctica, resulta útil disponer de condiciones expresadas directamente en términos de los coeficientes. Dos condiciones **necesarias** (aunque no suficientes) para la convergencia son las ecuaciones (2.63) y (2.64):

$$|a_p| < 1 \quad (2.63)$$

$$a_1 + a_2 + \dots + a_p < 1 \quad (2.64)$$

Si alguna de ellas falla, el proceso es divergente; sin embargo, su cumplimiento no garantiza la convergencia, por lo que la verificación definitiva requiere calcular las raíces. Por otra parte, una condición **suficiente** (aunque no necesaria) es que $|a_1| + |a_2| + \dots + |a_p| < 1$.

Cuando $g_1 = g_2 = \dots = g_p = g$, la condición de la ecuación (2.62) se resume a que $|g| < 1$. En resumen, la condición descrita en la ecuación (2.62) se puede ilustrar mediante un círculo unitario como el de la Figura 2.9: si todas las raíces g_i se ubican dentro de éste, podemos decir que el proceso es convergente en el largo plazo.

```
# Crear datos para el círculo
theta <- seq(0, 2*pi, length.out=100)
x <- cos(theta)
y <- sin(theta)
circle_data <- data.frame(x, y)

# Dibujar el círculo
ggplot(circle_data, aes(x=x, y=y)) +
  geom_polygon(fill=NA, color="black") +
  coord_fixed(ratio=1) +
  xlim(-1.5, 1.5) +
  ylim(-1.5, 1.5)
```

2.4 Operador de rezago L

Denotemos, como se ha mencionado con anterioridad, con L al operador de rezago, el cual nos permitirá construir una relación entre diferencias y medias móviles como se verá más adelante en los procesos univariados Autorregresivos de orden p , $AR(p)$, y de medias móviles de orden q , $MA(q)$ y, en general, Autorregresivos de Media Móviles Integrados $ARIMA(p, d, q)$. Sean X , Y o Z variables con las que denotaremos a una serie de tiempo (note que hasta el momento no hemos definido qué es una serie de tiempo, no obstante, no es necesario definirla para hacer uso del operador).




Figura 2.9: Círculo unitario en el que se cumple que $|g_i| < 1$

En esta sección resumiremos algunas propiedades usadas en el capítulo y en capítulos más adelante. Así, si a dicha serie le aplicamos el operador rezago antes definido, el resultado deberá ser que cada uno de los valores de la serie es retardado o regresado un período. Es decir:

$$LZ_t = Z_{t-1} \quad (2.65)$$

De esta forma, si aplicamos el operador rezago L a la nueva serie de tiempo dada por Z_{t-1} podemos obtener Z_{t-2} . Haciendo uso de la ecuación (2.65) podemos obtener:

$$LZ_{t-1} = L(LZ_t) = L^2Z_t = Z_{t-2} \quad (2.66)$$

Mediante una generalización podemos obtener:

$$L^k Z_t = Z_{t-k} \quad (2.67)$$

Para $k = \dots, -2, -1, 0, 1, 2, \dots$. Así, para $k = 0$ obtenemos la identidad dado que $L^0 Z_t = Z_t$, de tal forma que siempre asumiremos que $L^0 = 1$. En otro caso, cuando $k > 0$ a la serie de tiempo a la cual se le aplique el operador rezago L se le deberá aplicar un rezago de k periodos a cada uno de los elementos de la serie. Por el contrario, cuando $k < 0$ el operador rezago significa que se deberá adelantar $|k|$ veces a cada elemento de la serie. Por ejemplo, $L^{-3}Z_t = Z_{t+3}$.

Las reglas descritas en lo subsecuente se mantienen indistintamente cuando aplican para el caso de rezagar como para cuando se adelanta una serie. Como primera propiedad tomemos a la siguiente propiedad:

$$L^m Z_{t-n} = L^m(L^n Z_t) = L^{m+n} Z_t = Z_{t-(n+m)} \quad (2.68)$$

De lo anterior, podemos inferir el siguiente resultado:

$$\Delta Z_t = Z_t - Z_{t-1} = (1 - L)Z_t \quad (2.69)$$

En el caso de la diferencia de orden cuatro o cuarta diferencia se puede expresar como:

$$\Delta_4 Z_t = Z_t - Z_{t-4} = (1 - L^4)Z_t \quad (2.70)$$

Al respecto, vale la pena distinguir dos notaciones que suelen confundirse: $\Delta_k Z_t = (1 - L^k)Z_t = Z_t - Z_{t-k}$ denota la diferencia respecto del periodo $t - k$ –también llamada diferencia estacional cuando k coincide con la periodicidad de los datos–, mientras que $\Delta^k Z_t = (1 - L)^k Z_t$ denota la aplicación iterada k veces de la primera diferencia. Ambas coinciden únicamente cuando $k = 1$. La primera notación resulta de gran utilidad cuando se quiere comparar períodos equivalentes como, por ejemplo, el mismo trimestre pero de un año anterior ($k = 4$ con datos trimestrales). En logaritmos, la ecuación (2.70) se escribe como:

$$\Delta_4 \ln(Z_t) = \ln(Z_t) - \ln(Z_{t-4}) = (1 - L^4)\ln(Z_t) \quad (2.71)$$

Para el caso de una serie de tiempo que se le ha transformado mediante medias móviles, digamos de 4 periodos, podemos escribirla como:

$$Zs_t = \frac{1}{4}(Z_t + Z_{t-1} + Z_{t-2} + Z_{t-3}) = \frac{1}{4}(1 + L + L^2 + L^3)Z_t \quad (2.72)$$

Una generalización del anterior caso puede ser escrita como un polinomio de orden p con el operador rezago L dado como:

$$\begin{aligned} \alpha(L)Z_t &= (1 - \alpha_1 L - \alpha_2 L^2 - \dots - \alpha_p L^p)Z_t \\ &= Z_t - \alpha_1 Z_{t-1} - \alpha_2 Z_{t-2} - \dots - \alpha_p Z_{t-p} \end{aligned} \quad (2.73)$$

Donde α_i puede ser reemplazada por cualquier constante a_i , con $i = 1, 2, 3, \dots$, para escribir ecuaciones como las anteriores. Adicionalmente, podemos decir que la ecuación (2.73) es una generalización del caso de medias móviles, el cual admite una ponderación distinta para cada uno de los elementos rezagados.

Existe la posibilidad de operar más de un polinomio a la vez. Para múltiples polinomios (digamos, los polinomios $\alpha(L)$ y $\beta(L)$) podemos escribir el siguiente resultado:

$$\alpha(L)\beta(L) = \beta(L)\alpha(L) \quad (2.74)$$

Tales polinomios del operador rezago también son llamados *filtros lineales*. A manera de ejemplo, tomemos el siguiente caso de diferencias para una serie de Z_t :

$$\Delta Z_t = (1 - L)Z_t = Z_t - Z_{t-1} \quad (2.75)$$

y un proceso de medias móviles para la misma serie de Z_t :

$$Zs_t = \frac{1}{4}(1 + L + L^2 + L^3)Z_t = \frac{1}{4}(Z_t + Z_{t-1} + Z_{t-2} + Z_{t-3}) \quad (2.76)$$

De tal forma que el producto de ambos procesos se puede escribir como:

$$(1 - L) \times \frac{1}{4}(1 + L + L^2 + L^3)Z_t = \frac{1}{4}(1 - L^4)Z_t \quad (2.77)$$

Es decir, que el producto de dos polinomios, uno de diferencias y otro más de medias móviles, resulta en uno de diferencias pero de mayor grado, en este caso de grado 4.

2.5 De las Ecuaciones en Diferencia a los Procesos Estocásticos

Hasta aquí hemos estudiado ecuaciones en diferencia **deterministas**: dado un valor inicial Z_0 , la trayectoria futura del proceso queda completamente determinada por los parámetros $a_0, a_1, \dots, a_p$. Sin embargo, en las aplicaciones económicas y financieras raramente observamos series que sigan una trayectoria perfectamente predecible. En la práctica, las series de tiempo se ven afectadas por

choques aleatorios —innovaciones, perturbaciones o errores— que las hacen impredecibles en su detalle, aunque sí modelables en su estructura probabilística.

La extensión natural de una ecuación en diferencia determinista de orden p a un proceso estocástico consiste en agregar un término de error U_t :

$$Z_t = a_0 + a_1 Z_{t-1} + a_2 Z_{t-2} + \dots + a_p Z_{t-p} + U_t \quad (2.78)$$

Donde U_t es un proceso de ruido blanco con $\mathbb{E}[U_t] = 0$, $\text{Var}(U_t) = \sigma^2$ y $\text{Cov}(U_t, U_s) = 0$ para $t \neq s$. A la ecuación (2.78) se le conoce como un proceso **Autorregresivo de orden p** , denotado $AR(p)$, y constituye la base de los modelos de series de tiempo que se estudiarán en los capítulos siguientes.

Usando el operador de rezagos L , la ecuación (2.78) se puede escribir de forma compacta como:

$$(1 - a_1 L - a_2 L^2 - \dots - a_p L^p) Z_t = a_0 + U_t \quad (2.79)$$

O bien, definiendo el polinomio $\alpha(L) = 1 - a_1 L - a_2 L^2 - \dots - a_p L^p$:

$$\alpha(L) Z_t = a_0 + U_t \quad (2.80)$$

La conexión con las ecuaciones deterministas es directa: las **condiciones de convergencia** que estudiamos en las secciones anteriores se convierten en las **condiciones de estacionariedad** del proceso estocástico. En concreto, el proceso $AR(p)$ descrito en la ecuación (2.78) será **estacionario** si y solo si todas las raíces del polinomio característico $\alpha(x) = 0$ se ubican **fuera del círculo unitario**, o equivalentemente, si todos los valores $|g_i| < 1$ para $i = 1, 2, \dots, p$.

Esta equivalencia es el vínculo fundamental entre el presente capítulo y el Capítulo 3, en el que se estudiarán formalmente los procesos estocásticos estacionarios, sus propiedades y los métodos de estimación e identificación de modelos $AR(p)$, $MA(q)$ y $ARMA(p, q)$.

Capítulo 3

Procesos Estacionarios y Modelos Univariados

3.1 Definición de ergodicidad y estacionariedad

A partir de esta sección introduciremos mayor formalidad matemática al análisis de las series de tiempo. Por ello cambiaremos un poco la notación y ocuparemos a X_t en lugar de Z_t como objeto de nuestro análisis. Con X_t denotaremos a una serie de tiempo, ya que con Z_t denotaremos a una variable, sin que ella fuera necesariamente una serie de tiempo en los términos que a continuación discutimos. Asimismo, iniciaremos por establecer una serie de definiciones.

De esta forma, definiremos a una *serie de tiempo* como un vector de variables aleatorias de dimensión T , dado como:

$$X_1, X_2, X_3, \dots, X_T \quad (3.1)$$

Cada una de las X_t ($t = 1, 2, \dots, T$) consideradas como una variable aleatoria. Así, también podemos denotar a la serie de tiempo como:

$$\{X_t\}_{t=1}^T \quad (3.2)$$

Es decir, definiremos a una *serie de tiempo como una realización de un proceso estocástico* –o un Proceso Generador de Datos (PGD). Consideremos una muestra de los múltiples posibles resultados de muestras de tamaño T , la colección dada por:

$$\{X_1^{(1)}, X_2^{(1)}, \dots, X_T^{(1)}\} \quad (3.3)$$

Digamos que la ecuación (3.3) es una de las tantas posibles resultantes del proceso estocástico o PGD. Eventualmente podríamos estar dispuestos a observar

este proceso indefinidamente, de forma tal que estemos interesados en la secuencia dada por $\{X_t^{(1)}\}_{t=1}^{\infty}$, lo cual no dejaría de ser sólo una de las tantas realizaciones o secuencias del proceso estocástico original.

Tan solo por poner un ejemplo, podríamos observar las siguientes realizaciones del mismo PGD:

$$\begin{aligned} &\{X_1^{(2)}, X_2^{(2)}, \dots, X_T^{(2)}\} \\ &\{X_1^{(3)}, X_2^{(3)}, \dots, X_T^{(3)}\} \\ &\{X_1^{(4)}, X_2^{(4)}, \dots, X_T^{(4)}\} \\ &\vdots \\ &\{X_1^{(j)}, X_2^{(j)}, \dots, X_T^{(j)}\} \end{aligned}$$

Donde $j \in \mathbb{Z}$. En lo subsecuente, diremos que una serie de tiempo es una realización del proceso estocástico subyacente. Considerando, en consecuencia, al proceso estocástico con todas sus posibilidades de realización.

Para hacer más sencilla la notación no distinguiremos entre el proceso en sí mismo y una de sus realizaciones, es decir, siempre escribiremos a una serie de tiempo como la secuencia mostrada en la ecuación (3.2), o más precisamente como la siguiente realización:

$$\{X_1, X_2, \dots, X_T\} \quad (3.4)$$

O simplemente:

$$X_1, X_2, \dots, X_T \quad (3.5)$$

El proceso estocástico de dimensión T puede ser completamente descrito por su función de distribución multivariada de dimensión T . No obstante, esto no resulta práctico para el análisis que desarrollaremos más adelante. Por ello, en estas notas –como se hace en casi todos los textos– sólo nos enfocaremos en sus primer y segundo momentos. Es decir, en su media o valor esperado:

$$\mathbb{E}[X_t]$$

Para $t = 1, 2, \dots, T$; o:

$$\begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_T] \end{bmatrix}$$

o,

$$[\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_T]]$$

Y en su varianza:

$$Var[X_t] = \mathbb{E}[(X_t - \mathbb{E}[X_t])^2]$$

Para $t = 1, 2, \dots, T$, y de sus $T(T-1)/2$ covarianzas:

$$\text{Cov}[X_t, X_s] = \mathbb{E}[(X_t - \mathbb{E}[X_t])(X_s - \mathbb{E}[X_s])]$$

Para $t < s$. Por lo tanto, en la forma matricial podemos escribir lo siguiente:

$$\begin{aligned} & \begin{bmatrix} \text{Var}[X_1] & \text{Cov}[X_1, X_2] & \cdots & \text{Cov}[X_1, X_T] \\ \text{Cov}[X_2, X_1] & \text{Var}[X_2] & \cdots & \text{Cov}[X_2, X_T] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[X_T, X_1] & \text{Cov}[X_T, X_2] & \cdots & \text{Var}[X_T] \end{bmatrix} \\ &= \begin{bmatrix} \sigma_1^2 & \rho_{12} & \cdots & \rho_{1T} \\ \rho_{21} & \sigma_2^2 & \cdots & \rho_{2T} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{T1} & \rho_{T2} & \cdots & \sigma_T^2 \end{bmatrix} \end{aligned} \quad (3.6)$$

Donde es claro que en la matriz de la ecuación (3.6) existen $T(T-1)/2$ covarianzas distintas, ya que se cumple que $\text{Cov}[X_t, X_s] = \text{Cov}[X_s, X_t]$, para $t \neq s$.

A menudo, esas covarianzas son denominadas como autocovarianzas puesto que ellas son covarianzas entre variables aleatorias pertenecientes al mismo proceso estocástico pero en un momento t diferente. Si el proceso estocástico tiene una distribución normal multivariada, su función de distribución estará totalmente descrita por sus momentos de primer y segundo orden.

Ahora introduciremos el concepto de ergodicidad, el cual indica que los momentos muestrales –calculados con base en una serie de tiempo con un número finito de observaciones– tienden, en la medida en que $T \rightarrow \infty$, a los verdaderos valores poblacionales, los cuales definiremos como μ , para la media, y σ_X^2 para la varianza.

Este concepto sólo es cierto si asumimos que, por ejemplo, el valor esperado y la varianza son como se dice a continuación para todo $t = 1, 2, \dots, T$:

$$\mathbb{E}[X_t] = \mu_t = \mu \quad (3.7)$$

$$(3.8)$$

$$\text{Var}[X_t] = \sigma_X^2 \quad (3.9)$$

Más formalmente, se dice que el PGD o el proceso estocástico es ergódico en la media si:

$$\lim_{T \rightarrow \infty} \mathbb{E} \left[\left(\frac{1}{T} \sum_{t=1}^T (X_t - \mu) \right)^2 \right] = 0 \quad (3.10)$$

y ergódico en la varianza si:

$$\lim_{T \rightarrow \infty} \mathbb{E} \left[\left(\frac{1}{T} \sum_{t=1}^T (X_t - \mu)^2 - \sigma_X^2 \right)^2 \right] = 0 \quad (3.11)$$

A estas condiciones se les conoce como *propiedades de consistencia* para las variables aleatorias. Sin embargo, éstas no pueden ser probadas con una única realización del proceso, por lo que se tratan como un supuesto de trabajo. Lo relevante para lo que sigue es que **para que los momentos muestrales de una serie de tiempo aproximen a los momentos poblacionales del proceso, se requiere que éste sea estacionario y ergódico.**

Podemos distinguir dos tipos de estacionariedad. Si asumimos que la función común de distribución del proceso estocástico no cambia a lo largo del tiempo, se dice que el proceso es *estrictamente estacionario*. Como este concepto es difícil de aplicar en la práctica, solo consideraremos a la *estacionariedad débil* o estacionariedad en sus momentos.

Definiremos a la estacionariedad por sus momentos del correspondiente proceso estocástico dado por $\{X_t\}$:

1. *Estacionariedad en media:* Un proceso estocástico es estacionario en media si $E[X_t] = \mu_t = \mu$ es constante para todo t .
2. *Estacionariedad en varianza:* Un proceso estocástico es estacionario en varianza si $Var[X_t] = E[(X_t - \mu_t)^2] = \sigma_X^2 = \gamma(0)$ es constante y finita para todo t .
3. *Estacionariedad en covarianza:* Un proceso estocástico es estacionario en covarianza si $Cov[X_t, X_s] = E[(X_t - \mu_t)(X_s - \mu_s)] = \gamma(|s - t|)$ es sólo una función de la distancia $|s - t|$ entre las dos variables aleatorias, y no del momento t en que se observa el proceso.
4. *Estacionariedad débil:* Como la estacionariedad en varianza resulta de forma inmediata de la estacionariedad en covarianza cuando se asume que $s = t$, un proceso estocástico es débilmente estacionario cuando es estacionario en media y covarianza.

Puesto que resulta poco factible asumir una estacionariedad diferente a la débil, en adelante, siempre que digamos que un proceso es estacionario, nos referiremos al caso débil, sin el apelativo de débil.

Ejemplo. Supongamos una serie de tiempo denotada por: $\{U_t\}_{t=0}^T$. Decimos que el proceso estocástico $\{U_t\}$ es un *proceso estocástico puramente aleatorio* o simplemente un *proceso de ruido blanco*, si este tiene las siguientes propiedades:

1. $E[U_t] = 0, \forall t$;
2. $Var[U_t] = E[(U_t - \mu_t)^2] = E[(U_t - \mu)^2] = E[(U_t)^2] = \sigma^2, \forall t, y$
3. $Cov[U_t, U_s] = E[(U_t - \mu_t)(U_s - \mu_s)] = E[(U_t - \mu)(U_s - \mu)] = E[U_t U_s] = 0, \forall t \neq s.$

En otras palabras, un proceso U_t es un ruido blanco si su valor esperado (promedio) es cero (0), tiene una varianza finita y constante, y además no le importa la historia pasada. Así, su valor presente no se ve influenciado por sus valores pasados, no importando respecto de qué período se tome referencia.

En apariencia, por sus propiedades, este proceso es débilmente estacionario –o simplemente, estacionario–. Todas las variables aleatorias tienen una media de cero, una varianza σ^2 y no existe correlación entre ellas.

Ahora, supongamos que definimos un nuevo proceso estocástico $\{X_t\}$ como:

$$X_t = \begin{cases} U_0 & \text{para } t = 0 \\ X_{t-1} + U_t & \text{para } t = 1, 2, 3, \dots \end{cases} \quad (3.12)$$

Donde $\{U_t\}$ es un proceso puramente aleatorio. Este proceso estocástico, conocido como caminata aleatoria sin deriva (*drift*), puede ser reescrito como:

$$X_t = \sum_{j=0}^t U_j \quad (3.13)$$

Tratemos de dar más claridad al ejemplo, para ello asumamos que generamos a $\{U_t\}$ por medio del lanzamiento de una moneda. Donde obtenemos una cara (águila) con una probabilidad de 0.5, en cuyo caso decimos que la variable aleatoria U_t tomará el valor de +1, y una cruz (sol) con una probabilidad de 0.5, en cuyo caso decimos que la variable aleatoria U_t toma el valor de −1.

Este planteamiento cumple con las propiedades enunciadas ya que:

1. $\mathbb{E}[U_t] = 0.5 \times -1 + 0.5 \times 1 = 0, \forall t$
2. $Var[U_t] = \mathbb{E}[(U_t - 0)^2] = \frac{1}{2}((-1)^2) + \frac{1}{2}((1)^2) = 1, \forall t$
3. $Cov[U_t, U_s] = \mathbb{E}[(U_t - 0)(U_s - 0)] = \mathbb{E}[U_t \cdot U_s] = 0, \forall t \neq s.$

Retomando a nuestro proceso X_t , diremos que el caso de $X_0 = 0$, para $t = 0$. Si verificamos cuáles son sus primeros y segundos momentos de $\{X_t\}$, tenemos:

$$\mathbb{E}[X_t] = \mathbb{E}\left[\sum_{j=1}^t U_j\right] = \sum_{j=1}^t \mathbb{E}[U_j] = 0 \quad (3.14)$$

En cuanto a la varianza:

$$\begin{aligned}
 Var[X_t] &= Var\left[\sum_{j=1}^t U_j\right] \\
 &= \sum_{j=1}^t Var[U_j] + 2 * \sum_{j \neq k} Cov[U_j, U_k] \\
 &= \sum_{j=1}^t 1 \\
 &= t
 \end{aligned} \tag{3.15}$$

Lo anterior, dado que hemos supuesto que en la caminata aleatoria todas las variables aleatorias son independientes, es decir, $Cov[U_t, U_s] = E[U_t \cdot U_s] = 0$. Por su parte, la covarianza del proceso estocástico se puede ver como:

$$\begin{aligned}
 Cov[X_t, X_s] &= \mathbb{E}\left[\left(\sum_{j=1}^t U_j - 0\right)\left(\sum_{i=1}^s U_i - 0\right)\right] \\
 &= \mathbb{E}[(U_1 + U_2 + \dots + U_t)(U_1 + U_2 + \dots + U_s)] \\
 &= \sum_{j=1}^t \sum_{i=1}^s \mathbb{E}[U_j U_i] \\
 &= \mathbb{E}[U_1^2] + \mathbb{E}[U_2^2] + \dots + \mathbb{E}[U_{\min(t,s)}^2] \\
 &= \min(t, s) \cdot \sigma^2 \\
 &= \min(t, s)
 \end{aligned}$$

Donde la última igualdad usa que en este ejemplo $\sigma^2 = 1$; sólo sobreviven los términos cruzados con $i = j$, que son exactamente $\min(t, s)$.

Así, el proceso estocástico dado por la caminata aleatoria sin deriva es estacionario en media, pero no en varianza ni en covarianza y, consecuentemente, no es estacionario –condición contraria al caso del proceso simple descrito en U_t^- .

Es fácil ver que muchas de las posibilidades de realización de este proceso estocástico (series de tiempo) pueden tomar cualquiera de las rutas consideradas en la Figura 3.1.

```

set.seed(1234)
# Utilizaremos una función guardada en un archivo a parte
# Llamamos a la función:
source("Caminata.R")

# Definimos argumentos de la función

```

```

Opciones <- c(-1, 1)
#
Soporte <- 10000

# Vamos a réplicar el proceso con estos parámetros
Rango <- 200
#
Caminos <- 10

#
for(i in 1:Caminos){
  TT <- data.matrix(data.frame(Caminata(Opciones, Soporte)[1]))
  #
  G_t <- data.matrix(data.frame(Caminata(Opciones, Soporte)[2]))
  #
  plot(TT, G_t, col = "blue", type = "l", ylab = "Ganancias",
        xlab = "Tiempo", ylim = c(-Rango,Rango))
  #
  par(new = TRUE)
  #
  i <- i +1
}
#
par(new = FALSE)

```

3.2 Función de autocorrelación

Para ampliar la discusión, es posible calcular la fuerza o intensidad de la dependencia de las variables aleatorias dentro de un proceso estocástico, ello mediante el uso de las autocovarianzas. Cuando las covarianzas son normalizadas respecto de la varianza, el resultado es un término que es independiente de las unidades de medida aplicadas, y se conoce como la *función de autocorrelación*.

Para procesos estacionarios, dicha función de autocorrelación está dada por:

$$\rho(\tau) = \frac{\mathbb{E}[(X_t - \mu)(X_{t+\tau} - \mu)]}{\mathbb{E}[(X_t - \mu)^2]} = \frac{\gamma(\tau)}{\gamma(0)} \quad (3.16)$$

Donde $\tau = \dots, -2, -1, 0, 1, 2, \dots$. Dicha función tiene las siguientes propiedades:

1. $\rho(0) = 1$. Es fácil demostrar que la función $\rho(0)$ es:




Figura 3.1: Ejemplo de 10 trayectorias de la caminata aleatoria, cuando sólo son posibles cambios de +1 y -1

$$\rho(0) = \frac{\mathbb{E}[(X_t - \mu)(X_{t+0} - \mu)]}{\mathbb{E}[(X_t - \mu)^2]} = \frac{\mathbb{E}[(X_t - \mu)^2]}{\mathbb{E}[(X_t - \mu)^2]} = 1 \quad (3.17)$$

2. $\rho(\tau) = \rho(-\tau)$. Partiendo de la definición de $\rho(\tau)$ podemos ver que la distancia que existe entre t y $t+\tau$ es τ , de esta forma la autocorrelación de la variable X entre los periodos antes señalados debería ser la misma para el caso en que $\rho(-\tau)$. Partamos de la ecuación para ver más claramente:

$$\rho(\tau) = \frac{\mathbb{E}[(X_t - \mu)(X_{t+\tau} - \mu)]}{\mathbb{E}[(X_t - \mu)^2]} = \frac{\mathbb{E}[(X_t - \mu)(X_{t-\tau} - \mu)]}{\mathbb{E}[(X_t - \mu)^2]} = \rho(-\tau) \quad (3.18)$$

3. $|\rho(\tau)| \leq 1$, para todo τ .

Derivado de las propiedades 1 y 2 antes descritas se puede concluir que sólo es necesario conocer la función de autocorrelación para el caso de $\tau = 1, 2, 3, \dots$, ya que de estos casos podemos derivar los valores de la función de autocorrelación complementarios de $\tau = \dots, -3, -2, -1$.

Partiendo de los supuestos de ergodicidad en relación con la media, varianza y covarianzas de un proceso estacionario, podemos estimar dichos parámetros con las siguientes formulaciones o propuestas de estimadores puntuales:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T X_t \quad (3.19)$$

$$\hat{\gamma}(0) = \frac{1}{T} \sum_{t=1}^T (X_t - \hat{\mu})^2 = \hat{\sigma}^2 \quad (3.20)$$

$$\hat{\gamma}(\tau) = \frac{1}{T} \sum_{t=1}^{T-\tau} (X_t - \hat{\mu})(X_{t+\tau} - \hat{\mu}), \text{ para } \tau = 1, 2, \dots, T-1 \quad (3.21)$$

No hacemos la demostración en estas notas –sería deseable que el alumno revisara la siguiente afirmación–, pero estos últimos son estimadores consistentes de μ , $\gamma(0)$ y $\gamma(\tau)$. Por su parte, un estimador consistente de la función de autocorrelación estará dado por:

$$\hat{\rho}(\tau) = \frac{\sum_{t=1}^{T-\tau} (X_t - \hat{\mu})(X_{t+\tau} - \hat{\mu})}{\sum_{t=1}^T (X_t - \hat{\mu})^2} = \frac{\hat{\gamma}(\tau)}{\hat{\gamma}(0)} \quad (3.22)$$

El estimador de la ecuación (3.22) es asintóticamente insesgado. Por ejemplo, para el caso de un proceso de ruido blanco, su varianza puede ser aproximada por el valor dado $1/T$. Ésta tiene, asintóticamente, una distribución normal. Dado esto, el intervalo de confianza al 95% será el dado por $\pm 2/\sqrt{T}$, en el cual se encuentra la mayoría de los coeficientes de autocorrelación estimados.

Ahora discutamos algunos ejemplos o aplicaciones. Cuando se realiza la evaluación de la estimación de un modelo de series de tiempo es importante saber si los residuales del modelo realmente tienen propiedades de un proceso puramente aleatorio, en particular, si ellos no están correlacionados entre sí. Así, la hipótesis a probar será:

$$H_0 : \rho(\tau) = 0, \text{ para todo } \tau = 1, 2, \dots, m \text{ y } m < T \quad (3.23)$$

Esta expresión se puede interpretar como una prueba respecto de si la correlación entre la información de periodos atrás es cero con la información contemporánea. Para hacer una prueba global de la hipótesis de si un número m de coeficientes de autocovarianzas son cero, Box y Pierce (1970) desarrollaron la siguiente estadística:

$$Q^* = T \sum_{j=1}^m \hat{\rho}(j)^2 \quad (3.24)$$

Bajo la hipótesis nula esta estadística se distribuye asintóticamente como una chi cuadrado (χ^2) con $m-k$ grados de libertad y con k que representa al número de parámetros estimados.

La distribución de esta estadística sólo se sostiene asintóticamente. Por ello, Ljung y Box (1978) propusieron la siguiente modificación de la estadística para muestras pequeñas:

$$Q = T(T+2) \sum_{j=1}^m \frac{\hat{\rho}(j)^2}{T-j} \quad (3.25)$$

La cual también se distribuye asintóticamente como χ^2 con $m-k$ grados de libertad.

También es intuitivamente claro que la hipótesis nula de no autocorrelación de residuales debería ser rechazada si alguno de los valores $\hat{\rho}(j)$ es muy grande, es decir, si Q o Q^* es muy grande. O más precisamente, si estas estadísticas son más grandes que los correspondientes valores críticos de la distribución χ^2 con $m-k$ grados de libertad a algún grado dado de significancia.

Una alternativa para esta prueba es una del tipo Multiplicadores de Lagrange (o LM) desarrollada por Breusch (1978) y Godfrey (1978), en la cual, al igual que en las estadísticas Q y Q^* , la hipótesis nula está dada por:

H_0 : Los residuales no están autocorrelacionados.

H_a : Los residuales muestran alguna autocorrelación de forma autor-regresiva o de medias móviles.

La prueba consiste en realizar una regresión auxiliar en la cual los residuales se estiman en función de las variables explicativas del modelo original y en los residuales mismos pero rezagados hasta el término m (regresión auxiliar). La prueba resulta en una estadística con una distribución χ^2 con m grados de libertad la cual está dada por la expresión:

$$LM = T \times R^2 \quad (3.26)$$

Donde R^2 es el resultante de la regresión auxiliar y T es el número de observaciones totales.

En comparación con una prueba Durbin - Watson que es comúnmente usada en la econometría tradicional, para probar autocorrelación de los residuales, las estadísticas Q , Q^* y LM tienen las siguientes ventajas:

1. Permiten corroborar la existencia de autocorrelación para cualquier orden, y no solo para un primer orden (es decir, para cualquier valor de $\tau = 1, 2, 3, \dots$);

2. Los resultados se mantienen aún y cuando exista una probable variable endógena en forma rezagada, y
3. No depende del orden o la forma en que se acomoden las observaciones, algo que es muy probable que ocurra en la econometría tradicional.

El hecho de que los residuales no estén autocorrelacionados no implica que estos sean independientes y normalmente distribuidos: la ausencia de autocorrelación sólo implica independencia estocástica cuando las variables se distribuyen de forma normal.

A menudo se asume que estos residuales están distribuidos normalmente, ya que la mayoría de las pruebas estadísticas tienen este supuesto detrás. No obstante, ello también depende de los otros momentos de la distribución, específicamente del tercer y cuarto momento. Los cuales se expresan como:

$$\mathbb{E}[(X_t - \mathbb{E}[X_t])^i], i = 3, 4$$

El tercer momento es necesario para determinar el sesgo, el cual está dado como:

$$\hat{S} = \frac{1}{T} \frac{\sum_{t=1}^T (X_t - \hat{\mu})^3}{\sqrt{\hat{\gamma}(0)^3}} \quad (3.27)$$

Para distribuciones simétricas (como en el caso de la distribución normal) el valor teórico para el sesgo es cero.

La curtosis, la cual está dada en función del cuarto momento, se puede expresar como:

$$\hat{K} = \frac{1}{T} \frac{\sum_{t=1}^T (X_t - \hat{\mu})^4}{\hat{\gamma}(0)^2} \quad (3.28)$$

Para el caso de una distribución normal, esta estadística toma el valor de 3. Valores más grandes que 3 indican que la distribución tiene colas anchas. En tales casos se ubican los datos financieros.

Usando el valor de las estadísticas para medir el sesgo y la curtosis, S y K , respectivamente, Jarque y Bera (1980) propusieron una prueba de normalidad, la cual puede ser aplicada a series de tiempo en niveles o en diferencias indistintamente. Dicha prueba se expresa como:

$$JB = \frac{T}{6} \left(\hat{S}^2 + \frac{1}{4}(\hat{K} - 3)^2 \right) \quad (3.29)$$

La cual tiene una distribución χ^2 con 2 grados de libertad y donde T es el tamaño de la muestra. La hipótesis de que las observaciones están distribuidas de forma normal se rechaza si el valor de la estadística de prueba es más grande que los correspondientes valores críticos en tablas.

Ejemplo. Veamos un ejemplo para ilustrar el uso de la función de autocorrelación. Tomemos como variable al número de pasajeros transportados por el sistema de transporte del metro de la CDMX.¹ Los datos empleados fueron tomados del INEGI y son una serie de tiempo en el período que va de enero de 2000 a junio de 2025, es decir, 306 observaciones. Como se puede apreciar en la Figura 3.2, el número de pasajeros por mes ha oscilado significativamente a lo largo del tiempo. Incluso podemos observar un cambio estructural de la serie entre 2011 y 2012. Asimismo, podemos ubicar una caída atípica que ocurrió en septiembre de 2017. Pero lo más relevante es la caída asociada a la pandemia de COVID-19 de 2020.

```
library(ggplot2)
library(dplyr)
library(readxl)

Datos <- read_excel("BD/Base_Transporte.xlsx",
                    sheet = "Datos", col_names = TRUE)

ggplot(data = Datos, aes(x = Periodo, y = Pax_Metro)) +
  geom_line(linewidth = 0.5, color = "darkblue") +
  #geom_point(size = 1.0, color = "darkblue") +
  #theme_bw() +
  xlab("Tiempo") +
  ylab("Millones de pasajeros") +
  theme(plot.title = element_text(size = 11, face = "bold", hjust
    ↵ = 0)) +
  theme(plot.subtitle = element_text(size = 10, hjust = 0)) +
  theme(plot.caption = element_text(size = 10, hjust = 0)) +
  theme(plot.margin = unit(c(1,1,1,1), "cm")) +
  labs(
    title = "Pasajeros Transportados en el Metro de la CDMX",
    subtitle = "(Ene-2000 a Jun-2025)",
    caption = "Fuente: Elaboración propia con información del
    ↵ INEGI,
    ↵ \nhttps://www.inegi.org.mx/app/indicadores/?tm=0&t=1090"
  )

#
```

A esta serie de tiempo le calculamos los principales estadísticos hasta ahora estudiados y obtenemos el Cuadro 3.1. En dicho cuadro se destaca que se muestra la función de autocorrelación para los tres primeros rezagos. Para

¹Los datos y el algoritmo están disponibles en el repositorio de GitHub del proyecto.




Figura 3.2: Evolución del número de pasajeros en el Metro de la CDMX, enero 2000 a junio 2025

mayor detalle, en la Figura 3.3 se muestra la función de autocorrelación, en donde las bandas descritas por las líneas azules son el intervalo de confianza dentro de las cuales no se puede rechazar la hipótesis nula de que $H_0 : \rho(\tau) = 0$, para todo $\tau = 1, 2, \dots, T - 1$.

```
Pax_Metro <- ts(Datos$Pax_Metro,
               start = 2000,
               freq = 12)

acf(Pax_Metro,
    lag.max = 150,
    xlab = 'Rezagos k en meses',
    main = "Función de Autocorrelación del número de pasajeros
    ↪ del metro")
```

3.3 Procesos estacionarios univariados

En este capítulo analizaremos el método o metodología de análisis de series de tiempo propuesto por Box y Jenkins (1970). Los modelos propuestos dentro

Cuadro 3.1: Estadísticas descriptivas del número de pasajeros en el Metro de la CDMX, enero de 2000 a junio de 2025

Estadística	Valor
$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T X_t$	115.9972
$\hat{\gamma}(0) = \frac{1}{T} \sum_{t=1}^T (X_t - \hat{\mu})^2$	428.3240
$\hat{\gamma}(1) = \frac{1}{T} \sum_{t=1}^{T-1} (X_t - \hat{\mu})(X_{t+1} - \hat{\mu})$	381.7028
$\hat{\gamma}(2) = \frac{1}{T} \sum_{t=1}^{T-2} (X_t - \hat{\mu})(X_{t+2} - \hat{\mu})$	372.1024
$\hat{\gamma}(3) = \frac{1}{T} \sum_{t=1}^{T-3} (X_t - \hat{\mu})(X_{t+3} - \hat{\mu})$	349.3550
$\hat{\rho}(1) = \hat{\gamma}(1)/\hat{\gamma}(0)$	0.8912
$\hat{\rho}(2) = \hat{\gamma}(2)/\hat{\gamma}(0)$	0.8687
$\hat{\rho}(3) = \hat{\gamma}(3)/\hat{\gamma}(0)$	0.8156
$Q^* = T \sum_{j=1}^1 \hat{\rho}(j)^2$	243.0117
$Q^* = T \sum_{j=1}^2 \hat{\rho}(j)^2$	473.9530


Función de Autocorrelación del número de pasajeros del metro

Figura 3.3: Función de Autocorrelación: 150 rezagos del número de pasajeros en el Metro de la CDMX, enero de 2000 a junio de 2025

de esta metodología o conjunto de métodos se han vuelto indispensables para efectos de realizar pronósticos de corto plazo.

En este sentido, se analizarán los métodos más importantes en series de tiempo: procesos autorregresivos (AR, por sus siglas en inglés) y procesos de medias móviles (MA, por sus siglas en inglés). Asimismo, se realizará un análisis de los procesos que resultan de la combinación de ambos, conocida como ARMA, los cuales son más comúnmente usados para realizar pronósticos.

3.4 Procesos Autorregresivos (AR)

Los procesos autorregresivos tienen su origen en el trabajo de Cochrane y Orcutt de 1949, mediante el cual analizaron los residuales de una regresión clásica como un proceso autorregresivo. Puede consultarse el apéndice para la discusión del modelo de regresión clásica.

3.4.1 AR(1)

Como primer caso analizaremos al proceso autorregresivo de primer orden, $AR(1)$, el cual podemos definir como una Ecuación Lineal en Diferencia de Primer Orden Estocástica. Diremos que una Ecuación Lineal en Diferencia de Primer Orden es estocástica si en su representación analítica considera un componente estocástico como en la ecuación (3.30) descrita a continuación:

$$X_t = a_0 + a_1 X_{t-1} + U_t \quad (3.30)$$

Donde a_0 es un término constante, U_t es un proceso estacionario, con media cero (0), una varianza finita y constante (σ^2) y una covarianza que depende de la distancia entre t y cualquier $t-s$ (γ_s)—que no depende de los valores pasados o futuros de la variable—, X_0 es el valor inicial del proceso X_t . No obstante, en ocasiones vamos a asumir que la covarianza será cero (0), por lo que en esos casos tendremos un proceso puramente aleatorio. Considerando la ecuación (3.30) y un proceso de sustitución sucesivo podemos establecer lo siguiente, empezando con X_1 :

$$X_1 = a_0 + a_1 X_0 + U_1$$

Para X_2 :

$$\begin{aligned} X_2 &= a_0 + a_1 X_1 + U_2 \\ &= a_0 + a_1(a_0 + a_1 X_0 + U_1) + U_2 \\ &= a_0 + a_1 a_0 + a_1^2 X_0 + a_1 U_1 + U_2 \end{aligned}$$

Para X_3 :

$$\begin{aligned} X_3 &= a_0 + a_1 X_2 + U_3 \\ &= a_0 + a_1(a_0 + a_1 a_0 + a_1^2 X_0 + a_1 U_1 + U_2) + U_3 \\ &= a_0 + a_1 a_0 + a_1^2 a_0 + a_1^3 X_0 + a_1^2 U_1 + a_1 U_2 + U_3 \end{aligned}$$

Así, para cualquier X_t , $t = 1, 2, 3, \dots$, obtendríamos:

$$\begin{aligned} X_t &= a_0 + a_1 X_{t-1} + U_t \\ &= a_0 + a_1(a_0 + a_1 a_0 + a_1^2 a_0 + \dots + a_1^{t-2} a_0 + a_1^{t-1} X_0 \\ &\quad + a_1^{t-2} U_1 + \dots + a_1 U_{t-2} + U_{t-1}) + U_t \\ &= a_0 + a_1 a_0 + a_1^2 a_0 + a_1^3 a_0 + \dots + a_1^{t-1} a_0 + a_1^t X_0 \\ &\quad + a_1^{t-1} U_1 + \dots + a_1^2 U_{t-2} + a_1 U_{t-1} + U_t \\ &= (1 + a_1 + a_1^2 + a_1^3 + \dots + a_1^{t-1}) a_0 + a_1^t X_0 \\ &\quad + a_1^{t-1} U_1 + \dots + a_1^2 U_{t-2} + a_1 U_{t-1} + U_t \\ &= \frac{1 - a_1^t}{1 - a_1} a_0 + a_1^t X_0 + \sum_{j=0}^{t-1} a_1^j U_{t-j} \end{aligned} \tag{3.31}$$

De esta forma en la ecuación (3.31) observamos un proceso que es explicado por dos partes: una que depende del tiempo y otra que depende de un proceso estocástico. Asimismo, debe notarse que la condición de convergencia es idéntica al caso de ecuaciones en diferencia estudiadas en el capítulo previo: $|a_1| < 1$, por lo que cuando $t \rightarrow \infty$, la expresión (3.31) será la siguiente:

$$X_t = a_0 \frac{1}{1 - a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-j} \tag{3.32}$$

Así, desaparece la parte dependiente del tiempo y únicamente prevalece la parte que es dependiente del proceso estocástico. Esta es la solución de largo plazo del proceso $AR(1)$, la cual depende del proceso estocástico. Notemos, además, que esta solución implica que la variable o la serie de tiempo X_t es también un proceso estocástico que hereda las propiedades de U_t . Así, X_t es también un proceso estocástico estacionario, como demostraremos más adelante.

Observemos que la ecuación (3.32) se puede reescribir si consideramos la formulación que en la literatura se denomina como la descomposición de Wold, en la cual se define que es posible asumir que $\psi_j = a_1^j$ y se considera el caso en el cual $|a_1| < 1$. De esta forma tendremos, por ejemplo, que:

$$\sum_{j=0}^{\infty} \psi_j^2 = \sum_{j=0}^{\infty} a_1^{2j} = \frac{1}{1 - a_1^2}$$

Alternativamente y de forma similar a las ecuaciones en diferencia estudiadas previamente, podemos escribir el proceso $AR(1)$ mediante el uso del operador

rezago como:

$$\begin{aligned}
 X_t &= a_0 + a_1 L X_t + U_t \\
 X_t - a_1 L X_t &= a_0 + U_t \\
 (1 - a_1 L) X_t &= a_0 + U_t \\
 X_t &= \frac{a_0}{1 - a_1 L} + \frac{1}{1 - a_1 L} U_t
 \end{aligned} \tag{3.33}$$

En esta última ecuación retomamos el siguiente término para reescribirlo como:

$$\frac{1}{1 - a_1 L} = 1 + a_1 L + a_1^2 L^2 + a_1^3 L^3 + \dots \tag{3.34}$$

Tomando este resultado para sustituirlo en la ecuación (3.33), obtenemos la siguiente expresión:

$$\begin{aligned}
 X_t &= (1 + a_1 L + a_1^2 L^2 + a_1^3 L^3 + \dots) a_0 + (1 + a_1 L + a_1^2 L^2 + a_1^3 L^3 + \dots) U_t \\
 &= (1 + a_1 + a_1^2 + a_1^3 + \dots) a_0 + U_t + a_1 U_{t-1} + a_1^2 U_{t-2} + a_1^3 U_{t-3} + \dots \\
 &= \frac{a_0}{1 - a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-j}
 \end{aligned} \tag{3.35}$$

Donde la condición de convergencia y estabilidad del proceso descrito en esta ecuación es que $|a_1| < 1$. Por lo que hemos demostrado que, mediante el uso del operador de rezago, es posible llegar al mismo resultado que obtuvimos mediante el procedimiento de sustituciones iterativas.

La ecuación (3.35) se puede interpretar como sigue. La solución o trayectoria de equilibrio de un AR(1) se divide en dos partes. La primera es una constante que depende de los valores de a_0 y a_1 . La segunda parte es la suma ponderada de las desviaciones o errores observados y acumulados en el tiempo hasta el momento t .

Ahora obtendremos los momentos que describen a la serie de tiempo cuando se trata de un proceso AR(1). Para ello debemos obtener la media, la varianza y las covarianzas de X_t . Para los siguientes resultados debemos recordar y tener en mente que si U_t es un proceso puramente aleatorio, entonces:

1. $\mathbb{E}[U_t] = 0$ para todo t
2. $Var[U_t] = \sigma^2$ para todo t
3. $Cov[U_t, U_s] = 0$ para todo $t \neq s$

Dicho lo anterior y partiendo de la ecuación (3.35), el primer momento o valor esperado de la serie de tiempo será el siguiente:

$$\begin{aligned}
\mathbb{E}[X_t] &= \mathbb{E}\left[\frac{a_0}{1-a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-j}\right] \\
&= \frac{a_0}{1-a_1} + \sum_{j=0}^{\infty} a_1^j \mathbb{E}[U_{t-j}] \\
&= \frac{a_0}{1-a_1} = \mu
\end{aligned} \tag{3.36}$$

Respecto de la varianza podemos escribir la siguiente expresión a partir de la ecuación (3.35):

$$\begin{aligned}
\text{Var}[X_t] &= \mathbb{E}[(X_t - \mu)^2] \\
&= \mathbb{E}\left[\left(\frac{a_0}{1-a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-j} - \frac{a_0}{1-a_1}\right)^2\right] \\
&= \mathbb{E}[(U_t + a_1 U_{t-1} + a_1^2 U_{t-2} + a_1^3 U_{t-3} + \dots)^2] \\
&= \mathbb{E}[U_t^2 + a_1^2 U_{t-1}^2 + a_1^4 U_{t-2}^2 + a_1^6 U_{t-3}^2 + \dots \\
&\quad + 2a_1 U_t U_{t-1} + 2a_1^2 U_t U_{t-2} + \dots] \\
&= \mathbb{E}[U_t^2] + a_1^2 \mathbb{E}[U_{t-1}^2] + a_1^4 \mathbb{E}[U_{t-2}^2] + a_1^6 \mathbb{E}[U_{t-3}^2] + \dots \\
&= \sigma^2 + a_1^2 \sigma^2 + a_1^4 \sigma^2 + a_1^6 \sigma^2 + \dots \\
&= \sigma^2(1 + a_1^2 + a_1^4 + a_1^6 + \dots) \\
&= \sigma^2 \frac{1}{1-a_1^2} = \gamma(0)
\end{aligned} \tag{3.37}$$

Previo a analizar la covarianza de la serie de tiempo, recordemos que para el proceso puramente aleatorio U_t su varianza y covarianza pueden verse como $\mathbb{E}[U_t U_s] = \sigma^2$, para $t = s$, y $\mathbb{E}[U_t U_s] = 0$, para cualquier otro caso, respectivamente.

Dicho lo anterior, partiendo de la ecuación (3.35) la covarianza de la serie estará dada por:

$$\begin{aligned}
\text{Cov}(X_t, X_{t-\tau}) &= \mathbb{E}[(X_t - \mu)(X_{t-\tau} - \mu)] \\
&= \mathbb{E}\left[\left(\frac{a_0}{1-a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-j} - \frac{a_0}{1-a_1}\right) \right. \\
&\quad \left. \times \left(\frac{a_0}{1-a_1} + \sum_{j=0}^{\infty} a_1^j U_{t-\tau-j} - \frac{a_0}{1-a_1}\right)\right] \\
&= a_1^\tau \mathbb{E}[U_{t-\tau}^2 + a_1^2 U_{t-\tau-1}^2 + a_1^4 U_{t-\tau-2}^2 + a_1^6 U_{t-\tau-3}^2 + \dots] \\
&= a_1^\tau \sigma^2 \frac{1}{1-a_1^2} = \gamma(\tau)
\end{aligned} \tag{3.38}$$

Nótese que con estos resultados en las ecuaciones (3.37) y (3.38) podemos construir la función de autocorrelación teórica como sigue:

$$\begin{aligned}\rho(\tau) &= \frac{\gamma(\tau)}{\gamma(0)} \\ &= a_1^\tau\end{aligned}\tag{3.39}$$

Donde $\tau = 1, 2, 3, \dots$ y $|a_1| < 1$. Este último resultado significa que cuando el proceso autorregresivo es de orden 1 (es decir, AR(1)) la función de autocorrelación teóricamente es igual al parámetro a_1 elevado al número de rezagos considerados. No obstante, esto no significa que la autocorrelación estimada en una muestra coincida exactamente con la teórica: en muestras finitas, la autocorrelación observada será ligeramente distinta. Ahora veamos algunos ejemplos.

Ejemplo. En el primer ejemplo simularemos una serie y mostraremos el análisis de un proceso construido considerando un proceso puramente aleatorio como componente U_t . Por su parte, en un segundo ejemplo aplicaremos el análisis a una serie de tiempo de una variable económica observada.

Para el primer ejemplo, consideremos un proceso dado por la forma de un AR(1) como en la ecuación (3.33) cuya solución está dada por la ecuación (3.35). En específico, supongamos que el término o componente estocástico U_t es una serie generada a partir de números aleatorios de una función normal con media 0 y desviación estándar 4. Los detalles del proceso simulado se muestran en las siguientes gráficas.

La Figura 3.4 ilustra el comportamiento que se debería observar en una serie considerando el procedimiento iterativo de construcción. Por su parte, la Figura 3.5 ilustra el proceso o trayectoria de la solución de la serie de tiempo. Finalmente, las Figuras 3.6 y 3.7 muestran el correlograma calculado considerando una función de autocorrelación aplicada al proceso real y una función de autocorrelación aplicada al proceso teórico, respectivamente.

```
library(ggplot2)
library(dplyr)
library(latex2exp)

a0 <- 5; a1 <- 0.9; X_0 <- (a0/(1 - a1)); T <- 1000

X_t <- data.frame(Tiempo = c(0:T))

set.seed(12345)

# Agregamos un término estocástico al data frame

X_t$U_t <- rnorm(T+1, mean = 0, sd = 4)
```

```

# Agregamos columnas con NA's para un proceso teorico y uno real
X_t$X_t <- NA
X_t$XR_t <- NA

# La serie teórica inicia en un valor inicial X_0
X_t$X_t[1] <- X_0

# La serie real inicia en un valor inicial X_0
X_t$XR_t[1] <- X_0

# Agregamos una columna para la función de Autocorrelación
  ↪ teórica:
X_t$rho <- NA

for (i in 2:(T + 1)) {
  # Real:
  X_t$XR_t[i] = a0 + a1*X_t$XR_t[i-1] + X_t$U_t[i-1]

  # Teórico:
  X_t$X_t[i] = X_t$X_t[i-1] + (a1^(i-1))*X_t$U_t[i-1]

  # Autocorrelación:
  X_t$rho[i-1] = a1^(i-1)
}

ggplot(data = X_t, aes(x = Tiempo, y = XR_t)) +
  geom_line(size = 0.5, color = "darkred") +
  #theme_bw() +
  xlab("Tiempo") +
  ylab(TeX("$X_t$")) +
  theme(plot.title = element_text(size = 11, face = "bold",
                                   hjust = 0)) +
  theme(plot.subtitle = element_text(size = 10, hjust = 0)) +
  theme(plot.caption = element_text(size = 10, hjust = 0)) +
  theme(plot.margin = unit(c(1,1,1,1), "cm")) +
  labs(
    title = "Comportamiento del Proceso Real ('Estimado')",
    subtitle = "Con un error con Distribución Normal (media = 0,
  ↪ desviación estándar = 4)",
    caption = "Fuente: Elaboración propia."
  )

```




Figura 3.4: Comportamiento del Proceso Real ('Estimado')

```
ggplot(data = X_t, aes(x = Tiempo, y = X_t)) +
  geom_line(size = 0.5, color = "darkblue") +
  #theme_bw() +
  xlab("Tiempo") +
  ylab(TeX("$X_t$")) +
  theme(plot.title = element_text(size = 11, face = "bold",
                                   hjust = 0)) +
  theme(plot.subtitle = element_text(size = 10, hjust = 0)) +
  theme(plot.caption = element_text(size = 10, hjust = 0)) +
  theme(plot.margin = unit(c(1,1,1,1), "cm")) +
  labs(
    title = "Comportamiento del Proceso Teórico",
    subtitle = "Con un error con Distribución Normal (media = 0,
    ↪ desviación estándar = 4)",
    caption = "Fuente: Elaboración propia."
  )
```

```
acf(X_t$XR_t, lag.max = 30, col = "blue",
  ylab = "Autocorrelación",
  xlab = "Rezagos",
```




Figura 3.5: Comportamiento del Proceso Teórico

```
main="Función de Autocorrelación Real")
```

```
barplot(X_t$rho[1:30], names.arg = c(1:30), col = "blue",
        border="blue", density = c(10,20),
        ylab = "Autocorrelación",
        xlab="Rezagos",
        main="Función de Autocorrelación Teórica")
```

Recordemos que una trayectoria de equilibrio o solución de un $AR(1)$ es como se muestra en la ecuación (3.35). Así, nuestra serie simulada cumple con la característica de que los errores son más relevantes cuando la serie es corta. Por el contrario, los errores son menos relevantes, cuando la serie es muy larga. La Figura 3.8 ilustra esta observación de la trayectoria de equilibrio.

```
ggplot(data = X_t, aes(x = Tiempo)) +
  geom_line(aes(y = XR_t), size = 0.5, color = "darkred") +
  geom_line(aes(y = X_t), size = 0.5, color = "darkblue") +
  #theme_bw() +
  xlab("Tiempo") +
  ylab(TeX("$X_t$")) +
```




Figura 3.6: Función de Autocorrelación Real




Figura 3.7: Función de Autocorrelación Teórica

```

theme(plot.title = element_text(size = 11, face = "bold",
                                hjust = 0)) +
theme(plot.subtitle = element_text(size = 10, hjust = 0)) +
theme(plot.caption = element_text(size = 10, hjust = 0)) +
theme(plot.margin = unit(c(1,1,1,1), "cm")) +
labs(
  title = "Comportamiento de los Procesos Real y Teórico",
  subtitle = "Con un error con Distribución Normal (media = 0,
    ↪ desviación estándar = 4)",
  caption = "Fuente: Elaboración propia."
)

```




Figura 3.8: Comportamiento de los Procesos Real y Teórico

Ejemplo. Para el segundo ejemplo consideremos una aplicación a una serie de tiempo en específico: Pasajeros transportados mensualmente en el Sistema de Transporte Colectivo Metro (pasajeros medidos en millones).²

A la serie se le aplicará una metodología de estimación dada por el método de Máxima Verosimilitud (ML, por sus siglas en inglés). Antes de realizar el proceso de estimación, consideremos una transformación de diferencias logarítmicas con

²Fuente: INEGI, <https://www.inegi.org.mx/app/indicadores/?tm=0&t=1090>.

el objeto de obtener una serie de tiempo expresada en tasas de crecimiento³ y con un comportamiento parecido a un proceso estacionario.

Así, para cada una de las series que analicemos en diferencias logarítmicas respecto del momento k las expresaremos bajo la siguiente transformación:

$$DLX_t = \log(X_t) - \log(X_{t-k})$$

Donde $k = 1, 2, 3, \dots$ y $\log(\cdot)$ es la función logaritmo natural. Esta expresión se puede interpretar como una tasa de crecimiento, puesto que asumimos variaciones pequeñas para las cuales se cumple que: $\log(X_t) - \log(X_{t-k}) \approx \frac{X_t - X_{t-k}}{X_{t-k}}$.

Primero, para realizar el análisis de una serie de tiempo deberemos decidir si éste se realizará para la serie en niveles o en diferencias. Por convención, decimos que la serie está en niveles si ésta se analiza sin hacerle ninguna transformación o si se analiza aplicando solo logaritmos. Cuando la serie se analiza en diferencias significa que la diferencia se hace sin aplicar logaritmos o aplicando logaritmos. Sin embargo, la convención es hacer un análisis en diferencias logarítmicas.

Para decidir cómo analizar la serie de pasajeros en el metro de la CDMX en la Figura 3.9 se muestra la gráfica de la serie en niveles (sin transformación logarítmica y con transformación logarítmica) y en diferencias logarítmicas mensuales (es decir, con $k = 1$).

```
library(ggplot2)
library(dplyr)
library(readxl)
library(stats)

Datos <- read_excel("BD/Base_Transporte.xlsx",
                    sheet = "Datos", col_names = TRUE)

# En Niveles
Pax_Metro <- ts(Datos$Pax_Metro, start = c(2000, 1),
               freq = 12)

# En Logaritmos:
Pax_LMetro <- ts(log(Datos$Pax_Metro), start = c(2000, 1),
                freq = 12)

# Diferencias mensuales:
Pax_DLMetro <- ts( log(Datos$Pax_Metro) -
                  lag( log(Datos$Pax_Metro), 1 ),
                  start = c(2000, 1), freq = 12)
```

³Estas tasas no son porcentuales, para hacerlas porcentuales faltaría multiplicar por 100 cada valor de la serie.

```

#
par(mfrow = c(3,1))

plot(Pax_Metro, xlab = "Tiempo",
     main = "Pasajeros transportados (Millones) en el Metro
           ↪ CDMX",
     col = "darkgreen")

plot(Pax_LMetro, xlab = "Tiempo",
     main = "LN Pasajeros transportados (Millones) en el Metro
           ↪ CDMX",
     col = "darkblue")

plot(Pax_DLMetro, xlab = "Tiempo",
     main = "Diff LN Pasajeros transportados (Millones) en el
           ↪ Metro CDMX",
     col = "darkred")

```




Figura 3.9: Pasajeros transportados (Millones) en el Metro de la CDMX en niveles y en diferencias logarítmicas

```
par(mfrow=c(1,1))
```

A continuación, estimaremos una $AR(1)$ para la serie en niveles bajo la transformación logarítmica ($PaxLMetro_t$) y en diferencias logarítmicas ($PaxDLMetro_t$). Los resultados se muestran en los Cuadros 3.2 y 3.3.

```
source("arroots.R")
source("plot.armacroots.R")
AR_LMetro <- arima(Pax_LMetro, order = c(1, 0, 0), method =
  ↪ "ML")
AR_DLMetro <- arima(Pax_DLMetro, order = c(1, 0, 0), method =
  ↪ "ML")

arima_kable <- function(mod, cap) {
  cf <- mod$coef
  se <- sqrt(diag(mod$var.coef))
  tv <- round(cf / se, 3)
  pv <- 2 * pnorm(-abs(tv))
  sig <- ifelse(pv < 0.001, "***", ifelse(pv < 0.01, "**",
  ↪ ifelse(pv < 0.05, "*", ifelse(pv < 0.1, ".", ""))))
  df <- data.frame(Estimado = round(cf, 4), SE = round(se, 4), t
  ↪ = tv, Signif = sig)
  # Con escape = FALSE, los guiones bajos de nombres de
  ↪ coeficientes
  # (p. ej. dummies como D_Sep2017_MA) deben escaparse solo para
  ↪ LaTeX
  if (knitr::is_latex_output()) rownames(df) <- gsub("_",
  ↪ "\\_", rownames(df))
  knitr::kable(df, col.names = c("Estimado", "Error Est.",
  ↪ "Estad. $t$", "Signif."),
    caption = paste0(cap, " ($\\hat{\\sigma}^2 = ",
    ↪ round(mod$sigma2, 6),
    "$; AIC $=$ ", round(AIC(mod),
    ↪ 2), "$)$."),
    align = c("r", "r", "r", "c"), booktabs = TRUE,
    ↪ escape = FALSE)
}

arima_kable(AR_LMetro, "AR(1) para la variable $PaxLMetro_t$")
```

```
arima_kable(AR_DLMetro, "AR(1) para la variable $PaxDLMetro_t$")
```

En ambos casos observamos que el parámetro asociado al componente AR es significativo y cumple con la restricción de ser en valor absoluto menor a 1,

Cuadro 3.2: AR(1) para la variable $PaxLMetro_t$ ($\hat{\sigma}^2 = 0.009682$; AIC = -543.1).

	Estimado	Error Est.	Estad. t	Signif.
ar1	0.8913	0.0253	35.225	***
intercept	4.7294	0.0504	93.794	***

Cuadro 3.3: AR(1) para la variable $PaxDLMetro_t$ ($\hat{\sigma}^2 = 0.009845$; AIC = -537.76).

	Estimado	Error Est.	Estad. t	Signif.
ar1	-0.1991	0.0560	-3.553	***
intercept	-0.0004	0.0047	-0.074	

por lo que la solución asociada al proceso será convergente. También en ambos casos se reporta la estadística o Criterio de Información de Akaike (AIC, por sus siglas en inglés), cuya importancia y aplicación discutiremos más adelante.

3.4.2 AR(2)

Una vez analizado el caso de $AR(1)$ analizaremos el caso del $AR(2)$. La ecuación generalizada del proceso autorregresivo de orden 2 (denotado como $AR(2)$) puede ser escrita como:

$$X_t = a_0 + a_1 X_{t-1} + a_2 X_{t-2} + U_t \quad (3.40)$$

Donde U_t denota un proceso puramente aleatorio con media cero (0), varianza constante (σ^2) y autocovarianza cero ($Cov(U_t, U_s) = 0$, con $t \neq s$), y un parámetro $a_2 \neq 0$. Así, utilizando el operador rezago podemos reescribir la ecuación (3.40) como:

$$\begin{aligned} X_t - a_1 X_{t-1} - a_2 X_{t-2} &= a_0 + U_t \\ (1 - a_1 L^1 - a_2 L^2) X_t &= a_0 + U_t \end{aligned}$$

Donde, vamos a denotar a $\alpha(L) = (1 - a_1 L^1 - a_2 L^2)$, y lo denotaremos como un polinomio que depende del operador rezago y que es distinto de cero. De esta forma podemos reescribir la ecuación (3.40) como:

$$\alpha(L) X_t = a_0 + U_t \quad (3.41)$$

Ahora, supongamos que existe el inverso multiplicativo del polinomio $\alpha(L)$, el cual será denotado como: $\alpha^{-1}(L)$ y cumple con que:

$$\alpha^{-1}(L) \alpha(L) = 1 \quad (3.42)$$

Así, podemos escribir la solución a la ecuación (3.40) como:

$$X_t = \alpha^{-1}(L)\delta + \alpha^{-1}(L)U_t$$

Si utilizamos el hecho que $\alpha^{-1}(L)$ se puede descomponer a través del procedimiento de Wold en un polinomio de forma similar al caso de $AR(1)$, tenemos que:

$$\alpha^{-1}(L) = \psi_0 + \psi_1 L + \psi_2 L^2 + \dots \quad (3.43)$$

Por lo tanto, el inverso multiplicativo $\alpha^{-1}(L)$ se puede ver como:

$$1 = (1 - a_1 L - a_2 L^2)(\psi_0 + \psi_1 L + \psi_2 L^2 + \dots) \quad (3.44)$$

Desarrollando la ecuación (3.44) tenemos la siguiente expresión:

$$\begin{aligned} 1 &= \psi_0 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots \\ &\quad - a_1 \psi_0 L - a_1 \psi_1 L^2 - a_1 \psi_2 L^3 - \dots \\ &\quad - a_2 \psi_0 L^2 - a_2 \psi_1 L^3 - \dots \end{aligned}$$

Ahora, podemos agrupar todos los términos en función del exponente asociado al operador rezago L . La siguiente es una solución particular y es una de las múltiples que podrían existir que cumpla con la ecuación (3.44). Sin embargo, para efectos del análisis, sólo necesitamos una de esas soluciones. Utilizaremos las siguientes condiciones que deben cumplirse en una de las posibles soluciones:

$$\begin{aligned} L^0 &: \Rightarrow \psi_0 = 1 \\ L^1 &: \psi_1 - a_1 \psi_0 = 0 \Rightarrow \psi_1 = a_1 \\ L^2 &: \psi_2 - a_1 \psi_1 - a_2 \psi_0 = 0 \Rightarrow \psi_2 = a_1^2 + a_2 \\ L^3 &: \psi_3 - a_1 \psi_2 - a_2 \psi_1 = 0 \Rightarrow \psi_3 = a_1^3 + 2a_1 a_2 \\ &\vdots \end{aligned}$$

De esta forma podemos observar que en el límite siempre obtendremos una ecuación del tipo $\psi_j - a_1 \psi_{j-1} - a_2 \psi_{j-2} = 0$ asociada a cada uno de los casos en que exista un L^j , donde $j \neq 0, 1$, y la cual siempre podremos resolver conociendo que las condiciones iniciales son: $\psi_0 = 1$ y $\psi_1 = a_1$.

Así, de las relaciones antes mencionadas y considerando que $\alpha^{-1}(L)$ aplicada a una constante como a_0 tendrá como resultado otra constante, podemos escribir la solución del proceso $AR(2)$ de la ecuación (3.40) mediante una expresión como sigue:

$$X_t = \frac{a_0}{1 - a_1 - a_2} + \sum_{j=0}^{\infty} \psi_j U_{t-j} \quad (3.45)$$

Donde todos los parámetros ψ_i están determinados por los parámetros a_0 , a_1 y a_2 . En particular, $\psi_0 = 1$ y $\psi_1 = a_1$, como describimos anteriormente. Al igual

que en el caso del $AR(1)$, en la ecuación (3.45) las condiciones de estabilidad estarán dadas por las soluciones del siguiente polinomio característico:⁴

$$\lambda^2 - \lambda a_1 - a_2 = 0 \quad (3.46)$$

Así, la condición de estabilidad de la trayectoria es que $|\lambda_i| < 1$, para $i = 1, 2$. Es decir, es necesario que cada una de las raíces sea, en valor absoluto, siempre menor que la unidad. Estas son las condiciones de estabilidad para el proceso $AR(2)$.

Finalmente, al igual que en un $AR(1)$, a continuación determinamos los momentos de una serie que sigue un proceso $AR(2)$. Iniciamos con la determinación de la media de la serie:

$$\mathbb{E}[X_t] = \mu = \frac{a_0}{1 - a_1 - a_2} \quad (3.47)$$

Lo anterior es cierto puesto que $\mathbb{E}[U_{t-i}] = 0$, para todo $i = 0, 1, 2, \dots$. Para determinar la varianza utilizaremos las siguientes relaciones basadas en el uso del valor esperado, varianza y covarianza de la serie. Adicionalmente, para simplificar el trabajo asumamos que $a_0 = 0$, lo cual implica que $\mu = 0$. Dicho lo anterior, partamos de:

$$\begin{aligned} \mathbb{E}[X_t X_{t-\tau}] &= \mathbb{E}[(a_1 X_{t-1} + a_2 X_{t-2} + U_t) X_{t-\tau}] \\ &= a_1 \mathbb{E}[X_{t-1} X_{t-\tau}] + a_2 \mathbb{E}[X_{t-2} X_{t-\tau}] + \mathbb{E}[U_t X_{t-\tau}] \end{aligned}$$

Donde $\tau = 0, 1, 2, 3, \dots$ y $\mathbb{E}[U_t X_{t-\tau}] = 0$ para todo $\tau \neq 0$.⁵ Dicho esto, podemos derivar el valor del valor esperado para diferentes valores de τ :

$$\begin{aligned} \tau = 0 & : \quad \gamma(0) = a_1 \gamma(1) + a_2 \gamma(2) + \sigma^2 \\ \tau = 1 & : \quad \gamma(1) = a_1 \gamma(0) + a_2 \gamma(1) \\ \tau = 2 & : \quad \gamma(2) = a_1 \gamma(1) + a_2 \gamma(0) \\ & \vdots \end{aligned}$$

Donde debe ser claro que $\mathbb{E}[(X_t - \mu)(X_{t-\tau} - \mu)] = \mathbb{E}[X_t X_{t-\tau}] = \gamma(\tau)$. Así, en general cuando $\tau \neq 0$:

$$\gamma(\tau) = a_1 \gamma(\tau - 1) + a_2 \gamma(\tau - 2) \quad (3.48)$$

Realizando la sustitución recursiva y solucionando el sistema respectivo obtenemos que la varianza y las covarianzas estarán determinadas por:

$$\text{Var}[X_t] = \gamma(0) = \frac{1 - a_2}{(1 + a_2)[(1 - a_2)^2 - a_1^2]} \sigma^2 \quad (3.49)$$

⁴Note que las raíces son equivalentes al inverso de las del polinomio dado por $\lambda^2 a_2 - \lambda a_1 - 1 = 0$.

⁵Es fácil demostrar esta afirmación, sólo requiere desarrollar la expresión y utilizar el hecho de que U_t es un proceso puramente aleatorio, por lo que la covarianza es cero (0).


```

# En Niveles
Pax_Nal <- ts(Datos$Pax_Nal,
              start = c(2000, 1),
              freq = 12)

# Logaritmos:
LPax_Nal <- ts(log(Datos$Pax_Nal),
               start = c(2000, 1),
               freq = 12)

# Diferencias mensuales:
DLPax_Nal <- ts(log(Datos$Pax_Nal) -
                lag(log(Datos$Pax_Nal), 1),
                start = c(2000, 1), freq = 12)

#
par(mfrow=c(3,1))

plot(Pax_Nal, xlab = "Tiempo", ylab = "Pasajeros",
     main = "Pasajeros en vuelos nacionales de salida",
     col = "darkgreen")

plot(LPax_Nal, xlab = "Tiempo", ylab = "LN Pasajeros",
     main = "LN Pasajeros en vuelos nacionales de salida",
     col = "darkblue")

plot(DLPax_Nal, xlab = "Tiempo", ylab = "DLN Pasajeros",
     main = "Diff LN Pasajeros en vuelos nacionales de salida",
     col = "darkred")

```

```

par(mfrow=c(1,1))

```

A continuación, estimaremos un $AR(2)$ para la serie en niveles bajo la transformación logarítmica ($LPaxNal_t$) y en diferencias logarítmicas ($DLPaxNal_t$). Los resultados se muestran en los Cuadros 3.4 y 3.5.

```

AR_LPax_Nal <- arima(LPax_Nal, order = c(2, 0, 0), method =
  ↪ "ML")
AR_DLPax_Nal <- arima(DLPax_Nal, order = c(2, 0, 0), method =
  ↪ "ML")
arima_kable(AR_LPax_Nal, "AR(2) para la variable $LPaxNal_t$")

```





Figura 3.10: Pasajeros en vuelos de salidas nacionales en niveles y en diferencias logarítmicas

Cuadro 3.4: AR(2) para la variable $LPaxNal_t$ ($\hat{\sigma}^2 = 0.02771$; AIC = -218.9).

	Estimado	Error Est.	Estad. t	Signif.
ar1	1.0391	0.0566	18.360	***
ar2	-0.1189	0.0570	-2.087	*
intercept	14.7729	0.1155	127.896	***

Cuadro 3.5: AR(2) para la variable $DLPaxNal_t$ ($\hat{\sigma}^2 = 0.026535$; AIC = -233.2).

	Estimado	Error Est.	Estad. t	Signif.
ar1	0.0984	0.0548	1.796	.
ar2	-0.2850	0.0547	-5.206	***
intercept	0.0040	0.0079	0.508	

```
arima_kable(AR_DLPax_Nal, "AR(2) para la variable $DLPaxNal_t$")
```

Para ambos casos se reportan los errores estándar y el criterio de Akaike (AIC). Finalmente, en la Figura 3.11 mostramos las raíces del polinomio característico para verificar la convergencia de las soluciones.

```
par(mfrow=c(1,2))

plot.armaroots(arroots(AR_LPax_Nal),
               main="Inverse AR roots of \nAR(2): LN Pax Nal")

#
plot.armaroots(arroots(AR_DLPax_Nal),
               main="Inverse AR roots of \nAR(2): Diff LN Pax
               ↪ Nal")
```

```
par(mfrow=c(1,1))
```

3.4.3 AR(p)

Veremos ahora una generalización de los procesos autorregresivos (AR). Esta generalización es conocida como un proceso $AR(p)$ y que puede ser descrito por la siguiente ecuación en diferencia estocástica:

$$X_t = a_0 + a_1 X_{t-1} + a_2 X_{t-2} + a_3 X_{t-3} + \dots + a_p X_{t-p} + U_t \quad (3.53)$$

Donde $a_p \neq 0$, y U_t es un proceso puramente aleatorio con media cero (0), varianza constante (σ^2) y covarianza cero (0). Usando el operador rezago, L^k , para $k = 0, 1, 2, \dots, p$, obtenemos la siguiente expresión de la ecuación (3.53):

$$(1 - a_1 L - a_2 L^2 - a_3 L^3 - \dots - a_p L^p) X_t = a_0 + U_t \quad (3.54)$$

Definamos el polinomio $\alpha(L)$ como:

$$\alpha(L) = 1 - a_1 L - a_2 L^2 - a_3 L^3 - \dots - a_p L^p \quad (3.55)$$




Figura 3.11: Inverso de las Raíces del polinomio característico

De forma similar que en los procesos $AR(1)$ y $AR(2)$, las condiciones de estabilidad del proceso $AR(p)$ estarán dadas por la solución de la ecuación característica:

$$\lambda^p - a_1\lambda^{p-1} - a_2\lambda^{p-2} - a_3\lambda^{p-3} - \dots - a_p = 0 \quad (3.56)$$

Así, solo si el polinomio anterior tiene raíces cuyo valor absoluto sea menor a uno ($|\lambda_i| < 1$) podremos decir que el proceso es convergente y estable. Lo anterior significa que la ecuación (3.55) puede expresarse en términos de la descomposición de Wold o como la suma infinita de términos como:

$$\frac{1}{1 - a_1L - a_2L^2 - a_3L^3 - \dots - a_pL^p} = \psi_0 + \psi_1L + \psi_2L^2 + \psi_3L^3 + \dots \quad (3.57)$$

Donde, por construcción de $\alpha(L)\alpha^{-1}(L) = 1$ implica que $\psi_0 = 1$. De forma similar a los procesos $AR(1)$ y $AR(2)$, es posible determinar el valor de los coeficientes ψ_j en términos de los coeficientes a_i . Así, la solución del proceso $AR(p)$ estará dada por:

$$X_t = \frac{a_0}{1 - a_1 - a_2 - a_3 - \dots - a_p} + \sum_{j=0}^{\infty} \psi_j U_{t-j} \quad (3.58)$$

Considerando la solución de la ecuación (3.53) expresada en la ecuación (3.58) podemos determinar los momentos del proceso y que estarán dados por una

media como:

$$\mathbb{E}[X_t] = \mu = \frac{a_0}{1 - a_1 - a_2 - a_3 - \dots - a_p} \quad (3.59)$$

Lo anterior, considerado que $\mathbb{E}[U_t] = 0$, para todo t . Para determinar la varianza del proceso, sin pérdida de generalidad, podemos definir una ecuación: $\gamma(\tau) = \mathbb{E}[X_{t-\tau}X_t]$, la cual (omitiendo la constante, ya que la correlación de una constante con cualquier variable aleatoria que depende del tiempo es cero (0)) puede ser escrita como:

$$\gamma(\tau) = \mathbb{E}[(X_{t-\tau}) \cdot (a_1X_{t-1} + a_2X_{t-2} + a_3X_{t-3} + \dots + a_pX_{t-p} + U_t)] \quad (3.60)$$

Donde $\tau = 0, 1, 2, \dots, p$ y $a_0 = 0$, lo que implica que $\mu = 0$. De lo anterior obtenemos el siguiente conjunto de ecuaciones mediante sustituciones de los valores de τ :

$$\begin{aligned} \gamma(0) &= a_1\gamma(1) + a_2\gamma(2) + \dots + a_p\gamma(p) + \sigma^2 \\ \gamma(1) &= a_1\gamma(0) + a_2\gamma(1) + \dots + a_p\gamma(p-1) \\ &\vdots \\ \gamma(p) &= a_1\gamma(p-1) + a_2\gamma(p-2) + \dots + a_p\gamma(0) \end{aligned}$$

De esta forma, es fácil observar que la ecuación general para $p > 0$ estará dada por:

$$\gamma(\tau) - a_1\gamma(\tau-1) - a_2\gamma(\tau-2) - \dots - a_p\gamma(\tau-p) = 0 \quad (3.61)$$

Dividiendo la ecuación (3.61) por $\gamma(0)$, se obtiene la siguiente ecuación:

$$\rho(\tau) - a_1\rho(\tau-1) - a_2\rho(\tau-2) - \dots - a_p\rho(\tau-p) = 0 \quad (3.62)$$

Así, podemos escribir el siguiente sistema de ecuaciones:

$$\begin{aligned} \rho(1) &= a_1 + a_2\rho(1) + a_3\rho(2) + \dots + a_p\rho(p-1) \\ \rho(2) &= a_1\rho(1) + a_2 + a_3\rho(1) + \dots + a_p\rho(p-2) \\ &\vdots \\ \rho(p) &= a_1\rho(p-1) + a_2\rho(p-2) + \dots + a_p \end{aligned}$$

Lo anterior se puede expresar como un conjunto de vectores y matrices de la siguiente forma:

$$\begin{bmatrix} \rho(1) \\ \rho(2) \\ \vdots \\ \rho(p) \end{bmatrix} = \begin{bmatrix} 1 & \rho(1) & \dots & \rho(p-1) \\ \rho(1) & 1 & \dots & \rho(p-2) \\ \rho(2) & \rho(1) & \dots & \rho(p-3) \\ \vdots & \vdots & \dots & \vdots \\ \rho(p-1) & \rho(p-2) & \dots & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ \vdots \\ a_p \end{bmatrix} \quad (3.63)$$

De lo anterior podemos escribir la siguiente ecuación que es una forma alternativa para expresar los valores de los coeficientes a_i de la solución del proceso $AR(p)$:

$$\rho = \mathbf{R}\mathbf{a} \quad (3.64)$$

Es decir, podemos obtener la siguiente expresión:

$$\mathbf{a} = \mathbf{R}^{-1}\rho \quad (3.65)$$

Ejemplo. Utilizaremos la serie de Pasajeros en vuelos internacionales de salida para estimar un $AR(p)$ mediante el método de máxima verosimilitud (ML). Antes de realizar el proceso de estimación, consideremos una transformación de la serie en logaritmos y una más en diferencias logarítmicas; lo anterior con el objeto de obtener una serie de tiempo suavizada y expresada en tasas de crecimiento, con un comportamiento parecido a un proceso estacionario.

Primero, para decidir si se realizará un $AR(p)$ para la serie en niveles o en diferencias, analizaremos su gráfica. La serie de Pasajeros en vuelos internacionales de salidas se muestra en la Figura 3.12. En esta se muestra la gráfica de la serie en niveles (sin transformación logarítmica y con transformación logarítmica) y en diferencias logarítmicas mensuales (es decir, con diferencia respecto del mes inmediato anterior).

```
library(ggplot2)
library(dplyr)
library(readxl)
library(stats)

Datos <- read_excel("BD/Base_Transporte.xlsx",
                    sheet = "Datos", col_names = TRUE)

# En Niveles
Pax_Int <- ts(Datos$Pax_Int,
              start = c(2000, 1),
              freq = 12)

# Logaritmos:
LPax_Int <- ts(log(Datos$Pax_Int),
               start = c(2000, 1),
               freq = 12)

# Diferencias mensuales:
DLPax_Int <- ts(log(Datos$Pax_Int) - lag(log(Datos$Pax_Int), 1),
                start = c(2000, 1),
                freq = 12)
```

```
#
par(mfrow=c(3,1))

plot(Pax_Int, xlab = "Tiempo", ylab = "Pasajeros",
     main = "Pasajeros en vuelos internacionales de salida",
     col = "darkgreen")

plot(LPax_Int, xlab = "Tiempo", ylab = "LN Pasajeros",
     main = "LN Pasajeros en vuelos internacionales de salida",
     col = "darkblue")

plot(DLPax_Int, xlab = "Tiempo", ylab = "DLN Pasajeros",
     main = "Diff LN Pasajeros en vuelos internacionales de salida",
     col = "darkred")
```




Figura 3.12: Pasajeros en vuelos internacionales de salida en niveles y en diferencias logarítmicas

```
par(mfrow=c(1,1))
```

De la gráfica en la Figura 3.12 observamos que quizá la mejor forma de estimar un $AR(p)$ es mediante la serie en diferencias, ya que ésta es la que parece ser

Cuadro 3.6: AR(4) para la variable $DLPaxInt_t$ ($\hat{\sigma}^2 = 0.06076$; AIC = 23.57).

	Estimado	Error Est.	Estad. t	Signif.
ar1	0.0834	0.0572	1.457	
ar2	-0.2952	0.0568	-5.202	***
ar3	-0.1358	0.0567	-2.396	*
ar4	-0.0288	0.0570	-0.505	
intercept	0.0043	0.0103	0.414	

una serie estacionaria. A continuación, estimaremos una AR(4) para la serie en diferencias logarítmicas ($DLPaxInt_t$):

```
source("arroots.R")
source("plot.armaroots.R")
AR_LPax_Int <- arima(LPax_Int, order = c(4, 0, 0), method =
  ↪ "ML")
AR_DLPax_Int <- arima(DLPax_Int, order = c(4, 0, 0), method =
  ↪ "ML")

arima_kable(AR_DLPax_Int, "AR(4) para la variable $DLPaxInt_t$")
```

Los resultados se muestran en el Cuadro 3.6. Finalmente, en la Figura 3.13 mostramos las raíces del polinomio característico; la inspección visual confirma que el AR(4) tiene solución convergente y estable.

```
par(mfrow=c(1,2))

plot.armaroots(arroots(AR_LPax_Int),
  main="Inverse AR roots of \nAR(4): LN Pax Int")

#
plot.armaroots(arroots(AR_DLPax_Int),
  main="Inverse AR roots of \nAR(4): Diff LN Pax
  ↪ Int")

par(mfrow=c(1,1))
```




Figura 3.13: Inverso de las Raíces del polinomio característico

3.5 Procesos de Medias Móviles (MA)

3.5.1 MA(1)

Una vez planteado el proceso generalizado de $AR(p)$, iniciamos el planteamiento de los procesos de medias móviles, denotados como $MA(q)$. Iniciemos con el planteamiento del proceso $MA(1)$, que se puede escribir como una ecuación como la siguiente:

$$X_t = \mu + U_t - b_1 U_{t-1} \quad (3.66)$$

O como:

$$X_t - \mu = (1 - b_1 L)U_t \quad (3.67)$$

Donde U_t es un proceso puramente aleatorio, es decir, con $\mathbb{E}[U_t] = 0$, $\text{Var}[U_t] = \sigma^2$, y $\text{Cov}[U_t, U_s] = 0$. Así, un proceso $MA(1)$ puede verse como un proceso AR con una descomposición de Wold en la que $\psi_0 = 1$, $\psi_1 = -b_1$ y $\psi_j = 0$ para todo $j > 1$.

Al igual que los procesos autorregresivos, determinaremos los momentos de un proceso $MA(1)$. En el caso de la media, observamos que será:

$$\begin{aligned} \mathbb{E}[X_t] &= \mu + \mathbb{E}[U_t] - b_1 \mathbb{E}[U_{t-1}] \\ &= \mu \end{aligned} \quad (3.68)$$

Por su parte, la varianza estará dada por:

$$\begin{aligned}
 Var[X_t] &= \mathbb{E}[(X_t - \mu)^2] \\
 &= \mathbb{E}[(U_t - b_1 U_{t-1})^2] \\
 &= \mathbb{E}[U_t^2 - 2b_1 U_t U_{t-1} + b_1^2 U_{t-1}^2] \\
 &= \mathbb{E}[U_t^2] - 2b_1 \mathbb{E}[U_t U_{t-1}] + b_1^2 \mathbb{E}[U_{t-1}^2] \\
 &= \sigma^2 + b_1^2 \sigma^2 \\
 &= (1 + b_1^2) \sigma^2 = \gamma(0)
 \end{aligned} \tag{3.69}$$

De esta forma, la varianza del proceso es constante en cualquier periodo t . Para determinar la covarianza utilizaremos la siguiente ecuación:

$$\begin{aligned}
 \mathbb{E}[(x_t - \mu)(x_{t+\tau} - \mu)] &= \mathbb{E}[(U_t - b_1 U_{t-1})(U_{t+\tau} - b_1 U_{t+\tau-1})] \\
 &= \mathbb{E}[U_t U_{t+\tau} - b_1 U_t U_{t+\tau-1} - b_1 U_{t-1} U_{t+\tau} \\
 &\quad + b_1^2 U_{t-1} U_{t+\tau-1}] \\
 &= \mathbb{E}[U_t U_{t+\tau}] - b_1 \mathbb{E}[U_t U_{t+\tau-1}] \\
 &\quad - b_1 \mathbb{E}[U_{t-1} U_{t+\tau}] + b_1^2 \mathbb{E}[U_{t-1} U_{t+\tau-1}]
 \end{aligned} \tag{3.70}$$

Si hacemos sustituciones de diferentes valores de τ en la ecuación (3.70) notaremos que la covarianza será distinta de cero únicamente para el caso de $\tau = 1, -1$. En ambos casos tendremos como resultado:

$$\begin{aligned}
 \mathbb{E}[(x_t - \mu)(x_{t+1} - \mu)] &= \mathbb{E}[(x_t - \mu)(x_{t-1} - \mu)] \\
 &= -b_1 \mathbb{E}[U_t U_t] \\
 &= -b_1 \mathbb{E}[U_{t-1} U_{t-1}] \\
 &= -b_1 \sigma^2 = \gamma(1)
 \end{aligned} \tag{3.71}$$

De esta forma tendremos que las funciones de autocorrelación estarán dadas por los siguientes casos:

$$\begin{aligned}
 \rho(0) &= 1 \\
 \rho(1) &= \frac{-b_1}{1 + b_1^2} \\
 \rho(\tau) &= 0 \text{ para todo } \tau > 1
 \end{aligned}$$

Ahora regresando a la ecuación (3.66), su solución la podemos expresar como:

$$\begin{aligned}
 U_t &= -\frac{\mu}{1 - b_1} + \frac{1}{1 - b_1 L} X_t \\
 &= -\frac{\mu}{1 - b_1} + X_t + b_1 X_{t-1} + b_1^2 X_{t-2} + \dots
 \end{aligned}$$

Donde la condición para que se cumpla esta ecuación es que $|b_1| < 1$. La manera de interpretar esta condición es como una condición de estabilidad de la solución

y como una condición de invertibilidad. Notemos que un $MA(1)$ (y en general un $MA(q)$) es equivalente a un $AR(\infty)$, es decir, cuando se invierte un MA se genera un AR con infinitos rezagos.

En esta sección no desarrollaremos un ejemplo, primero explicaremos en qué consiste una modelación del tipo $MA(q)$ y después plantearemos un ejemplo en concreto.

3.5.2 $MA(q)$

En general, el proceso de medias móviles de orden q , $MA(q)$, puede ser escrito como:

$$X_t = \mu + U_t - b_1 U_{t-1} - b_2 U_{t-2} - \dots - b_q U_{t-q} \quad (3.72)$$

Podemos reescribir la ecuación (3.72) utilizando el operador rezago. Así, tendremos el proceso de $MA(q)$ como:

$$\begin{aligned} X_t - \mu &= (1 - b_1 L - b_2 L^2 - \dots - b_q L^q) U_t \\ X_t - \mu &= \beta(L) U_t \end{aligned} \quad (3.73)$$

Donde U_t es un proceso puramente aleatorio con $\mathbb{E}[U_t] = 0$, $Var[U_t] = \mathbb{E}[U_t^2] = \sigma^2$ y $Cov[U_t, U_s] = \mathbb{E}[U_t U_s] = 0$, y $\beta(L) = 1 - b_1 L - b_2 L^2 - \dots - b_q L^q$ es un polinomio del operador rezago L . La ecuación (3.73) puede ser interpretada como un polinomio de rezagos de orden q aplicado a la serie U_t .

Ahora determinemos los momentos de un proceso $MA(q)$:

$$\begin{aligned} \mathbb{E}[X_t] &= \mathbb{E}[\mu + U_t - b_1 U_{t-1} - b_2 U_{t-2} - \dots - b_q U_{t-q}] \\ &= \mu + \mathbb{E}[U_t] - b_1 \mathbb{E}[U_{t-1}] - b_2 \mathbb{E}[U_{t-2}] - \dots - b_q \mathbb{E}[U_{t-q}] \\ &= \mu \end{aligned} \quad (3.74)$$

En el caso de la varianza tenemos que se puede expresar como:

$$\begin{aligned} Var[X_t] &= \mathbb{E}[(X_t - \mu)^2] \\ &= \mathbb{E}[(U_t - b_1 U_{t-1} - b_2 U_{t-2} - \dots - b_q U_{t-q})^2] \\ &= \mathbb{E}[U_t^2 + b_1^2 U_{t-1}^2 + b_2^2 U_{t-2}^2 + \dots + b_q^2 U_{t-q}^2 \\ &\quad - 2b_1 U_t U_{t-1} - \dots - 2b_{q-1} b_q U_{t-q+1} U_{t-q}] \\ &= \mathbb{E}[U_t^2] + b_1^2 \mathbb{E}[U_{t-1}^2] + b_2^2 \mathbb{E}[U_{t-2}^2] + \dots + b_q^2 \mathbb{E}[U_{t-q}^2] \\ &\quad - 2b_1 \mathbb{E}[U_t U_{t-1}] - \dots - 2b_{q-1} b_q \mathbb{E}[U_{t-q+1} U_{t-q}] \\ &= \sigma^2 + b_1^2 \sigma^2 + b_2^2 \sigma^2 + \dots + b_q^2 \sigma^2 \\ &= (1 + b_1^2 + b_2^2 + \dots + b_q^2) \sigma^2 \end{aligned} \quad (3.75)$$

En el caso de las covarianzas podemos utilizar una idea similar al caso del $AR(p)$, construir una expresión general para cualquier rezago τ :

$$\begin{aligned} Cov[X_t, X_{t+\tau}] &= \mathbb{E}[(X_t - \mu)(X_{t+\tau} - \mu)] \\ &= \mathbb{E}[(U_t - b_1 U_{t-1} - b_2 U_{t-2} - \dots - b_q U_{t-q}) \\ &\quad (U_{t+\tau} - b_1 U_{t+\tau-1} - b_2 U_{t+\tau-2} - \dots - b_q U_{t+\tau-q})] \end{aligned}$$

La expresión anterior se puede desarrollar para múltiples casos de $\tau = 1, 2, \dots, q$. De esta forma tenemos el siguiente sistema:

$$\begin{aligned} \tau = 1 & : \gamma(1) = (-b_1 + b_1 b_2 + \dots + b_{q-1} b_q) \sigma^2 \\ \tau = 2 & : \gamma(2) = (-b_2 + b_1 b_3 + \dots + b_{q-2} b_q) \sigma^2 \\ & : \\ \tau = q & : \gamma(q) = -b_q \sigma^2 \end{aligned}$$

Donde $\gamma(\tau) = 0$ para todo $\tau > q$. Es decir, todas las autocovarianzas y autocorrelaciones con órdenes superiores a q son cero (0). De esta forma, esta característica teórica permite identificar el orden de $MA(q)$ visualizando la función de autocorrelación y verificando a partir de cuál valor de rezago la autocorrelación es no significativa.

Regresando al problema original que es el de determinar una solución para la ecuación (3.72), tenemos que dicha solución estará dada por un $AR(\infty)$ en términos de U_t :

$$\begin{aligned} U_t &= -\frac{\mu}{1 - b_1 - b_2 - \dots - b_q} + \beta(L)^{-1} X_t \\ &= -\frac{\mu}{1 - b_1 - b_2 - \dots - b_q} + \sum_{j=0}^{\infty} c_j X_{t-j} \end{aligned} \quad (3.76)$$

Donde se cumple que: $1 = (1 - b_1 L^1 - b_2 L^2 - \dots - b_q L^q)(1 - c_1 L - c_2 L^2 - \dots)$ y los coeficientes c_j se pueden determinar por un método de coeficientes indeterminados y en términos de los valores b_i . De igual forma que en el caso de la ecuación (3.53), en la ecuación (3.76) se deben cumplir condiciones de estabilidad asociadas con las raíces del polinomio característico dado por:

$$1 - b_1 x - b_2 x^2 - \dots - b_q x^q = 0 \quad (3.77)$$

El cual debe cumplir que todas sus raíces se ubiquen fuera del círculo unitario ($|x_i| > 1$) o, equivalentemente, que las raíces del polinomio $\lambda^q - b_1 \lambda^{q-1} - \dots - b_q = 0$ cumplan $|\lambda_i| < 1$ –la condición de invertibilidad del proceso–.

Ejemplo. Ahora veamos un ejemplo del proceso $MA(q)$, para lo cual retomaremos la serie de Pasajeros transportados en el metro de la CDMX (*PaxMetro*).

Estimaremos el $MA(q)$ mediante el método de máxima verosimilitud (ML). Antes de realizar el proceso de estimación, consideremos una transformación de la serie en logaritmos y una más en diferencias logarítmicas; lo anterior con el objeto de obtener una serie de tiempo suavizada y expresada en tasas de crecimiento, con un comportamiento parecido a un proceso estacionario.

La serie de Pasajeros transportados en el metro de la CDMX se muestra en la Figura 3.9. En esta, se muestra la gráfica de la serie en niveles (sin transformación logarítmica y con transformación logarítmica) y en diferencias logarítmicas mensuales (es decir, con una diferencia respecto del mes inmediato anterior). Utilizaremos la serie en diferencias, ya que es la que parece ser estacionaria. Esta serie tiene la peculiaridad de que tiene un salto a la baja y uno al alza entre septiembre de 2017 y octubre de 2017. Para controlar ese efecto, en nuestro modelo $MA(q)$ incluiremos dos variables dummies para dichos meses.

A continuación, estimaremos una $MA(4)$ para la serie en diferencias. Los resultados se muestran en el Cuadro 3.7.

```
library(readxl)
Datos_MA <- read_excel("BD/Base_Transporte_ARIMA.xlsx",
                      sheet = "Datos", col_names = TRUE)
DLPax_Metro_MA <- ts(log(Datos_MA$Pax_Metro) -
  ↪ lag(log(Datos_MA$Pax_Metro), 1),
                  start = c(2000, 1), freq = 12)
D_Sep2017_MA <- ts(Datos_MA$D_Sep2017, start = c(2000, 1), freq =
  ↪ 12)
t_idx <- time(DLPax_Metro_MA)
D_Oct2017_MA <- as.numeric(abs(t_idx - (2017 + 9/12)) < 0.01)

MA_DLPax_Metro <- arima(DLPax_Metro_MA, order = c(0, 0, 4),
                      xreg = cbind(D_Sep2017_MA,
  ↪ D_Oct2017_MA),
                      method = "ML")
arima_kable(MA_DLPax_Metro, "MA(4) para la variable
  ↪ $DLPaxMetro_t$")
```

Entre paréntesis se reportan los errores estándar y el criterio de Akaike (AIC). Finalmente, podemos determinar si la solución será convergente; para ello en la Figura 3.14 mostramos las raíces asociadas a cada uno de los polinomios. De la inspección visual, podemos concluir que ambas propuestas de $MA(4)$ representan una solución convergente y estable.

```
library(ggplot2)
library(dplyr)
library(readxl)
library(stats)
```

Cuadro 3.7: MA(4) para la variable $DLPaxMetro_t$ ($\hat{\sigma}^2 = 0.008478$; AIC = -573.15).

	Estimado	Error Est.	Estad. t	Signif.
ma1	-0.1739	0.0648	-2.685	**
ma2	-0.0519	0.0767	-0.677	
ma3	-0.1807	0.0980	-1.843	.
ma4	-0.0985	0.0797	-1.236	
intercept	-0.0004	0.0027	-0.148	
D_Sep2017_MA	-0.4021	0.0898	-4.477	***
D_Oct2017_MA	0.3948	0.0899	4.389	***

```

Datos <- read_excel("BD/Base_Transporte_ARIMA.xlsx",
                    sheet = "Datos", col_names = TRUE)

source("maroots.R")

source("plot.armaroots.R")

Pax_Metro <- ts(Datos$Pax_Metro,
               start = c(2000, 1),
               freq = 12)

LPax_Metro <- ts(log(Datos$Pax_Metro),
                start = c(2000, 1),
                freq = 12)

DLPax_Metro <- ts(log(Datos$Pax_Metro) -
                 lag(log(Datos$Pax_Metro), 1),
                 start = c(2000, 1),
                 freq = 12)

D_Sep2017 <- ts(Datos$D_Sep2017,
               start = c(2000, 1),
               freq = 12)

D_Abr2020 <- ts(Datos$D_Abr2020,
               start = c(2000, 1),
               freq = 12)

D_May2020 <- ts(Datos$D_May2020,

```

```

      start = c(2000, 1),
      freq = 12)

MA_LPax_Metro <- arima(LPax_Metro, order = c(0, 0, 4),
                      method = "ML")

MA_LPax_Metro_2 <- arima(LPax_Metro, order = c(0, 0, 4),
                        xreg = cbind(D_Abr2020, D_Sep2017,
                                     D_May2020),
                        method = "ML")

par(mfrow=c(1,2))

plot.armacroots(maroots(MA_LPax_Metro),
               main="Inverse MA roots of \nMA(4): LN Pax Metro")

plot.armacroots(maroots(MA_LPax_Metro_2),
               main="Inverse MA roots of \nMA(4): LN Pax Metro
               ↪ con Dummy")

```




Figura 3.14: Inverso de las Raíces del polinomio característico

```
par(mfrow=c(1,1))
```

3.6 Procesos ARMA(p, q) y ARIMA(p, d, q)

Hemos establecido algunas relaciones de los procesos AR y los procesos MA, es decir, cómo un $MA(q)$ de la serie X_t puede ser reexpresado como un $AR(\infty)$ de la serie U_t y, viceversa, un $AR(p)$ de la serie X_t puede ser reexpresado como un $MA(\infty)$.

En este sentido, para cerrar esta sección veamos el caso de la especificación que conjunta ambos modelos en un modelo general conocido como $ARMA(p, q)$ o $ARIMA(p, d, q)$. La diferencia entre el primero y el segundo es el número de veces que se tuvo que diferenciar la serie analizada, registro que se lleva en el índice d de los parámetros dentro del concepto $ARIMA(p, d, q)$. No obstante, en general nos referiremos al modelo como $ARMA(p, q)$ y dependerá del analista si modela la serie en niveles (por ejemplo, en logaritmos) o en diferencias logarítmicas (o diferencias sin logaritmos).

3.6.1 ARMA(1, 1)

Dicho lo anterior, vamos a empezar con el análisis de un $ARMA(1, 1)$. Un proceso $ARMA(1, 1)$ puede verse como:

$$X_t = \delta + a_1 X_{t-1} + U_t - b_1 U_{t-1} \quad (3.78)$$

Aplicando el operador rezago podemos reescribir la ecuación (3.78) como:

$$(1 - a_1 L)X_t = \delta + (1 - b_1 L)U_t \quad (3.79)$$

Donde U_t es un proceso puramente aleatorio como en los casos de $AR(p)$ y $MA(q)$, y X_t puede ser una serie en niveles o en diferencias (ambas, en términos logarítmicos).

Así, el modelo $ARMA(p, q)$ también tiene una representación de Wold que estará dada por las siguientes expresiones:

$$X_t = \frac{\delta}{1 - a_1} + \frac{1 - b_1 L}{1 - a_1 L} U_t \quad (3.80)$$

Donde $a_1 \neq b_1$, puesto que en caso contrario X_t sería un proceso puramente aleatorio con una media $\mu = \frac{\delta}{1 - a_1}$. Así, podemos reescribir la descomposición de Wold a partir del componente de la ecuación (3.80):

$$\frac{1 - b_1 L}{1 - a_1 L} = \psi_0 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots \quad (3.81)$$

Esta ecuación es equivalente a la expresión:

$$\begin{aligned}
 (1 - b_1 L) &= (1 - a_1 L)(\psi_0 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots) \\
 &= \psi_0 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots \\
 &\quad - a_1 \psi_0 L - a_1 \psi_1 L^2 - a_1 \psi_2 L^3 - a_1 \psi_3 L^4 - \dots
 \end{aligned}$$

De esta forma podemos establecer el siguiente sistema de coeficientes indeterminados:

$$\begin{aligned}
 L^0 &: \Rightarrow \psi_0 = 1 \\
 L^1 &: \psi_1 - a_1 \psi_0 = -b_1 \Rightarrow \psi_1 = a_1 - b_1 \\
 L^2 &: \psi_2 - a_1 \psi_1 = 0 \Rightarrow \psi_2 = a_1(a_1 - b_1) \\
 L^3 &: \psi_3 - a_1 \psi_2 = 0 \Rightarrow \psi_3 = a_1^2(a_1 - b_1) \\
 &\vdots \\
 L^j &: \psi_j - a_1 \psi_{j-1} = 0 \Rightarrow \psi_j = a_1^{j-1}(a_1 - b_1)
 \end{aligned}$$

Así, la solución a la ecuación (3.78) estará dada por la siguiente generalización:

$$X_t = \frac{\delta}{1 - a_1} + U_t + (a_1 - b_1)U_{t-1} + a_1(a_1 - b_1)U_{t-2} + a_1^2(a_1 - b_1)U_{t-3} + \dots \quad (3.82)$$

En la ecuación (3.82) las condiciones de estabilidad y de invertibilidad del sistema (de un MA a un AR, y viceversa) estarán dadas por: $|a_1| < 1$ y $|b_1| < 1$. Adicionalmente, la ecuación (3.82) expresa cómo una serie que tiene un comportamiento $ARMA(1, 1)$ es equivalente a una serie modelada bajo un $MA(\infty)$.

Al igual que en los demás modelos, ahora determinaremos los momentos del proceso $ARMA(1, 1)$. La media estará dada por:

$$\begin{aligned}
 \mathbb{E}[X_t] &= \mathbb{E}[\delta + a_1 X_{t-1} + U_t - b_1 U_{t-1}] \\
 &= \delta + a_1 \mathbb{E}[X_{t-1}] \\
 &= \frac{\delta}{1 - a_1} \\
 &= \mu
 \end{aligned} \quad (3.83)$$

Donde hemos utilizado que $\mathbb{E}[X_t] = \mathbb{E}[X_{t-1}] = \mu$. Es decir, la media de un $ARMA(1, 1)$ es idéntica a la de un $AR(1)$.

Para determinar la varianza tomaremos una estrategia similar a los casos de $AR(p)$ y $MA(q)$. Por lo que para todo $\tau \geq 0$, y suponiendo por simplicidad que $\delta = 0$ (lo que implica que $\mu = 0$) tendremos:

$$\begin{aligned}
 \mathbb{E}[X_{t-\tau} X_t] &= \mathbb{E}[(X_{t-\tau}) \cdot (a_1 X_{t-1} + U_t - b_1 U_{t-1})] \\
 &= a_1 \mathbb{E}[X_{t-\tau} X_{t-1}] + \mathbb{E}[X_{t-\tau} U_t] - b_1 \mathbb{E}[X_{t-\tau} U_{t-1}]
 \end{aligned} \quad (3.84)$$

De la ecuación (3.84) podemos determinar una expresión para el caso de $\tau = 0$:

$$\begin{aligned}
 \mathbb{E}[X_t X_t] &= \gamma(0) \\
 &= a_1 \gamma(1) + \mathbb{E}[U_t X_t] - b_1 \mathbb{E}[X_t U_{t-1}] \\
 &= a_1 \gamma(1) + \sigma^2 - b_1 \mathbb{E}[U_{t-1}(a_1 X_{t-1} + U_t - b_1 U_{t-1})] \\
 &= a_1 \gamma(1) + \sigma^2 - b_1 a_1 \sigma^2 + b_1^2 \sigma^2 \\
 &= a_1 \gamma(1) + (1 - b_1(a_1 - b_1))\sigma^2
 \end{aligned} \tag{3.85}$$

Para el caso en que $\tau = 1$:

$$\begin{aligned}
 \mathbb{E}[X_{t-1} X_t] &= \gamma(1) \\
 &= a_1 \gamma(0) + \mathbb{E}[X_{t-1} U_t] - b_1 \mathbb{E}[X_{t-1} U_{t-1}] \\
 &= a_1 \gamma(0) - b_1 \sigma^2
 \end{aligned} \tag{3.86}$$

Estas últimas expresiones podemos resolverlas como sistema para determinar los siguientes valores:

$$\gamma(0) = \frac{1 + b_1^2 - 2a_1 b_1}{1 - a_1^2} \sigma^2 \tag{3.87}$$

$$\gamma(1) = \frac{(a_1 - b_1)(1 - a_1 b_1)}{1 - a_1^2} \sigma^2 \tag{3.88}$$

En general, para cualquier valor $\tau \geq 2$ tenemos que la autocovarianza y la función de autocorrelación serán:

$$\gamma(\tau) = a_1 \gamma(\tau - 1) \tag{3.89}$$

$$\rho(\tau) = a_1 \rho(\tau - 1) \tag{3.90}$$

Por ejemplo, para el caso de $\tau = 1$ tendríamos:

$$\rho(1) = \frac{(a_1 - b_1)(1 - a_1 b_1)}{1 + b_1^2 - 2a_1 b_1} \tag{3.91}$$

De esta forma, la función de autocorrelación oscilará en razón de los valores que tome a_1 y b_1 .

3.6.2 ARMA(p, q)

La especificación general de un ARMA(p, q) (donde $p, q \in \mathbb{N}$) puede ser descrita por la siguiente ecuación:

$$\begin{aligned}
 X_t &= \delta + a_1 X_{t-1} + a_2 X_{t-2} + \dots + a_p X_{t-p} \\
 &\quad + U_t - b_1 U_{t-1} - b_2 U_{t-2} - \dots - b_q U_{t-q}
 \end{aligned} \tag{3.92}$$

Donde U_t es un proceso puramente aleatorio, y X_t puede ser modelada en niveles o en diferencias (ya sea en logaritmos o sin transformación logarítmica).

Mediante el uso del operador rezago se puede escribir la ecuación (3.92) como:

$$(1 - a_1L - a_2L^2 - \dots - a_pL^p)X_t = \delta + (1 - b_1L - b_2L^2 - \dots - b_qL^q)U_t \quad (3.93)$$

En la ecuación (3.93) definamos dos polinomios: $\alpha(L) = (1 - a_1L - a_2L^2 - \dots - a_pL^p)$ y $\beta(L) = (1 - b_1L - b_2L^2 - \dots - b_qL^q)$. Así, podemos reescribir la ecuación (3.93) como:

$$\alpha(L)X_t = \delta + \beta(L)U_t \quad (3.94)$$

Asumiendo que existe el polinomio inverso tal que: $\alpha(L)^{-1}\alpha(L) = 1$. La solución entonces puede ser escrita como:

$$\begin{aligned} X_t &= \alpha(L)^{-1}\delta + \alpha(L)^{-1}\beta(L)U_t \\ &= \frac{\delta}{1 - a_1 - a_2 - \dots - a_p} + \frac{\beta(L)}{\alpha(L)}U_t \\ &= \frac{\delta}{1 - a_1 - a_2 - \dots - a_p} + U_t + \psi_1LU_t + \psi_2L^2U_t + \dots \end{aligned} \quad (3.95)$$

Donde la ecuación (3.95) nos permite interpretar que un $ARMA(p, q)$ se puede reexpresar e interpretar como un $MA(\infty)$ y donde las condiciones para la estabilidad de la solución y la invertibilidad son que las raíces de las ecuaciones características asociadas a $\alpha(L)$ y $\beta(L)$ sean, en valor absoluto, menores a 1 –equivalentemente, que las raíces de los polinomios en L se ubiquen fuera del círculo unitario–.

Adicionalmente, la fracción en la ecuación (3.95) se puede descomponer como en la forma de Wold:

$$\frac{\beta(L)}{\alpha(L)} = 1 + \psi_1L + \psi_2L^2 + \dots \quad (3.96)$$

Bajo los supuestos de estacionariedad del componente U_t , los valores de la media y varianza de un proceso $ARMA(p, q)$ serán como describimos ahora. Para el caso de la media, podemos partir de la ecuación (3.95) para generar:

$$\begin{aligned} \mathbb{E}[X_t] &= \mathbb{E}\left[\frac{\delta}{1 - a_1 - a_2 - \dots - a_p} + U_t + \psi_1U_{t-1} + \psi_2U_{t-2} + \dots\right] \\ &= \frac{\delta}{1 - a_1 - a_2 - \dots - a_p} \\ &= \mu \end{aligned} \quad (3.97)$$

Esta expresión indica que en general un proceso $ARMA(p, q)$ converge a una media idéntica a la de un proceso $AR(p)$. Para determinar la varianza utilizaremos la misma estrategia que hemos utilizado para otros modelos $AR(p)$ y $MA(q)$.

Sin pérdida de generalidad podemos asumir que $\delta = 0$, lo que implica que $\mu = 0$, de lo que podemos establecer una expresión de autocovarianzas para cualquier valor $\tau = 0, 1, 2, \dots$:

$$\begin{aligned}
 \gamma(\tau) &= \mathbb{E}[X_{t-\tau}X_t] \\
 &= \mathbb{E}[X_{t-\tau}(\delta + a_1X_{t-1} + a_2X_{t-2} + \dots + a_pX_{t-p} \\
 &\quad + U_t - b_1U_{t-1} - b_2U_{t-2} - \dots - b_qU_{t-q})] \\
 &= a_1\gamma(\tau-1) + a_2\gamma(\tau-2) + \dots + a_p\gamma(\tau-p) \\
 &\quad + \mathbb{E}[X_{t-\tau}U_t] - b_1\mathbb{E}[X_{t-\tau}U_{t-1}] - \dots - b_q\mathbb{E}[X_{t-\tau}U_{t-q}] \quad (3.98)
 \end{aligned}$$

Ahora veamos un ejemplo. Utilizaremos la serie de Pasajeros en vuelos nacionales de salida para estimar un $ARMA(p, q)$ mediante el método de máxima verosimilitud (ML). Antes de realizar el proceso de estimación, consideremos una transformación de la serie en diferencias logarítmicas, ya que, según la gráfica en la Figura 3.10, esa es la que puede ser estacionaria.

A continuación, estimaremos una $ARMA(1, 1)$ para la serie en diferencias logarítmicas ($DLPaxNal_t$). También incorporaremos al análisis variables exógenas tales como dummies de estacionalidad. En particular, utilizaremos los meses de enero, febrero, julio y diciembre. No debe pasar desapercibido que un análisis de estacionalidad más formal debería considerar todos los meses para separar del término de error la parte que puede ser explicada por los ciclos estacionales.

Los resultados se muestran en el Cuadro 3.8.

```

D_Ene_Nal <- as.numeric(cycle(DLPax_Nal) == 1)
D_Feb_Nal <- as.numeric(cycle(DLPax_Nal) == 2)
D_Jul_Nal <- as.numeric(cycle(DLPax_Nal) == 7)
D_Dic_Nal <- as.numeric(cycle(DLPax_Nal) == 12)

ARMA_DLPax_Nal <- arima(DLPax_Nal, order = c(1, 0, 1),
                        xreg = cbind(D_Ene_Nal, D_Feb_Nal,
                                      D_Jul_Nal, D_Dic_Nal),
                        method = "ML")
arima_kable(ARMA_DLPax_Nal, "ARMA(1, 1) para la variable
↪ $DLPaxNal_t$")

```

Donde entre paréntesis se reportan los errores estándar. Adicionalmente, reportamos el estadístico de Akaike (AIC). Finalmente, podemos determinar si las soluciones serán convergentes, para ello en la Figura 3.15 mostramos las raíces asociadas a cada uno de los polinomios. De la inspección visual, podemos concluir que tenemos una solución convergente y estable. Por su parte, la Figura 3.16 muestra los residuales de la estimación del $ARMA(1, 1)$.

Cuadro 3.8: ARMA(1, 1) para la variable $DLPaxNal_t$ ($\hat{\sigma}^2 = 0.022859$; AIC = -270.64).

	Estimado	Error Est.	Estad. t	Signif.
ar1	-0.5827	0.0988	-5.900	***
ma1	0.8163	0.0644	12.682	***
intercept	0.0032	0.0120	0.265	
D_Ene_Nal	-0.0913	0.0331	-2.758	**
D_Feb_Nal	-0.1263	0.0339	-3.727	***
D_Jul_Nal	0.1734	0.0304	5.698	***
D_Dic_Nal	0.0590	0.0324	1.823	.

```
source("maroots.R")

par(mfrow=c(1,2))

plot.armacoots(arroots(ARMA_DLPax_Nal),
               main="Inverse AR roots of \nARMA(1,1): Diff LN Pax
               ↪ Nal")

plot.armacoots(maroots(ARMA_DLPax_Nal),
               main="Inverse MA roots of \nARMA(1,1): Diff LN Pax
               ↪ Nal")
```

```
par(mfrow=c(1,1))
```

```
plot(residuals(ARMA_DLPax_Nal), col = "darkred",
     ylab = "Residuales", xlab = "Tiempo",
     main = "Residuales del ARMA(1,1) de Diff LN Pax Nal")
```

En lo que resta de este capítulo, utilizaremos la serie en diferencias logarítmicas de los pasajeros en vuelos nacionales de salida, $DLPaxNal_t$, para discutir los ejemplos que ilustran cada uno de los puntos teóricos que a continuación exponemos.

3.7 Función de Autocorrelación Parcial

Ahora introduciremos el concepto de Función de Autocorrelación Parcial (PACF, por sus siglas en inglés). Primero, dadas las condiciones de estabilidad




Figura 3.15: Inverso de las Raíces de los polinomios característicos de un $ARMA(1,1)$




Figura 3.16: Residuales de un $ARMA(1,1)$ de la serie $DLPaxNal_t$

y de convergencia, si suponemos que los procesos AR, MA, ARMA o ARIMA tienen toda la información de los rezagos de la serie en conjunto y toda la información de los promedios móviles del término de error, resulta importante construir una métrica para distinguir el efecto de $X_{t-\tau}$ o el efecto de $U_{t-\tau}$ (para cualquier τ) sobre X_t de forma individual.

La idea es construir una métrica de la correlación que existe entre las diferentes variables aleatorias, si para tal efecto se ha controlado el efecto del resto de la información. Así, podemos definir la ecuación que puede responder a este planteamiento como:

$$X_t = \phi_{k1}X_{t-1} + \phi_{k2}X_{t-2} + \dots + \phi_{kk}X_{t-k} + U_t \quad (3.99)$$

Donde ϕ_{ki} es el coeficiente de la variable dada con el rezago i si el proceso tiene un orden k . Así, los coeficientes ϕ_{kk} son los coeficientes de la autocorrelación parcial (considerando un proceso AR(k)). Observemos que la autocorrelación parcial mide la correlación entre X_t y X_{t-k} que se mantiene cuando el efecto de las variables $X_{t-1}, X_{t-2}, \dots$ y $X_{t-(k-1)}$ en X_t y X_{t-k} ha sido eliminado.

Dada la expresión considerada en la ecuación (3.99), podemos resolver el problema de establecer el valor de cada ϕ_{ki} mediante la solución del sistema que se representa en lo siguiente:

$$\begin{bmatrix} \rho(1) \\ \rho(2) \\ \vdots \\ \rho(k) \end{bmatrix} = \begin{bmatrix} 1 & \rho(1) & \dots & \rho(k-1) \\ \rho(1) & 1 & \dots & \rho(k-2) \\ \rho(2) & \rho(1) & \dots & \rho(k-3) \\ \vdots & \vdots & \dots & \vdots \\ \rho(k-1) & \rho(k-2) & \dots & 1 \end{bmatrix} \begin{bmatrix} \phi_{k1} \\ \phi_{k2} \\ \phi_{k3} \\ \vdots \\ \phi_{kk} \end{bmatrix} \quad (3.100)$$

Del cual se puede derivar una solución, resolviendo por cualquier método que consideremos y que permita calcular la solución de sistemas de ecuaciones.

Posterior al planteamiento analítico, plantearemos un enfoque para interpretar las funciones de autocorrelación y autocorrelación parcial. Este enfoque pretende aportar al principio de parsimonia, en el cual podemos identificar el número de parámetros que posiblemente puede describir mejor a la serie en un modelo ARMA(p, q).

En el siguiente cuadro mostramos un resumen de las características que debemos observar para determinar el número de parámetros de cada uno de los componentes AR y MA. Lo anterior por observación de las funciones de autocorrelación y autocorrelación parcial. Este enfoque no es el más formal, más adelante implementaremos uno más formal y que puede ser más claro de cómo determinar el número de parámetros.

Cuadro 3.9: Relación entre la Función de Autocorrelación y la Función de Autocorrelación Parcial de una serie X_t .

Modelo	Función de Autocorrelación	Función de Autocorrelación Parcial
$MA(q)$	Se corta después del rezago q	Decae gradualmente
$AR(p)$	Decae gradualmente	Se corta después del rezago p

Ejemplo. Continuando con el ejemplo en la Figura 3.17 mostramos tanto la Función de Autocorrelación como la Función de Autocorrelación Parcial. En esta identificamos que ambas gráficas muestran que el modelo que explica a la variable $DLPaxNal_t$ tiene tanto componentes AR como MA. Sin embargo, dado lo errático del comportamiento de ambas funciones, resulta complicado determinar cuál sería un buen número de parámetros p y q a considerar en el $ARMA(p, q)$. Por esta razón, a continuación, plantearemos algunas pruebas más formales para determinar dichos parámetros.

```
par(mfrow=c(2,1))

acf(na.omit(DLPax_Nal), lag.max = 48,
    xlab = "Rezagos k en meses",
    main = "Función de Autocorrelación de Diff LN Pax Nal")

pacf(na.omit(DLPax_Nal), lag.max = 48,
     xlab = "Rezagos k en meses",
     main = "Función de Autocorrelación Parcial de Diff LN Pax
     ↵ Nal")
```

```
par(mfrow=c(1,1))
```

3.8 Selección de las constantes p , q , d en un $AR(p)$, un $MA(q)$, un $ARMA(p, q)$ o un $ARIMA(p, d, q)$

Respecto de cómo estimar un proceso $ARMA(p, q)$ –en general utilizaremos este modelo para discutir, pero lo planteado en esta sección es igualmente aplicable en cualquier otro caso como aquellos modelos que incluyen variables exógenas– existen diversas formas de estimar los parámetros a_i y b_i : i) por máxima verosimilitud y ii) por mínimos cuadrados ordinarios. El primer caso requiere que conozcamos la distribución del proceso aleatorio U_t . El segundo, por el contrario, no




Figura 3.17: Función de Autocorrelación y la Función de Autocorrelación Parcial de una serie $DLPaxNal_t$

requiere el mismo supuesto. No obstante, en estas notas utilizaremos el método de máxima verosimilitud.

Otra duda que debe quedar hasta el momento es ¿cómo determinar el orden p y q del proceso $ARMA(p, q)$? La manera más convencional y formal que existe para tal efecto es utilizar los criterios de información. Así, el orden se elige de acuerdo con aquel criterio de información que resulta ser el mínimo. En el caso de d se selecciona revisando la gráfica que parezca más estacionaria—más adelante mostraremos un proceso más formal para su selección.

Los criterios de información más comunes son los siguientes:

1. FPE (Final Prediction Error):

$$FPE = \frac{T+m}{T-m} \frac{1}{T} \sum_{t=1}^T (\hat{U}_t^{(p)})^2 \quad (3.101)$$

2. Akaike:

$$AIC = \ln \left[\frac{1}{T} \sum_{t=1}^T (\hat{U}_t^{(p)})^2 \right] + m \frac{2}{T} \quad (3.102)$$

3. Schwarz:

$$SC = \ln \left[\frac{1}{T} \sum_{t=1}^T (\hat{U}_t^{(p)})^2 \right] + m \frac{\ln(T)}{T} \quad (3.103)$$

4. Hannan - Quinn:

$$HQ = \ln \left[\frac{1}{T} \sum_{t=1}^T (\hat{U}_t^{(p)})^2 \right] + m \frac{2\ln(\ln(T))}{T} \quad (3.104)$$

Donde $\hat{U}_t^{(p)}$ son los residuales estimados mediante un proceso $ARIMA$ y m es el número de parámetros estimados: $m = p + q + 0 + 1$ (ya que asumimos que $d = 0$). Una propiedad que no se debe perder de vista es que los criterios de información cumplen la siguiente relación:

$$\text{orden}(SC) \leq \text{orden}(HQ) \leq \text{orden}(AIC) \quad (3.105)$$

Por esta razón, en estas notas solo utilizaremos el criterio de Akaike para determinar el orden óptimo del proceso $ARMA$, ya que ello garantiza el orden más grande posible.

Ejemplo. Ahora veamos un ejemplo de estimación del número de rezagos óptimo de un $ARMA(p, q)$. Retomemos la serie en diferencias logarítmicas de los pasajeros en vuelos nacionales de salidas, pero ahora incluiremos las variables exógenas de dummies estacionales: enero, febrero, julio y diciembre.

Como mencionamos, las gráficas de las funciones de autocorrelación permiten observar el valor de la correlación existente entre la variable en el momento t con cada uno de los rezagos. Incluso la Función de Autocorrelación Parcial puede ayudar a determinar el número máximo de rezagos que se debe incluir en el proceso $AR(p)$. No obstante, una métrica más formal es el uso de los criterios de información. En nuestro caso, dado lo discutido, sólo utilizaremos el criterio de Akaike.

Al respecto, en el siguiente cuadro reportamos el criterio de Akaike que resulta de aplicar dicho criterio a los residuales resultantes de cada combinación de procesos $ARMA(p, q)$. La forma de escoger será aquel modelo que reporta el criterio de Akaike menor. En la cuarta columna de la tabla se señala el valor del criterio de información que resulta ser el mínimo de todos los posibles.

```
xreg_base <- cbind(D_Ene_Nal, D_Feb_Nal, D_Jul_Nal, D_Dic_Nal)
ciarma_rows <- vector("list", 36)
k <- 0L
for (p_ord in 1:6) {
  for (q_ord in 1:6) {
    k <- k + 1L
    fit_aic <- tryCatch(
      AIC(arima(DLPax_Nal, order = c(p_ord, 0L, q_ord),
        xreg = xreg_base, method = "ML")),
      error = function(e) NA_real_
    )
    ciarma_rows[[k]] <- data.frame(Modelo = k, AR = p_ord, MA =
      q_ord,
      AIC = round(fit_aic, 4))
  }
}
df_ciarma <- do.call(rbind, ciarma_rows)
opt_idx <- which.min(df_ciarma$AIC)
opt_p <- df_ciarma$AR[opt_idx]
opt_q <- df_ciarma$MA[opt_idx]
df_ciarma$Optimo <- ifelse(seq_len(nrow(df_ciarma)) == opt_idx,
  "*", "")
knitr::kable(df_ciarma,
  col.names = c("Modelo", "$AR(p)$", "$MA(q)$",
    "Akaike (AIC)", "Óptimo"),
  caption = "Criterio de Akaike para diferentes
    modelos $ARMA(p, q)$ de la serie $DLPaxNal_t$",
  align = c("c", "c", "c", "r", "c"), booktabs = TRUE,
  escape = FALSE)
```

El cuadro anterior reporta un resumen de los resultados para 36 diferentes modelos, todos incluyen variables exógenas. Como resultado del análisis concluimos

Cuadro 3.10: Criterio de Akaike para diferentes modelos $ARMA(p, q)$ de la serie $DLPaxNal_t$.

Modelo	$AR(p)$	$MA(q)$	Akaike (AIC)	Óptimo
1	1	1	-270.6410	
2	1	2	-300.8206	
3	1	3	-299.6956	
4	1	4	-298.0968	
5	1	5	-296.1442	
6	1	6	-311.1143	
7	2	1	-295.0399	
8	2	2	-301.2320	
9	2	3	-301.7227	
10	2	4	-300.4049	
11	2	5	-304.3696	
12	2	6	-309.1805	
13	3	1	-298.8680	
14	3	2	-301.7856	
15	3	3	-302.5249	
16	3	4	-365.4824	*
17	3	5	-363.7448	
18	3	6	-362.4339	
19	4	1	-272.0666	
20	4	2	-300.2736	
21	4	3	-326.0696	
22	4	4	-327.0874	
23	4	5	-328.0579	
24	4	6	-360.4310	
25	5	1	-296.0881	
26	5	2	-299.8217	
27	5	3	-363.6389	
28	5	4	-329.3828	
29	5	5	-327.3978	
30	5	6	-358.0163	
31	6	1	-310.6870	
32	6	2	-308.9701	
33	6	3	-363.9576	
34	6	4	-359.2916	
35	6	5	-359.5258	
36	6	6	-359.2032	

que el modelo más adecuado es el 16, el cual considera un $ARMA(3, 4)$, con variables dummies para controlar la estacionalidad de los meses de enero, febrero, julio y diciembre. Más adelante mostramos los resultados del modelo.

No obstante, una inspección de los residuales del modelo nos permite sospechar que requiere de incluir un par de dummies más. Ambas, asociadas con la caída del transporte aéreo en 2009, principalmente asociadas con la crisis mundial de ese año. La Figura 3.18 muestra los residuales mencionados.

```
mod1 <- arima(DLPax_Nal, order = c(opt_p, 0, opt_q),
              xreg = xreg_base, method = "ML")

plot(residuals(mod1), col = "darkred",
     ylab = "Residuales", xlab = "Tiempo",
     main = paste0("Residuales del ARMA(", opt_p, ",", opt_q,
                  ") de Diff LN Pax Nal"))
```




Figura 3.18: Residuales del $ARMA(3, 4)$ de una serie $DLPaxNal_t$

Una vez incluidas dos dummies más para mayo y junio de 2009, reestimamos el modelo con el orden óptimo antes seleccionado. El siguiente cuadro muestra los resultados de ambas especificaciones. No lo mostramos en esta sección, pero ambos modelos reportados tienen raíces de sus respectivos polinomios característicos menores a 1 en valor absoluto. En la Figura 3.19 mostramos los residuales ahora ajustados por las dummies de mayo y junio de 2009.

```

t_idx_nal <- time(DLPax_Nal)
D_May2009 <- as.numeric(abs(t_idx_nal - (2009 + 4/12)) < 0.01)
D_Jun2009 <- as.numeric(abs(t_idx_nal - (2009 + 5/12)) < 0.01)

mod2 <- arima(DLPax_Nal, order = c(opt_p, 0, opt_q),
              xreg = cbind(xreg_base, D_May2009, D_Jun2009),
              method = "ML")

lbl_map <- c(setNames(paste0("$DLPaxNal_{t-", 1:6, "}"),
  ↪ paste0("ar", 1:6)),
             setNames(paste0("$\\hat{U}_{t-", 1:6, "}"),
  ↪ paste0("ma", 1:6)),
             D_Ene_Nal="$DEne_{t}$", D_Feb_Nal="$DFeb_{t}$",
             D_Jul_Nal="$DJul_{t}$", D_Dic_Nal="$DDic_{t}$",
             intercept="Constante",
             D_May2009="$DMay2009_{t}$",
  ↪ D_Jun2009="$DJun2009_{t}$")

make_col <- function(mod) {
  cf <- mod$coef; se <- sqrt(diag(mod$var.coef))
  data.frame(nm = names(cf), cf = round(cf, 4), se = round(se,
  ↪ 4))
}

d1 <- make_col(mod1); d2 <- make_col(mod2)
d_all <- merge(d1, d2, by = "nm", all = TRUE)
d_all$lbl <- lbl_map[d_all$nm]
d_out <- d_all[, c("lbl", "cf.x", "se.x", "cf.y", "se.y")]
d_out <- rbind(d_out,
              data.frame(lbl = c("$\\hat{\\sigma}^2$", "AIC"),
                cf.x = c(round(mod1$sigma2, 6),
  ↪ round(AIC(mod1), 2)),
                se.x = NA_real_, cf.y =
  ↪ c(round(mod2$sigma2, 6),
  ↪ round(AIC(mod2), 2)),
                se.y = NA_real_))
d_out$se.x <- ifelse(is.na(d_out$se.x), "",
  ↪ as.character(d_out$se.x))
d_out$se.y <- ifelse(is.na(d_out$se.y), "",
  ↪ as.character(d_out$se.y))
d_out$cf.x <- ifelse(is.na(d_out$cf.x), "",
  ↪ as.character(d_out$cf.x))
d_out$cf.y <- ifelse(is.na(d_out$cf.y), "",
  ↪ as.character(d_out$cf.y))
knitr::kable(d_out,
              col.names = c("Variable", "Coef. M1", "SE M1",
  ↪ "Coef. M2", "SE M2"),

```

Cuadro 3.11: Modelo $ARMA(p, q)$ de la serie $DLPaxNal_t$.

Variable	Coef. M1	SE M1	Coef. M2	SE M2
$\$DLPaxNal_{t-1}\$$	-1.0196	0.0412	-1.035	0.0414
$\$DLPaxNal_{t-2}\$$	0.2333	0.0715	0.2056	0.0717
$\$DLPaxNal_{t-3}\$$	0.712	0.0413	0.6962	0.0414
$\$DDic_t\$$	0.0602	0.0378	0.0332	0.037
$\$DEne_t\$$	-0.1178	0.0356	-0.1175	0.0353
$\$DFeb_t\$$	-0.0153	0.038	-0.0357	0.0371
$\$DJul_t\$$	0.275	0.0463	0.2583	0.0464
$\$DJun2009_t\$$			0.2022	0.0882
$\$DMay2009_t\$$			-0.3776	0.0882
Constante	-0.0127	0.0088	-0.0066	0.0088
$\$\hat{U}_{t-1}\$$	1.274	0.0087	1.3377	
$\$\hat{U}_{t-2}\$$	-0.3286	0.0248	-0.2815	0.0099
$\$\hat{U}_{t-3}\$$	-1.3947	0.0181	-1.4405	0.0267
$\$\hat{U}_{t-4}\$$	-0.5464		-0.6126	
$\$\hat{\sigma}^2\$$	0.015607		0.014659	
AIC	-365.48		-381.35	

```
caption = "Modelo $ARMA(p, q)$ de la serie
↪ $DLPaxNal_t$. ",
align = c("l", "r", "r", "r", "r"), booktabs = TRUE)
```

```
plot(residuals(mod2), col = "darkblue",
     ylab = "Residuales", xlab = "Tiempo",
     main = paste0("Residuales del ARMA(", opt_p, ",", opt_q,
                  ") con dummies de mayo y junio de 2009"))
```

3.9 Pronósticos

Para pronosticar el valor de la serie es necesario determinar cuál es el valor esperado de la serie en un momento $t + \tau$ condicional en que ésta se comporta como un $AR(p)$, un $MA(q)$ o un $ARMA(p, q)$ y a que los valores antes de t están dados. Por lo que el pronóstico de la serie estará dado por una expresión:

$$\mathbb{E}_t[X_{t+\tau}] = \delta + a_1 \mathbb{E}_t[X_{t+\tau-1}] + a_2 \mathbb{E}_t[X_{t+\tau-2}] + \dots + a_p \mathbb{E}_t[X_{t+\tau-p}] \quad (3.106)$$




Figura 3.19: Residuales del ARMA(3, 4) con dummies de 2009 de una serie $DLPaxNal_t$

Lo anterior para todo $\tau = 0, 1, 2, \dots$ y considerando que los componentes $MA(q)$ en la ecuación (3.106) son cero dado que para todo valor $t + \tau$ es cierto que $\mathbb{E}_t[U_{t+\tau}] = 0$.

Continuando con el ejemplo, en la Figura 3.20 mostramos el resultado del pronóstico de la serie a 24 meses. Para este ejercicio estimamos un $ARMA(6, 6)$ sobre la serie en diferencias logarítmicas que, además de las dummies estacionales, incorpora variables dummy para los meses atípicos de la pandemia de COVID-19 (marzo, abril, junio y julio de 2020, y marzo de 2021); el pronóstico de la tasa de crecimiento se acumula después sobre el último nivel observado de la serie.

```
library(ggplot2)
library(dplyr)
library(readxl)
library(stats)

Datos <- read_excel("BD/Base_Transporte_ARIMA.xlsx",
                    sheet = "Datos", col_names = TRUE)

Pax_Nal <- ts(Datos$Pax_Nal,
              start = c(2000, 1),
              freq = 12)

LPax_Nal <- ts(log(Datos$Pax_Nal),
               start = c(2000, 1),
               freq = 12)

DLPax_Nal <- ts(log(Datos$Pax_Nal) - lag(log(Datos$Pax_Nal), 1),
                start = c(2000, 1),
                freq = 12)

D_Mar2020 <- ts(Datos$D_Mar2020,
                 start = c(2000, 1),
                 freq = 12)

D_Abr2020 <- ts(Datos$D_Abr2020,
                 start = c(2000, 1),
                 freq = 12)

D_Jun2020 <- ts(Datos$D_Jun2020,
                 start = c(2000, 1),
                 freq = 12)

D_Jul2020 <- ts(Datos$D_Jul2020,
                 start = c(2000, 1),
```



```

        freq = 12)

D_Mar2021 <- ts(Datos$D_Mar2021,
               start = c(2000, 1),
               freq = 12)

D_Ene <- ts(Datos$D_Ene,
            start = c(2000, 1),
            freq = 12)

D_Feb <- ts(Datos$D_Feb,
            start = c(2000, 1),
            freq = 12)

D_Jul <- ts(Datos$D_Jul,
            start = c(2000, 1),
            freq = 12)

D_Dic <- ts(Datos$D_Dic,
            start = c(2000, 1),
            freq = 12)

ARMA_Ex_DLPax_Nal_2 <- arima(DLPax_Nal, order = c(6, 0, 6),
                             xreg = cbind(D_Ene, D_Feb, D_Jul,
                                           D_Dic, D_Mar2020,
                                           D_Abr2020, D_Jun2020,
                                           D_Jul2020, D_Mar2021),
                             method = "ML")

Predict_Datos <-
  ↪ read_excel("BD/Predict_Base_Transporte_ARIMA.xlsx",
               sheet = "Datos", col_names = TRUE)

D_Mar2020_f <- ts(Predict_Datos$D_Mar2020,
                  start = c(2025, 7),
                  freq = 12)

D_Abr2020_f <- ts(Predict_Datos$D_Abr2020,
                  start = c(2025, 7),
                  freq = 12)

D_Jun2020_f <- ts(Predict_Datos$D_Jun2020,
                  start = c(2025, 7),
                  freq = 12)

```

```
D_Jul2020_f <- ts(Predict_Datos$D_Jul2020,
                 start = c(2025, 7),
                 freq = 12)

D_Mar2021_f <- ts(Predict_Datos$D_Mar2021,
                 start = c(2025, 7),
                 freq = 12)

D_Ene_f <- ts(Predict_Datos$D_Ene,
              start = c(2025, 7),
              freq = 12)

D_Feb_f <- ts(Predict_Datos$D_Feb,
              start = c(2025, 7),
              freq = 12)

D_Jul_f <- ts(Predict_Datos$D_Jul,
              start = c(2025, 7),
              freq = 12)

D_Dic_f <- ts(Predict_Datos$D_Dic,
              start = c(2025, 7),
              freq = 12)

DLPax_Nal_f <- predict(ARMA_Ex_DLPax_Nal_2, n.ahead = 24,
                     newxreg = cbind(D_Ene_f, D_Feb_f, D_Jul_f,
                                       D_Dic_f, D_Mar2020_f,
                                       D_Abr2020_f, D_Jun2020_f,
                                       D_Jul2020_f, D_Mar2021_f))

Pronostico_Arima <- read_excel("BD/Pronostico_Arima.xlsx",
                              sheet = "Datos", col_names = TRUE)

Pronostico_Arima$Pax_Nal_f <- Pronostico_Arima$Pax_Nal

for(i in 1:24){
  Pronostico_Arima$Pax_Nal_f[306 + i] <-
    Pronostico_Arima$Pax_Nal_f[306 + i - 1]*(1 +
    ↪ DLPax_Nal_f$pred[i])
}

options(scipen = 999) # NO notacion cientifica

ggplot(data = Pronostico_Arima, aes(x = Periodo)) +
  geom_line(aes(y = Pax_Nal_f, color = "Pax_Nal_f")) +
```

```

geom_line(aes(y = Pax_Nal, color = "Pax_Nal")) +
scale_color_brewer(type = "qual", palette = 2) +
#theme_bw() +
theme(legend.position = "bottom") +
theme(legend.title = element_blank()) +
guides(col = guide_legend(nrow = 1, byrow = TRUE)) +
xlab("Tiempo") +
ylab("Pasajeros") +
theme(plot.title = element_text(size = 11, face = "bold",
                                hjust = 0)) +
theme(plot.subtitle = element_text(size = 10, hjust = 0)) +
theme(plot.caption = element_text(size = 10, hjust = 0)) +
theme(plot.margin = unit(c(1,1,1,1), "cm")) +
labs(
  title = "Pasajeros en vuelos nacionales (Salidas)",
  subtitle = "(Ene-2000 a Jun-2025 y pronóstico a 24 meses)",
  caption = "Fuente: Elaboración propia"
)

```




Figura 3.20: Pronóstico de la serie $PaxNal_t$ a partir de un $ARMA(6,6)$ en diferencias logarítmicas

3.10 Desestacionalización y filtrado de Series

3.10.1 Motivación

Existen múltiples enfoques para la desestacionalización de series. Algunos modelos, por ejemplo, pueden estar basados en modelos ARIMA como un conjunto de dummies. No obstante, el caso particular que discutiremos en estas notas estará basado en un modelo ARIMA de la serie. Este enfoque está basado en el modelo X11 de la oficina del censo de Estados Unidos (Census Bureau) el cual es conocido como el modelo X13-ARIMA-SEATS.⁶ El modelo X13-ARIMA-SEATS es, como su nombre lo indica, la combinación de un modelo ARIMA con componentes estacionales (por la traducción literal de la palabra: seasonal).

Un modelo ARIMA estacional emplea la serie en diferencias y como regresores los valores rezagados de las diferencias de la serie tantas veces como procesos estacionales s existan en ésta, con el objeto de remover los efectos aditivos de la estacionalidad. Sólo para entender qué significa este mecanismo, recordemos que cuando se utiliza la primera diferencia de la serie respecto del periodo inmediato anterior se remueve la tendencia. Por su parte, cuando se incluye la diferencia respecto del mes s se está en el caso en que se modela la serie como una media móvil en términos del rezago s .

El modelo ARIMA estacional incluye como componentes autorregresivos y de medias móviles a los valores rezagados de la serie en el periodo s en diferencias. El ARIMA(p, d, q)(P, D, Q) estacional puede ser expresado de la siguiente manera utilizando el operador rezago L :

$$\Theta_P(L^s)\theta_p(L)(1-L^s)^D(1-L)^dX_t = \Psi_Q(L^s)\psi_q(L)U_t \quad (3.107)$$

Donde $\Theta_P(\cdot)$, $\theta_p(\cdot)$, $\Psi_Q(\cdot)$ y $\psi_q(\cdot)$ son polinomios de L de orden P , p , Q y q respectivamente. En general, la representación es de una serie no estacionaria; no obstante, si $D = d = 0$ y todas las raíces de los polinomios del lado izquierdo de la ecuación (3.107) son mayores que 1 en valor absoluto, el proceso modelado será estacionario.

Si bien es cierto que existen otras formas de modelar la desestacionalización, como la modelación en diferencias con dummies para identificar ciertos patrones regulares, en los algoritmos disponibles como el X11 o X13-ARIMA-SEATS se emplea la formulación de la ecuación (3.107). A continuación, implementaremos la desestacionalización de una serie.

Como ejemplo utilizaremos la serie del Índice Nacional de Precios al Consumidor (INPC).⁷ Podemos ver que la serie original del INPC y su ajuste estacional bajo

⁶La información y material respecto del modelo está disponible en la dirección <https://www.census.gov/srd/www/x13as/>.

⁷Las definiciones de las variables empleadas son: INPC: Índice Nacional de Precios al Consumidor (2QJul2018 = 100); TC: Tipo de Cambio FIX; CETE28: Tasa de rendimiento promedio mensual de los Cetes 28, en por ciento anual; IGAE: Indicador Global de la Actividad Económica (2013 = 100); IPI: Industrial Production Index (2012 = 100).

una metodología X13-ARIMA-SEATS son como se muestra en la Figura 3.21.

```
library(ggplot2)
library(dplyr)
library(readxl)
library(stats)
library(seasonal)
```

```
##
## Attaching package: 'seasonal'

## The following object is masked from 'package:tibble':
##
##      view
```

```
library(seasonalview)
```

```
##
## Attaching package: 'seasonalview'

## The following object is masked from 'package:seasonal':
##
##      view

## The following object is masked from 'package:tibble':
##
##      view
```

```
library(shiny)

Datos <- read_excel("BD/Base_VAR.xlsx", sheet = "Datos",
  ↪ col_names = TRUE)

INPC <- ts(Datos$INPC,
  start = c(2000, 1),
  freq = 12)

Seas_INPC <- seas(INPC)

INPC_Ad <- final(Seas_INPC)

#names(Seas_INPC)
```

```
#summary(Seas_INPC)
```

```
plot(Seas_INPC)
```




Figura 3.21: Índice Nacional de Precios al Consumidor ($INPC_t$) y su serie desestacionalizada utilizando un proceso X13-ARIMA-SEATS

```
# Forma Facil:
```

```
#view(Seas_INPC)
```

```
TC <- ts(Datos$TC,
        start = c(2000, 1),
        freq = 12)
```

```
Seas_TC <- seas(TC)
```

```
TC_Ad <- final(Seas_TC)
```

```
CETE28 <- ts(Datos$CETE28,
             start = c(2000, 1),
             freq = 12)
```

```

Seas_CETE28 <- seas(CETE28)

CETE28_Ad <- final(Seas_CETE28)

IGAE <- ts(Datos$IGAE,
           start = c(2000, 1),
           freq = 12)

Seas_IGAE <- seas(IGAE)

IGAE_Ad <- final(Seas_IGAE)

IPI <- ts(Datos$IPI,
          start = c(2000, 1),
          freq = 12)

Seas_IPI <- seas(IPI)

IPI_Ad <- final(Seas_IPI)

Datos_Ad <- data.frame(cbind(INPC_Ad, TC_Ad, CETE28_Ad, IGAE_Ad,
                             ↵ IPI_Ad))

Datos_Ad <- cbind(Datos, Datos_Ad)

save(Datos_Ad, file = "BD/Datos_Ad0.RData")

```

El mismo procesamiento puede ser seguido para todas las series que busquemos analizar. En particular, en adelante, además del INPC que incluimos en la lista, utilizaremos las siguientes series, así como su versión desestacionalizada:

- Índice Nacional de Precios al Consumidor (base 2QJul2018 = 100), $INPC_t$.
- Tipo de Cambio FIX, TC_t
- Tasa de rendimiento promedio mensual de los Cetes 28, en por ciento anual, $CETE28_t$
- Indicador global de la actividad económica (base 2013 = 100), $IGAE_t$
- Industrial Production Index o Índice de Producción Industrial de los Estados Unidos (base 2012 = 100), IPI_t

3.10.2 Filtro Hodrick-Prescott

Como último tema de los procesos univariados y que no necesariamente aplican a series estacionarias, a continuación desarrollaremos el procedimiento cono-

cido como filtro de Hodrick y Prescott (1997). El trabajo de estos autores era determinar una técnica de regresión que permitiera utilizar series agregadas o macroeconómicas para separarlas en dos componentes: uno de ciclo de negocios y otro de tendencia. En su trabajo original, Hodrick y Prescott (1997) utilizaron datos trimestrales de algunas series como el Producto Nacional Bruto (GNP, por sus siglas en inglés), los agregados monetarios M1, empleo, etc., de los Estados Unidos que fueron observados posteriormente a la Segunda Guerra Mundial.

El marco conceptual de Hodrick y Prescott (1997) parte de suponer una serie X_t que se puede descomponer en la suma de componente de crecimiento tendencial, g_t , y su componente de ciclo de negocios, c_t , de esta forma para $t = 1, 2, \dots, T$ tenemos que:

$$X_t = g_t + c_t \quad (3.108)$$

En la ecuación (3.108) se asume que la suavidad de la ruta seguida por g_t se controla penalizando la suma de los cuadrados de su segunda diferencia. En esa misma ecuación asumiremos que c_t son las desviaciones de g_t , las cuales en el largo plazo tienen una media igual a cero (0). Por esta razón, se suele decir que el filtro de Hodrick y Prescott representa una descomposición de la serie en su componente de crecimiento natural y de sus desviaciones transitorias que en promedio son cero, en el largo plazo.

Estas consideraciones que hemos mencionado señalan que el procedimiento de Hodrick y Prescott (1997) implica resolver el siguiente problema de minimización para determinar cada uno de los componentes en que X_t se puede descomponer:

$$\min_{\{g_t\}_{t=1}^T} \left[\sum_{t=1}^T c_t^2 + \lambda \sum_{t=1}^T [\Delta g_t - \Delta g_{t-1}]^2 \right] \quad (3.109)$$

Donde $\Delta g_t = g_t - g_{t-1}$ y $\Delta g_{t-1} = g_{t-1} - g_{t-2}$; $c_t = X_t - g_t$, y el parámetro λ es un número positivo que penaliza la variabilidad en el crecimiento de las series. De acuerdo con el trabajo de Hodrick y Prescott (1997) la constante λ debe tomar valores específicos de acuerdo con la periodicidad de las series. Así, λ será:

- 100 si la serie es de datos anuales
- 1,600 si la serie es de datos trimestrales
- 14,400 si la serie es de datos mensuales

En resumen, podemos decir que el filtro de Hodrick y Prescott (1997) es un algoritmo que minimiza las distancias o variaciones de la trayectoria de largo plazo. De esta forma, determina una trayectoria estable de largo plazo, por lo que las desviaciones respecto de esta trayectoria serán componentes de ciclos de negocio o cambios transitorios (tanto positivos como negativos).

A continuación, ilustraremos el filtro de Hodrick y Prescott (1997) para dos series desestacionalizadas: $INPC_t$ y TC_t . Las Figura 3.22 y Figura 3.23 muestran los resultados de la implementación del filtro.


```

library(ggplot2)
library(dplyr)
library(readxl)
library(stats)
library(mFilter)
library(plm)

##
## Attaching package: 'plm'

## The following objects are masked from 'package:dplyr':
##
##      between, lag, lead

load("BD/Datos_Ad0.RData")

INPC <- ts(Datos_Ad$INPC_Ad, start = c(2000, 1), freq = 12)

TC <- ts(Datos_Ad$TC_Ad, start = c(2000, 1), freq = 12)

INPC_hpf <- hpfilter(INPC, freq = 14400)

plot(INPC_hpf)

TC_hpf <- hpfilter(TC, freq = 14400)

plot(TC_hpf)

```

3.10.2.1 Filtro Hodrick-Prescott planteado por St-Amant y van Norden

Existe una técnica adicional que soluciona un problema de distribuciones de colas pesadas: la planteada por St-Amant y van Norden (1997). Analicemos ese caso. El método tradicional de HP consiste en elegir la serie $\{\tau_t\}_{t=-1}^T$ que minimiza:

$$\sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=1}^T [(\tau_t - \tau_{t-1}) - (\tau_{t-1} - \tau_{t-2})]^2 \quad (3.110)$$

Donde λ es un parámetro fijo (determinado ex-ante) y τ_t es un componente de tendencia de y_t .




Figura 3.22: Descomposición del Índice Nacional de Precios al Consumidor ($INPC_t$) en su tendencia o trayectoria de largo plazo y su ciclo de corto plazo utilizando un filtro Hodrick y Prescott [-@hodrickprescott1997]




Figura 3.23: Descomposición del Tipo de Cambio FIX (TC_t) en su tendencia o trayectoria de largo plazo y su ciclo de corto plazo utilizando un filtro Hodrick y Prescott [-@hodrickprescott1997]

Sin pérdida de generalidad, asumiremos que τ_{-1} y τ_0 son cero (0). De esta manera, la forma matricial del filtro HP es:

$$(Y - G)'(Y - G) + \lambda G' K' K G \quad (3.111)$$

La derivada de los anteriores:

$$-2Y + 2G + \lambda 2K' K G = 0 \quad (3.112)$$

Despejando:

$$G_{hp} = [I_T + \lambda K' K]^{-1} Y \quad (3.113)$$

Donde G es el vector de tendencia, Y es el vector de la serie de datos, λ es la constante tradicional, y K es de dimensión $T \times T$ y está dada por la expresión:

$$K = \begin{pmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ -2 & 1 & 0 & 0 & \dots & 0 \\ 1 & -2 & 1 & 0 & \dots & 0 \\ 0 & 1 & -2 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 1 \end{pmatrix} \quad (3.114)$$

Así:

$$K' = \begin{pmatrix} 1 & -2 & 1 & 0 & \dots & 0 \\ 0 & 1 & -2 & 1 & \dots & 0 \\ 0 & 0 & 1 & -2 & \dots & 0 \\ 0 & 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 1 \end{pmatrix} \quad (3.115)$$

El método modificado de HP consiste en elegir la serie $\{\tau_t\}_{t=1}^T$ que minimiza:

$$\sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=2}^{T-1} [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2 + \lambda_{ss} \sum_{t=T-j}^T [\Delta \tau_t - u_{ss}] \quad (3.116)$$

Donde λ es un parámetro fijo (determinado ex-ante), τ_t es un componente de tendencia de y_t , y los nuevos parámetros son u_{ss} y λ_{ss} , ajustados por el procedimiento de Marcet y Ravn (2004).

Este procedimiento parte del filtro HP y reconoce que esa versión tiene el problema de pérdida de información al final y al principio de la muestra. La razón es que es un procedimiento univariado que requiere de mucha información futura y pasada para mejorar el ajuste.

El componente adicional al filtro HP es un componente de castigo por desviaciones de la tasa de crecimiento de largo plazo, u_{ss} .

El proceso de selección de λ_{ss} es el propuesto por Marcet y Ravn (2004), el cual consiste en utilizar un λ convencional y el filtro HP convencional para estimar la siguiente función:

$$F(\lambda) = \frac{\sum_{t=2}^{T-1} ((\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1}))^2}{\sum_{t=1}^T (y_t - \tau_t)^2} \quad (3.117)$$

Entonces el valor de λ_{ss} será aquel que:

$$F(\lambda_{ss}) = \frac{\sum_{t=2}^{T-1} ((\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1}))^2}{\sum_{t=1}^T (y_t - \tau_t)^2} = F(\lambda) \quad (3.118)$$

Nota: Antón Sarabia (2010) estimó $\lambda_{ss} = 1096$ para datos trimestrales del PIB de México.

La forma matricial del filtro HP-SAVN es:

$$(Y - G)'(Y - G) + \lambda G'K'KG + \lambda_{ss}(L^jG + \bar{u}_{ss}M^j) \quad (3.119)$$

Donde $L^j = (0, 0, \dots, 0, -1, 0, \dots, 0, 1)$, en el cual el valor -1 es en la posición $T-j-1$ -ésima, y M^j es un vector que toma valores de cero hasta antes de $T-j$ y de 1 después.

La derivada de los anteriores:

$$-2Y + 2G + \lambda 2K'KG + \lambda_{ss}L'^j = 0 \quad (3.120)$$

Despejando:

$$G_{SAVN} = \frac{1}{2}[I_T + \lambda K'K]^{-1}(2Y - \lambda_{ss}L'^j) \quad (3.121)$$

$$G_{SAVN} = [I_T + \lambda K'K]^{-1}Y - \frac{1}{2}[I_T + \lambda K'K]^{-1}\lambda_{ss}L'^j \quad (3.122)$$

Donde G es el vector de tendencia, Y es el vector de la serie de datos, λ es la constante tradicional, y K es de dimensión $T \times T$ y está dada por la expresión:

$$K' = \begin{pmatrix} 1 & -2 & 1 & 0 & \dots & 0 \\ 0 & 1 & -2 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 1 \end{pmatrix} \quad (3.123)$$

Dicho lo anterior, podemos modificar $F(\lambda)$ para el filtro HP convencional como en forma matricial:

$$F(\lambda) = \frac{G'K'KG}{(Y - G)'(Y - G)} \quad (3.124)$$

3.11 Resumen del capítulo

En este capítulo estudiamos los fundamentos de los procesos estocásticos estacionarios y los principales modelos univariados de series de tiempo.

Estacionariedad y ergodicidad. Un proceso es débilmente estacionario si su media, varianza y estructura de covarianzas no dependen del tiempo. La ergodicidad garantiza que los promedios temporales convergen a los promedios del conjunto. El proceso de ruido blanco, $U_t \sim (0, \sigma^2)$, es el bloque elemental a partir del cual se construyen todos los modelos de este capítulo.

Herramientas de diagnóstico. La función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF) son el puente entre la teoría y la práctica: permiten identificar el orden de los componentes AR y MA, respectivamente. Las pruebas Box-Pierce (Q^*), Ljung-Box (Q) y Breusch-Godfrey (LM) contrastan formalmente si los residuales de un modelo presentan autocorrelación; la prueba de Jarque-Bera evalúa normalidad.

Modelos AR, MA y ARMA. Los procesos autorregresivos $AR(p)$ modelan X_t en función de sus propios rezagos; son estacionarios si todas las raíces del polinomio característico caen dentro del círculo unitario. Los procesos de medias móviles $MA(q)$ expresan X_t como combinación lineal de errores pasados; son siempre estacionarios e invertibles si sus raíces caen dentro del círculo unitario. El modelo $ARMA(p, q)$ combina ambos componentes y, bajo diferenciación d veces, da lugar al $ARIMA(p, d, q)$.

Selección de modelos. Los criterios AIC y BIC equilibran el ajuste del modelo con el principio de parsimonia. El patrón de la ACF y la PACF —corte abrupto vs. decaimiento gradual— orienta la selección inicial del orden (p, q) .

Pronósticos. En el horizonte h , el pronóstico óptimo (mínimo error cuadrático medio) es la esperanza condicional $\mathbb{E}[X_{t+h}|\mathcal{F}_t]$. El intervalo de predicción se amplía con h porque la incertidumbre se acumula.

Desestacionalización y filtrado. El filtro Hodrick-Prescott separa la tendencia de largo plazo (τ_t) del ciclo de corto plazo; la elección del parámetro λ depende de la frecuencia de los datos ($\lambda = 1600$ para datos trimestrales, $\lambda = 14400$ para datos mensuales). La variante St-Amant y van Norden corrige el problema de pérdida de información en los extremos de la muestra.

El siguiente capítulo extiende este marco a series no estacionarias y presenta las pruebas de raíz unitaria que determinan si es necesario diferenciar una serie antes de modelarla con las herramientas aquí desarrolladas.

Capítulo 4

Procesos No Estacionarios Univariados

4.1 Definición y formas de No Estacionariedad

Hasta ahora hemos planteado una serie de técnicas de regresión (AR, MA, ARMA, ARIMA, ARIMAX, etc.) que aplican sólo a procesos o series estacionarias. Sin embargo, no hemos proporcionado una prueba estadística para determinar si una serie es estacionaria. Ese es uno de los objetivos de esta sección.

Adicionalmente, en esta sección relajaremos la definición de estacionariedad y plantearemos pruebas para determinar cuándo una serie es estacionaria bajo tres diferentes especificaciones:

1. Estacionariedad alrededor de una tendencia determinística;
2. Estacionariedad alrededor de una media, y
3. Estacionariedad alrededor del cero.

A continuación, discutiremos cómo es posible que una serie sea estacionaria alrededor de una tendencia determinística. Diremos que una tendencia es determinística si ésta puede ser aproximada o modelada por un polinomio en función de t , la cual incluye posibles transformaciones logarítmicas.

Bajo este enfoque, el proceso está lejos de cumplir con la definición de estacionariedad que hemos establecido en capítulos previos, pero relajaremos el supuesto y reconoceremos que una serie puede ser estacionaria en varianza bajo una tendencia determinística. Así, diremos que la serie será descrita por una ecuación

dada por:

$$Y_t = \sum_{j=0}^m \delta_j t^j + X_t \quad (4.1)$$

Donde X_t es un proceso $ARMA(p, q)$ con media cero, que se puede ver como:

$$\alpha(L)X_t = \beta(L)U_t \quad (4.2)$$

Entonces, los momentos y varianza de la ecuación (4.1) estarán dados por:

$$\mathbb{E}[Y_t] = \sum_{j=0}^m \delta_j t^j = \mu_t \quad (4.3)$$

Dada la ecuación (4.3) podemos plantear la siguiente ecuación de covarianzas:

$$\begin{aligned} \mathbb{E}[(Y_t - \mu_t) \cdot (Y_{t+\tau} - \mu_{t+\tau})] &= \mathbb{E}[X_t \cdot X_{t+\tau}] \\ &= \gamma_X(\tau) \end{aligned} \quad (4.4)$$

Utilizando el resultado de la ecuación (4.4) podemos establecer que:

$$\mathbb{E}[(Y_t - \mu_t)^2] = \mathbb{E}[X_t^2] = \sigma_X^2 \quad (4.5)$$

Así, las ecuaciones (4.3) y (4.5) significan que el proceso descrito por la ecuación (4.1) es estacionario en varianza, aunque no en media. De esta forma, a partir de este momento diremos que una serie será estacionaria alrededor de una tendencia determinística si cumple con las condiciones establecidas en las ecuaciones (4.1), (4.3) y (4.5).

Dicho lo anterior, estudiaremos el concepto de raíz unitaria de un proceso estocástico o de una serie de tiempo. Partamos de plantear que un proceso $AR(1)$ tiene raíz unitaria cuando el coeficiente $a_1 = 1$, es decir:

$$Y_t = Y_{t-1} + U_t \quad (4.6)$$

Donde U_t es un proceso puramente aleatorio con media cero, varianza constante y autocovarianza cero (0), al cual nos referiremos simplemente como ruido blanco. Supongamos ahora que incluimos un término constante en la ecuación (4.6), de forma que tenemos:

$$Y_t = \delta + Y_{t-1} + U_t \quad (4.7)$$

Tomando a la ecuación (4.7) y suponiendo que existe un valor inicial Y_0 de la serie, podemos plantear la siguiente secuencia de expresiones:

$$\begin{aligned} Y_1 &= \delta + Y_0 + U_1 \\ Y_2 &= \delta + Y_1 + U_2 \\ &= \delta + (\delta + Y_0 + U_1) + U_2 \\ &= 2 \times \delta + Y_0 + U_1 + U_2 \end{aligned}$$

Si repitiéramos la sustitución sucesiva anterior hasta el momento t encontraríamos que la ecuación de la solución general que describe a un $AR(1)$ con término constante que tiene raíz unitaria es de la forma:

$$Y_t = t\delta + Y_0 + \sum_{i=1}^t U_i \quad (4.8)$$

La ecuación (4.8) es equivalente a la ecuación (4.1). A la ecuación (4.8) se le conoce como proceso con *drift* o con término constante. El parámetro δ es el *drift*: determina la pendiente de la tendencia lineal $\mathbb{E}[Y_t] = Y_0 + \delta t$, de modo que un valor $\delta > 0$ produce una deriva ascendente en la trayectoria esperada de la serie. La acumulación de errores $\sum_{i=1}^t U_i$ no es consecuencia del drift sino de la raíz unitaria: cada innovación queda incorporada de forma permanente en el nivel de la serie.

Si revisamos el comportamiento de sus momentos y varianza de la ecuación (4.8) encontramos que:

$$\begin{aligned} \mathbb{E}[Y_t] &= Y_0 + \delta t = \mu_t \\ \text{Var}[Y_t] &= t\sigma^2 = \gamma(0, t) \\ \text{Cov}(Y_t, Y_{t+\tau}) &= t\sigma^2 = \gamma(t, \tau) \end{aligned}$$

De esta forma, la ecuación (4.8) no describe un proceso estacionario: tanto la media como la varianza dependen de t , por lo que el proceso es no estacionario en media y en varianza. Ahora hagamos un resumen y acordemos notación que se utilizará en esta sección. Supongamos un proceso o serie de tiempo que es descrito por la siguiente ecuación:

$$Y_t = \delta + Y_{t-1} + X_t \quad (4.9)$$

Donde X_t es un $ARMA(p, q)$ con media cero. Si definimos a $\Delta Y_t = Y_t - Y_{t-1}$, entonces la ecuación (4.9) la podemos escribir como:

$$\Delta Y_t = \delta + X_t \quad (4.10)$$

A la ecuación (4.10) la denominaremos como un proceso estacionario en diferencias o simplemente como un proceso integrado. Así, utilizaremos la siguiente definición.

Sea un proceso estocástico Y , decimos que es un **proceso integrado de orden d** , $I(d)$, si este puede transformarse a uno estacionario, que sea invertible, mediante la diferenciación del mismo d -veces, es decir:

$$(1 - L)^d Y_t = \delta + X_t \quad (4.11)$$

Donde X_t es un proceso $ARMA(p, q)$. De lo cual se infiere que en la ecuación (4.11) Y_t será una $ARIMA(p, d, q)$, el cual contiene d raíces unitarias. A estos procesos también se les conoce como procesos con tendencia estocástica.

Dada la discusión anterior, resumimos los dos tipos de procesos no estacionarios en media que estudiaremos:

$$\begin{aligned} Y_t &= Y_0 + \delta t + U_t \\ Y_t &= Y_0 + t\delta + \sum_{i=1}^t U_i \end{aligned}$$

El primer caso (tendencia determinística, TS) no es estacionario en media —la media crece como $Y_0 + \delta t$ —, pero sí es estacionario en varianza: $\text{Var}(Y_t) = \sigma^2$ es constante y los choques tienen un efecto transitorio. El segundo caso (tendencia estocástica, DS) tampoco es estacionario en media, pero además no lo es en varianza: $\text{Var}(Y_t) = t\sigma^2 \rightarrow \infty$ cuando $t \rightarrow \infty$, y los choques tienen un efecto permanente sobre el nivel de la serie.

4.2 Simulación: Caminata Aleatoria vs. Proceso Estacionario

Antes de presentar las pruebas formales, resulta útil visualizar la diferencia entre un proceso estacionario y uno con raíz unitaria. El siguiente ejemplo simula dos series de $T = 300$ observaciones generadas con el mismo ruido blanco $U_t \sim N(0, 1)$: un $AR(1)$ estacionario con $\phi = 0.7$ y una caminata aleatoria ($\phi = 1$).

```
set.seed(2024)
T <- 300
e <- rnorm(T)

# AR(1) estacionario: phi = 0.7
x_ar <- numeric(T)
for (t in 2:T) x_ar[t] <- 0.7 * x_ar[t - 1] + e[t]

# Caminata aleatoria: phi = 1
x_rw <- numeric(T)
for (t in 2:T) x_rw[t] <- x_rw[t - 1] + e[t]

par(mfrow = c(1, 2))
plot(x_ar, type = "l", col = "darkblue",
     main = expression(paste("AR(1) estacionario (", phi, " = 
     ↪ 0.7)")),
     ylab = expression(Y[t]), xlab = "t")
abline(h = mean(x_ar), col = "red", lty = 2)

plot(x_rw, type = "l", col = "darkred",
```

```
main = "Caminata aleatoria (raíz unitaria)",
ylab = expression(Y[t]), xlab = "t")
abline(h = 0, col = "red", lty = 2)
```




Figura 4.1: AR(1) estacionario vs. Caminata Aleatoria. Ambos procesos usan el mismo ruido blanco.

```
par(mfrow = c(1, 1))
```

La figura ilustra dos características clave. Primero, el $AR(1)$ estacionario regresa continuamente a su media (línea roja punteada), mientras que la caminata aleatoria se aleja de ella de forma permanente. Segundo, los choques en el proceso estacionario tienen un efecto transitorio —que se disipa con el tiempo—, en tanto que los choques en la caminata aleatoria se acumulan y tienen un efecto permanente sobre el nivel de la serie.

En términos de sus momentos, la caminata aleatoria $Y_t = Y_{t-1} + U_t$ con valor inicial $Y_0 = 0$ satisface:

$$\begin{aligned}\mathbb{E}[Y_t] &= Y_0 = 0 \\ \text{Var}(Y_t) &= t\sigma^2 \rightarrow \infty \quad \text{cuando } t \rightarrow \infty\end{aligned}$$

La varianza crece con el tiempo, por lo que el proceso no es estacionario en

varianza. Esta es la característica que las pruebas de raíces unitarias buscan detectar.

4.3 Pruebas de Raíces Unitarias

En esta sección plantearemos una serie de pruebas estadísticas para determinar cuándo una serie puede ser estacionaria bajo tres posibles casos:

1. Estacionariedad alrededor de una tendencia determinística;
2. Estacionariedad alrededor de una media, y
3. Estacionariedad alrededor del cero.

A continuación, mostraremos como ejemplo la aplicación de las pruebas de raíces unitarias a la serie de Tipo de Cambio en forma logarítmica y de diferencias logarítmicas. Asumamos que determinamos el valor de los rezagos de la prueba con el criterio de $p = \text{int}\{4(T/100)^{1/4}\}$. En la práctica, existen otras formas de determinar el valor de p , como el criterio de AIC, pero es decisión del investigador cuál usar.

```
library(ggplot2)
library(dplyr)
library(stats)
library(MASS)
library(strucchange)
library(zoo)
library(sandwich)
library(urca)
library(lmtest)
library(vars)

#
load("BD/Datos_Ad.RData")

#
## Conversion a series de tiempo:
Datos <- ts(Datos_Ad[7: 11],
            start = c(2000, 1),
            freq = 12)

## Nombres cortos para las etiquetas de los paneles de las
  ↪ figuras
## (las series son las versiones desestacionalizadas *_Ad)
```

```

colnames(Datos) <- c("INPC", "TC", "CETE28", "IGAE", "IPI")

LDatos <- log(Datos)

DLDatos <- diff(log(Datos, base = exp(1)),
               lag = 1,
               differences = 1)

DaLDatos <- diff(log(Datos, base = exp(1)),
                 lag = 12,
                 differences = 1)

```

Como primer paso, exploraremos las series en niveles (bajo una transformación logarítmica), como en la Figura 4.2, y en diferencias logarítmicas, como en la Figura 4.3. La Figura 4.4 muestra las diferencias anuales logarítmicas; finalmente, las Figuras 4.5 y 4.6 comparan las transformaciones entre sí. De dicha exploración, podemos concluir que las series parecen estacionarias en diferencias, pero no en niveles.

```

plot(LDatos,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     main = "Series en Logaritmos",
     xlab = "Tiempo")

```

```

plot(DLDatos,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     main = "Series en Diferencias Logarítmicas",
     xlab = "Tiempo")

```

```

plot(DaLDatos,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     main = "Series en Diferencias Anuales Logarítmicas",
     xlab = "Tiempo")

```




Figura 4.2: Series en Logaritmos




Figura 4.3: Series en Diferencias Logarítmicas




Figura 4.4: Series en Diferencias Anuales Logarítmicas

```
Comp_D <- cbind(DLDatos, DaLDatos)
colnames(Comp_D) <- c(paste0("DL.", colnames(Datos)),
                      paste0("DaL.", colnames(Datos)))

plot(Comp_D,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     main = "Comparación de Series en Diferencias Mensuales y
             ↪ Anuales",
     xlab = "Tiempo")
```

```
Comp_N <- cbind(LDatos, DLDatos)
colnames(Comp_N) <- c(paste0("L.", colnames(Datos)),
                      paste0("DL.", colnames(Datos)))

plot(Comp_N,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
```

Comparación de Series en Diferencias Mensuales y Anuales




Figura 4.5: Comparación de Series en Diferencias Mensuales y Anuales (Logarítmicas)


```
main = "Comparación de Series en Niveles y Diferencias",
xlab = "Tiempo")
```

4.3.1 Dickey - Fuller (DF)

La prueba de Dickey y Fuller (Dickey and Fuller, 1979, 1981) parte de una forma del proceso Y_t dada por:

$$Y_t = \sum_{j=0}^m \delta_j t^j + X_t \quad (4.12)$$

Donde X_t es un $ARMA(p, q)$ con media cero. Esta prueba asume que $m = 1$, por lo que utilizaremos un modelo del tipo:

$$Y_t = \alpha + \delta t + \rho Y_{t-1} + U_t \quad (4.13)$$

Si el $AR(1)$ planteado tiene raíz unitaria, es decir, $\rho = 1$, entonces tendríamos:

$$\begin{aligned} Y_t &= \alpha + \delta t + Y_{t-1} + U_t \\ \Delta Y_t &= \alpha + \delta t + U_t \end{aligned}$$

De esta forma, para determinar si una serie tiene raíz unitaria basta con probar la hipótesis nula de que $H_0 : \rho = 1$, junto con las diferentes combinaciones que impliquen restricciones respecto a δ y α .

En resumen, la prueba DF consiste en asumir un modelo general dado por la ecuación (4.13) y probar tres especificaciones distintas que serían válidas bajo $H_0 : \rho = 1$:

1. Modelo A: con intercepto y tendencia:

$$\Delta Y_t = \alpha + \delta t + \beta Y_{t-1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una tendencia determinística.

2. Modelo B: con intercepto:

$$\Delta Y_t = \alpha + \beta Y_{t-1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una constante.

Comparación de Series en Niveles y Diferencias




Figura 4.6: Comparación de Series en Niveles (Logaritmos) y en Diferencias Logarítmicas

3. Modelo C: sin intercepto y tendencia:

$$\Delta Y_t = \beta Y_{t-1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario sin considerar una constante o una tendencia determinística, es decir, es un proceso puramente aleatorio.

Ejemplo. A continuación mostramos los resultados de aplicar las pruebas de raíces unitarias a la serie LTC_t ($T = 282$ observaciones mensuales), considerando $p = \text{int}\{4(282/100)^{(1/4)}\} = 5$ para aquellas pruebas que requieren de rezagos: ADF, PP y KPSS. La convención es implementar las pruebas de raíces unitarias iniciando con el modelo más general hasta llegar al más restringido. Es decir, iniciar con el Modelo A, pasar al Modelo B y cerrar con el Modelo C.

Iniciaremos implementando una prueba de DF simple (o una ADF sin rezagos). En este caso obtenemos los resultados mostrados en la siguiente Tabla. En esta se reportan los resultados de la prueba para cada uno de los 3 modelos (A, B y C) y los valores críticos (CV, por sus siglas en inglés) de la prueba para los niveles 1%, 5% y 10%—estos valores son los reportados por MacKinnon (1996) para una prueba con distribución de 1 cola (izquierda). La convención es utilizar el nivel del 5% de significancia.

Los resultados se presentan en el Cuadro 4.1, donde se reportan los estadísticos τ y los valores críticos de MacKinnon (1996) para los tres modelos, tanto en niveles (LTC_t) como en primeras diferencias (ΔLTC_t). Rechazaremos la hipótesis nula cuando el estadístico t sea menor que el valor crítico. La serie se vuelve estacionaria en su primera diferencia.

```
## Dickey-Fuller - Niveles
df_nA <- ur.df(LDatos[, 2], type = "trend", lags = 0)
df_nB <- ur.df(LDatos[, 2], type = "drift", lags = 0)
df_nC <- ur.df(LDatos[, 2], type = "none", lags = 0)

## Dickey-Fuller - Diferencias
df_dA <- ur.df(DLDatos[, 2], type = "trend", lags = 0)
df_dB <- ur.df(DLDatos[, 2], type = "drift", lags = 0)
df_dC <- ur.df(DLDatos[, 2], type = "none", lags = 0)

urdf_fila <- function(lbl, obj) {
  data.frame(Modelo      = lbl,
             Estadistico = round(obj@teststat[1], 4),
             CV_1pct     = round(obj@cval[1, 1], 4),
             CV_5pct     = round(obj@cval[1, 2], 4),
             CV_10pct    = round(obj@cval[1, 3], 4))
}
```

Cuadro 4.1: Resumen: prueba Dickey-Fuller (DF) para LTC_t .

Modelo	Estadístico t	CV 1%	CV 5%	CV 10%
LTC_t — A (tendencia)	-2.0752	-3.98	-3.42	-3.13
LTC_t — B (intercepto)	-1.1724	-3.44	-2.87	-2.57
LTC_t — C (sin det.)	1.1815	-2.58	-1.95	-1.62
ΔLTC_t — A (tendencia)	-12.6805	-3.98	-3.42	-3.13
ΔLTC_t — B (intercepto)	-12.6899	-3.44	-2.87	-2.57
ΔLTC_t — C (sin det.)	-12.6515	-2.58	-1.95	-1.62

```

}

# Con escape = FALSE el LaTeX de las celdas (p. ej.  $\Delta LTC_t$ ) se
  ↪ LTC_t$) se
# renderiza como fórmula; el % de los encabezados requiere \%
  ↪ solo en PDF.
pct      <- if (knitr::is_latex_output()) "\\%" else "%"
cv_cols  <- paste0(c("CV 1", "CV 5", "CV 10"), pct)

knitr::kable(
  rbind(urdf_fila("$LTC_t$ - A (tendencia)",      df_nA),
        urdf_fila("$LTC_t$ - B (intercepto)",     df_nB),
        urdf_fila("$LTC_t$ - C (sin det.)",       df_nC),
        urdf_fila("$\\Delta LTC_t$ - A (tendencia)", df_dA),
        urdf_fila("$\\Delta LTC_t$ - B (intercepto)", df_dB),
        urdf_fila("$\\Delta LTC_t$ - C (sin det.)", df_dC)),
  col.names = c("Modelo", "Estadístico  $t$ ", cv_cols),
  caption   = "Resumen: prueba Dickey-Fuller (DF) para  $LTC_t$ .",
  align     = c("l", "r", "r", "r", "r"),
  booktabs = TRUE,
  escape    = FALSE
)

```

4.3.2 Dickey - Fuller Aumentada (ADF)

La prueba ADF (Dickey and Fuller, 1981) extiende la prueba DF al caso de un $AR(p)$. A diferencia de un modelo $AR(1)$ para el caso de una prueba DF como en la ecuación (4.13), en una prueba ADF se asume que el proceso es un $AR(p)$ de la forma (por simplicidad, hemos omitido el término constante y el término de tendencia determinística):

$$Y_t = a_1 Y_{t-1} + a_2 Y_{t-2} + \dots + a_p Y_{t-p} + U_t \quad (4.14)$$

Haciendo una sustitución de términos similar a las que hemos planteado en otras secciones, podemos reexpresar la ecuación (4.14) en su versión en diferencias siguiendo el proceso:

$$Y_t = \rho Y_{t-1} + \theta_1 \Delta Y_{t-1} + \theta_2 \Delta Y_{t-2} + \dots + \theta_{p-1} \Delta Y_{t-p+1} + U_t \quad (4.15)$$

Donde $\rho = \theta_0 = \sum_{j=1}^p a_j$, $\theta_i = -\sum_{j=i+1}^p a_j$, $i = 1, 2, \dots, p-1$. Así, si el proceso AR(p) tiene raíz unitaria, entonces, veremos que:

$$\begin{aligned} 1 - a_1 - a_2 - \dots - a_p &= 0 \\ \rho &= 1 \end{aligned}$$

De donde podemos establecer que el modelo general de una prueba ADF será:

$$\Delta Y_t = \alpha + \beta t + (\rho - 1)Y_{t-1} + \theta_1 \Delta Y_{t-1} + \theta_2 \Delta Y_{t-2} + \dots + \theta_k \Delta Y_{t-k} + U_t \quad (4.16)$$

Donde U_t es un proceso puramente aleatorio y k es elegido de tal manera que los residuales sean un proceso puramente aleatorio. En resumen, la prueba ADF consiste en asumir un modelo general dado por la ecuación (4.14), que incluya constante y tendencia, y probar tres especificaciones distintas que serían válidas bajo $H_0 : \rho = 1$:

1. Modelo A: con intercepto y tendencia:

$$\Delta Y_t = \alpha + \delta t + \beta Y_{t-1} + \theta_1 \Delta Y_{t-1} + \theta_2 \Delta Y_{t-2} + \dots + \theta_{p-1} \Delta Y_{t-p+1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una tendencia determinística.

2. Modelo B: con intercepto:

$$\Delta Y_t = \alpha + \beta Y_{t-1} + \theta_1 \Delta Y_{t-1} + \theta_2 \Delta Y_{t-2} + \dots + \theta_{p-1} \Delta Y_{t-p+1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una constante.

3. Modelo C: sin intercepto y tendencia:

$$\Delta Y_t = \beta Y_{t-1} + \theta_1 \Delta Y_{t-1} + \theta_2 \Delta Y_{t-2} + \dots + \theta_{p-1} \Delta Y_{t-p+1} + U_t$$

Buscamos probar si $H_0 : \beta = \rho - 1 = 0$ contra $H_a : \beta < 0$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario sin considerar una constante o una tendencia determinística, es decir, es un proceso puramente aleatorio.

Cuadro 4.2: Resumen: prueba Augmented Dickey-Fuller (ADF, 5 rezagos) para LTC_t .

Modelo	Estadístico t	CV 1%	CV 5%	CV 10%
LTC_t — A (tendencia)	-2.4972	-3.98	-3.42	-3.13
LTC_t — B (intercepto)	-1.1265	-3.44	-2.87	-2.57
LTC_t — C (sin det.)	1.0273	-2.58	-1.95	-1.62
ΔLTC_t — A (tendencia)	-7.4125	-3.98	-3.42	-3.13
ΔLTC_t — B (intercepto)	-7.4034	-3.44	-2.87	-2.57
ΔLTC_t — C (sin det.)	-7.2639	-2.58	-1.95	-1.62

Ejemplo. El Cuadro 4.2 muestra los resultados de la prueba ADF con 5 rezagos ($p = \text{int}\{4(282/100)^{(1/4)}\} = 5$) para LTC_t y ΔLTC_t . Al igual que en el caso anterior, rechazaremos la hipótesis nula cuando el estadístico t sea menor que el valor crítico. La serie se vuelve estacionaria en su primera diferencia.

```
## Augmented Dickey-Fuller - Niveles
adf_nA <- ur.df(LDatos[, 2], type = "trend", lags = 5)
adf_nB <- ur.df(LDatos[, 2], type = "drift", lags = 5)
adf_nC <- ur.df(LDatos[, 2], type = "none", lags = 5)

## Augmented Dickey-Fuller - Diferencias
adf_dA <- ur.df(DLDatos[, 2], type = "trend", lags = 5)
adf_dB <- ur.df(DLDatos[, 2], type = "drift", lags = 5)
adf_dC <- ur.df(DLDatos[, 2], type = "none", lags = 5)

knitr::kable(
  rbind(urdf_fila("$LTC_t$ - A (tendencia)", adf_nA),
        urdf_fila("$LTC_t$ - B (intercepto)", adf_nB),
        urdf_fila("$LTC_t$ - C (sin det.)", adf_nC),
        urdf_fila("$\\Delta LTC_t$ - A (tendencia)", adf_dA),
        urdf_fila("$\\Delta LTC_t$ - B (intercepto)", adf_dB),
        urdf_fila("$\\Delta LTC_t$ - C (sin det.)", adf_dC)),
  col.names = c("Modelo", "Estadístico  $t$ ", cv_cols),
  caption = "Resumen: prueba Augmented Dickey-Fuller (ADF, 5
    ↪ rezagos) para  $LTC_t$ .",
  align = c("l", "r", "r", "r", "r", "r"),
  booktabs = TRUE,
  escape = FALSE
)
```

4.3.3 Phillips - Perron (PP)

La prueba de Phillips y Perron (Phillips and Perron, 1988) también está basada en un AR(1) descrito por la ecuación:

$$Y_t = d\eta + \rho Y_{t-1} + U_t \quad (4.17)$$

Donde d incluye a cualquiera de los componentes determinísticos como constante y tendencia.

Al igual que los casos pasados, la hipótesis a probar es $H_0 : \rho = 1$ contra la alternativa $H_a : |\rho| < 1$, y asumimos una estructura de MA(l) que es un término de error de la forma:

$$U_t = \psi(L)\varepsilon_t = \psi_0\varepsilon_t + \psi_1\varepsilon_{t-1} + \dots + \psi_l\varepsilon_{t-l} \quad (4.18)$$

Con ε_t que es un ruido blanco con media cero y varianza σ^2 . En este modelo se elige el valor l que hace que el componente sea un MA(l). Las tablas estadísticas de PP para esta prueba pueden utilizar una estadística Z_τ o Z_ρ , las cuales se pueden emplear indistintamente.

En resumen, la prueba PP consiste en asumir un modelo general dado por la ecuación (4.17) y probar dos especificaciones distintas que serían válidas bajo $H_0 : \rho = 1$, ambas considerando un componente Drift:

1. Modelo A: con intercepto y tendencia:

$$Y_t = \alpha + \delta t + \rho Y_{t-1} + U_t$$

Buscamos probar si $H_0 : \rho = 1$ contra $H_a : |\rho| < 1$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una tendencia determinística.

2. Modelo B: con intercepto:

$$Y_t = \alpha + \rho Y_{t-1} + U_t$$

Buscamos probar si $H_0 : \rho = 1$ contra $H_a : |\rho| < 1$, por lo que es una prueba de una cola. Otra forma de decirlo es: probamos si el proceso tiene raíz unitaria contra si el proceso es estacionario alrededor de una constante.

Ejemplo. El Cuadro 4.3 muestra los resultados de la prueba PP con 5 rezagos para LTC_t y ΔLTC_t . Rechazaremos la hipótesis nula cuando el estadístico Z_τ sea menor que el valor crítico. La serie se vuelve estacionaria en su primera diferencia.

Cuadro 4.3: Resumen: prueba Phillips-Perron (PP, 5 rezagos) para LTC_t .

Modelo	Estadístico Z_τ	CV 1%	CV 5%	CV 10%
LTC_t — A (tendencia)	-2.5039	-3.9941	-3.4272	-3.1366
LTC_t — B (intercepto)	-1.2297	-3.4552	-2.8719	-2.5723
ΔLTC_t — A (tendencia)	-12.3906	-3.9942	-3.4273	-3.1366
ΔLTC_t — B (intercepto)	-12.4037	-3.4553	-2.8720	-2.5723

```
## Phillips-Perron - Niveles
pp_nA <- ur.pp(LDatos[, 2], type = "Z-tau", model = "trend",
  ↪ use.lag = 5)
pp_nB <- ur.pp(LDatos[, 2], type = "Z-tau", model = "constant",
  ↪ use.lag = 5)

## Phillips-Perron - Diferencias
pp_dA <- ur.pp(DLDatos[, 2], type = "Z-tau", model = "trend",
  ↪ use.lag = 5)
pp_dB <- ur.pp(DLDatos[, 2], type = "Z-tau", model = "constant",
  ↪ use.lag = 5)

urpp_fila <- function(lbl, obj) {
  cv <- as.numeric(obj@cval)
  data.frame(Modelo = lbl,
    Estadístico = round(as.numeric(obj@teststat), 4),
    CV_1pct = round(cv[1], 4),
    CV_5pct = round(cv[2], 4),
    CV_10pct = round(cv[3], 4))
}

knitr::kable(
  rbind(urpp_fila("$LTC_t$ - A (tendencia)", pp_nA),
    urpp_fila("$LTC_t$ - B (intercepto)", pp_nB),
    urpp_fila("$\\Delta LTC_t$ - A (tendencia)", pp_dA),
    urpp_fila("$\\Delta LTC_t$ - B (intercepto)", pp_dB)),
  col.names = c("Modelo", "Estadístico  $Z_{\\tau}$ ", cv_cols),
  caption = "Resumen: prueba Phillips-Perron (PP, 5 rezagos)
  ↪ para $LTC_t$",
  align = c("l", "r", "r", "r", "r"),
  booktabs = TRUE,
  escape = FALSE
)
```


4.3.4 Kwiatkowski - Phillips - Schmidt - Shin (KPSS)

La prueba KPSS (Kwiatkowski et al., 1992) considera que el proceso es estacionario bajo la hipótesis nula, lo cual hace una diferencia respecto de las anteriores pruebas. El modelo considerado es:

$$Y_t = \delta t + \xi_t + U_t \quad (4.19)$$

Donde U_t es un proceso estacionario y ξ_t es una caminata aleatoria descrita por la forma: $\xi_t = \xi_{t-1} + \varepsilon_t$, donde ε_t es un ruido blanco normalmente distribuido con media cero y varianza σ_ε^2 .

Así, bajo la hipótesis nula $H_0 : \sigma_\varepsilon^2 = 0$, ξ_t se vuelve una constante y el proceso es estacionario alrededor de una tendencia determinística (o de una constante, según la especificación). Dado el planteamiento de la prueba, los valores críticos al 95% son:

1. **Modelo A:** 0.146, para un modelo con tendencia (estadístico τ).
2. **Modelo B:** 0.463, para un modelo con constante (estadístico μ).

Ejemplo. Finalmente, el Cuadro 4.4 muestra los resultados de la prueba KPSS para LTC_t y ΔLTC_t . En este caso se acepta H_0 (estacionariedad) cuando el estadístico es **menor** que el valor crítico. La serie se vuelve estacionaria en su primera diferencia.

```
## KPSS - Niveles
kpss_nA <- ur.kpss(LDatos[, 2], type = "tau")
kpss_nB <- ur.kpss(LDatos[, 2], type = "mu")

## KPSS - Diferencias
kpss_dA <- ur.kpss(DLDatos[, 2], type = "tau")
kpss_dB <- ur.kpss(DLDatos[, 2], type = "mu")

# @cval en ur.kpss: orden 10%, 5%, 2.5%, 1% (posiciones 1,2,3,4)
urkpss_fila <- function(lbl, obj) {
  cv <- as.numeric(obj@cval)
  data.frame(Modelo      = lbl,
              Estadistico = round(as.numeric(obj@teststat), 4),
              CV_1pct     = round(cv[4], 4),
              CV_5pct     = round(cv[2], 4),
              CV_10pct    = round(cv[1], 4))
}

knitr::kable(
  rbind(urkpss_fila("$LTC_t$ - A ($\\tau$, tendencia)",
    ↵ kpss_nA),
```

Cuadro 4.4: Resumen: prueba KPSS para LTC_t (rechazar H_0 si estadístico $>$ CV).

Modelo	Estadístico	CV 1%	CV 5%	CV 10%
LTC_t — A (τ , tendencia)	0.3433	0.216	0.146	0.119
LTC_t — B (μ , intercepto)	4.4290	0.739	0.463	0.347
ΔLTC_t — A (τ , tendencia)	0.0701	0.216	0.146	0.119
ΔLTC_t — B (μ , intercepto)	0.0801	0.739	0.463	0.347

```

urkpss_fila("$LTC_t$ - B ($\\mu$, intercepto)",
  ↪ kpss_nB),
urkpss_fila("$\\Delta LTC_t$ - A ($\\tau$, tendencia)",
  ↪ kpss_dA),
urkpss_fila("$\\Delta LTC_t$ - B ($\\mu$, intercepto)",
  ↪ kpss_dB)),
col.names = c("Modelo", "Estadístico", cv_cols),
caption = "Resumen: prueba KPSS para $LTC_t$ (rechazar $H_0$
  ↪ si estadístico $>$ CV).",
align = c("l", "r", "r", "r", "r"),
booktabs = TRUE,
escape = FALSE
)

```

4.3.5 Zivot - Andrews (ZA)

Una limitación de las pruebas DF, ADF, PP y KPSS es que asumen que los parámetros del proceso son constantes a lo largo de toda la muestra. Sin embargo, muchas series económicas presentan **quiebres estructurales** —cambios abruptos en la media o en la tendencia— asociados a eventos como crisis financieras, cambios de política económica o pandemias. En presencia de un quiebre estructural no considerado, las pruebas anteriores tienen un sesgo hacia no rechazar la hipótesis nula de raíz unitaria, incluso cuando la serie es estacionaria.

La prueba de Zivot and Andrews (1992) extiende la prueba ADF para el caso en que existe un quiebre estructural en una fecha desconocida τ^* . La prueba evalúa tres modelos:

- **Modelo A:** quiebre en el nivel (intercepto).
- **Modelo B:** quiebre en la tendencia.
- **Modelo C:** quiebre en el nivel y en la tendencia (modelo más general).

En cada caso, la hipótesis nula es que la serie tiene una raíz unitaria sin quiebre estructural, contra la alternativa de que es estacionaria con un quiebre en la fecha τ^* . La fecha del quiebre se determina endógenamente como aquella que minimiza el estadístico t de la prueba.

El estadístico de la prueba sigue una distribución no estándar cuyos valores críticos al 1%, 5% y 10% son, respectivamente, -5.34 , -4.80 y -4.58 para el Modelo C.

Ejemplo. La siguiente Tabla y el código en R muestran la aplicación de la prueba ZA a la serie LTC_t . Rechazamos la hipótesis nula si el estadístico es menor (en valor absoluto más grande) que el valor crítico correspondiente.

```
## Zivot - Andrews: los tres modelos

za_A <- ur.za(LDatos[, 2], model = "intercept", lag = 5)
za_B <- ur.za(LDatos[, 2], model = "trend",      lag = 5)
za_C <- ur.za(LDatos[, 2], model = "both",      lag = 5)

# Convierte índice de quiebre a cadena "AAAA-MM"
bp_fecha <- function(x, bp) {
  t <- time(x)
  yr <- floor(t[bp])
  mo <- round((t[bp] - yr) * 12) + 1
  paste0(yr, "-", sprintf("%02d", mo))
}

za_df <- data.frame(
  Modelo      = c("A (intercepto)", "B (tendencia)", "C
    ↪ (ambos)"),
  Estadistico = round(c(za_A@teststat, za_B@teststat,
    ↪ za_C@teststat), 4),
  CV_1pct     = c(za_A@cval[1], za_B@cval[1], za_C@cval[1]),
  CV_5pct     = c(za_A@cval[2], za_B@cval[2], za_C@cval[2]),
  CV_10pct    = c(za_A@cval[3], za_B@cval[3], za_C@cval[3]),
  Quiebre     = c(bp_fecha(LDatos[, 2], za_A@bpoint),
    ↪ bp_fecha(LDatos[, 2], za_B@bpoint),
    ↪ bp_fecha(LDatos[, 2], za_C@bpoint))
)

knitr::kable(
  za_df,
  col.names = c("Modelo", "Estadístico", cv_cols, "Quiebre
    ↪ est."),
  caption   = "Resumen de resultados de la prueba Zivot-Andrews
    ↪ (ZA) para $LTC_t$",
  align     = c("l", "r", "r", "r", "r", "r"),
```

Cuadro 4.5: Resumen de resultados de la prueba Zivot-Andrews (ZA) para LTC_t .

Modelo	Estadístico	CV 1%	CV 5%	CV 10%	Quiebre est.
A (intercepto)	-4.1412	-5.34	-4.80	-4.58	2014-11
B (tendencia)	-3.0552	-4.93	-4.42	-4.11	2022-02
C (ambos)	-3.9598	-5.57	-5.08	-4.82	2015-05

```
booktabs = TRUE,
escape   = FALSE
)
```

4.4 Resumen y Guía de Decisión

La siguiente tabla ofrece una comparación de las cuatro pruebas principales de raíces unitarias estudiadas en este capítulo:

Prueba	H_0	H_a	Distribución	Notas
DF	Raíz unitaria	Proceso estacionario	No estándar	Solo válida si errores son ruido blanco
ADF	Raíz unitaria	Proceso estacionario	No estándar	Corrige autocorrelación con rezagos
PP	Raíz unitaria	Proceso estacionario	No estándar	Corrige autocorrelación no paramétricamente
KPSS	Estacionario	Raíz unitaria	KPSS	H_0 inversa; útil como complemento
ZA	Raíz unitaria	Estacionario con quiebre	No estándar	Endogeniza la fecha del quiebre estructural

La convención en la práctica econométrica es aplicar las pruebas siguiendo el proceso de decisión que se describe a continuación:

1. **Inspección visual:** graficar la serie en niveles y en diferencias para tener una primera impresión sobre su comportamiento.
2. **Aplicar ADF, PP y KPSS en niveles:** si ADF y PP rechazan H_0 (raíz unitaria) y KPSS no rechaza su H_0 (estacionariedad), la serie es estacionaria en niveles, $I(0)$.

3. **Si no se rechaza la raíz unitaria en niveles:** tomar primeras diferencias y repetir las pruebas. Si las pruebas sobre las diferencias indican estacionariedad, la serie es integrada de orden uno, $I(1)$.
4. **Ante resultados contradictorios o series con posibles quiebres estructurales:** aplicar la prueba de Zivot-Andrews para descartar que el resultado de no rechazar la raíz unitaria se deba a la presencia de un quiebre no modelado.
5. **En todos los casos:** reportar los tres modelos (A, B y C) y los valores críticos al 1%, 5% y 10% para transparencia y replicabilidad.

Capítulo 5

Causalidad de Granger, Modelos Multivariados de Vectores Autorregresivos y de Cointegración, Modelos ARDL y Filtro Multivariado

En este capítulo removeremos el supuesto de que el análisis es univariado, ya que introduciremos la posibilidad de que los procesos generadores de datos compartan información entre dos o más series. Como primera aproximación desarrollaremos el concepto de Causalidad de Granger. Mediante esta metodología discutiremos cuándo dos series se causan estadísticamente. Posteriormente, introduciremos una técnica más sofisticada conocida como la metodología de Vectores Autorregresivos (VAR), la cual es una generalización de los procesos Autorregresivos (AR) que analizamos en los primeros capítulos. Finalmente, introduciremos la técnica de cointegración y de rezagos distribuidos (ARDL) para los casos en que las series que analicemos sean procesos no estacionarios.

A partir de este punto, asumiremos que las series empleadas son estacionarias en sus primeras diferencias y solo nos preocuparemos por su estacionariedad en los casos particulares de Cointegración y los modelos ARDL.

5.1 Causalidad de Granger

Hasta ahora hemos supuesto que una serie puede ser explicada únicamente con la información contenida en ella misma. No obstante, en adelante trataremos de analizar el caso en el que buscamos determinar relaciones entre variables y cómo el comportamiento de una serie influye en las demás. Una de las relaciones más importantes entre variables es la de causalidad. En este caso analizaremos el procedimiento de Granger (1969), conocido como causalidad de Granger. En adelante asumiremos que las series involucradas son débilmente estacionarias.

Sean X y Y dos series débilmente estacionarias. Definamos a I_t un conjunto de toda la información disponible hasta el momento t . Asimismo, digamos que $\bar{X}_t$ y $\bar{Y}_t$ son los conjuntos de toda la información disponible (actual y pasada) de X y Y , respectivamente. Es decir:

$$\begin{aligned}\bar{X}_t &:= \{X_t, X_{t-1}, X_{t-2}, \dots\} \\ \bar{Y}_t &:= \{Y_t, Y_{t-1}, Y_{t-2}, \dots\} \\ I_t &:= \bar{X}_t + \bar{Y}_t\end{aligned}$$

Adicionalmente, definamos $\sigma^2(*)$ como la varianza del término de error estimado de una regresión dada. Dicho lo anterior, digamos que:

1. Existe Causalidad de Granger o X causa a Y si y solo si, una regresión lineal da como resultado que:

$$\sigma^2(Y_{t+1}|I_t) < \sigma^2(Y_{t+1}|I_t - X_t) \quad (5.1)$$

Es decir, que la variabilidad del término de error de una regresión lineal de Y sobre el conjunto de toda la información aplicada a un pronóstico de Y_{t+1} es MENOR que la variabilidad del término de error de una regresión lineal de Y sobre el conjunto de la información de Y aplicada a un pronóstico de Y_{t+1} .

2. Existe Causalidad de Granger Instantánea o X causa de forma instantánea a Y si y solo si, una regresión lineal da como resultado:

$$\sigma^2(Y_{t+1}|\{I_t, X_{t+1}\}) < \sigma^2(Y_{t+1}|I_t) \quad (5.2)$$

La definición anterior aplica de igual forma si se reemplaza a X por Y y a Y por X , respectivamente. De acuerdo con la definición anterior, existen 5 diferentes posibilidades de relaciones causales entre las dos series:

1. X y Y son independientes: (X, Y) ;
2. Existe solo causalidad instantánea: $(X - Y)$;

3. X causa a Y : $(X \longrightarrow Y)$;
4. Y causa a X : $(X \longleftarrow Y)$, y
5. Ambas series se causan: $(X \longleftrightarrow Y)$.

Por lo anterior, representaremos mediante un $AR(p)$ con variables exógenas lo siguiente:

$$A(L) \begin{bmatrix} Y_t \\ X_t \end{bmatrix} = \begin{bmatrix} a_{11}(L) & a_{12}(L) \\ a_{21}(L) & a_{22}(L) \end{bmatrix} \begin{bmatrix} Y_t \\ X_t \end{bmatrix} = \begin{bmatrix} V_t \\ U_t \end{bmatrix} \quad (5.3)$$

O en su versión $MA(q)$ con variables exógenas:

$$\begin{bmatrix} Y_t \\ X_t \end{bmatrix} = B(L) \begin{bmatrix} V_t \\ U_t \end{bmatrix} = \begin{bmatrix} b_{11}(L) & b_{12}(L) \\ b_{21}(L) & b_{22}(L) \end{bmatrix} \begin{bmatrix} V_t \\ U_t \end{bmatrix} \quad (5.4)$$

Para determinar el test de causalidad utilizaremos una especificación similar a la de la ecuación (5.3). Para probar si X causa a Y , consideraremos la siguiente regresión:

$$Y_t = \alpha_0 + \sum_{k=1}^{k_1} a_{11}^k Y_{t-k} + \sum_{k=k_0}^{k_2} a_{12}^k X_{t-k} + U_{1,t} \quad (5.5)$$

Donde $k_0 = 1$ y, en general, se asume que $k_1 = k_2$. Asimismo, el valor de estas constantes se puede determinar con el criterio de Akaike (o cualquier otro criterio de información). No obstante, algunos autores sugieren que una buena práctica es considerar valores de k_1 y k_2 que recorran los valores 4, 8, 12 y 16.

Dicho lo anterior, el test de causalidad de Granger se establece con una prueba F, en la cual se prueba la siguiente hipótesis nula:

$$H_0 : a_{12}^1 = a_{12}^2 = \dots = a_{12}^{k_2} = 0 \quad (5.6)$$

Ejemplo. Consideremos como variables analizadas al Índice Nacional de Precios al Consumidor ($INPC_t$), al Tipo de Cambio (TDC_t) y al rendimiento anual de los Cetes a 28 días ($CETE28_t$), todas desestacionalizadas para el periodo de enero de 2000 a junio de 2023. Dado que la metodología de Granger supone que las series son estacionarias, utilizaremos las diferencias logarítmicas de cada una de las tres series (es decir, utilizaremos una transformación del tipo $\ln(X_t) - \ln(X_{t-1})$). La Figura 5.1 muestra las series en su transformación de diferencias logarítmicas.

```
library(ggplot2)
library(dplyr)
library(stats)
library(MASS)
library(strucchange)
```

```
library(zoo)
library(sandwich)
library(urca)
library(lmtest)
library(vars)

#
load("BD/Datos_Ad.RData")

#
INPC <- ts(Datos_Ad$INPC_Ad,
           start = c(2000, 1),
           freq = 12)

DLINPC <- diff(log( ts(Datos_Ad$INPC_Ad, start = c(2000, 1), freq
↵ = 12) ))

TC <- ts(Datos_Ad$TC_Ad,
         start = c(2000, 1),
         freq = 12)

DLTC <- diff(log( ts(Datos_Ad$TC_Ad, start = c(2000, 1), freq =
↵ 12) ))

CETE28 <- ts(Datos_Ad$CETE28_Ad,
            start = c(2000, 1),
            freq = 12)

DLCETE28 <- diff(log( ts(Datos_Ad$CETE28_Ad, start = c(2000, 1),
↵ freq = 12) ))

#
#png("Plots/DLGranger.png", width = 800, height = 1200)

par(mfrow=c(3, 1))

plot(DLINPC, xlab = "Tiempo",
     main = "Diferencias Logarítmicas del INPC",
     col = "darkgreen")

plot(DLTC, xlab = "Tiempo",
     main = "Diferencias Logarítmicas del Tipo de Cambio",
     col = "darkblue")
```

```
plot(DLCETE28, xlab = "Tiempo",
     main = "Diferencias Logarítmicas de los Cetes a 28 días",
     col = "darkred")
```




Figura 5.1: Series en diferencias logarítmicas dadas por las siguientes expresiones: $DLINPC_t = \ln(INPC_t) - \ln(INPC_{t-1})$, $DLTC_t = \ln(TC_t) - \ln(TC_{t-1})$ y $DLCETE28_t = \ln(CETE28_t) - \ln(CETE28_{t-1})$.

```
par(mfrow=c(1, 1))

#dev.off()
```

Por simplicidad, en el Cuadro 5.1 se muestra el resultado de aplicar el test de Granger a diferentes especificaciones, con rezagos 4, 8, 12 y 16, sólo para la serie de Tipo de Cambio en diferencias logarítmicas. En cada una de las pruebas se compara el modelo considerado como regresor a la variable que es candidata de causar, respecto del modelo sin considerar a dicha variable.

```
granger_rows <- lapply(c(4, 8, 12, 16), function(p) {
  gt <- grangertest(DLTC ~ DLINPC, order = p)
  pv <- gt$`Pr(>F)`[2]
  data.frame(Rezagos = p,
```

Cuadro 5.1: Prueba de si $DLINPC_t$ Granger causa a $DLTC_t$.

Rezagos	Estadística F	Probabilidad ($> F$)	Signif.
4	1.3488	0.25219	
8	1.0029	0.43425	
12	1.0098	0.44036	
16	0.8123	0.67111	

```

Fstat = round(gt$F[2], 4),
Prob = round(pv, 5),
Signif = ifelse(pv < 0.001, "***",
               ifelse(pv < 0.01, "**",
                     ifelse(pv < 0.05, "*", "")))
})
knitr::kable(
  do.call(rbind, granger_rows),
  col.names = c("Rezagos", "Estadística  $F$ ", "Probabilidad
    ↪ ( $> F$ )", "Signif."),
  caption = "Prueba de si  $DLINPC_t$  Granger causa a
    ↪  $DLTC_t$ .",
  align = c("c", "c", "c", "c"),
  booktabs = TRUE,
  escape = FALSE
)

```

De acuerdo con el Cuadro 5.1, podemos concluir que existe información estadísticamente significativa para concluir que la inflación causa a la tasa de depreciación cambiaria, ambas medidas como las diferencias logarítmicas. El resto de los resultados para las otras combinaciones de causalidad se puede replicar con el código disponible en el repositorio de GitHub del proyecto.

5.2 Definición y representación del Sistema o Modelo de Vectores Autorregresivos (VAR(p))

En esta sección ampliaremos la discusión planteada en el apartado anterior. En el sentido de que en la sección pasada nuestra discusión se limitó al análisis de causalidad entre dos variables a la vez, que si bien es posible extenderlo a más variables, es un procedimiento limitado a casos particulares por las siguientes razones.

El procedimiento de causalidad de Granger supone que es posible identificar un sistema de ecuaciones que debe conformarse una vez que se ha identificado el sentido de la causalidad. Así, el proceso anterior necesita del conocimiento previo de las relaciones que existen entre las variables.

Adicionalmente, no resuelve el problema más general que está relacionado con cómo identificar la causalidad cuando se tienen múltiples variables con múltiples sentidos de causalidad. En esta sección analizaremos una mejor aproximación al problema de cómo identificar la causalidad múltiple. Por lo tanto, como mecanismo para solucionar el problema planteado, analizaremos el caso de un Sistema o Modelo de Vectores Autorregresivos conocido como VAR.

El primer supuesto del que partiremos es que existe algún grado de endogeneidad entre las variables consideradas en el análisis. Adicionalmente, el segundo supuesto que estableceremos es que requerimos que las variables que tengamos consideradas sean estacionarias.

Por lo anterior, diremos que un modelo de Vectores Autorregresivos (VAR) es un procedimiento fundado en el supuesto de que las variables consideradas son estacionarias. Así, hasta este momento hemos pasado de modelos univariados a modelos multivariados, pero no hemos podido dejar de asumir que las series son estacionarias.

En lo subsecuente asumiremos que las series empleadas son estacionarias y sólo lo demostraremos cuando, en su caso, sea necesario. Esto no significa que el lector deba asumir estacionariedad. Por el contrario, siempre debe probar que las series son estacionarias antes de iniciar la implementación de cualquier técnica de series de tiempo.

Ahora bien, iniciaremos con el establecimiento de la representación del proceso. Digamos que tenemos un proceso estocástico $\mathbf{X}_t$ estacionario vectorial de dimensión k :

$$\mathbf{X}_t = \begin{bmatrix} X_{1t} \\ X_{2t} \\ \vdots \\ X_{kt} \end{bmatrix}$$

Para cualquier $i = 1, 2, \dots, p$:

$$\mathbf{X}_{t-i} = \begin{bmatrix} X_{1t-i} \\ X_{2t-i} \\ \vdots \\ X_{kt-i} \end{bmatrix}$$

Donde cada X_{kt} en $\mathbf{X}_t$ es una serie de tiempo por sí misma. De esta forma, la expresión reducida del modelo o el proceso $VAR(p)$ estará dado por:

$$\mathbf{X}_t = \delta + A_1 \mathbf{X}_{t-1} + A_2 \mathbf{X}_{t-2} + \dots + A_p \mathbf{X}_{t-p} + \mathbf{U}_t \quad (5.7)$$

Donde cada uno de las A_i , $i = 1, 2, \dots, p$, son matrices cuadradas de dimensión k y $\mathbf{U}_t$ representa un vector de dimensión $k \times 1$ con los residuales en el momento del tiempo t que son, por individual, un proceso puramente aleatorio. También se incorpora un vector de términos constantes denominado como δ , el cual es de dimensión $k \times 1$.

Así, la ecuación (5.7) supone la siguiente estructura del vector δ :

$$\delta = \begin{bmatrix} \delta_1 \\ \delta_2 \\ \vdots \\ \delta_k \end{bmatrix}$$

También, la ecuación (5.7) supone que cada matriz A_i , $i = 1, 2, \dots, p$ está definida de la siguiente forma:

$$\mathbf{A}_i = \begin{bmatrix} a_{11}^{(i)} & a_{12}^{(i)} & \dots & a_{1k}^{(i)} \\ a_{21}^{(i)} & a_{22}^{(i)} & \dots & a_{2k}^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1}^{(i)} & a_{k2}^{(i)} & \dots & a_{kk}^{(i)} \end{bmatrix}$$

Donde $i = 1, 2, \dots, p$.

Retomando la ecuación (5.7) y considerando que podemos ocupar el operador rezago L^j de forma análoga al caso del modelo $AR(p)$, pero aplicado a un vector, tenemos las siguientes ecuaciones:

$$\begin{aligned} \mathbf{X}_t - A_1 \mathbf{X}_{t-1} - A_2 \mathbf{X}_{t-2} - \dots - A_p \mathbf{X}_{t-p} &= \delta + \mathbf{U}_t \\ \mathbf{X}_t - A_1 L \mathbf{X}_t - A_2 L^2 \mathbf{X}_t - \dots - A_p L^p \mathbf{X}_t &= \delta + \mathbf{U}_t \\ (I_k - \mathbf{A}_1 L - \mathbf{A}_2 L^2 - \dots - \mathbf{A}_p L^p) \mathbf{X}_t &= \delta + \mathbf{U}_t \\ \mathbf{A}(L) \mathbf{X}_t &= \delta + \mathbf{U}_t \end{aligned} \quad (5.8)$$

Adicionalmente, requeriremos que dado que $\mathbf{U}_t$ es un proceso puramente aleatorio, este debe cumplir con las siguientes condiciones:

1. El valor esperado del término de error es cero:

$$\mathbb{E}[\mathbf{U}_t] = 0 \quad (5.9)$$

2. Existe una matriz de varianzas y covarianzas entre los términos de error

contemporáneos dada por:

$$\begin{aligned}
 \mathbb{E}[\mathbf{U}_t \mathbf{U}_t'] &= \mathbb{E} \left[\begin{bmatrix} U_1^{(t)} \\ U_2^{(t)} \\ \vdots \\ U_k^{(t)} \end{bmatrix} \begin{bmatrix} U_1^{(t)} & U_2^{(t)} & \dots & U_k^{(t)} \end{bmatrix} \right] \\
 &= \mathbb{E} \begin{bmatrix} U_1^{(t)} U_1^{(t)} & U_1^{(t)} U_2^{(t)} & \dots & U_1^{(t)} U_k^{(t)} \\ U_2^{(t)} U_1^{(t)} & U_2^{(t)} U_2^{(t)} & \dots & U_2^{(t)} U_k^{(t)} \\ \vdots & \vdots & \dots & \vdots \\ U_k^{(t)} U_1^{(t)} & U_k^{(t)} U_2^{(t)} & \dots & U_k^{(t)} U_k^{(t)} \end{bmatrix} \\
 &= \begin{bmatrix} \sigma_1^2 & \rho_{12} & \dots & \rho_{1k} \\ \rho_{21} & \sigma_2^2 & \dots & \rho_{2k} \\ \vdots & \vdots & \dots & \vdots \\ \rho_{k1} & \rho_{k2} & \dots & \sigma_k^2 \end{bmatrix} \\
 &= \mathbf{U} \mathbf{U}'
 \end{aligned} \tag{5.10}$$

3. La matriz de varianzas y covarianzas no contemporáneas es nula. Es decir, que para todo $t \neq s$:

$$\begin{aligned}
 \mathbb{E}[\mathbf{U}_t \mathbf{U}_s'] &= \mathbb{E} \left[\begin{bmatrix} U_1^{(t)} \\ U_2^{(t)} \\ \vdots \\ U_k^{(t)} \end{bmatrix} \begin{bmatrix} U_1^{(s)} & U_2^{(s)} & \dots & U_k^{(s)} \end{bmatrix} \right] \\
 &= \mathbb{E} \begin{bmatrix} U_1^{(t)} U_1^{(s)} & U_1^{(t)} U_2^{(s)} & \dots & U_1^{(t)} U_k^{(s)} \\ U_2^{(t)} U_1^{(s)} & U_2^{(t)} U_2^{(s)} & \dots & U_2^{(t)} U_k^{(s)} \\ \vdots & \vdots & \dots & \vdots \\ U_k^{(t)} U_1^{(s)} & U_k^{(t)} U_2^{(s)} & \dots & U_k^{(t)} U_k^{(s)} \end{bmatrix} \\
 &= \mathbf{0}
 \end{aligned} \tag{5.11}$$

Las ecuaciones (5.10) y (5.11) significan que los residuales $\mathbf{U}_t$ pueden estar correlacionados entre ellos solo en el caso de que la información sea contemporánea, pero no tienen información en común entre residuales de otros periodos.

Al igual que en el caso del modelo o especificación $AR(p)$, en la especificación del modelo $VAR(p)$ existen condiciones de estabilidad. El proceso es estable si el determinante del polinomio matricial asociado a $\mathbf{A}(L)$ en la ecuación (5.8) no se anula sobre el círculo unitario ni en su interior:

$$\text{Det}[I_k - A_1 z - A_2 z^2 - \dots - A_p z^p] \neq 0 \quad \text{para todo } |z| \leq 1 \tag{5.12}$$

Es decir, todas las raíces del polinomio determinante deben ubicarse fuera del círculo unitario o, equivalentemente, todos los eigenvalores de la matriz compañera del sistema deben tener módulo menor que 1.

La ecuación (5.8) puede ser reescrita en una forma similar a un proceso de MA. Al respecto, de forma similar a la siguiente ecuación podemos construir un modelo $VARMA(p, q)$, el cual no estudiamos en estas notas.

Retomando el primer planteamiento, podemos escribir:

$$\begin{aligned}\mathbf{X}_t &= \mathbf{A}^{-1}(L)\delta + \mathbf{A}^{-1}(L)\mathbf{U}_t \\ &= \mu + \beta(L)\mathbf{U}_t\end{aligned}\tag{5.13}$$

Donde μ es un vector de $k \times 1$ constantes y $\beta(L)$ es una matriz que depende de L .

Por el lado de las matrices que representan la autocovarianza, éstas resultan de resolver lo siguiente:

$$\Gamma_X(\tau) = E[(\mathbf{X}_t - \mu)(\mathbf{X}_{t-\tau} - \mu)']\tag{5.14}$$

Ahora, sin pérdida de generalidad digamos que la especificación $VAR(p)$ en la ecuación (5.7) no tiene constante, por lo que $\delta = \mathbf{0}$, lo que implica que $\mu = \mathbf{0}$. De esta forma las matrices de autocovarianza resultan de:

$$\begin{aligned}\Gamma_X(\tau) &= E[(\mathbf{X}_t)(\mathbf{X}_{t-\tau})'] \\ &= \mathbf{A}_1 E[(\mathbf{X}_{t-1})(\mathbf{X}_{t-\tau})'] + \mathbf{A}_2 E[(\mathbf{X}_{t-2})(\mathbf{X}_{t-\tau})'] \\ &\quad + \dots + \mathbf{A}_p E[(\mathbf{X}_{t-p})(\mathbf{X}_{t-\tau})'] + E[(\mathbf{U}_t)(\mathbf{X}_{t-\tau})']\end{aligned}$$

Finalmente, al igual que en el caso $AR(p)$, requerimos de una métrica que nos permita determinar el número de rezagos óptimo p en el $VAR(p)$. Así, establecemos criterios de información similares a los del $AR(p)$ dados por:

1. Final Prediction Error (FPE):

$$FPE(p) = \left[\frac{T + kp + 1}{T - kp - 1} \right]^k |\hat{\mathbf{U}}\hat{\mathbf{U}}(p)|\tag{5.15}$$

2. Akaike Criterion (AIC):

$$AIC(p) = \ln |\hat{\mathbf{U}}\hat{\mathbf{U}}(p)| + (k + pk^2) \frac{2}{T}\tag{5.16}$$

3. Hannan - Quinn Criterion (HQ):

$$HQ(p) = \ln |\hat{\mathbf{U}}\hat{\mathbf{U}}(p)| + (k + pk^2) \frac{2\ln(\ln(T))}{T}\tag{5.17}$$

4. Schwartz Criterion (SC):

$$SC(p) = \ln |\hat{\mathbf{U}}\hat{\mathbf{U}}(p)| + (k + pk^2) \frac{\ln(T)}{T}\tag{5.18}$$

Donde la matriz de varianzas y covarianzas contemporáneas estará dada por:

$$\hat{U}\hat{U}(p) = \mathbb{E} \left[\begin{bmatrix} U_1^{(t)} \\ U_2^{(t)} \\ \vdots \\ U_k^{(t)} \end{bmatrix} \begin{bmatrix} U_1^{(t)} & U_2^{(t)} & \dots & U_k^{(t)} \end{bmatrix} \right]$$

Ejemplo. Ahora veamos un ejemplo de estimación de $VAR(p)$. Para el ejemplo utilizaremos las series de INPC, Tipo de Cambio, rendimiento de los Cetes a 28 días, el IGAE y el Índice de Producción Industrial de los Estados Unidos, todas desestacionalizadas y para el período de enero de 2000 a junio de 2023. Dado que el supuesto de estacionariedad sigue presente en nuestro análisis, emplearemos cada una de las series en su versión de diferencias logarítmicas. Las Figuras 5.2 y 5.3 muestran las series referidas.

```
library(ggplot2)
library(dplyr)
library(stats)
library(MASS)
library(strucchange)
library(zoo)
library(sandwich)
library(urca)
library(lmtest)
library(vars)

#
load("BD/Datos_Ad.RData")

#
DLINPC <- diff(log( ts(Datos_Ad$INPC_Ad, start = c(2000, 1), freq
↵ = 12) ))

DLTC <- diff(log( ts(Datos_Ad$TC_Ad, start = c(2000, 1), freq =
↵ 12) ))

DLCETE28 <- diff(log( ts(Datos_Ad$CETE28_Ad, start = c(2000, 1),
↵ freq = 12) ))

DLIGAE <- diff(log( ts(Datos_Ad$IGAE_Ad, start = c(2000, 1), freq
↵ = 12) ))

DLIPI <- diff(log( ts(Datos_Ad$IPI_Ad, start = c(2000, 1), freq =
↵ 12) ))
```

```
Datos <- data.frame(cbind(DLINPC, DLTC, DLCETE28, DLIGAE, DLIPI))
```

```
Datos <- ts(Datos,  
           start = c(2000, 2), freq = 12)
```

```
plot(Datos, plot.type = "s",  
     col = c("darkgreen", "darkblue", "darkred", "black",  
             ↪ "purple"),  
     main = "Series en Diferencias logarítmicas",  
     xlab = "Tiempo", ylab = "Variacion")  
  
legend("bottomright", c("INPC", "TC", "CETES28", "IGAE", "IPI"),  
      cex = 0.6, lty = 1:1,  
      col = c("darkgreen", "darkblue", "darkred", "black",  
             ↪ "purple"))
```




Figura 5.2: Series en diferencias logarítmicas (Forma 1)

```
plot(Datos, plot.type = "m",  
     col = "darkgreen",  
     main = "Series en Diferencias logarítmicas", xlab =  
     ↪ "Tiempo")
```

Series en Diferencias logarítmicas




Figura 5.3: Series en diferencias logarítmicas (Forma 2)

Dicho lo anterior, a continuación mostraremos la tabla que resume el valor de los distintos criterios de información para una especificación de un $VAR(p)$ con constante. Nótese que es posible especificar un $VAR(p)$ con tendencia, siempre que exista evidencia de que algunas de las series sean estacionarias alrededor de una tendencia. Caso que no aplica hasta este momento, ya que nuestro análisis de estacionariedad es claro respecto a la media constante (más adelante aportaremos la evidencia de esto), lo cual elimina la posibilidad de incluir una tendencia.

En el Cuadro 5.2 reportamos el número de rezagos propuesto a partir de cada criterio de información y en el Cuadro 5.3 reportamos los resultados de aplicar una prueba de criterios de información para diferentes valores de rezagos. Del cual se concluye que el número óptimo de rezagos es 2 (según el criterio AIC y el FPE) y 1 (según el criterio HQ y el SC). Recordemos que es común que el criterio AIC siempre reporte el mayor valor de rezagos, por lo que es una buena práctica utilizarlo como referente principal.

```
vs <- VARselect(Datos, lag.max = 12, type = "const")
knitr::kable(
  as.data.frame(t(vs$selection)),
  col.names = c("AIC", "HQ", "SC", "FPE"),
  caption = paste("Número de rezagos según cada criterio de
    ↪ información para",
```

Cuadro 5.2: Número de rezagos según cada criterio de información para modelos $VAR(p)$ con constante: series $DLINPC_t$, $DLTC_t$, $DLCE28_t$, $DLIGAE_t$ y $DLIPI_t$.

AIC	HQ	SC	FPE
2	1	1	2

```

                                "modelos VAR($p$) con constante: series
                                ↪ $DLINPC_t$, $DLTC_t$,
                                "$DLCE28_t$, $DLIGAE_t$ y $DLIPI_t$."),
align      = rep("c", 4),
booktabs   = TRUE
)

```

```

crit_df      <- as.data.frame(t(vs$criteria))
crit_df      <- cbind(Rezagos = seq_len(nrow(crit_df)),
  ↪ crit_df)
knitr::kable(
  crit_df,
  col.names = c("Rezagos", "AIC", "HQ", "SC", "FPE"),
  caption   = paste("Criterios de información para modelos
  ↪ VAR($p$) con constante:",
                    "$DLINPC_t$, $DLTC_t$, $DLCE28_t$,
                    ↪ $DLIGAE_t$ y $DLIPI_t$."),
  align     = c("c", "r", "r", "r", "r"),
  digits    = 4,
  booktabs  = TRUE
)

```

De esta forma, justificamos la estimación de un $VAR(2)$. Los resultados del mismo se reportan en los siguientes cuadros, en los que se muestra el resultado de una de las ecuaciones. Los resultados restantes se encuentran en el código de R mostrado más abajo. Primero mostraremos los resultados de las raíces del polinomio característico en el Cuadro 5.4, seguido de un cuadro para la ecuación del IGAE en el Cuadro 5.5 (por simplicidad se omiten las otras cuatro ecuaciones del $VAR(2)$), y del Cuadro 5.6 con la matriz $\hat{U}\hat{U}$ estimada del VAR.

```

VAR_p <- VAR(Datos, p = 2, type = "const")
summary(VAR_p)

```

```

##
## VAR Estimation Results:

```

Cuadro 5.3: Criterios de información para modelos VAR(p) con constante: $DLINPC_t$, $DLTC_t$, $DLCETE28_t$, $DLIGAE_t$ y $DLIPI_t$.

Rezagos	AIC	HQ	SC	FPE
1	-43.4369	-43.2759	-43.0360	0
2	-43.4878	-43.1927	-42.7528	0
3	-43.4268	-42.9975	-42.3578	0
4	-43.3869	-42.8234	-41.9837	0
5	-43.2932	-42.5955	-41.5559	0
6	-43.2432	-42.4113	-41.1719	0
7	-43.2902	-42.3242	-40.8848	0
8	-43.2419	-42.1418	-40.5025	0
9	-43.2201	-41.9858	-40.1466	0
10	-43.1788	-41.8103	-39.7712	0
11	-43.1191	-41.6165	-39.3774	0
12	-43.0502	-41.4134	-38.9744	0

```
## =====
## Endogenous variables: DLINPC, DLTC, DLCETE28, DLIGAE, DLIPI
## Deterministic variables: const
## Sample size: 279
## Log Likelihood: 4142.895
## Roots of the characteristic polynomial:
## 0.53 0.53 0.4501 0.4501 0.4425 0.4425 0.3251 0.3251 0.1677
## ↪ 0.1677
## Call:
## VAR(y = Datos, p = 2, type = "const")
##
##
## Estimation results for equation DLINPC:
## =====
## DLINPC = DLINPC.11 + DLTC.11 + DLCETE28.11 + DLIGAE.11 +
## ↪ DLIPI.11 + DLINPC.12 + DLTC.12 + DLCETE28.12 + DLIGAE.12 +
## ↪ DLIPI.12 + const
##
##          Estimate Std. Error t value      Pr(>|t|)
## DLINPC.11    0.387061   0.063100   6.134 0.0000000030610259
## ↪ ***
## DLTC.11      -0.004611   0.005286  -0.872      0.3839
## DLCETE28.11  0.001229   0.002078   0.592      0.5546
## DLIGAE.11    -0.022088   0.015077  -1.465      0.1441
## DLIPI.11      0.009878   0.019363   0.510      0.6104
## DLINPC.12    -0.006707   0.063621  -0.105      0.9161
```

```
## DLTC.12      0.009608    0.005496    1.748          0.0816 .
## DLCETE28.12  0.001827    0.002051    0.891          0.3737
## DLIGAE.12    0.006544    0.014289    0.458          0.6473
## DLIPI.12     -0.015245    0.019632   -0.777          0.4381
## const        0.002325    0.000294    7.908 0.0000000000000688
↪ ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.002176 on 268 degrees of freedom
## Multiple R-Squared: 0.1783, Adjusted R-squared: 0.1476
## F-statistic: 5.815 on 10 and 268 DF, p-value: 0.00000006289
##
## Estimation results for equation DLTC:
## =====
## DLTC = DLINPC.11 + DLTC.11 + DLCETE28.11 + DLIGAE.11 +
↪ DLIPI.11 + DLINPC.12 + DLTC.12 + DLCETE28.12 + DLIGAE.12 +
↪ DLIPI.12 + const
##
##           Estimate Std. Error t value    Pr(>|t|)
## DLINPC.11  -1.344803   0.745382  -1.804    0.07233 .
## DLTC.11      0.315786   0.062442   5.057 0.00000079 ***
## DLCETE28.11 -0.039912   0.024542  -1.626    0.10506
## DLIGAE.11    0.379306   0.178102   2.130    0.03411 *
## DLIPI.11    -0.514827   0.228727  -2.251    0.02521 *
## DLINPC.12    0.071779   0.751538   0.096    0.92398
## DLTC.12     -0.183813   0.064926  -2.831    0.00499 **
## DLCETE28.12  0.030125   0.024228   1.243    0.21481
## DLIGAE.12    0.070713   0.168797   0.419    0.67561
## DLIPI.12    -0.166610   0.231909  -0.718    0.47312
## const        0.006463   0.003473   1.861    0.06388 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0257 on 268 degrees of freedom
## Multiple R-Squared: 0.1425, Adjusted R-squared: 0.1105
## F-statistic: 4.454 on 10 and 268 DF, p-value: 0.000008102
##
## Estimation results for equation DLCETE28:
## =====
```

```
## DLCETE28 = DLINPC.11 + DLTC.11 + DLCETE28.11 + DLIGAE.11 +
  ↳ DLIPI.11 + DLINPC.12 + DLTC.12 + DLCETE28.12 + DLIGAE.12 +
  ↳ DLIPI.12 + const
##
##           Estimate Std. Error t value Pr(>|t|)
## DLINPC.11    3.933798   1.861561   2.113  0.0355 *
## DLTC.11      0.112997   0.155945   0.725  0.4693
## DLCETE28.11  -0.113300   0.061292   1.849  0.0656 .
## DLIGAE.11    -0.588758   0.444803  -1.324  0.1868
## DLIPI.11     1.174496   0.571237   2.056  0.0407 *
## DLINPC.12   -2.213087   1.876936  -1.179  0.2394
## DLTC.12      0.117661   0.162151   0.726  0.4687
## DLCETE28.12  0.063398   0.060509   1.048  0.2957
## DLIGAE.12    -0.237974   0.421565  -0.565  0.5729
## DLIPI.12     1.110203   0.579183   1.917  0.0563 .
## const       -0.007514   0.008674  -0.866  0.3872
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.06419 on 268 degrees of freedom
## Multiple R-Squared: 0.08823, Adjusted R-squared: 0.05421
## F-statistic: 2.593 on 10 and 268 DF,  p-value: 0.005122
##
##
## Estimation results for equation DLIGAE:
## =====
## DLIGAE = DLINPC.11 + DLTC.11 + DLCETE28.11 + DLIGAE.11 +
  ↳ DLIPI.11 + DLINPC.12 + DLTC.12 + DLCETE28.12 + DLIGAE.12 +
  ↳ DLIPI.12 + const
##
##           Estimate Std. Error t value      Pr(>|t|)
## DLINPC.11    0.719855   0.393617   1.829      0.0685 .
## DLTC.11     -0.218508   0.032974  -6.627 0.000000000188 ***
## DLCETE28.11  0.007718   0.012960   0.596      0.5520
## DLIGAE.11     0.037559   0.094051   0.399      0.6900
## DLIPI.11     0.389894   0.120785   3.228      0.0014 **
## DLINPC.12   -0.737653   0.396868  -1.859      0.0642 .
## DLTC.12      0.073830   0.034286   2.153      0.0322 *
## DLCETE28.12 -0.013542   0.012794  -1.058      0.2908
## DLIGAE.12    -0.142845   0.089138  -1.603      0.1102
## DLIPI.12    -0.154835   0.122465  -1.264      0.2072
## const        0.001637   0.001834   0.893      0.3729
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
##
## Residual standard error: 0.01357 on 268 degrees of freedom
## Multiple R-Squared: 0.3272, Adjusted R-squared: 0.3021
## F-statistic: 13.03 on 10 and 268 DF, p-value: <
  ↪ 0.00000000000000022
##
##
## Estimation results for equation DLIPI:
## =====
## DLIPI = DLINPC.11 + DLTC.11 + DLCETE28.11 + DLIGAE.11 +
  ↪ DLIPI.11 + DLINPC.12 + DLTC.12 + DLCETE28.12 + DLIGAE.12 +
  ↪ DLIPI.12 + const
##
##           Estimate Std. Error t value      Pr(>|t|)
## DLINPC.11    0.042383   0.326611    0.130      0.8968
## DLTC.11     -0.163742   0.027361   -5.985 0.00000000693 ***
## DLCETE28.11  0.012143   0.010754    1.129      0.2598
## DLIGAE.11    0.098821   0.078041    1.266      0.2065
## DLIPI.11     0.067742   0.100224    0.676      0.4997
## DLINPC.12   -0.524835   0.329309   -1.594      0.1122
## DLTC.12      0.053353   0.028449    1.875      0.0618 .
## DLCETE28.12 -0.016237   0.010616   -1.529      0.1273
## DLIGAE.12   -0.088483   0.073964   -1.196      0.2326
## DLIPI.12    -0.082982   0.101618   -0.817      0.4149
## const        0.002361   0.001522    1.551      0.1220
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##
## Residual standard error: 0.01126 on 268 degrees of freedom
## Multiple R-Squared: 0.1978, Adjusted R-squared: 0.1679
## F-statistic: 6.61 on 10 and 268 DF, p-value: 0.000000003715
##
##
## Covariance matrix of residuals:
##           DLINPC      DLTC      DLCETE28      DLIGAE
## DLINPC    0.0000047345 -0.0000001939 0.000004559 0.000006652
## DLTC      -0.0000001939 0.0006606619 0.000369751 -0.000035441
## DLCETE28  0.0000045591 0.0003697510 0.004120747 0.000063618
## DLIGAE    0.0000066522 -0.0000354410 0.000063618 0.000184234
## DLIPI     0.0000069998 -0.0000317443 0.000085254 0.000116407
##           DLIPI
## DLINPC    0.00000700
## DLTC      -0.00003174
## DLCETE28  0.00008525
```


Cuadro 5.4: Módulos de las raíces del polinomio característico del VAR(2).

0.5300	0.5300	0.4501	0.4501	0.4425
0.4425	0.3251	0.3251	0.1677	0.1677

```
## DLIGAE    0.00011641
## DLIPI     0.00012685
##
## Correlation matrix of residuals:
##           DLINPC      DLTC DLCETE28   DLIGAE   DLIPI
## DLINPC    1.000000 -0.003466  0.03264  0.22524  0.2856
## DLTC      -0.003466  1.000000  0.22409 -0.10159 -0.1097
## DLCETE28  0.032640  0.224095  1.00000  0.07301  0.1179
## DLIGAE    0.225240 -0.101585  0.07301  1.00000  0.7615
## DLIPI     0.285629 -0.109656  0.11792  0.76147  1.0000
```

```
rts      <- roots(VAR_p)
rts_mat  <- matrix(round(rts, 4), nrow = 2, byrow = TRUE)
knitr::kable(
  rts_mat,
  col.names = rep("", ncol(rts_mat)),
  caption   = "Módulos de las raíces del polinomio característico
  ↪ del VAR(2).",
  booktabs = TRUE
)
```

```
coef_IGAE <- summary(VAR_p)$varresult$DLIGAE$coefficients
coef_df   <- as.data.frame(coef_IGAE)
lbl_map   <- c(
  DLINPC.11 = "$DLINPC_{t-1}$", DLTC.11      = "$DLTC_{t-1}$",
  DLCETE28.11 = "$DLCETE28_{t-1}$", DLIGAE.11 =
  ↪ "$DLIGAE_{t-1}$",
  DLIPI.11    = "$DLIPI_{t-1}$", DLINPC.12 =
  ↪ "$DLINPC_{t-2}$",
  DLTC.12     = "$DLTC_{t-2}$", DLCETE28.12 =
  ↪ "$DLCETE28_{t-2}$",
  DLIGAE.12   = "$DLIGAE_{t-2}$", DLIPI.12 =
  ↪ "$DLIPI_{t-2}$",
  const       = "$\\delta_4$"
)
rownames(coef_df) <- lbl_map[rownames(coef_df)]
```

Cuadro 5.5: Ecuación $DLIGAE_t$ estimada en el VAR(2).

	Coef.	Error Est.	Estad. t	Prob. ($> t $)	Signif.
$DLINPC_{t-1}$	0.7199	0.3936	1.8288	0.0685	.
$DLTC_{t-1}$	-0.2185	0.0330	-6.6267	0.0000	***
$DLCETE28_{t-1}$	0.0077	0.0130	0.5955	0.5520	
$DLIGAE_{t-1}$	0.0376	0.0941	0.3993	0.6900	
$DLIPI_{t-1}$	0.3899	0.1208	3.2280	0.0014	**
$DLINPC_{t-2}$	-0.7377	0.3969	-1.8587	0.0642	.
$DLTC_{t-2}$	0.0738	0.0343	2.1534	0.0322	*
$DLCETE28_{t-2}$	-0.0135	0.0128	-1.0585	0.2908	
$DLIGAE_{t-2}$	-0.1428	0.0891	-1.6025	0.1102	
$DLIPI_{t-2}$	-0.1548	0.1225	-1.2643	0.2072	
δ_4	0.0016	0.0018	0.8926	0.3729	

```
coef_df$Signif <- ifelse(coef_df[, 4] < 0.001, "***",
                        ifelse(coef_df[, 4] < 0.01, "**",
                              ifelse(coef_df[, 4] < 0.05, "*",
                                      ifelse(coef_df[, 4] < 0.1, ".", ""))))
knitr::kable(
  coef_df,
  col.names = c("Coef.", "Error Est.", "Estad.  $t$ ", "Prob.
    ↪  $(> |t|)$ ", "Signif."),
  caption = "Ecuación  $DLIGAE_t$  estimada en el VAR(2).",
  align = c("r", "r", "r", "r", "c"),
  digits = 4,
  booktabs = TRUE,
  escape = FALSE
)
```

```
sig_mat <- summary(VAR_p)$covres
vnames <- c("$DLINPC$", "$DLTC$", "$DLCETE28$", "$DLIGAE$",
  ↪ "$DLIPI$")
colnames(sig_mat) <- vnames
rownames(sig_mat) <- vnames
knitr::kable(
  sig_mat,
  caption = "Matriz  $\mathbf{\hat{\Sigma}_{\hat{U}\hat{U}}}$ 
    ↪ estimada del VAR(2).",
  digits = 4,
  booktabs = TRUE,
```

Cuadro 5.6: Matriz $\hat{U}\hat{U}$ estimada del VAR(2).

	<i>DLINPC</i>	<i>DLTC</i>	<i>DLCETE28</i>	<i>DLIGAE</i>	<i>DLIPI</i>
<i>DLINPC</i>	0e+00	0e+00	0.0e+00	0e+00	0e+00
<i>DLTC</i>	0e+00	7e-04	4.0e-04	0e+00	0e+00
<i>DLCETE28</i>	0e+00	4e-04	4.1e-03	1e-04	1e-04
<i>DLIGAE</i>	0e+00	0e+00	1.0e-04	2e-04	1e-04
<i>DLIPI</i>	0e+00	0e+00	1.0e-04	1e-04	1e-04

```
escape      = FALSE,
format.args = list(scientific = TRUE, digits = 3)
)
```

Finalmente, en el Cuadro 5.7 reportamos las pruebas de diagnóstico del VAR(2). Incluimos las pruebas de correlación serial (o autocorrelación), normalidad y de heterocedasticidad. De acuerdo con esa información, la correlación serial muestra que existe relación de la matriz de covarianzas no contemporánea considerando pocos rezagos, pero se elimina conforme los rezagos se incrementan. En cuanto a normalidad, se observa que los residuales no lo son, por lo que se requeriría mejorar la especificación del VAR. Finalmente, se observa que los residuales no son homocedásticos.

```
diag_s2 <- serial.test(VAR_p, lags.bg = 2, type = "BG")
diag_s4 <- serial.test(VAR_p, lags.bg = 4, type = "BG")
diag_s6 <- serial.test(VAR_p, lags.bg = 6, type = "BG")
diag_n  <- normality.test(VAR_p)
diag_a  <- arch.test(VAR_p, lags.multi = 6)

diagn_fila <- function(nombre, stat, pval) {
  data.frame(
    Prueba      = nombre,
    Estadistico = round(stat, 3),
    pvalor      = round(pval, 4),
    Conclusion  = ifelse(pval < 0.05, "Se rechaza", "No se
    ↪ rechaza")
  )
}

knitr::kable(
  rbind(
    diagn_fila("Corr. serial -  $\chi^2(2)$ ",
      as.numeric(diag_s2$serial$statistic),
      ↪ diag_s2$serial$p.value),
```

Cuadro 5.7: Pruebas de diagnóstico sobre los residuales del VAR(2).

Prueba	Estadístico	p-valor	Conclusión (H_0)
Corr. serial — $\chi^2(2)$	74.839	0.0130	Se rechaza
Corr. serial — $\chi^2(4)$	131.687	0.0185	Se rechaza
Corr. serial — $\chi^2(6)$	201.633	0.0031	Se rechaza
Normalidad JB — χ^2	36186.086	0.0000	Se rechaza
ARCH multivariado — χ^2	2122.423	0.0000	Se rechaza

```

diagn_fila("Corr. serial -  $\chi^2(4)$ ",
           as.numeric(diag_s4$serial$statistic),
           diag_s4$serial$p.value),
diagn_fila("Corr. serial -  $\chi^2(6)$ ",
           as.numeric(diag_s6$serial$statistic),
           diag_s6$serial$p.value),
diagn_fila("Normalidad JB -  $\chi^2$ ",
           as.numeric(diag_n$jb.mul$JB$statistic),
           diag_n$jb.mul$JB$p.value),
diagn_fila("ARCH multivariado -  $\chi^2$ ",
           as.numeric(diag_a$arch.mul$statistic),
           diag_a$arch.mul$p.value)
),
col.names = c("Prueba", "Estadístico", "p-valor", "Conclusión
              ($H_0$)",
caption    = "Pruebas de diagnóstico sobre los residuales del
              VAR(2).",
align      = c("l", "r", "r", "l"),
booktabs   = TRUE,
escape     = FALSE,
row.names  = FALSE
)

```

5.3 Análisis de Impulso-Respuesta

Una de las grandes ventajas que aporta el análisis de los modelos VAR es el análisis de Impulso-Respuesta. Dicho análisis busca cuantificar el efecto que tiene en $\mathbf{X}_t$ una innovación o cambio en los residuales de cualquiera de las variables en un momento definido. Partamos de la ecuación (5.13) de forma que

tenemos:

$$\begin{aligned}\mathbf{X}_t &= \mathbf{A}^{-1}(L)\delta + \mathbf{A}^{-1}(L)\mathbf{U}_t \\ &= \mu + \mathbf{B}(L)\mathbf{U}_t \\ &= \mu + \Psi_0\mathbf{U}_t + \Psi_1\mathbf{U}_{t-1} + \Psi_2\mathbf{U}_{t-2} + \Psi_3\mathbf{U}_{t-3} + \dots\end{aligned}\quad (5.19)$$

Donde $\Psi_0 = I$ y cada una de las $\Psi_i = \mathbf{B}_i$, $i = 1, 2, \dots$. De esta forma se verifica el efecto que tiene en $\mathbf{X}_t$ cada una de las innovaciones pasadas. Por lo que el análisis de Impulso-Respuesta cuantifica el efecto de cada una de esas matrices en las que hemos descompuesto a $\mathbf{B}(L)$.

Ejemplo. Retomando el modelo $VAR(2)$ anteriormente estimado, en las siguientes figuras reportamos las gráficas de Impulso-Respuesta de la serie $DLTC_t$ ante cambios en los residuales del resto de las series y de la propia serie.

```
IR_DLINPC <- irf(VAR_p, n.ahead = 12, boot = TRUE,
                 ci = 0.95, response = "DLINPC")
```

```
IR_DLINPC
```

```
##
## Impulse response coefficients
## $DLINPC
##              DLINPC
## [1,] 0.0021759002410
## [2,] 0.0008094393250
## [3,] 0.0002429936391
## [4,] 0.0001048999556
## [5,] 0.0000430519256
## [6,] 0.0000257195308
## [7,] 0.0000108405478
## [8,] 0.0000011471582
## [9,] -0.0000014256627
## [10,] -0.0000009999499
## [11,] -0.0000003443770
## [12,] -0.0000001512886
## [13,] -0.0000001157354
##
## $DLTC
##              DLINPC
## [1,] 0.00000000000000
## [2,] -0.0000826837093
## [3,] 0.0003117546911
## [4,] 0.0002648974979
## [5,] 0.0000587162871
```

```
## [6,] -0.0000289491380
## [7,] -0.0000105463736
## [8,] 0.0000105785893
## [9,] 0.0000076216336
## [10,] -0.0000004038885
## [11,] -0.0000021138204
## [12,] -0.0000004691794
## [13,] 0.0000003771599
##
## $DLCETE28
##          DLINPC
## [1,] 0.000000000000000
## [2,] 0.00006486928725
## [3,] 0.00013182636385
## [4,] 0.00003487943931
## [5,] 0.00004740702286
## [6,] 0.00003336371156
## [7,] 0.00001571609856
## [8,] 0.00000377046957
## [9,] 0.00000005672766
## [10,] 0.00000025569500
## [11,] 0.00000033794064
## [12,] 0.00000004626880
## [13,] -0.00000011376620
##
## $DLIGAE
##          DLINPC
## [1,] 0.000000000000000
## [2,] -0.00021156780483
## [3,] -0.00017900748374
## [4,] -0.00001453803984
## [5,] 0.00004387550079
## [6,] 0.00001348412556
## [7,] -0.00000660541189
## [8,] -0.00000344927548
## [9,] 0.00000223865243
## [10,] 0.00000206681740
## [11,] 0.00000008258756
## [12,] -0.00000046595182
## [13,] -0.00000009698431
##
## $DLIPI
##          DLINPC
## [1,] 0.000000000000000
## [2,] 0.00007038187903
## [3,] -0.00011077803202
```

```

## [4,] -0.00003218007799
## [5,] -0.00001697303009
## [6,] 0.00000048565947
## [7,] 0.00001045292187
## [8,] 0.00000469541763
## [9,] 0.00000035996398
## [10,] -0.00000051048646
## [11,] 0.00000005294854
## [12,] 0.00000026647657
## [13,] 0.00000009015073
##
##
## Lower Band, CI= 0.95
## $DLINPC
##          DLINPC
## [1,] 0.001838373072
## [2,] 0.000518652005
## [3,] -0.000040073478
## [4,] -0.000089945122
## [5,] -0.000071529482
## [6,] -0.000065420883
## [7,] -0.000025877168
## [8,] -0.000020660009
## [9,] -0.000013709915
## [10,] -0.000009464753
## [11,] -0.000004522265
## [12,] -0.000001440414
## [13,] -0.000002048700
##
## $DLTC
##          DLINPC
## [1,] 0.000000000000
## [2,] -0.000314952732
## [3,] 0.000043328067
## [4,] 0.000058156165
## [5,] -0.000046048227
## [6,] -0.000120936718
## [7,] -0.000076224564
## [8,] -0.000007891362
## [9,] -0.000009172364
## [10,] -0.000007929963
## [11,] -0.000011843887
## [12,] -0.000007903583
## [13,] -0.000002111994
##
## $DLCETE28

```

```
##          DLINPC
## [1,]  0.000000000000
## [2,] -0.000239313565
## [3,] -0.000098341839
## [4,] -0.000117733371
## [5,] -0.000069735906
## [6,] -0.000032684064
## [7,] -0.000016351526
## [8,] -0.000010518342
## [9,] -0.000008945074
## [10,] -0.000007579667
## [11,] -0.000002782037
## [12,] -0.000001604100
## [13,] -0.000000866400
##
## $DLIGAE
##          DLINPC
## [1,]  0.000000000000
## [2,] -0.000444308277
## [3,] -0.000419171825
## [4,] -0.000181953972
## [5,] -0.000035719492
## [6,] -0.000030779152
## [7,] -0.000037937061
## [8,] -0.000029537221
## [9,] -0.000010252903
## [10,] -0.000005106796
## [11,] -0.000003744009
## [12,] -0.000004429396
## [13,] -0.000002510175
##
## $DLIPI
##          DLINPC
## [1,]  0.000000000000
## [2,] -0.000163837560
## [3,] -0.000353351357
## [4,] -0.000147750087
## [5,] -0.000115618929
## [6,] -0.000068216543
## [7,] -0.000029684282
## [8,] -0.000013958262
## [9,] -0.000012172176
## [10,] -0.000009254213
## [11,] -0.000004198030
## [12,] -0.000002467996
## [13,] -0.000001587290
```



```

##
##
## Upper Band, CI= 0.95
## $DLINPC
##          DLINPC
## [1,] 0.002362796507
## [2,] 0.001065850520
## [3,] 0.000471149985
## [4,] 0.000266199991
## [5,] 0.000147449841
## [6,] 0.000097296667
## [7,] 0.000060926736
## [8,] 0.000029261321
## [9,] 0.000015848499
## [10,] 0.000011015886
## [11,] 0.000008967841
## [12,] 0.000005612821
## [13,] 0.000002729922
##
## $DLTC
##          DLINPC
## [1,] 0.000000000000
## [2,] 0.000195652861
## [3,] 0.000652936510
## [4,] 0.000438051252
## [5,] 0.000153213815
## [6,] 0.000031057160
## [7,] 0.000032324978
## [8,] 0.000037650153
## [9,] 0.000033703376
## [10,] 0.000014107003
## [11,] 0.000003844765
## [12,] 0.000003370530
## [13,] 0.000003225092
##
## $DLCETE28
##          DLINPC
## [1,] 0.000000000000
## [2,] 0.000282522508
## [3,] 0.000356338416
## [4,] 0.000153947270
## [5,] 0.000119992900
## [6,] 0.000087638194
## [7,] 0.000046520320
## [8,] 0.000021718743
## [9,] 0.000009265402

```

```
## [10,] 0.000004995045
## [11,] 0.000003825128
## [12,] 0.000002492365
## [13,] 0.000001168148
##
## $DLIGAE
##          DLINPC
## [1,] 0.000000000000
## [2,] 0.000053029002
## [3,] 0.000122113355
## [4,] 0.000165727758
## [5,] 0.000119593545
## [6,] 0.000075889090
## [7,] 0.000028313521
## [8,] 0.000011974246
## [9,] 0.000011962327
## [10,] 0.000013674259
## [11,] 0.000006119498
## [12,] 0.000002781622
## [13,] 0.000001557107
##
## $DLIPI
##          DLINPC
## [1,] 0.000000000000
## [2,] 0.000331122721
## [3,] 0.000144030832
## [4,] 0.000064736977
## [5,] 0.000065074757
## [6,] 0.000035973151
## [7,] 0.000034499508
## [8,] 0.000020302466
## [9,] 0.000008355612
## [10,] 0.000003977985
## [11,] 0.000002565717
## [12,] 0.000002802144
## [13,] 0.000001089726
```

```
#plot(IR_DLINPC)
```

```
IR_DLTC <- irf(VAR_p, n.ahead = 12, boot = TRUE,
               ci = 0.95, response = "DLTC")
plot(IR_DLTC)
```

Los resultados muestran que la respuesta de $DLTC_t$ ante impulsos en los térmi-




Figura 5.4: Impulso - Respuesta en $DLTC_t$




Figura 5.5: Impulso - Respuesta en $DLTC_t$




Figura 5.6: Impulso - Respuesta en $DLTC_t$





Figura 5.7: Impulso - Respuesta en $DLTC_t$

Figura 5.8: Impulso - Respuesta en $DLTC_t$

nos de error fue estadísticamente significativa sólo para algunos de los casos y en periodos cortos de tiempo. El resto de los resultados de Impulso-Respuesta se puede replicar con el código disponible en el repositorio de GitHub del proyecto.

5.4 Identificación de los Choques Estructurales en los Modelos VAR

En su trabajo seminal “*Macroeconomics and Reality*”, Sims (1980) cuestionó los modelos macroeconómicos utilizados en ese momento. Antes de la aparición de los modelos de referencia modernos, como los Vectores Autorregresivos (VAR) y los modelos estocásticos dinámicos de equilibrio general (DSGE), se estimaban modelos de ecuaciones simultáneas derivados de la escuela keynesiana, especificados con n cantidad de ecuaciones. Por lo tanto, para entender el surgimiento de los modelos VAR en la macroeconometría, es necesario partir del contexto en el que se escribió el trabajo seminal de Sims.

A finales de los años 70 e inicios de los 80, comenzó una crisis en torno a los modelos estructurales tradicionales. Los modelos macroeconómicos de gran escala –como los de la Cowles Commission– utilizaban restricciones teóricas para identificar relaciones estructurales que, en muchos casos, eran impuestas de manera arbitraria. Estos modelos estaban altamente parametrizados y basados

en supuestos teóricos fuertes –como las expectativas adaptativas–, lo que los hacía sensibles a errores específicos. De esta situación surge en parte la *Crítica de Lucas*, en la cual Robert Lucas (1976) mostró que este tipo de modelos fallaba al capturar cambios en el comportamiento cuando las políticas cambiaban, debido a que no trataban adecuadamente las expectativas racionales.

Ante este panorama, Sims propuso los modelos VAR, lo que eventualmente le valió el Premio Nobel de Economía. El objetivo de estos modelos era ofrecer una alternativa más flexible y empíricamente realista, sin imponer supuestos estructurales fuertes a priori. De esta manera, los VAR permiten modelar un conjunto de variables macroeconómicas como funciones de sus propios rezagos, sin imponer una estructura teórica rígida. Además, todos los choques y relaciones se tratan inicialmente de forma simétrica y empírica. Así, los modelos VAR en su forma reducida son modelos completamente ateóricos.

Sin embargo, aunque los modelos VAR permiten capturar la dinámica conjunta entre variables sin imponer restricciones teóricas fuertes a priori, tienen una limitación que no es menor: los choques estimados a partir de la forma reducida –forma que hemos trabajado hasta ahora– están correlacionados entre sí. Es decir, los errores u_t de la forma reducida reflejan combinaciones lineales de múltiples choques estructurales y esto nos impide identificar la interacción contemporánea de las variables. Los choques u_t no se pueden interpretar directamente porque no son ortogonales. En este sentido, para encontrar choques estructurales, debemos encontrar choques w_t que sí sean ortogonales y tengan una interpretación económica.

Comencemos con la forma estructural del VAR para comprender sus parámetros:

$$B_0 y_t = B_1 y_{t-1} + \dots + B_p y_{t-p} + w_t \quad (5.20)$$

donde w_t es un término de error con media cero y no correlacionado en el tiempo, también conocido como innovación estructural o shock estructural. Además, se asume que el término de error es incondicionalmente homocedástico a menos de que se indique lo contrario. La matriz B_0 es no singular y establece la interacción contemporánea entre las variables del modelo. De este modo, el modelo puede escribirse de manera compacta como:

$$B(L)y_t = w_t \quad (5.21)$$

donde $B(L) \equiv B_0 - B_1 L - B_2 L^2 - \dots - B_p L^p$ es el polinomio autorregresivo en rezagos. La matriz de covarianza del término de error estructural es normalizada tal que:

$$\mathbb{E}(w_t w_t') \equiv \Sigma_w = I_K. \quad (5.22)$$

Con esto, sabemos que existen tantos shocks estructurales como variables en el modelo. Asimismo, los shocks estructurales, por definición, son mutuamente no correlacionados lo que implica que Σ_w es diagonal. Por último, también

sabemos que si normalizamos la varianza de todos los shocks estructurales a uno, no implica una pérdida de generalidad siempre y cuando los elementos diagonales B_0 permanezcan sin restricciones.

Sin embargo, para que el modelo $B_0 y_t = B_1 y_{t-1} + \dots + B_p y_{t-p} + w_t$ sea considerado como un VAR estructural no es suficiente con que los elementos de w_t no se encuentren correlacionados, sino que los choques también deben ser económicamente interpretables. Para esto, derivamos la forma reducida de este modelo VAR estructural de tal modo que y_t es una función de los rezagos de y_t únicamente. Si multiplicamos ambos lados de la representación estructural del VAR por B_0^{-1}

$$B_0^{-1} B_0 y_t = B_0^{-1} B_1 y_{t-1} + \dots + B_0^{-1} B_p y_{t-p} + B_0^{-1} w_t \quad (5.23)$$

de tal modo que puede ser representado como

$$y_t = A_1 y_{t-1} + \dots + A_p y_{t-p} + u_t \quad (5.24)$$

donde $A_i = B_0^{-1} B_i$, $i = 1, \dots, p$, y $u_t = B_0^{-1} w_t$. Así, las innovaciones en forma reducida de u_t son un promedio ponderado de los shocks estructurales w_t . De manera compacta, el modelo puede ser expresado como:

$$A(L)y_t = u_t \quad (5.25)$$

donde $A(L) = I_K - A_1 L - A_2 L^2 - \dots - A_p L^p$ es el polinomio autorregresivo en rezagos. Los métodos de estimación estándar permiten obtener estimaciones de los parámetros de la forma reducida A_i , para $i = 1, \dots, p$, de las innovaciones reducidas u_t y de su matriz de covarianza $\mathbb{E}(u_t u_t') \equiv \Sigma_u$.

Sin embargo, el debate que se ha generado desde entonces es, una vez estimada la forma reducida, de qué manera se puede recuperar la representación estructural del modelo VAR. Es decir, queremos recuperar la matriz B_0 -o bien, su inversa- que contiene las relaciones estructurales contemporáneas de las variables, recordando que $u_t = B_0^{-1} w_t$.

El método para recuperar dicha matriz ha generado gran debate en el análisis macroeconómico, dando pie incluso a tesis doctorales al respecto. Con esto en mente, ahora veremos algunos de los métodos clásicos para recuperar las relaciones estructurales de las variables. Nos concentraremos en los siguientes:

1. *Identificación Recursiva*
2. *Restricción de largo plazo*
3. *Imposición de restricciones de signo*

Nota: Los paquetes disponibles en R son un poco limitados en cuanto a los métodos de identificación de las innovaciones estructurales relacionados con la teoría económica. En los trabajos actuales de macroeconomía suele ocuparse, mayoritariamente, el método de Identificación Recursiva. Para los métodos de Restricción de largo plazo

y de Imposición de restricciones de signo, el repositorio del proyecto incluye un script de Matlab complementario.

5.4.1 VAR Recursivo - Identificación Recursiva

Una de las formas más populares para recuperar las innovaciones estructurales es mediante la *identificación recursiva*, un caso particular de las restricciones de corto plazo que se implementa utilizando la **descomposición de Cholesky**.

La idea detrás de este método es simple e intuitiva: queremos recuperar las innovaciones estructurales w_t a partir de las innovaciones de forma reducida u_t . Para lograr esto, buscamos *ortogonalizar* los errores de forma reducida, lo que en este contexto significa transformarlos en un conjunto de choques no correlacionados contemporáneamente. Es decir, deseamos que $\mathbb{E}[w_t w_t'] = I$.

Para lograr esto, definimos una matriz P de tamaño $K \times K$, triangular inferior y con diagonal principal positiva, de tal modo que:

$$\Sigma_u = \mathbb{E}[u_t u_t'] = P P' \quad (5.26)$$

La matriz P es conocida como la **descomposición de Cholesky inferior** de Σ_u . Por ejemplo, en un VAR con tres variables, P tendría la forma:

$$P = \begin{bmatrix} p_{11} & 0 & 0 \\ p_{21} & p_{22} & 0 \\ p_{31} & p_{32} & p_{33} \end{bmatrix}$$

Ahora, si recordamos que en el modelo estructural los errores están relacionados por $u_t = B_0^{-1} w_t$ y que

$$\Sigma_u = B_0^{-1} \mathbb{E}[w_t w_t'] B_0^{-1'} = B_0^{-1} B_0^{-1'} \quad (5.27)$$

entonces una solución válida al problema de identificación estructural es asumir que $B_0^{-1} = P$. Dado que P es triangular inferior, contiene exactamente $\frac{K(K-1)}{2}$ ceros impuestos, lo que cumple la condición de orden para identificar todos los elementos libres de la matriz B_0^{-1} . Por simetría, si B_0^{-1} es triangular inferior, entonces B_0 también lo es -aunque triangular superior-.

Sin embargo, es importante destacar que esta ortogonalización de los errores solo es válida si la estructura recursiva impuesta por la matriz P se puede justificar con fundamentos económicos. El método impone que la primera variable del sistema responde solo a su propio shock contemporáneo, la segunda puede responder al shock de la primera, la tercera a los dos primeros, y así sucesivamente. Por eso se dice que el modelo estructural resultante es recursivo: se impone una estructura jerárquica de causalidad contemporánea, en lugar de inferirla directamente de los datos.

En este sentido, la **descomposición de Cholesky** no descubre las relaciones estructurales sino que las impone. Por lo tanto, el orden de las variables en el VAR **sí importa**, ya que determina la interpretación de los shocks estructurales. Por esta razón, se recomienda justificar el orden mediante teoría económica. Por ejemplo, en aplicaciones del Banco de México, el orden se suele establecer de acuerdo con la hipótesis de una economía pequeña y abierta, ordenando las variables de la más exógena a la más endógena.

Veamos un ejemplo rápido de la *identificación recursiva* mediante la **descomposición de Cholesky**:

```
# install.packages("svars")
# install.packages("ggplot2")
# install.packages("ggfortify")
library(svars)
library(ggplot2)
library(ggfortify)


var.reducido <- vars::VAR(USA, lag.max = 10, ic = "AIC")
var.estructural <- id.chol(var.reducido)
summary(var.estructural)

##
## Identification Results
## -----
##
## Method: Cholesky
## Sample size: 169
##
## Estimated B Matrix (unique decomposition of the covariance
  ↪ matrix):
##           [,1]      [,2]      [,3]
## x  0.68338360 0.0000000 0.0000000
## pi -0.03642697 1.0726563 0.0000000
## i   0.22450359 0.1818031 0.7672318

# x = Porcentaje de desviación logarítmica del PIB real con
  ↪ respecto a la
#     estimación del producto potencial
# pi = Crecimiento anualizado trimestre a trimestre del deflactor
  ↪ del PIB
# i = Tasa de interés de los fondos federales

cores <- parallel::detectCores() - 1
boot.svar <- wild.boot(var.estructural, n.ahead = 24, nboot =
  ↪ 1000, nc = cores)
```

`plot(boot.svar)`



5.4.2 VAR Estructural - Restricción de largo plazo

Otra manera de identificar las innovaciones estructurales de un modelo VAR, es mediante el método propuesto por Blanchard y Quah (1989) en “*The Dynamic Effects of Aggregate Demand and Supply Disturbances*”.

La intuición de este método es simple: Blanchard y Quah querían medir el efecto de choques de oferta agregada w_t^{AS} y demanda agregada w_t^{AD} sobre el Producto y el Desempleo, imponiendo restricciones en la respuesta acumulada, es decir, en el efecto acumulado permanente (horizonte $h \rightarrow \infty$). La lógica económica detrás de este método es, básicamente, que el choque de demanda agregada no tiene efectos de largo plazo sobre el nivel del PIB real.

Ahora bien, sean:

- ur_t : tasa de desempleo en EE.UU.
- gdp_t : logaritmo del PIB real de EE.UU.

Y definimos el vector z_t

$$z_t = \begin{bmatrix} \Delta gdp_t \\ ur_t \end{bmatrix} \sim I(0) \quad (5.28)$$

Aunque $gdp_t \sim I(1)$, su primera diferencia es estacionaria ($I(0)$), lo cual justifica que $z_t \sim I(0)$. Por otro lado, podemos suponer que este vector es generado por un VAR reducido:

$$A(L)z_t = u_t \quad (5.29)$$

donde $A(L) = I_2 - A_1L - \dots - A_pL^p$, y $u_t \sim (0, \Sigma_u)$ es ruido blanco. Si lo representamos como su forma estructural, tenemos que:

$$B(L)z_t = w_t \quad (5.30)$$

donde $B(L) = B_0 - B_1L - \dots - B_pL^p = B_0A(L)$, y si recordamos a qué es igual w_t , tenemos que:

$$w_t = B_0u_t \rightarrow u_t = B_0^{-1}w_t \rightarrow \Sigma_u = B_0^{-1}(B_0^{-1})' \quad (5.31)$$

Ahora, pasemos a la representación MA estructural para entender dónde se impone la restricción. Desde el modelo MA, tenemos que:

$$z_t = B(L)^{-1}w_t = \Theta(L)w_t \quad (5.32)$$

Esto implica que, dado que $z_t \sim I(0)$, el efecto de un choque estructural sobre z_t se desvanece con el tiempo y, por tanto, tanto Δgdp_t como ur_t eventualmente vuelven a su nivel original tras un choque. Sin embargo, el nivel del PIB real -y no su crecimiento- no necesariamente vuelve a su nivel inicial, por lo que la suma acumulada de las respuestas al choque nos da su efecto permanente. Ahora, pasemos a la matriz de efectos acumulados de largo plazo, definida como:

$$\Theta(1) = \sum_{i=0}^{\infty} \Theta_i = B(1)^{-1} \quad (5.33)$$

Dado que queremos que el PIB real vuelva a su tendencia tras un choque de demanda -recordemos que no tiene efectos de largo plazo- implica imponer un cero en la posición θ_{12} de la matriz $\Theta(1)$:

$$\Theta(1) = \begin{bmatrix} \theta_{11}(1) & 0 \\ \theta_{21}(1) & \theta_{22}(1) \end{bmatrix} \quad (5.34)$$

el hecho de que $\theta_{12}(1) = 0$ implica que el choque de demanda no afecta permanentemente al PIB real y, por otro lado, que $\theta_{11}(1)$ permanezca libre, implica que los choques de oferta sí pueden tener efectos de largo plazo.

Para la identificación, recordemos que:

$$\Theta(1) = B(1)^{-1} = A(1)^{-1}B_0^{-1} \rightarrow B_0^{-1} = A(1)\Theta(1) \quad (5.35)$$

De este modo, una vez que conocemos $A(1)$ y $\Theta(1)$ podemos recuperar B_0^{-1} , recordando que la restricción en $\Theta(1)$ es equivalente a imponer una restricción sobre B_0 .

Para estimar $\Theta(1)$, sabemos que:

$$\Sigma_u = B_0^{-1}(B_0^{-1})' = \Theta(1)\Theta(1)' \quad (5.36)$$

y, entonces, si usamos $A(1)$:

$$A(1)^{-1}\Sigma_u A(1)^{-1'} = \Theta(1)\Theta(1)' \quad (5.37)$$

lo cual implica que podemos calcular el lado izquierdo usando solo parámetros estimados del VAR reducido y luego identificar $\Theta(1)$ imponiendo que tenga forma triangular inferior, y aplicar la **descomposición de Cholesky** para tener finalmente que:

$$B_0^{-1} = A(1)\Theta(1) \quad (5.38)$$

5.4.3 VAR Estructural - Imposición de restricciones de signo

Una alternativa a la identificación de las innovaciones estructurales además de la *Identificación recursiva* es la **Imposición de restricciones de signo**. Sigue un poco la misma lógica: queremos imponer restricciones de signo en vez de proponer una matriz triangular inferior en la matriz B_0^{-1} . Este método ofrece una alternativa menos restrictiva que imponer ceros exactos. Para explicar este método, tomemos el siguiente modelo ejemplo.

Consideremos un modelo bivariado de un mercado de bienes con:

- Un choque de demanda $w_t^{demanda}$
- Un choque de oferta w_t^{oferta}

en donde nuestras variables observables son:

- Precio p_t
- Cantidad q_t

Y los errores en forma reducida están dados por:

$$u_t = \begin{bmatrix} u_t^q \\ u_t^p \end{bmatrix} = B_0^{-1} w_t \quad \text{donde} \quad w_t = \begin{bmatrix} w_t^{oferta} \\ w_t^{demanda} \end{bmatrix} \quad (5.39)$$

Es sencillo: la interpretación económica es que los efectos de los choques u_t dependen de la pendiente de las curvas de demanda y oferta.

En un método tradicional -restricción de exclusión-, se asume que la oferta es vertical en el corto plazo, lo cual implica que los choques de demanda no afectan la cantidad contemporáneamente:

$$\begin{bmatrix} u_t^q \\ u_t^p \end{bmatrix} = \begin{bmatrix} * & 0 \\ * & * \end{bmatrix} \begin{bmatrix} w_t^{oferta} \\ w_t^{demanda} \end{bmatrix} \quad (5.40)$$

En donde los asteriscos representan *coeficientes libres* y el cero es una *restricción de exclusión*.

En cambio, si tomamos la teoría económica básica en el enfoque alternativo de **Imposición de restricción de signo** esperaríamos que, ante un choque de oferta positivo -la curva de oferta se desplaza a la derecha-, la cantidad aumente y el precio caiga, mientras que, ante un choque de demanda positiva -la curva de demanda se desplaza a la derecha-, la cantidad aumenta y el precio aumenta. De este modo, tenemos que:

$$\begin{bmatrix} u_t^q \\ u_t^p \end{bmatrix} = \underbrace{\begin{bmatrix} + & + \\ - & + \end{bmatrix}}_{B_0^{-1}} \begin{bmatrix} w_t^{oferta} \\ w_t^{demanda} \end{bmatrix} \quad (5.41)$$

Donde + indica signo positivo estricto y - negativo estricto.

La diferencia clave con el método de *Identificación recursiva mediante la descomposición de Cholesky* es que, en estos últimos modelos, los parámetros están puntualmente identificados mientras que con **restricciones de signo** los parámetros no se identifican exactamente, sino que quedan dentro de un conjunto compatible con las restricciones. De este modo, no hay una única solución, pues hay muchas matrices B_0^{-1} que cumplen con los signos impuestos. También, se pueden imponer **restricciones de signo** de la siguiente forma:

$$\begin{bmatrix} + & + \\ 0 & + \end{bmatrix} \quad \text{o} \quad \begin{bmatrix} + & + \\ - & 0 \end{bmatrix} \quad (5.42)$$

Estas formas también pueden ser admisibles pero algunas podrían llegar a ser problemáticas si llevan a choques no identificables entre sí.

Se dice que los modelos identificados por signos son más generales que los recursivos pero no son modelos “anidados”, o sea, uno no puede validar o rechazar el otro con datos. Así, las **restricciones de signo** permiten más flexibilidad, pero imponen otras limitaciones como perder identificación puntual.

Ahora, de manera más puntual, para imponer las **restricciones de signo estáticas** consideremos un modelo VAR en su forma estructural:

$$B_0 y_t = B_1 y_{t-1} + \dots + B_p y_{t-p} + w_t \quad (5.43)$$

y normalizamos la matriz de varianzas-covarianzas del término de error estructural w_t tal que:

$$\mathbb{E}(w_t w_t') \equiv \Sigma_w = I_K. \quad (5.44)$$

Ahora, sea $u_t = P\eta_t$, donde u_t es la innovación del VAR en forma reducida y P es la descomposición de Cholesky de Σ_u . Por construcción, los choques η_t son mutuamente no correlacionados y tienen varianza unitaria. Por supuesto, no hay razón para que estos choques correspondan a choques estructurales económicamente interpretables, como los choques de oferta y demanda en el modelo bivariado mencionado anteriormente. Sin embargo, podemos buscar soluciones candidatas w_t^* para los choques estructurales desconocidos w_t construyendo un gran número de combinaciones de los choques η_t de la forma:

$$w_t^* = Q'\eta_t, \quad (5.45)$$

donde Q' es una matriz ortogonal cuadrada tal que $Q'Q = QQ' = I_K$ y $u_t = PQ\eta_t = PQw_t^*$. Por lo tanto, cada solución candidata w_t^* consiste en choques no correlacionados con varianza unitaria. Que una de estas soluciones candidatas w_t^* sea una solución admisible para el choque estructural desconocido w_t , dado el vector de parámetros en forma reducida, depende de si la matriz de impacto estructural implicado PQ satisface las restricciones de signo mantenidas sobre B_0^{-1} . De este modo, solo conservamos las soluciones que satisfagan las restricciones de signo y se descartan las demás. El hecho de repetir este procedimiento nos permite caracterizar el conjunto de todos los modelos estructurales que son consistentes con las restricciones de signo mantenidas y los parámetros en forma reducida. Conocer PQ permite construir todos los coeficientes estructurales de respuesta al impulso que se derivan de las estimaciones de los parámetros en forma reducida.

Los dos enfoques comunes para construir las matrices ortogonales Q están basados en:

1. Matrices de rotación de Givens.
2. Transformación de Householder.

La paquetería del código de MatLab, VAR Toolbox, ocupa el enfoque de **Matrices de rotación de Givens**.

5.5 Cointegración

Hasta ahora hemos usado el supuesto de que las series son estacionarias para el conjunto de técnicas $ARMA(p, q)$ y $VAR(p)$. No obstante, dado que relajamos el supuesto de estacionariedad (incluyendo la estacionariedad en varianza) y que establecimos una serie de pruebas para determinar cuándo una serie es estadísticamente estacionaria, ahora podemos plantear una técnica llamada Cointegración. Para esta técnica consideraremos sólo series que son $I(1)$ y reconoceremos que se originó con los trabajos de Engle y Granger (1987), Stock (1987) y Johansen (1988).

5.5.1 Definición y propiedades del proceso de cointegración

Cointegración puede ser caracterizada o definida en palabras sencillas como que dos o más variables tienen una relación común estable en el largo plazo. Es decir, estas no suelen tomar caminos o trayectorias diferentes, excepto por períodos de tiempo transitorios y eventuales. A continuación, utilizaremos la definición de Engle y Granger (1987) de cointegración.

Sea $\mathbf{Y}$ un vector de k -series de tiempo, decimos que los elementos en $\mathbf{Y}$ están cointegrados en un orden (d, c) , es decir, $\mathbf{Y} \sim CI(d, c)$, si todos los elementos de $\mathbf{Y}$ son series integradas de orden d , $I(d)$, y si existe al menos una combinación lineal no trivial $\mathbf{Z}$ de esas variables que es de orden $I(d - c)$, donde $d \geq c > 0$, si y sólo si:

$$\beta'_i \mathbf{Y}_t = \mathbf{Z}_{it} \sim I(d - c) \quad (5.46)$$

Donde $i = 1, 2, \dots, r$ y $r < k$.

A los diferentes vectores β_i se les denomina como vectores de cointegración. El rango de la matriz de vectores de cointegración r es el número de vectores de cointegración linealmente independientes. En general diremos que los vectores de la matriz de cointegración β tendrán la forma de:

$$\beta' \mathbf{Y}_t = \mathbf{Z}_t \quad (5.47)$$

Antes de continuar hagamos algunas observaciones. Si todas las variables de $\mathbf{Y}$ son $I(1)$ y $0 \leq r < k$, diremos que las series no cointegran si $r = 0$. Si esto pasa,

entonces, como demostraremos más adelante, la mejor opción será estimar un modelo VAR(p) en diferencias. Adicionalmente, asumiremos que $c = d = 1$, por lo que la relación de cointegración, en su caso, generará combinaciones lineales $\mathbf{Z}$ estacionarias.

5.5.2 Cointegración para modelos de más de una ecuación o para modelos basados en Vectores Autorregresivos

Sean $Y_1, Y_2, \dots, Y_k$ las series que forman $\mathbf{Y}$, todas ellas $I(1)$; entonces los siguientes casos son posibles:

1. Si $r = 1$ entonces existe una única relación de cointegración y el caso puede analizarse con el enfoque de Engle y Granger.
2. Si $r > 1$ entonces se trata de un caso de cointegración múltiple, que requiere el enfoque de Johansen.

Por lo anterior, en estas notas analizaremos el caso de Cointegración de Johansen, que cubre ambas situaciones. Ahora plantearemos la forma de estimar el proceso de cointegración. El primer paso para ello es determinar un modelo VAR(p) con las k -series no estacionarias (series en niveles)—en este punto se vuelve fundamental caracterizar las series a través de pruebas de raíces unitarias—. Elegimos el valor de p mediante el uso de los criterios de información. De esta forma tendremos una especificación similar a:

$$\mathbf{Y}_t = \sum_{j=1}^p \mathbf{A}_j \mathbf{Y}_{t-j} + \mathbf{D}_t + \mathbf{U}_t \quad (5.48)$$

Donde $\mathbf{U}_t$ es un término de error k -dimensional puramente aleatorio; $\mathbf{D}_t$ contiene los componentes determinísticos de constante y tendencia, y $\mathbf{A}_i$, $i = 1, 2, \dots, p$, son matrices de $k \times k$ coeficientes. Notemos que el VAR(p) involucrado en este caso, a diferencia del VAR anteriormente estudiado, puede incluir un término de tendencia. Esto en razón de que hemos relajado el concepto de estacionariedad.

Si reescribimos la ecuación (5.48) en su forma de Vector Corrector de Errores (VEC, por sus siglas en inglés), restamos $\mathbf{Y}_{t-1}$ en ambos lados y usamos la

identidad $\mathbf{Y}_{t-j} = \mathbf{Y}_{t-1} - \sum_{i=1}^{j-1} \Delta \mathbf{Y}_{t-i}$ válida para $j \geq 2$:

$$\begin{aligned}
 \Delta \mathbf{Y}_t &= \sum_{j=1}^p \mathbf{A}_j \mathbf{Y}_{t-j} + \mathbf{D}_t - \mathbf{Y}_{t-1} + \mathbf{U}_t \\
 &= (\mathbf{A}_1 - \mathbf{I}) \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \dots + \mathbf{A}_p \mathbf{Y}_{t-p} + \mathbf{D}_t + \mathbf{U}_t \\
 &= \left(\sum_{j=1}^p \mathbf{A}_j - \mathbf{I} \right) \mathbf{Y}_{t-1} - \sum_{j=2}^p \mathbf{A}_j \sum_{i=1}^{j-1} \Delta \mathbf{Y}_{t-i} + \mathbf{D}_t + \mathbf{U}_t \\
 &= \left(\sum_{j=1}^p \mathbf{A}_j - \mathbf{I} \right) \mathbf{Y}_{t-1} + \sum_{j=1}^{p-1} \mathbf{A}_j^* \Delta \mathbf{Y}_{t-j} + \mathbf{D}_t + \mathbf{U}_t \\
 &= - \left(\mathbf{I} - \sum_{j=1}^p \mathbf{A}_j \right) \mathbf{Y}_{t-1} + \sum_{j=1}^{p-1} \mathbf{A}_j^* \Delta \mathbf{Y}_{t-j} + \mathbf{D}_t + \mathbf{U}_t \\
 \Delta \mathbf{Y}_t &= -\Pi \mathbf{Y}_{t-1} + \sum_{j=1}^{p-1} \mathbf{A}_j^* \Delta \mathbf{Y}_{t-j} + \mathbf{D}_t + \mathbf{U}_t \tag{5.49}
 \end{aligned}$$

Donde $\mathbf{A}_j^* = -\sum_{i=j+1}^p \mathbf{A}_i$, para $j = 1, 2, \dots, p-1$, y la matriz Π captura todas las relaciones de largo plazo entre las variables. Para que exista cointegración, Π debe tener rango reducido r , con $0 \leq r < k$. Por lo tanto, tenemos que dicha matriz en la ecuación (5.49) se puede factorizar como:

$$\Pi_{(k \times k)} = \Gamma_{(k \times r)} \beta'_{(r \times k)} \tag{5.50}$$

Donde $\beta'_{(r \times k)} \mathbf{Y}_{t-1}$ son r combinaciones linealmente independientes que son estacionarias.

Dada la ecuación (5.49) podemos establecer la aproximación de Johansen (1988) que se realiza mediante una estimación por Máxima Verosimilitud de la ecuación:

$$\Delta \mathbf{Y}_t + \Gamma \beta' \mathbf{Y}_{t-1} = \sum_{j=1}^{p-1} \mathbf{A}_j^* \Delta \mathbf{Y}_{t-j} + \mathbf{D}_t + \mathbf{U}_t \tag{5.51}$$

Donde una vez estimado el sistema:

$$\beta = [v_1, v_2, \dots, v_r] \tag{5.52}$$

Cada v_i , $i = 1, 2, \dots, r$ es un vector propio que está asociado con los r valores propios positivos, mismos que están asociados con la prueba de hipótesis de cointegración. Dicha hipótesis está basada en dos estadísticas con las que se determina el rango r de Π :

1. Prueba de Traza: H_0 : Existen al menos r valores propios positivos o Existen al menos r relaciones de largo plazo estacionarias.

2. Prueba del valor propio máximo o λ_{max} : H_0 : Existen r valores propios positivos o Existen r relaciones de largo plazo estacionarias.

Ejemplo. Para ejemplificar el procedimiento de cointegración utilizaremos las series de INPC, Tipo de Cambio, rendimiento de los Cetes a 28 días, IGAE e Índice de Producción Industrial de Estados Unidos. Quizá el marco teórico de la relación entre las variables no sea del todo correcto, pero dejando de lado ese problema, estimaremos si las 5 series cointegran.

Por principio, probaremos que todas las series son $I(1)$, lo cual es cierto (ver Script para mayores detalles). En las Figuras 5.9, 5.10 y 5.11 se muestran las series en niveles y en diferencias, con lo cual ilustramos como es viable que las series sean $I(1)$.

```
library(ggplot2)
library(dplyr)
library(stats)
library(MASS)
library(strucchange)
library(zoo)
library(sandwich)
library(urca)
library(lmtest)
library(vars)

#
load("BD/Datos_Ad.RData")

#
### Conversión a series de tiempo
Datos <- ts(Datos_Ad[7: 11],
            start = c(2000, 1),
            freq = 12)

LDatos <- log(Datos)

DLDatos <- diff(log(Datos, base = exp(1)),
               lag = 1,
               differences = 1)

plot(LDatos,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     #main = "Series en Logaritmos",
     xlab = "Tiempo")
```




Figura 5.9: Series en niveles (logaritmos) para la prueba de Cointegración

```
plot(DLDatos,
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     #main = "Series en Diferencias Logaritmicas",
     xlab = "Tiempo")
```

```
plot(cbind(LDatos, DLDatos),
     plot.type = "m", nc = 2,
     col = c("darkgreen", "darkblue", "darkred", "orange",
             ↪ "purple"),
     #main = "Comparación de Series en Diferencias",
     xlab = "Tiempo")
```

Posteriormente, determinamos cuál es el orden adecuado de un VAR(p) en niveles. En el Cuadro 5.8 mostramos los resultados de los criterios de información para determinar el número de rezagos óptimos, el cual resultó en $p = 3$ para los




Figura 5.10: Series en Diferencias Logarítmicas para la prueba de Cointegración




Figura 5.11: Comparación de Series en Diferencias para la prueba de Cointegración

criterios AIC y FPE, y $p = 2$ para los criterios HQ y SC. Por lo tanto, decidiremos utilizar un VAR(3) con tendencia y constante. Note que es posible elegir otros modelos de VAR que incluyan: solo tendencia, solo constante o ninguno de estos elementos.

```
vs_niv <- VARselect(LDatos, lag.max = 10, type = "both")
crit_niv <- as.data.frame(t(vs_niv$criteria))
tab_niv <- data.frame(
  Rezagos = seq_len(nrow(crit_niv)),
  AIC      = round(crit_niv[, 1], 4),
  HQ       = round(crit_niv[, 2], 4),
  SC       = round(crit_niv[, 3], 4),
  FPE      = formatC(crit_niv[, 4], format = "e", digits = 3))
knitr::kable(
  tab_niv,
  col.names = c("Rezagos", "AIC", "HQ", "SC", "FPE"),
  caption   = paste("Criterios de información para diferentes",
                    "especificaciones de modelos VAR(p) con",
                    "↪ término",
                    "constante y tendencia de las series",
                    "↪ $LINPC_t$",
                    "$LTC_t$, $LCETE28_t$, $LIGAE_t$ y",
                    "↪ $LIPI_t$.") ,
  align     = c("c", "r", "r", "r", "r"),
  booktabs = TRUE,
  row.names = FALSE
)
```

Selección de rezagos VAR(p)

```
VARselect(LDatos, lag.max = 10, type = "both")
```

```
## $selection
## AIC(n)  HQ(n)  SC(n) FPE(n)
##      3      2      2      3
##
## $criteria
##                                1
##      2
## AIC(n) -43.1308318646810135987834656
##      -43.5668661854371990216350241
## HQ(n)  -42.9445592539269327403417265
##      -43.2475417098587726627556549
## SC(n)  -42.6668499811502783813921269
##      -42.7714686708130784609238617
```



```
## HQ(n) -42.3730894555203079221428197
  ↪ -42.3299427172535587260426837
## SC(n) -40.9051975851294216113274160
  ↪ -40.6636870805936325723450864
## FPE(n) 0.0000000000000000001491718
  ↪ 0.0000000000000000001368875
##
  ↪ 9
  ↪ 10
## AIC(n) -43.3742641642367701138027769
  ↪ -43.3660356138277762738653109
## HQ(n) -42.1235766348879465681420697
  ↪ -41.9822962196546143331943313
## SC(n) -40.2589572319589734661349212
  ↪ -39.9193130504566013883049891
## FPE(n) 0.0000000000000000001480478
  ↪ 0.0000000000000000001502148
```

```
VARselect(LDatos, lag.max = 10, type = "trend")
```

```
## $selection
## AIC(n) HQ(n) SC(n) FPE(n)
##      3      2      2      3
##
## $criteria
##
  ↪ 1
  ↪ 2
## AIC(n) -43.0218334558386885646541486
  ↪ -43.4733608627676417768270767
## HQ(n) -42.8621712180494753852144640
  ↪ -43.1806467601540902023771196
## SC(n) -42.6241346985266318370122463
  ↪ -42.7442464743621997058653506
## FPE(n) 0.0000000000000000002069525
  ↪ 0.0000000000000000001317817
##
  ↪ 3
  ↪ 4
## AIC(n) -43.4926570116813877575623337
  ↪ -43.4403901004477006608794909
## HQ(n) -43.0668910442434906826747465
  ↪ -42.8815722681854651909816312
## SC(n) -42.4321269921825603432807839
  ↪ -42.0484444498554950087054749
## FPE(n) 0.0000000000000000001293226
  ↪ 0.0000000000000000001363788
```

```
## 5
  ↪ 6
## AIC(n) -43.4055918510038054591859691
  ↪ -43.3210122680509144288407697
## HQ(n) -42.7137221539172173834231216
  ↪ -42.4960907061399879580676497
## SC(n) -41.6822305693182144636921294
  ↪ -41.2662353552719451954544638
## FPE(n) 0.000000000000000001414042
  ↪ 0.000000000000000001541996
## 7
  ↪ 8
## AIC(n) -43.3018930975745490741246613
  ↪ -43.3631837990786621617189667
## HQ(n) -42.3439196708392771029139112
  ↪ -42.2721585075190517954979441
## SC(n) -40.9157005537021944974185317
  ↪ -40.6455756241129293471203709
## FPE(n) 0.000000000000000001576227
  ↪ 0.000000000000000001488111
## 9
  ↪ 10
## AIC(n) -43.3123078988938914335449226
  ↪ -43.289311818269602838427090
## HQ(n) -42.0882307425099355668862700
  ↪ -41.932182797061308576758165
## SC(n) -40.2632840928347732756265032
  ↪ -39.908872381117106442616205
## FPE(n) 0.000000000000000001573361
  ↪ 0.00000000000000000161972
```

```
VARselect(LDatos, lag.max = 10, type = "const")
```

```
## $selection
## AIC(n) HQ(n) SC(n) FPE(n)
##      3      2      2      3
##
## $criteria
## 1
  ↪ 2
## AIC(n) -43.0529318587713945021278050
  ↪ -43.495191294123372927060700
## HQ(n) -42.8932696209821813226881204
  ↪ -43.202477191509821352610743
```



```

## SC(n) -42.6552331014593377744859026
  ↪ -42.766076905717930856098974
## FPE(n) 0.000000000000000002006156
  ↪ 0.00000000000000000128936
##
  ↪ 3
  ↪ 4
## AIC(n) -43.5086218228659333817631705
  ↪ -43.4510965812944505159975961
## HQ(n) -43.0828558554280363068755833
  ↪ -42.8922787490322150460997364
## SC(n) -42.4480918033671059674816206
  ↪ -42.0591509307022448638235801
## FPE(n) 0.000000000000000001272744
  ↪ 0.000000000000000001349265
##
  ↪ 5
  ↪ 6
## AIC(n) -43.4144752420798099024068506
  ↪ -43.325553474358613925687678
## HQ(n) -42.7226055449932289320713608
  ↪ -42.500631912447687454914558
## SC(n) -41.6911139603942189069130109
  ↪ -41.270776561579644692301372
## FPE(n) 0.000000000000000001401536
  ↪ 0.00000000000000000153501
##
  ↪ 7
  ↪ 8
## AIC(n) -43.3069657328556019137977273
  ↪ -43.3724989978216228792007314
## HQ(n) -42.3489923061203299425869773
  ↪ -42.2814737062620125129797088
## SC(n) -40.9207731889832473370915977
  ↪ -40.6548908228558900646021357
## FPE(n) 0.000000000000000001568252
  ↪ 0.000000000000000001474313
##
  ↪ 9
  ↪ 10
## AIC(n) -43.316467649333738165751129
  ↪ -43.2911053192979622394886974
## HQ(n) -42.092390492949782299092476
  ↪ -41.9339762980896679778197722
## SC(n) -40.267443843274620007832709
  ↪ -39.9106658821454658436778118
## FPE(n) 0.00000000000000000156683
  ↪ 0.000000000000000001616817

```

```
VARselect(LDatos, lag.max = 10, type = "none")
```

```
## $selection
## AIC(n)  HQ(n)  SC(n) FPE(n)
##      3      2      2      3
##
## $criteria
##                                     1
##      2
## AIC(n) -43.009650989538556586921914
##      -43.4653473630038362784944184
## HQ(n)  -42.876599124714218191911641
##      -43.1992436333551523830465158
## SC(n)  -42.678235358445178349029447
##      -42.8025161008170726972821285
## FPE(n)  0.00000000000000000209486
##      0.000000000000000001328347
##                                     3
##      4
## AIC(n) -43.4961615576300175689539174
##      -43.4416013221261536614292709
## HQ(n)  -43.0970059631569952784957422
##      -42.9093938628287787651061080
## SC(n)  -42.5019146643498757498491614
##      -42.1159387977526264990046911
## FPE(n)  0.000000000000000001288547
##      0.000000000000000001361851
##                                     5
##      6
## AIC(n) -43.3978234579566617412638152
##      -43.31937496312242075191534
## HQ(n)  -42.7325641338349484499303799
##      -42.52106377417636196014428
## SC(n)  -41.7407453024897563409467693
##      -41.33088117656213000827847
## FPE(n)  0.000000000000000001424605
##      0.0000000000000000015438
##                                     7
##      8
## AIC(n) -43.2856068136311264993310033
##      -43.342694393587237300380366
## HQ(n)  -42.3542437598607293125496653
##      -42.278279474992494613161398
## SC(n)  -40.9656973959774575178016676
##      -40.691369344840175870103849
```


Cuadro 5.9: Prueba de la traza para cointegración considerando un VAR(3) con término constante de las series $LINPC_t$, LTC_t , $LCETE28_t$, $LIGAE_t$ y $LIPI_t$.

Hipótesis nula	Estadística	10%	5%	1%
$r \leq 4$	4.79	7.52	9.24	12.97
$r \leq 3$	13.97	17.85	19.96	24.60
$r \leq 2$	27.45	32.00	34.91	41.07
$r \leq 1$	48.14	49.65	53.12	60.16
$r = 0$	118.98	71.86	76.07	84.45

```
booktabs = TRUE,
escape    = FALSE,
row.names = FALSE
)
```

Los resultados del Cuadro 5.9 indican que aceptamos la hipótesis nula para el caso de $r \leq 1$ al 5%, por lo que podemos concluir que existe evidencia estadística para probar que existe al menos 1 vector de cointegración. Por lo que dicho vector normalizado a la primera entrada es:

$$\beta = \begin{bmatrix} 1.00000000 \\ 0.2100057 \\ 0.4812626 \\ -2.8386112 \\ -1.2576912 \\ 14.2887887 \end{bmatrix} \quad (5.53)$$

Donde el vector esta normalizado para la serie $LINPC_t$, por lo que concluimos que la relación de largo plazo que encontramos cointegra estará dada por:

$$\begin{aligned} LINPC_t &= -0.2100057LTC_t - 0.4812626LCETE28_t \\ &\quad + 2.8386112LIGAE_t + 1.2576912LIPI_t \\ &\quad - 14.2887887 \end{aligned}$$

```
### Estimación del VAR(p)

VAR_1 <- VAR(LDatos, p = 3, type = "both")

#summary(VAR_1)

#plot(VAR_1, names = "INPC_Ad")
#plot(VAR_1, names = "TC_Ad")
```

```

#plot(VAR_1, names = "CETE28_Ad")
#plot(VAR_1, names = "IGAE_Ad")
#plot(VAR_1, names = "IPI_Ad")

# Cointegration Test:
#ca.jo = function (x, type = c("eigen", "trace"), ecdet =
  ↪ c("none", "const",
# "trend"), K = 2, spec = c("longrun", "transitory"), season =
  ↪ NULL,
#dumvar = NULL)

#summary(ca.jo(LDatos, type = "trace", ecdet = "trend", K = 3,
  ↪ spec = "longrun"))

#summary(ca.jo(LDatos, type = "trace", ecdet = "const", K = 3,
  ↪ spec = "longrun"))

#summary(ca.jo(LDatos, type = "trace", ecdet = "none", K = 3,
  ↪ spec = "longrun"))

summary(CA_1)

```

```

##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: trace statistic , without linear trend and constant
  ↪ in cointegration
##
## Eigenvalues (lambda):
## [1] 0.2242278157790942305638 0.0714829742929301154009
## [3] 0.0471697381127354625763 0.0323558252755368550013
## [5] 0.0170373866386099859227 0.0000000000000001925707
##
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 4 |    4.79  7.52  9.24 12.97
## r <= 3 |   13.97 17.85 19.96 24.60
## r <= 2 |   27.45 32.00 34.91 41.07
## r <= 1 |   48.14 49.65 53.12 60.16
## r = 0  |  118.98 71.86 76.07 84.45
##
## Eigenvectors, normalised to first column:

```

```
## (These are the cointegration relations)
##
##          INPC_Ad.13   TC_Ad.13   CETE28_Ad.13   IGAE_Ad.13
## INPC_Ad.13   1.0000000   1.0000000   1.0000000   1.0000000
## TC_Ad.13     0.2100057   0.3958412   0.6038714   -3.946863
## CETE28_Ad.13 0.4812626  -0.3505729   0.2932620   1.025381
## IGAE_Ad.13   -2.8386112  -4.9448228  -4.1431506   10.685831
## IPI_Ad.13    -1.2576912   0.8682351   2.2789480  -19.080015
## constant     14.2887887  13.2882018   1.6072247   43.673551
##          IPI_Ad.13   constant
## INPC_Ad.13   1.00000000   1.00000000
## TC_Ad.13     -0.66160415  -0.84381863
## CETE28_Ad.13 0.02134859   0.06866727
## IGAE_Ad.13   -1.62038123   1.32792512
## IPI_Ad.13     1.60589077  -3.05544132
## constant     -2.75645487   5.81151022
##
## Weights W:
## (This is the loading matrix)
##
##          INPC_Ad.13          TC_Ad.13   CETE28_Ad.13
## ↪ IGAE_Ad.13
## INPC_Ad.d   0.001551917   0.00004896886   0.0002254138
## ↪ -0.0001685412
## TC_Ad.d     0.002200808  -0.00575637923  -0.0293306746
## ↪ -0.0003866727
## CETE28_Ad.d -0.009399815  -0.02250446234  -0.0166361225
## ↪ -0.0160384399
## IGAE_Ad.d   0.001105776   0.01441007456   0.0023574644
## ↪ -0.0015712694
## IPI_Ad.d    0.001442047   0.01286401841  -0.0014986278
## ↪ -0.0011379265
##          IPI_Ad.13          constant
## INPC_Ad.d   -0.0002093347   0.000000000000001290255
## TC_Ad.d     0.0139760105  -0.0000000000000017253317
## CETE28_Ad.d -0.0111636433  -0.00000000000000295711342
## IGAE_Ad.d   0.0077903982   0.0000000000000030602278
## IPI_Ad.d    -0.0046051140   0.0000000000000027991698
```

Considerando lo anterior, podemos determinar $\hat{U}_t$ para esta ecuación de cointegración. En la Figura 5.12 mostramos los residuales estimados. Derivado de la inspección visual, parecería que estos no son estacionarios –cuando, de existir cointegración, deberían serlo–. De esta forma, una prueba deseable es aplicar todas las pruebas de raíces unitarias a esta serie para verificar que es $I(0)$; al hacerlo (el código está disponible en el repositorio del proyecto) se encuentra

que es posible que no sea estacionaria, por lo que la evidencia de cointegración debe tomarse con cautela.

```

TT <- ts(c(1:282),
        start = c(2000, 1),
        freq = 12)

U <- LDatos[ , 1] + 0.2100057 * LDatos[ , 2] + 0.4812626 * LDatos[ ,
  ↪ 3] - 2.8386112 * LDatos[ , 4] - 1.2576912 * LDatos[ , 5] +
  ↪ 14.2887887

#

plot(U,
     main = "Residuales de la Ecuación de Cointegración",
     type = "l",
     col = "darkred")

```




Figura 5.12: Residuales estimados de la ecuación de cointegración

5.6 Modelos ARDL

5.6.1 Teoría

Una vez que hemos analizado diversas técnicas de series de tiempo, el problema consiste en seleccionar el modelo correcto. La Figura 5.13 muestra un esquema o diagrama de cómo podríamos proceder para seleccionar el modelo correcto.

```
knitr::include_graphics("Plots/TimeSeries_Models.png")
```




Figura 5.13: Method selection for time series data. OLS: Ordinary least squares; VAR: Vector autoregressive; ARDL: Autoregressive distributed lags; ECM: Error correction models, retomado de: Shrestha y Bhatta [-@shresthabhatta2018]

En este caso incorporaremos a los modelos autoregressive distributed lag models (ARDL, por sus siglas en inglés). En estos casos el procedimiento de Johansen no podría aplicarse directamente cuando las variables incluidas son de un orden mixto o cuando simplemente todas no son estacionarias. Un modelo ARDL está basado en procedimientos de MCO.

Este tipo de modelos toma suficientes rezagos para capturar el mecanismo generador de datos. También es posible llegar a una especificación del mecanismo corrector de errores a partir de una transformación lineal del ARDL.

Consideremos la siguiente ecuación:

$$Y_t = \alpha + \delta X_t + \gamma Z_t + U_t \quad (5.54)$$

Dada la ecuación (5.54) podemos establecer su forma de mecanismo corrector de errores en forma ARDL dada por:

$$\begin{aligned}\Delta Y_t = & \alpha + \sum_{i=1}^p \beta_i \Delta Y_{t-i} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + \sum_{i=1}^p \gamma_i \Delta Z_{t-i} \\ & + \lambda_1 Y_{t-1} + \lambda_2 X_{t-1} + \lambda_3 Z_{t-1} + U_t\end{aligned}$$

Donde los coeficientes β_i , δ_i , γ_i representan la dinámica de corto plazo y las λ 's la dinámica de largo plazo.

La hipótesis nula (H_0) es que las $\lambda_1 + \lambda_2 + \lambda_3 = 0$, es decir, que no existe relación de largo plazo.

En la práctica estimamos una especificación con rezagos distribuidos:

$$Y_t = \alpha + \sum_{i=1}^p \beta_i Y_{t-i} + \sum_{i=1}^p \delta_i X_{t-i} + \sum_{i=1}^p \gamma_i Z_{t-i} + U_t \quad (5.55)$$

Además de verificar si las series involucradas son estacionarias y decidir el número de rezagos p mediante criterios de información.

5.6.2 Ejemplo

5.6.2.1 DESCRIPCIÓN DEL PROBLEMA

Supongamos que queremos modelar el logaritmo de dinero (M2) como una función de LRY (logarithm of real income), IBO (bond rate) e IDE (bank deposit rate).

- El problema es que la aplicación de una regresión de MCO en datos no estacionarios daría lugar a una regresión espúrea.
- Los parámetros estimados serían consistentes solo si las series estuvieran cointegradas.

5.6.2.2 Importamos Datos desde un dataset de R:

Utilizaremos un dataset integrado en la biblioteca ARDL de R. Se trata de un dataframe con 55 renglones y 5 variables en el período de 1974:Q1 a 1987:Q3 de las siguientes variables:

- LRM: logaritmo del dinero real (M2)
- LRY: logaritmo del ingreso real

- LPY: logaritmo del deflactor de precios
- IBO: tasa de los bonos
- IDE: tasa de los depósitos bancarios

```
library(zoo)
library(xts)
library(ARDL)

#
data(denmark)

names(denmark)
```

```
## [1] "LRM" "LRY" "LPY" "IBO" "IDE"
```

5.6.2.3 Procedimiento:

1. Calculamos un auto ARDL para determinar la combinación óptima de rezagos.

```
models <- auto_ardl(LRM ~ LRY + IBO + IDE, data = denmark,
  ↪ max_order = 5)

names(models)
```

```
## [1] "best_model" "best_order" "top_orders"
```

```
#
models$top_orders
```

```
##      LRM LRY IBO IDE      AIC
## 1      3   1   3   2 -251.0259
## 2      3   1   3   3 -250.1144
## 3      2   2   0   0 -249.6266
## 4      3   2   3   2 -249.1087
## 5      3   2   3   3 -248.1858
## 6      2   2   0   1 -247.7786
## 7      2   1   0   0 -247.5643
## 8      2   2   1   1 -246.6885
## 9      3   3   3   3 -246.3061
## 10     2   2   1   2 -246.2709
```

```
## 11  2  1  1  1 -245.8736
## 12  2  2  2  2 -245.7722
## 13  1  1  0  0 -245.6620
## 14  2  1  2  2 -245.1712
## 15  3  1  2  2 -245.0996
## 16  1  0  0  0 -244.4317
## 17  1  1  0  1 -243.7702
## 18  5  5  5  5 -243.3120
## 19  4  1  3  2 -243.0728
## 20  4  1  3  3 -242.4378
```

```
#
models$best_order
```

```
## LRM LRY IBO IDE
##  3  1  3  2
```

```
#
models$best_model
```

```
##
## Time series regression with "zooreg" data:
## Start = 1974 Q4, End = 1987 Q3
##
## Call:
## dynlm::dynlm(formula = full_formula, data = data, start =
##   start,
##   end = end)
##
## Coefficients:
## (Intercept)      L(LRM, 1)      L(LRM, 2)      L(LRM, 3)
##   LRY
##      2.6202      0.3192      0.5326      -0.2687
##   0.6728
##   L(LRY, 1)      IBO      L(IBM, 1)      L(IBM, 2)      L(IBM,
##   3)
##      -0.2574      -1.0785      -0.1062      0.2877
##   -0.9947
##      IDE      L(IDE, 1)      L(IDE, 2)
##      0.1255      -0.3280      1.4079
```

```
#
BestMod <- models$best_model
```

```
summary(BestMod)
```

```
##
## Time series regression with "zooreg" data:
## Start = 1974 Q4, End = 1987 Q3
##
## Call:
## dynlm::dynlm(formula = full_formula, data = data, start =
  ↪ start,
##     end = end)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.029939 -0.008856 -0.002562  0.008190  0.072577
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.6202     0.5678   4.615 0.00004187 ***
## L(LRM, 1)     0.3192     0.1367   2.336  0.024735 *
## L(LRM, 2)     0.5326     0.1324   4.024  0.000255 ***
## L(LRM, 3)    -0.2687     0.1021  -2.631  0.012143 *
## LRY           0.6728     0.1312   5.129 0.00000832 ***
## L(LRY, 1)    -0.2574     0.1472  -1.749  0.088146 .
## IB0          -1.0785     0.3217  -3.353  0.001790 **
## L(IB0, 1)    -0.1062     0.5858  -0.181  0.857081
## L(IB0, 2)     0.2877     0.5691   0.505  0.616067
## L(IB0, 3)    -0.9947     0.3925  -2.534  0.015401 *
## IDE           0.1255     0.5545   0.226  0.822161
## L(IDE, 1)    -0.3280     0.7213  -0.455  0.651847
## L(IDE, 2)     1.4079     0.5520   2.550  0.014803 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0191 on 39 degrees of freedom
## Multiple R-squared:  0.988, Adjusted R-squared:  0.9843
## F-statistic: 266.8 on 12 and 39 DF, p-value: <
  ↪ 0.00000000000000022
```

2. Estimamos el UECM (Modelo de Corrección de Error No Restringido) del ARDL subyacente.

```
UECM_BestMod <- uecm(BestMod)
```

```
summary(UECM_BestMod)
```

```
##
## Time series regression with "zooreg" data:
## Start = 1974 Q4, End = 1987 Q3
##
## Call:
## dynlm::dynlm(formula = full_formula, data = data, start =
## ↪ start,
## end = end)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.029939 -0.008856 -0.002562  0.008190  0.072577
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.62019    0.56777   4.615 0.00004187 ***
## L(LRM, 1)    -0.41685    0.09166  -4.548 0.00005154 ***
## L(LRY, 1)     0.41538    0.11761   3.532  0.00108 **
## L(IBO, 1)    -1.89172    0.39111  -4.837 0.00002093 ***
## L(IDE, 1)     1.20534    0.44690   2.697  0.01028 *
## d(L(LRM, 1)) -0.26394    0.10192  -2.590  0.01343 *
## d(L(LRM, 2))  0.26867    0.10213   2.631  0.01214 *
## d(LRY)        0.67280    0.13116   5.129 0.00000832 ***
## d(IBO)       -1.07852    0.32170  -3.353  0.00179 **
## d(L(IBO, 1))  0.70701    0.46874   1.508  0.13953
## d(L(IBO, 2))  0.99468    0.39251   2.534  0.01540 *
## d(IDE)        0.12546    0.55445   0.226  0.82216
## d(L(IDE, 1)) -1.40786    0.55204  -2.550  0.01480 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0191 on 39 degrees of freedom
## Multiple R-squared:  0.7458, Adjusted R-squared:  0.6676
## F-statistic: 9.537 on 12 and 39 DF, p-value: 0.00000003001
```

3. Estimamos el RECM (Modelo de Corrección de Error Restringido) del ARDL subyacente. Nota: se permite que la constante forme parte de la relación de corto plazo (caso 2), en lugar de la de largo plazo (caso 3).

```
RECM_BestMod <- recm(UECM_BestMod, case = 2)
```

```
summary(RECM_BestMod)
```

```
##
## Time series regression with "zooreg" data:
## Start = 1974 Q4, End = 1987 Q3
##
## Call:
## dynlm::dynlm(formula = full_formula, data = data, start =
## ↪ start,
##           end = end)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.029939 -0.008856 -0.002562  0.008190  0.072577
##
## Coefficients:
##              Estimate Std. Error t value    Pr(>|t|)
## d(L(LRM, 1)) -0.26394    0.09008  -2.930  0.005405 **
## d(L(LRM, 2))  0.26867    0.09127   2.944  0.005214 **
## d(LRY)        0.67280    0.11591   5.805 0.000000703 ***
## d(IB0)       -1.07852    0.30025  -3.592  0.000837 ***
## d(L(IB0, 1))  0.70701    0.44359   1.594  0.118300
## d(L(IB0, 2))  0.99468    0.36491   2.726  0.009242 **
## d(IDE)        0.12546    0.48290   0.260  0.796248
## d(L(IDE, 1)) -1.40786    0.48867  -2.881  0.006160 **
## ect          -0.41685    0.07849  -5.311 0.000003633 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01819 on 43 degrees of freedom
## (0 observations deleted due to missingness)
## Multiple R-squared:  0.7613, Adjusted R-squared:  0.7113
## F-statistic: 15.24 on 9 and 43 DF,  p-value: 0.00000000009545
```

4. Aplicamos la prueba de límites (*bounds test*) para la relación de largo plazo en niveles (cointegración).

```
bounds_f_test(BestMod, case = 2)
```

```
##
## Bounds F-test (Wald) for no cointegration
```

```
##
## data: d(LRM) ~ L(LRM, 1) + L(LRY, 1) + L(IBO, 1) + L(IDE, 1)
##       + d(L(LRM, 1)) + d(L(LRM, 2)) + d(LRY) + d(IBO) +
##       + d(L(IBO, 1)) + d(L(IBO, 2)) + d(IDE) + d(L(IDE, 1))
## F = 5.1168, p-value = 0.004418
## alternative hypothesis: Possible cointegration
## null values:
##      k      T
##      3 1000
```

5. Calculamos los multiplicadores de largo plazo (con errores estándar, estadísticos t y valores p).

```
multipliers(BestMod)
```

```
##      Term      Estimate Std. Error   t value
##      Pr(>|t|)
## 1 (Intercept)  6.2856579  0.7719160  8.142930
##      0.00000000006107445
## 2      LRY      0.9964676  0.1239310  8.040503
##      0.00000000008358472
## 3      IBO     -4.5381160  0.5202961 -8.722180
##      0.00000000001058619
## 4      IDE      2.8915201  0.9950853  2.905801
##      0.0060092393605960
```

```
#
Result <- coint_eq(BestMod, case = 2)
```

5.6.2.4 Gráfica de la ecuación de cointegración

```
Datos <- cbind.zoo(LRM = denmark[, "LRM"], Result)

Datos <- xts(Datos)

plot(Datos, legend.loc = "right")
```

5.7 Filtro Kalman

En secciones pasadas, entendimos la naturaleza del filtrado univariado como, por ejemplo, el *Filtro Hodrick-Prescott*. Este ha sido utilizado ampliamente en




Figura 5.14: Gráfica de la ecuación de cointegración

la literatura macroeconómica, sobre todo para la estimación del Producto Potencial y, de este modo, la Brecha del Producto. Sin embargo, este método presenta dos limitaciones importantes: 1) es univariado, es decir, únicamente se explica por sí mismo y, 2) el llamado “problema de colas”, que si bien entendimos que se puede solucionar aplicando la metodología de “colas pesadas”, la estimación del λ es un tanto ambigua.

De este modo, el **Filtro Kalman** puede ser una alternativa viable y metodológicamente robusta, sobre todo si queremos trabajar con variables no observables como el *Producto Potencial* o, incluso, la *Tasa de interés neutral*, variable clave en la decisión de Política Monetaria de los Bancos Centrales.

En este sentido, el **Filtro Kalman** nació a partir del artículo seminal de Rudolf E. Kálmán (1960) *A New Approach to Linear Filtering and Prediction Problems*. La idea principal de Kálmán era describir los procesos estocásticos con un modelo de “estado” y resolver, de alguna manera, el problema de estimación con un ciclo *predicción-corrección* ejecutado en tiempo real. Así, el **Filtro Kalman** es un algoritmo de estimación recursivo a partir de mediciones ruidosas. De este modo, también podemos entender al **Filtro Kalman** como una especie de filtro multivariado. Sus aplicaciones no se han limitado únicamente a la Economía, pues ha sido utilizado para trabajos de la *NASA* como el pronóstico de la posición y velocidad del *Apollo 11* en 1969.

5.7.1 Modelos Estado-Espacio y Teoría Económica

Para hacer uso del **Filtro Kalman**, necesitamos de un modelo estructural que vincule a nuestras variables (observables y no observables), representado en la *Forma Estado-Espacio*. En general, casi todos los modelos de series de tiempo pueden ser representados como *Modelos Estado-Espacio*. El modelo estructural puede basarse en la teoría económica como, por ejemplo, un modelo DSGE. Para efectos prácticos, tomaremos como ejemplo el *Modelo de Proyección Trimestral (QPM)* del IMF (2020). No nos enfocaremos en el por qué y cómo del *Modelo QPM*, pues el objetivo principal es entender el **Filtro Kalman** y su aplicación.

5.7.1.1 Modelo de Proyección Trimestral (QPM) del IMF (2020)

Supongamos una economía pequeña y abierta, en donde:

- **Demanda Agregada (Curva IS)**

$$\hat{y}_t = b_1 \hat{y}_{t-1} - b_2 mci_t + b_3 \hat{y}_t^* + \varepsilon_t^y \quad (5.56)$$

$$mci_t = b_4 \hat{r}_t + (1 - b_4)(-\hat{z}_t) \quad (5.57)$$

donde:

- $\hat{y}_t$ = Brecha del Producto Doméstico,
- $\hat{y}_{t-1}$ = Brecha del Producto Doméstico rezagada,
- mci_t = Índice de Condiciones Monetarias Real,
- $\hat{y}_t^*$ = Brecha del Producto Foráneo,
- ε_t^y = Choque de Demanda,
- $\hat{r}_t$ = Brecha de la tasa de interés real y
- $\hat{z}_t$ = Brecha del tipo de cambio real.

- **Inflación (Curva de Phillips)**

$$\pi_t = a_1 \pi_{t-1} + (1 - a_1)E\{\pi_{t+1}\} + a_2 rmc_t + \varepsilon_t^\pi \quad (5.58)$$

$$rmc_t = a_3 \hat{y}_t + (1 - a_3)\hat{z}_t \quad (5.59)$$

donde:

- π_t = Inflación,
- π_{t-1} = Inflación rezagada,
- $E\{\pi_{t+1}\}$ = Expectativa de inflación,
- rmc_t = Costo Marginal Real,
- ε_t^π = Choque de Oferta (cost-push shock),

- $\hat{y}_t$ = Brecha del Producto Doméstica y
- $\hat{z}_t$ = Brecha del tipo de cambio real.

• **Paridad Descubierta de Tasas de Interés (UIP)**

$$S_t = (1-e_1)\mathbb{E}_t\{S_{t+1}\} + e_1 \left[S_{t-1} + \frac{2(\pi_t - \pi_t^* + \Delta\bar{z}_t)}{4} + \frac{i_t^* - i_t + prem_t}{4} \right] + \varepsilon_s \quad (5.60)$$

donde:

- $\mathbb{E}_t\{S_{t+1}\}$ = Expectativas sobre el tipo de cambio nominal futuro,
- S_{t-1} = Tipo de cambio nominal rezagado,
- π_t = Inflación,
- π_t^* = Inflación foránea,
- $\Delta\bar{z}_t$ = Depreciación del tipo de cambio tendencial,
- i_t^* = Tasa de interés real foránea,
- i_t = Tasa de interés real doméstica,
- $prem_t$ = Premio Riesgo-País y
- ε_t = Choque del Tipo de cambio.

• **Función de Reacción de Política Monetaria (Regla de Taylor)**

$$i_t = g_1 i_{t-1} + (1 - g_1) \{i_t^n + g_2 (\mathbb{E}_t[\pi_{t+N}^4] - \pi_{t+N}^T) + g_3 \hat{y}_t\} + \varepsilon_t \quad (5.61)$$

donde:

- i_t = Tasa de interés (o política),
- i_{t-1} = Tasa de interés rezagada,
- i_t^n = Tasa de interés natural o neutral,
- $\mathbb{E}_t[\pi_{t+N}^4]$ = Inflación esperada (YoY) en el periodo $t+N$,
- π_{t+N}^T = Meta de inflación,
- $\hat{y}_t$ = Brecha del Producto Doméstica y
- ε_t = Choque de política monetaria no sistémico.

• **Bloque externo**

En este caso, todas las variables siguen procesos autorregresivos simples

Brecha del producto foráneo

$$\hat{y}_t^* = \rho_y \hat{y}_{t-1}^* + \varepsilon_t^{\hat{y}}$$

Tasa natural (tendencia) de interés real foránea

$$\tilde{r}_t^* = \rho_{\tilde{r}} \tilde{r}_{t-1}^* + (1 - \rho_{\tilde{r}}) \tilde{r}^{*SS} + \varepsilon_t^{\tilde{r}}$$

Tasa de interés nominal foránea

$$i_t^* = \rho_i i_{t-1}^* + (1 - \rho_i)(r_t^* + \pi_t^*) + \varepsilon_t^{i^*}$$

Brecha de la tasa de interés real foránea

$$\hat{r}_t^* = r_t^* - \tilde{r}_t^*$$

Tasa de interés real foránea

$$r_t^* = i_t^* - \pi_t^*$$

Inflación foránea

$$\pi_t^* = \rho_{\pi} \pi_{t-1}^* + (1 - \rho_{\pi}) \pi^{*SS} + \varepsilon_t^{\pi^*}$$

5.7.1.2 Modelos Estado-Espacio

La idea general detrás de los *Modelos Estado-Espacio* es que una (múltiples) variable observable $Y_1, \dots, Y_T$ depende de un posible estado no observable X_t que sigue un proceso estocástico. La relación entre Y_t y X_t es descrita por la **Ecuación de Observación**

$$Y_t = CX_t + v_t \quad (5.62)$$

donde C es una matriz de parámetros conocidos y v_t es un vector de errores observados (si los hay), los cuales son independientes e idénticamente distribuidos con media cero y matriz de covarianza R , es decir, $v_t \sim iid(0, R)$. De este modo, la ecuación (5.62) describe la relación estática entre las variables observables y no observables.

La ecuación que describe la dinámica de las variables de estado, también conocida como **Ecuación de Transición**, es definida como

$$X_t = AX_{t-1} + \varepsilon_t, \quad (5.63)$$

en donde A es una matriz de parámetros conocidos, ε_t es un vector de errores, los cuales son independientes e idénticamente distribuidos con media cero y matriz de covarianza Q , es decir, $\varepsilon_t \sim iid(0, Q)$. Adicionalmente, se asume que v_t y ε_t son independientes entre sí, es decir, $Cov(v_t, \varepsilon_t) = 0$.

En la *Figura 5.15* se puede observar un ejemplo de la relación de las variables en los *Modelos Estado-Espacio* en el *QPM* básico del IMF (2020).




Figura 5.15: State-space models. Recuperado de IMF [-@imf2020].

Afortunadamente, nuestro *Modelo QPM* está construido de tal manera que tenemos **ecuaciones de transición** y **observación** que vinculan las variables observables con las no observables:

```
% =====
% Basic Quarterly Projection Model (QPM)
% =====

!transition_variables
'Real GDP (100*log)'
  ↳ L_GDP
'Trend in Real GDP (100*log)'
  ↳ L_GDP_BAR
'Output Gap (in %)'
  ↳ L_GDP_GAP
'Quarterly Growth in Real GDP(in % pa)'
  ↳ DLA_GDP
'Real GDP Growth YoY (in % pa)'
  ↳ D4L_GDP
'Real GDP Trend Growth QoQ annualized (in % pa)'
  ↳ DLA_GDP_BAR

'Real Monetary Condition Index (in % pa)'
  ↳ MCI

'CPI (level, 100*log)'
  ↳ L_CPI
'CPI Inflation QoQ annualized (in % pa)'
  ↳ DLA_CPI
'Expected CPI Inflation QoQ annualized (in % pa)'
  ↳ E_DLA_CPI
'CPI Inflation YoY (in % pa)'
  ↳ D4L_CPI
```

```

'Inflation Target (in % pa)'
  ⇨ D4L_CPI_TAR

'Real Marginal Cost (in %)'
  ⇨ RMC

'Nominal Exchange Rate (LCY/FCY, 100*log)'
  ⇨ L_S
'Nominal Exch. Rate Depreciation QoQ annualized (in % pa)'
  ⇨ DLA_S
'Nominal Exch. Rate Depreciation YoY (in % pa)'
  ⇨ D4L_S
'Country Risk Premium (in % pa)'
  ⇨ PREM

'Nominal Policy Interest Rate (in % pa)'
  ⇨ RS
'Real Interest Rate (in % pa)'
  ⇨ RR
'Trend Real Interest Rate (in % pa)'
  ⇨ RR_BAR
'Real Interest Rate Gap (in %)'
  ⇨ RR_GAP
'Nominal Policy Neutral Interest Rate (in % pa)'
  ⇨ RSNEUTRAL

'Real Exchange Rate (level, 100*log)'
  ⇨ L_Z
'Trend Real Exchange Rate (level, 100*log)'
  ⇨ L_Z_BAR
'Real Exchange Rate Gap (in %)'
  ⇨ L_Z_GAP
'Real Exchange Rate Depreciation QoQ annualized (in % pa)'
  ⇨ DLA_Z
'Trend Real Exchange Rate Depreciation QoQ annualized(in % pa)'
  ⇨ DLA_Z_BAR

'Foreign Output Gap (in %)'
  ⇨ L_GDP_RW_GAP
'Foreign Nominal Interest Rate (in % pa)'
  ⇨ RS_RW
'Foreign Real Interest Rate (in % pa)'
  ⇨ RR_RW
'Foreign Real Interest Rate Trend (in % pa)'
  ⇨ RR_RW_BAR

```

```

'Foreign Real Interest Rate Gap (in %)'
  ↪ RR_RW_GAP
'Foreign CPI (level, 100*log)'
  ↪ L_CPI_RW
'Foreign Inflation QoQ annualized (in % pa)'
  ↪ DLA_CPI_RW

% -----
  ↪ -----
  ↪ %
!transition_shocks
'Shock: Output gap (demand)'
  ↪ SHK_L_GDP_GAP
'Shock: CPI inflation (cost-push)'
  ↪ SHK_DLA_CPI
'Shock: Exchange rate (UIP)'
  ↪ SHK_L_S
'Shock: Interest rate (monetary policy)'
  ↪ SHK_RS
'Shock: Inflation target'
  ↪ SHK_D4L_CPI_TAR

'Shock: Real interest rate'
  ↪ SHK_RR_BAR
'Shock: Real exchange rate depreciation'
  ↪ SHK_DLA_Z_BAR
'Shock: Potential GDP growth'
  ↪ SHK_DLA_GDP_BAR

'Shock: Foreign output gap'
  ↪ SHK_L_GDP_RW_GAP
'Shock: Foreign nominal interest rate'
  ↪ SHK_RS_RW
'Shock: Foreign inflation'
  ↪ SHK_DLA_CPI_RW
'Shock: Foreign real interest rate'
  ↪ SHK_RR_RW_BAR

% -----
  ↪ -----
  ↪ %
!parameters
b1 b2 b3 b4
a1 a2 a3
e1
g1 g2 g3

```

```

rho_D4L_CPI_TAR
rho_DLA_Z_BAR
rho_RR_BAR
rho_DLA_GDP_BAR

rho_L_GDP_RW_GAP
rho_RS_RW
rho_DLA_CPI_RW
rho_RR_RW_BAR

ss_D4L_CPI_TAR
ss_DLA_Z_BAR
ss_RR_BAR
ss_DLA_GDP_BAR

ss_DLA_CPI_RW
ss_RR_RW_BAR

%% -----
%
%
!transition_equations
%% === Aggregate demand (the IS curve) ===
L_GDP_GAP = b1*L_GDP_GAP{-1} - b2*MCI + b3*L_GDP_RW_GAP +
% SHK_L_GDP_GAP;

%-- Real monetary conditions index
MCI = b4*RR_GAP + (1-b4)*(- L_Z_GAP);

%% === Inflation (the Phillips curve) ===
DLA_CPI = a1*DLA_CPI{-1} + (1-a1)*DLA_CPI{+1} + a2*RMC +
% SHK_DLA_CPI;

%-- Real marginal cost
RMC = a3*L_GDP_GAP + (1-a3)*L_Z_GAP;

%- expected inflation
E_DLA_CPI = DLA_CPI{+1};

%% === Monetary policy reaction function (a forward-looking
% Taylor-type Rule) ===
RS = g1*RS{-1} + (1-g1)*(RSNEUTRAL + g2*(D4L_CPI{+4} -
% D4L_CPI_TAR{+4}) + g3*L_GDP_GAP) + SHK_RS;

%- Neutral nominal policy interest rate

```

```

RSNEUTRAL = RR_BAR + D4L_CPI{+1};

%% === Modified Uncovered Interest Rate Parity (UIP) condition
%> ===
L_S = (1-e1)*L_S{+1} + e1*(L_S{-1} + 2/4*(D4L_CPI_TAR -
%> ss_DLA_CPI_RW + DLA_Z_BAR)) + (- RS + RS_RW + PREM)/4 +
%> SHK_L_S;

%% === Definitions ===

%- Fisher equation (RIR)
RR = RS - D4L_CPI{+1};

%- Real exchange rate (RER)
L_Z = L_S + L_CPI_RW - L_CPI;

%- Long-term version of UIP (consistency of trends)
DLA_Z_BAR{+1} = RR_BAR - RR_RW_BAR - PREM;

%% === Identities ===
DLA_GDP_BAR = 4*(L_GDP_BAR - L_GDP_BAR{-1});
DLA_Z_BAR    = 4*(L_Z_BAR - L_Z_BAR{-1});
DLA_Z        = 4*(L_Z - L_Z{-1});
DLA_GDP      = 4*(L_GDP - L_GDP{-1});
DLA_CPI      = 4*(L_CPI - L_CPI{-1});
DLA_S        = 4*(L_S - L_S{-1});

D4L_GDP      = L_GDP - L_GDP{-4};
D4L_CPI      = L_CPI - L_CPI{-4};
D4L_S        = L_S - L_S{-4};

%% === Gaps ===
RR_GAP      = RR - RR_BAR;
L_Z_GAP     = L_Z - L_Z_BAR;
L_GDP_GAP   = L_GDP - L_GDP_BAR;

%% === Trends ===
D4L_CPI_TAR = rho_D4L_CPI_TAR*D4L_CPI_TAR{-1} +
%> (1-rho_D4L_CPI_TAR)*ss_D4L_CPI_TAR + SHK_D4L_CPI_TAR;
DLA_Z_BAR   = rho_DLA_Z_BAR*DLA_Z_BAR{-1} +
%> (1-rho_DLA_Z_BAR)*ss_DLA_Z_BAR + SHK_DLA_Z_BAR;
RR_BAR      = rho_RR_BAR*RR_BAR{-1} + (1-rho_RR_BAR)*ss_RR_BAR +
%> SHK_RR_BAR;
DLA_GDP_BAR = rho_DLA_GDP_BAR*DLA_GDP_BAR{-1} +
%> (1-rho_DLA_GDP_BAR)*ss_DLA_GDP_BAR + SHK_DLA_GDP_BAR;

```



```

%% === Foreign Sector Equations ===
L_GDP_RW_GAP = rho_L_GDP_RW_GAP*L_GDP_RW_GAP{-1} +
↳ SHK_L_GDP_RW_GAP;
DLA_CPI_RW = rho_DLA_CPI_RW*DLA_CPI_RW{-1} +
↳ (1-rho_DLA_CPI_RW)*ss_DLA_CPI_RW + SHK_DLA_CPI_RW;
RS_RW = rho_RS_RW*RS_RW{-1} + (1-rho_RS_RW)*(RR_RW_BAR +
↳ DLA_CPI_RW) + SHK_RS_RW;
RR_RW_BAR = rho_RR_RW_BAR*RR_RW_BAR{-1} +
↳ (1-rho_RR_RW_BAR)*ss_RR_RW_BAR + SHK_RR_RW_BAR;
RR_RW = RS_RW - DLA_CPI_RW;
RR_RW_GAP = RR_RW - RR_RW_BAR;

DLA_CPI_RW = 4*(L_CPI_RW - L_CPI_RW{-1});

%% -----
↳ -----
↳ %
!measurement_variables
OBS_L_GDP
OBS_L_CPI
OBS_RS
OBS_L_S
OBS_D4L_CPI_TAR

OBS_L_GDP_RW_GAP
OBS_DLA_CPI_RW
OBS_RS_RW

!measurement_equations
OBS_L_GDP = L_GDP;
OBS_L_CPI = L_CPI;
OBS_RS = RS;
OBS_L_S = L_S;
OBS_D4L_CPI_TAR = D4L_CPI_TAR;

OBS_L_GDP_RW_GAP = L_GDP_RW_GAP;
OBS_DLA_CPI_RW = DLA_CPI_RW;
OBS_RS_RW = RS_RW;

%% -----
↳ -----
↳ %
Legend
_GAP      cyclical deviation from a trend
_BAR      trend (equilibrium)
ss_       steady-state value

```

DLA_	q-o-q change
D4L_	y-o-y change
_RW	foreign variable
SHK_	equation residual

Sin embargo, la **Ecuación de Transición** de los estados presentes dependen de los estados pasados, mientras que el *Modelo QPM* es prospectivo, es decir, las variables dependen de sus expectativas así que la ecuación toma la forma de

$$F\mathbb{E}_t[X_{t+1}] + GX_t + HX_{t-1} + M\eta_t = 0 \quad (5.64)$$

donde F, G, H, M son matrices de parámetros estructurales conocidos, $\mathbb{E}_t$ es el operador de expectativas y η_t es un vector de choques estructurales. Para pasar de este modelo a la *Forma Estado-Espacio*, tenemos que resolver para *Expectativas Racionales*. Para esto, proponemos una *hipótesis de solución*

$$X_t = AX_{t-1} + P\eta_t \quad \text{con} \quad \varepsilon_t \equiv P\eta_t \quad (5.65)$$

Ahora, suponemos que η_t sigue un proceso autorregresivo, es decir, tiene su propia dinámica:

$$\eta_{t+1} = S\eta_t + \gamma_{t+1} \quad \text{donde} \quad \gamma_{t+1} \sim iid(0, W) \quad (5.66)$$

Así, sabemos que

$$\mathbb{E}_t[X_{t+1}] = AX_t + P\mathbb{E}_t[\eta_{t+1}] = A(AX_{t-1} + P\eta_t) + PS\eta_t \quad (5.67)$$

De este modo, si sustituimos la ecuación (5.65) en la (5.64), tenemos que las matrices deben de satisfacer la identidad

$$F[A(AX_{t-1} + P\eta_t) + P(S\eta_t)] + G[AX_{t-1} + P\eta_t] + HX_{t-1} + M\eta_t = 0 \quad (5.68)$$

para todos los valores X_{t-1} y η_t , de tal modo que A y P son las soluciones de ecuaciones

$$FA^2 + GA + H = 0, \quad FAP + FPS + GP + M = 0 \quad (5.69)$$

De esta forma, obtenemos nuestro modelo en la *Forma Estado-Espacio*.

5.7.2 Recursión del Filtro Kalman

Ya que tenemos nuestro modelo en la *Forma Estado-Espacio* como se muestra en las ecuaciones (5.62) y (5.63), podemos hacer uso del **Filtro Kalman**.

Para comenzar, definamos $Y_{t/t-1}$ y $X_{t/t-1}$ como los valores predichos de Y_t y X_t , respectivamente, condicionado a la información del periodo $t-1$. Además, definamos $X_{t/t}$ como la estimación de X_t condicionada a la información del periodo t .

Como se mencionó en un inicio, el **Filtro Kalman** utiliza un algoritmo recursivo para cada periodo $1, 2, \dots, T$. Cada recursión está compuesta de dos pasos. Supongamos que tenemos los datos observados y las estimaciones del estado para el periodo $t-1$, es decir, conocemos Y_{t-1} y $X_{t-1/t-1}$. De este modo, para el periodo t :

- **Paso 1.** Predicción del estado y observación de las variables en el periodo t dada la información de $t-1$. Como no tenemos nueva información, el promedio de la predicción se basa en el *Modelo Estado-Espacio* (5.62) - (5.63):

$$X_{t/t-1} = AX_{t-1/t-1} \quad (5.70)$$

$$Y_{t/t-1} = CX_{t/t-1} \quad (5.71)$$

- **Paso 2.** Actualización de la estimación del estado dada la información en el periodo t . Una vez que conocemos la nueva información del periodo t , existirá una discrepancia entre la información actual (Y_t) y la predicción del modelo ($Y_{t/t-1}$). El **Filtro Kalman** utiliza dicha discrepancia para actualizar la estimación de los estados no observables utilizando la matriz K_t , que se llama **Ganancia de Kalman**:

$$X_{t/t} = X_{t/t-1} + K_t(Y_t - Y_{t/t-1}) \quad (5.72)$$

5.7.3 Ganancia de Kalman

Supongamos que los errores siguen una distribución normal, es decir, $v_t \sim N(0, R)$, $\varepsilon_t \sim N(0, Q)$.

Para la primera estimación (Paso 1) de la *Recursión de Kalman*, $P_{t/t-1}$ denota la varianza del error de predicción de las variables de estado (X_t) dada la información del periodo $t-1$, o sea, $P_{t/t-1} = \text{Var}_{t-1}[(X_t - X_{t/t-1})]$. De manera

similar, $F_{t/t-1}$ es la varianza del error de predicción de las variables observables (Y_t) dada la información del periodo $t-1$, o bien, $F_{t/t-1} = \text{Var}_{t-1}[(Y_t - Y_{t/t-1})]$.

Para la actualización (Paso 2) de la *Recursión de Kalman*, $P_{t/t}$ denota la varianza del error de las variables de estado (X_t) dada la información del periodo t , es decir, $P_{t/t} = \text{Var}_t[(X_t - X_{t/t})]$.

Así, la distribución multivariada del vector (Y_t, X_t) toma la forma

$$\begin{pmatrix} Y_t \\ X_t \end{pmatrix} \Big| Y_t, \dots, Y_{t-1} \sim N \left(\begin{pmatrix} Y_{t/t-1} \\ X_{t/t-1} \end{pmatrix}, \begin{pmatrix} F_{t/t-1} & CP_{t/t-1} \\ P_{t/t-1}C' & P_{t/t-1} \end{pmatrix} \right). \quad (5.73)$$

De (5.73), la distribución condicional de X_t dado Y_t toma la forma de

$$X_t \mid Y_t, Y_1, \dots, Y_{t-1} \sim N \begin{pmatrix} X_{t/t-1} + P_{t/t-1}C'F_{t/t-1}^{-1}[Y_t - Y_{t/t-1}] \\ P_{t/t-1} - P_{t/t-1}C'F_{t/t-1}^{-1}CP_{t/t-1} \end{pmatrix} \quad (5.74)$$

Y de la ecuación (5.74) obtenemos directamente que

$$X_{t/t} = X_{t/t-1} + P_{t/t-1}C'F_{t/t-1}^{-1}[Y_t - Y_{t/t-1}] = X_{t/t-1} + K_t[Y_t - Y_{t/t-1}], \quad (5.75)$$

$$P_{t/t} = P_{t/t-1} - P_{t/t-1}C'F_{t/t-1}^{-1}CP_{t/t-1} = (I - K_tC)P_{t/t-1}, \quad (5.76)$$

en donde la **Ganancia de Kalman** es

$$K_t = P_{t/t-1}C'F_{t/t-1}^{-1}. \quad (5.77)$$

Nótese que $F_{t/t-1}$ sigue:

$$F_{t/t-1} = \text{Var}_{t-1}[(Y_t - Y_{t/t-1})] = \text{Var}_{t-1}[(CX_t + v_t - CX_{t/t-1})] = CP_{t/t-1}C' + R \quad (5.78)$$

Por el contrario, $P_{t/t-1}$ sigue:

$$P_{t/t-1} = \text{Var}_{t-1}[(X_t - X_{t/t-1})] \quad (5.79)$$

$$= \text{Var}_{t-1}[(AX_{t-1} + \varepsilon_t - AX_{t-1/t-1})] \quad (5.80)$$

$$= AP_{t-1/t-1}A' + Q \quad (5.81)$$

$$= A(I - K_{t-1}C)P_{t-1/t-2}A' + Q \quad (5.82)$$

Y si sustituimos $F_{t/t-1}$ y $P_{t/t-1}$ en las ecuaciones (5.75) - (5.77), obtenemos las siguientes ecuaciones para el algoritmo del **Filtro Kalman**

$$K_t = P_{t/t-1} C' (C P_{t/t-1} C' + R)^{-1} \quad (5.83)$$

$$X_{t/t} = X_{t/t-1} + K_t [Y_t - Y_{t/t-1}] \quad (5.84)$$

$$P_{t+1|t} = A(I - K_t C) P_{t/t-1} A' + Q \quad (5.85)$$

De este modo, la **Ganancia de Kalman** en (5.83) depende de manera positiva de la varianza del error de predicción del estado ($P_{t/t-1}$) y de manera negativa de la varianza de la ecuación de observación R . Esto es bastante intuitivo:

- Si existen grandes errores en las predicciones del estado $X_{t/t-1}$ en el Paso 1 de la *Recurción de Kalman*, es decir, $P_{t/t-1}$ es grande, se le da más peso a la nueva información observada Y_t , lo cual significa que la **Ganancia de Kalman** es grande. En particular, esto es cierto para las ecuaciones de transición que no se cumplen de manera estricta, es decir, Q es grande;
- Si la información es ruidosa, o sea, R es grande, se le da menos peso a la información nueva por lo que K_t es pequeño.

5.7.4 Algoritmo del Filtro Kalman y del Suavizador de Kalman

Ya que encontramos las expresiones más relevantes, podemos combinar todas para entender cómo funciona el **Filtro Kalman**.

Sabemos que el filtro es recursivo. De este modo, para poder correrlo necesitamos *condiciones iniciales* para todos los estados al principio de la muestra ($X_{0|0}$), al igual que para la varianza del error de predicción del estado ($P_{0|0}$). Para muestras pequeñas, las *condiciones iniciales* pueden afectar significativamente los resultados del filtro. Si no tenemos información previa, una opción es asumir que las *condiciones iniciales* de los estados y de la varianza del error de predicción no están lejos de sus valores en estado estacionario. En particular, para modelos estacionarios, se puede establecer que las *condiciones iniciales* son iguales a los valores en estado estacionario.

Ahora, ya que hemos asignado las *condiciones iniciales*, el **Filtro Kalman** corre el algoritmo recursivo para cada periodo de tiempo $1, 2, \dots, T$. Cada recursión está compuesta de dos pasos:

- **Paso 1.** Predicción utilizando el *Modelo Estado-Espacio*:

$$X_{t/t-1} = AX_{t-1/t-1}, \quad (5.86)$$

$$Y_{t/t-1} = CX_{t/t-1}. \quad (5.87)$$

- **Paso 2.** Actualización utilizando la información:

$$K_t = P_{t/t-1}C'(CP_{t/t-1}C' + R)^{-1}, \quad (5.88)$$

$$X_{t/t} = X_{t/t-1} + K_t[Y_t - Y_{t/t-1}], \quad (5.89)$$

$$P_{t+1/t} = A(I - K_tC)P_{t/t-1}A' + Q. \quad (5.90)$$

El **Filtro Kalman** nos proporciona el estimador lineal óptimo de mínimos cuadrados del estado, dada la información hasta el periodo t . Si los errores están distribuidos normalmente, es óptimo entre todos los estimadores de X_t condicionados a la información disponible hasta ese periodo.

Para cada periodo t , el **Filtro Kalman** utiliza únicamente la información disponible hasta ese periodo para estimar X_t . Dichas estimaciones se encuentran en $X_{t/t-1}$ (del Paso 1) y en $X_{t/t}$ (del Paso 2). Sin embargo, para estimar X_t , comúnmente es deseable utilizar toda la información disponible, hasta el último periodo T . Es decir, podría ser deseable obtener estimaciones $X_{t/T}$, que se conocen como **estimaciones suavizadas** de los estados. Precisamente eso es lo que hace el **Suavizador de Kalman (Kalman smoother)**.

Para correr el **Suavizador de Kalman**, necesitamos primero correr el **Filtro Kalman** y obtener todas las estimaciones de los estados: $X_{1/1}, X_{2/2}, \dots, X_{T/T}$.

Después, el algoritmo del **Suavizador de Kalman** funciona recursivamente hacia atrás, desde $T-1, T-2, \dots, 1$. Para cada periodo $t+1$, observamos la diferencia entre las estimaciones suavizadas y las estimaciones filtradas de los estados: $X_{t+1/T} - X_{t+1/t}$. El **Suavizador de Kalman** utiliza la diferencia para actualizar las estimaciones filtradas de los estados en el periodo t , con el fin de obtener las estimaciones suavizadas:

$$X_{t/T} = X_{t/t} + J_t[X_{t+1/T} - X_{t+1/t}]. \quad (5.91)$$

La matriz J_t pondera cuánto se corrige la estimación filtrada con la información posterior y está dada por

$$J_t = P_{t/t}A'P_{t+1/t}^{-1}, \quad (5.92)$$

es decir, la corrección es mayor cuanto más incierta es la estimación filtrada del estado en t ($P_{t/t}$ grande) y menor cuanto más incierta es la predicción del estado en $t+1$ ($P_{t+1/t}$ grande). Nótese la analogía con la **Ganancia de Kalman** de la ecuación (5.88): ambas matrices reparten el peso entre la información propia y la nueva evidencia según sus varianzas relativas.

En la *Figura 5.16*, podemos observar los resultados del código de Matlab. Otra de las virtudes del **Filtro Kalman** es que podemos hacer una especie de descomposición de la varianza para, así, observar de donde vinieron los choques:




Figura 5.16: Simulación de la Descomposición de la Brecha del Producto. Elaboración propia con datos de IMF [-@imf2020].

Nota: Para este ejemplo, se ocupa el QPM básico presentado por el IMF (2020) en su curso “Monetary Policy Analysis and Forecasting” disponible en la plataforma edX. El código de Matlab fue realizado por el IMF.

5.7.5 Representación Estado-Espacio de modelos ARMA

Aunque motivamos el **Filtro Kalman** con un modelo macroeconómico estructural, la *Forma Estado-Espacio* es mucho más general: prácticamente todos los modelos estudiados en este libro pueden escribirse en ella. Como ilustración, consideremos el proceso $AR(2)$ del Capítulo 3:

$$Y_t = a_1 Y_{t-1} + a_2 Y_{t-2} + U_t \quad (5.93)$$

Si definimos el vector de estado $X_t = (Y_t, Y_{t-1})'$, el proceso se escribe como

$$X_t = \begin{pmatrix} a_1 & a_2 \\ 1 & 0 \end{pmatrix} X_{t-1} + \begin{pmatrix} U_t \\ 0 \end{pmatrix}, \quad Y_t = (1 \quad 0) X_t, \quad (5.94)$$

que es exactamente la estructura de las ecuaciones (5.63) y (5.62), con $v_t = 0$ (no hay error de medición). Los componentes de medias móviles se incorporan ampliando el vector de estado con los choques rezagados. Esta representación es la base de, por ejemplo, la función `arima()` de R, que estima modelos *ARMA* por máxima verosimilitud exacta precisamente vía el **Filtro Kalman**; además, permite manejar observaciones faltantes de forma natural, pues en los periodos sin dato simplemente se omite el paso de actualización.

5.7.6 Estimación por Máxima Verosimilitud

Hasta ahora asumimos que las matrices del sistema (A , C , Q , R) son conocidas. En la práctica, éstas dependen de un vector de parámetros θ que debe estimarse. El propio **Filtro Kalman** proporciona la herramienta para hacerlo mediante la llamada **descomposición del error de predicción**. Definamos la innovación del periodo t como

$$u_t = Y_t - Y_{t/t-1}, \quad (5.95)$$

es decir, la parte de Y_t que el modelo no pudo anticipar. Bajo el supuesto de normalidad de los errores, $u_t \sim N(0, F_{t/t-1})$ y las innovaciones no están correlacionadas entre sí, por lo que la función log-verosimilitud de la muestra completa se puede escribir como la suma

$$\ln L(\theta) = -\frac{1}{2} \sum_{t=1}^T \left[n \ln(2\pi) + \ln |F_{t/t-1}| + u_t' F_{t/t-1}^{-1} u_t \right], \quad (5.96)$$

donde n es el número de variables observables. Así, para cada valor candidato de θ se corre el **Filtro Kalman**, se acumulan las innovaciones u_t y sus varianzas $F_{t/t-1}$, y se evalúa la ecuación (5.96); un algoritmo numérico de optimización busca entonces el θ que maximiza $\ln L(\theta)$. Éste es el procedimiento que utilizan los paquetes de cómputo que estiman modelos estado-espacio (en R, por ejemplo, `StructTS()`, `arima()` o el paquete `KFAS`; en Matlab, el *toolbox* utilizado por el IMF para el QPM). Cuando algún estado es no estacionario (por ejemplo, una tendencia estocástica como el Producto Potencial), las condiciones iniciales se tratan con una *inicialización difusa*: se asigna a $P_{0/0}$ una varianza muy grande para reflejar la ignorancia inicial sobre el nivel del estado.

5.8 Resumen del capítulo

En este capítulo extendimos el análisis univariado a sistemas multivariados, introduciendo herramientas para capturar la dinámica conjunta de varias series de tiempo.

Causalidad de Granger. Dos series X y Y exhiben causalidad de Granger de X a Y cuando la información pasada de X mejora la predicción de Y más allá de lo que aporta la historia de Y sola. Es una noción estadística de precedencia temporal, no de causalidad económica en sentido estricto. El test se implementa comparando las varianzas del error de dos regresiones auxiliares mediante una prueba F .

Modelos VAR(p). El VAR(p) generaliza el AR(p) a sistemas de k variables, donde cada variable depende de sus propios rezagos y de los rezagos de todas las demás. La condición de estacionariedad requiere que todas las raíces del polinomio matricial característico caigan fuera del círculo unitario. La selección del orden p se realiza mediante los criterios AIC, SC, HQ y FPE. Las funciones de impulso-respuesta (IRF) cuantifican la reacción dinámica del sistema ante un choque unitario en una de las innovaciones.

VAR Estructural (SVAR). La identificación de los choques estructurales requiere imponer restricciones adicionales. Los tres enfoques principales son: (i) descomposición de Cholesky (identificación recursiva), que impone una estructura triangular inferior en la matriz de impacto contemporáneo; (ii) restricciones de largo plazo de Blanchard y Quah (1989), que restringen el efecto acumulado permanente de ciertos choques; y (iii) restricciones de signo, que imponen solo la dirección del impacto.

Cointegración y VEC. Cuando series no estacionarias $I(1)$ comparten una tendencia estocástica común, se dice que cointegran. El procedimiento de Johansen determina el número de vectores de cointegración (rango de cointegración) mediante las estadísticas de la traza y del máximo valor propio. El modelo VEC (Vector de Corrección de Error) incorpora tanto la dinámica de corto plazo como el ajuste hacia el equilibrio de largo plazo.

Modelos ARDL. El enfoque de rezagos distribuidos autorregresivos (ARDL) de Pesaran, Shin y Smith (2001) permite estimar relaciones de largo plazo incluso cuando las variables son una mezcla de $I(0)$ e $I(1)$. La prueba de límites (*bounds test*) contrasta si existe una relación de nivel entre las variables.

Filtro de Kalman y Modelos Estado-Espacio. El Filtro de Kalman es un algoritmo recursivo de dos pasos —predicción y actualización— que estima variables de estado no observables a partir de observaciones ruidosas. Sus aplicaciones incluyen la estimación de brechas del producto, tendencias estocásticas y parámetros variables en el tiempo. El Suavizador de Kalman extiende el filtro al usar toda la información muestral para refinar las estimaciones, y la descomposición del error de predicción permite estimar los parámetros del sistema por

máxima verosimilitud; los modelos ARMA de los capítulos anteriores son un caso particular de esta representación.

Capítulo 6

Modelos Univariados y Multivariados de Volatilidad

6.1 Motivación

En este capítulo discutiremos los modelos de Heterocedasticidad Condicional Autorregresiva (ARCH, por sus siglas en inglés) y los modelos de Heterocedasticidad Condicional Autorregresiva Generalizados (GARCH, por sus siglas en inglés), los cuales tienen la característica de modelar situaciones como las que ilustra la Figura 6.2. Es decir:

- 1) Existen zonas donde la variación de los datos es mayor y zonas donde la variación es más estable—a estas situaciones se les conoce como de variabilidad por clúster—, y
- 2) los datos corresponden a información de alta frecuencia.

Iniciemos por las bibliotecas necesarias:

```
library(expm)
library(Matrix)
library(ggplot2)
library(quantmod)
library(moments)
library(dynlm)
library(broom)
```


```
library(FinTS)
library(lubridate)
library(forecast)
library(readxl)
library(MASS)
library(rugarch)
library(tsbox)
library(MTS)
library(rmgarch)
library(Rcpp)
```

Para el análisis de temas financieros existe una librería de mucha utilidad llamada **quantmod**. En primer lugar esta librería permite acceder a datos financieros de un modo muy simple, es posible descargar series financieras desde *yahoo*, la *FRED* (*Federal Reserve Economic Data*), *google*, etc. Por otro lado, también es una librería que permite realizar gráficos altamente estéticos con unas cuantas líneas de código. Usaremos datos de la cotización del bitcoin (ticker: “BTC-USD”) descargados de Yahoo Finance, con corte al 7 de julio de 2026; la serie está almacenada en la carpeta BD/ del repositorio para garantizar la reproducibilidad de los resultados que se discuten en el texto.

```
## Datos congelados (corte: 2026-07-07) para reproducibilidad.
## Quien desee replicar el ejercicio con datos vivos puede
  ↪ descomentar
## las siguientes líneas para descargar la serie actualizada
  ↪ desde
## Yahoo Finance (los resultados numéricos cambiarán con cada
  ↪ descarga):
#
# options("getSymbols.warning4.0" = FALSE)
# BTC <- getSymbols("BTC-USD", src = "yahoo", auto.assign =
  ↪ FALSE)
# BTC <- na.omit(BTC)
# save(BTC, file = "BD/BTC_USD.RData")

load("BD/BTC_USD.RData")

chartSeries(BTC,TA='addBBands();
            addBBands(draw="p");
            addVo();
            addMACD()',# subset='2021',
            theme="white")
```



`head(BTC)`

```
##          BTC-USD.Open BTC-USD.High BTC-USD.Low BTC-USD.Close
## 2014-09-17      465.864      468.174      452.422      457.334
## 2014-09-18      456.860      456.860      413.104      424.440
## 2014-09-19      424.103      427.835      384.532      394.796
## 2014-09-20      394.673      423.296      389.883      408.904
## 2014-09-21      408.085      412.426      393.181      398.821
## 2014-09-22      399.100      406.916      397.130      402.152
##          BTC-USD.Volume BTC-USD.Adjusted
## 2014-09-17      21056800           457.334
## 2014-09-18      34483200           424.440
## 2014-09-19      37919700           394.796
## 2014-09-20      36863600           408.904
## 2014-09-21      26580100           398.821
## 2014-09-22      24127600           402.152
```

`tail(BTC)`

```
##          BTC-USD.Open BTC-USD.High BTC-USD.Low BTC-USD.Close
## 2026-07-02      60004.77      62117.88      59532.32      61485.30
## 2026-07-03      61492.07      62879.01      61176.72      62544.20
## 2026-07-04      62545.13      63398.41      62287.59      63088.30
```

##	2026-07-05	63089.06	63935.85	62413.99	63547.88
##	2026-07-06	63551.02	64597.57	61275.83	63995.02
##	2026-07-07	63994.60	64257.63	62623.93	63297.39
##		BTC-USD.Volume	BTC-USD.Adjusted		
##	2026-07-02	40109297349	61485.30		
##	2026-07-03	26131813598	62544.20		
##	2026-07-04	18608397613	63088.30		
##	2026-07-05	18267466154	63547.88		
##	2026-07-06	36552222303	63995.02		
##	2026-07-07	31026493556	63297.39		

Para fines del ejercicio de este capítulo, usaremos el precio ajustado del activo. Esto nos servirá para calcular el rendimiento diario, o puesto en lenguaje de series temporales podemos decir que usaremos la serie en diferencias logarítmicas.

```
plot(BTC$`BTC-USD.Adjusted`)
```



Figura 6.1: Evolución del precio del Bitcoin

Una de las preguntas relevantes al observar la serie en diferencias, es si podríamos afirmar que esta serie cumple con el supuesto de homocedasticidad. Para ello, la Figura 6.2 muestra que las variaciones en el precio del Bitcoin muestran un escenario en el que no se cumple dicho supuesto.

```
logret <- ts(diff(log(BTC$`BTC-USD.Adjusted`))[-1])
plot(logret)
```




Figura 6.2: Evolución del rendimiento (diferencias logarítmicas) del Bitcoin

6.1.1 Value at Risk (VaR)

Utilicemos como ejemplo el Valor en Riesgo. Este es básicamente un cálculo que nos permite estimar el monto que una acción o portafolio podría perder dada una probabilidad $(1 - \alpha)$. Supongamos un $\alpha = 0.05$, de esta forma, la Figura 6.3 ilustra la región de la distribución que consideraríamos como el VaR.

```
alpha <- 0.05
VaR <- quantile( logret, alpha )
round( VaR, 4 ) * 100
```

```
## 5%
## -5.4
```

```

qplot(logret , geom = 'histogram') +
  geom_histogram(fill = 'lightblue' , bins = 30) +
  geom_histogram( aes(logret[logret < quantile(logret , 0.05)]) ,
    ↪
                    fill = 'red' , bins = 30) +
  labs(x = 'Daily Returns')

```




Figura 6.3: Histograma de rendimientos del Bitcoin

Ahora bien, una de las preguntas que nos podemos hacer es si los rendimientos del Bitcoin se aproximan a una distribución normal. Para ello, la Figura 6.4 ilustra esta comparación, de la cual podemos observar que una prueba de normalidad rechaza esa hipótesis—el estadístico Jarque-Bera indica que la serie de rendimientos no tiene una distribución normal—.

```

normal_dist <- rnorm(100000, mean(logret), sd(logret))
VaR_n <- quantile(normal_dist, 0.05)
ES_n <- mean(normal_dist[normal_dist < VaR])

ggplot()+
  geom_density(aes(logret, geom = 'density', col = 'returns'))+
  geom_density(aes(normal_dist, col = 'normal'))

```





Figura 6.4: Densidad de rendimientos del Bitcoin Vs. una distribución normal

```
vector_ret <- as.vector(logret)

##Kurtosis
round(kurtosis(vector_ret),2)
```

```
## [1] 14.86
```

```
##Sesgo
round(skewness(vector_ret),2)
```

```
## [1] -0.71
```

6.1.2 Prueba de normalidad

Formalicemos la observación anterior con la prueba de Jarque-Bera, cuya hipótesis nula es que la serie se distribuye como una normal, es decir, $H_0 : K = S = 0$, donde K es el exceso de curtosis y S el sesgo:

```

jarque.test(vector_ret)

##
##  Jarque-Bera Normality Test
##
## data:  vector_ret
## JB = 25617, p-value < 0.00000000000000022
## alternative hypothesis: greater

```

6.2 Modelos ARCH y GARCH Univariados

Para plantear el modelo, supongamos—por simplicidad—que hemos construido y estimado un modelo AR(1). Es decir, asumamos que el proceso subyacente para la media condicional está dada por:

$$X_t = a_0 + a_1 X_{t-1} + U_t \quad (6.1)$$

Donde $|a_1| < 1$ para garantizar la convergencia del proceso en el largo plazo, en el cual:

$$\begin{aligned} \mathbb{E}[X_t] &= \frac{a_0}{1 - a_1} = \mu \\ \text{Var}[X_t] &= \frac{\sigma^2}{1 - a_1^2} \end{aligned}$$

Ahora, supongamos que este tipo de modelos pueden ser extendidos y generalizados a un modelo ARMA(p, q), que incluya otras variables exógenas. Denotemos a $\mathbf{Z}_t$ como el conjunto que incluye los componentes AR, MA y variables exógenas que pueden explicar a X_t de forma que el proceso estará dado por:

$$X_t = \mathbf{Z}_t \beta + U_t \quad (6.2)$$

Donde U_t es un proceso estacionario que representa el error asociado a un proceso ARMA(p, q) y donde siguen siendo válidos los supuestos:

$$\begin{aligned} \mathbb{E}[U_t] &= 0 \\ \text{Var}[U_t] &= \sigma^2 \end{aligned}$$

No obstante, en este caso podemos suponer que existe autocorrelación en el término de error al cuadrado que puede ser capturada por un proceso similar a uno de medias móviles (MA) dado por:

$$U_t^2 = \omega + \alpha_1 U_{t-1}^2 + \alpha_2 U_{t-2}^2 + \dots + \alpha_q U_{t-q}^2 + \nu_t \quad (6.3)$$

Donde ν_t es un ruido blanco y $U_{t-i} = X_{t-i} - \mathbf{Z}_{t-i}\beta$, $i = 1, 2, \dots$. Si bien los procesos son estacionarios por los supuestos antes enunciados, la varianza condicional estará dada por:

$$\begin{aligned}\sigma_{t|t-1}^2 &= \text{Var}[U_t|\Omega_{t-1}] \\ &= \mathbb{E}[U_t^2|\Omega_{t-1}]\end{aligned}$$

Donde $\Omega_{t-1} = \{U_{t-1}, U_{t-2}, \dots\}$ es el conjunto de toda la información pasada de U_t y observada hasta el momento $t-1$, por lo que:

$$U_t|\Omega_{t-1} \sim \mathbb{D}(0, \sigma_{t|t-1}^2)$$

Así, de forma similar a un proceso MA(q) podemos decir que la varianza condicional tendrá efectos ARCH de orden q (ARCH(q)) cuando:

$$\sigma_{t|t-1}^2 = \omega + \alpha_1 U_{t-1}^2 + \alpha_2 U_{t-2}^2 + \dots + \alpha_q U_{t-q}^2 \quad (6.4)$$

Donde $\mathbb{E}[\nu_t] = 0$, $\omega > 0$ y $\alpha_i \geq 0$, para $i = 1, 2, \dots, q$. Estas condiciones son necesarias para garantizar que la varianza sea positiva. En general, la varianza condicional se expresa de la forma $\sigma_{t|t-1}^2$, no obstante, para facilitar la notación, nos referiremos en cada caso a esta simplemente como σ_t^2 .

Podemos generalizar esta situación si asumimos a la varianza condicional como dependiente de los valores de la varianza rezagados, es decir, como si fuera un proceso AR de orden p para la varianza y juntándolo con la ecuación (6.4). Bollerslev (1986) y Taylor (1986) generalizaron el problema de heterocedasticidad condicional. El modelo se conoce como GARCH(p, q), el cual se especifica como:

$$\begin{aligned}\sigma_t^2 &= \omega + \alpha_1 U_{t-1}^2 + \alpha_2 U_{t-2}^2 + \dots + \alpha_q U_{t-q}^2 \\ &\quad + \beta_1 \sigma_{t-1}^2 + \beta_2 \sigma_{t-2}^2 + \dots + \beta_p \sigma_{t-p}^2\end{aligned} \quad (6.5)$$

Donde las condiciones de no negatividad son que $\omega > 0$, $\alpha_i \geq 0$ para $i = 1, 2, \dots, q$, y $\beta_j \geq 0$ para $j = 1, 2, \dots, p$. Además, otra condición de convergencia es que:

$$\alpha_1 + \dots + \alpha_q + \beta_1 + \dots + \beta_p < 1$$

Usando el operador rezago L en la ecuación (6.6) podemos obtener:

$$\sigma_t^2 = \omega + \alpha(L)U_t^2 + \beta(L)\sigma_t^2 \quad (6.6)$$

De donde podemos establecer:

$$\sigma_t^2 = \frac{\omega}{1 - \beta(L)} + \frac{\alpha(L)}{1 - \beta(L)} U_t^2 \quad (6.7)$$

Por lo que la ecuación (6.6) del GARCH(p, q) representa un ARCH(∞):

$$\sigma_t^2 = \frac{\omega}{1 - \beta_1 - \beta_2 - \dots - \beta_p} + \sum_{i=1}^{\infty} c_i U_{t-i}^2 \quad (6.8)$$

donde c_i son los coeficientes de la expansión en serie de potencias $\frac{\alpha(L)}{1-\beta(L)} = \sum_{i=1}^{\infty} c_i L^i$.

6.2.1 Propiedades: varianza no condicional y colas pesadas

Vale la pena detenerse en las propiedades del caso más simple, el ARCH(1), porque ilustran por qué esta familia de modelos reproduce los hechos estilizados de las series financieras que documentamos en la sección de motivación. Para el ARCH(1), $\sigma_t^2 = \omega + \alpha_1 U_{t-1}^2$, y aplicando esperanzas a ambos lados, la varianza **no condicional** del proceso es constante:

$$\bar{\sigma}^2 = \mathbb{E}[U_t^2] = \omega + \alpha_1 \mathbb{E}[U_{t-1}^2] \implies \bar{\sigma}^2 = \frac{\omega}{1 - \alpha_1}, \quad (6.9)$$

siempre que $\alpha_1 < 1$. Es decir, el proceso U_t es estacionario y homocedástico *sin condicionar*, aunque su varianza *condicional* cambie periodo a periodo: la heterocedasticidad es un fenómeno condicional a la información pasada. Esto explica el agrupamiento de volatilidad: un choque grande en $t-1$ eleva σ_t^2 y hace más probables choques grandes en t , pero en el largo plazo la varianza revierte a $\bar{\sigma}^2$.

Más aún, si el término estandarizado U_t/σ_t es normal, la curtosis no condicional del ARCH(1) es:

$$\kappa = \frac{\mathbb{E}[U_t^4]}{(\mathbb{E}[U_t^2])^2} = \frac{3(1 - \alpha_1^2)}{1 - 3\alpha_1^2} > 3, \quad \text{si } 3\alpha_1^2 < 1. \quad (6.10)$$

Es decir, aun cuando las innovaciones condicionales sean normales, la distribución no condicional de U_t tiene **colas más pesadas que la normal**. Esta es exactamente la característica que encontramos en los rendimientos del Bitcoin al inicio del capítulo (curtosis muestral muy superior a 3), y es una de las razones del éxito empírico de los modelos ARCH/GARCH en finanzas.

6.2.2 Estimación por Máxima Verosimilitud

Los modelos GARCH no pueden estimarse por mínimos cuadrados ordinarios, pues la varianza condicional σ_t^2 es una función no lineal de los parámetros y no

es observable. La estrategia estándar es la estimación por **máxima verosimilitud**. Si suponemos que $U_t|\Omega_{t-1} \sim N(0, \sigma_t^2)$, la función log-verosimilitud condicional de la muestra es:

$$\ln L(\theta) = -\frac{1}{2} \sum_{t=1}^T \left[\ln(2\pi) + \ln \sigma_t^2(\theta) + \frac{U_t^2(\theta)}{\sigma_t^2(\theta)} \right], \quad (6.11)$$

donde θ agrupa los parámetros de la media condicional (β) y de la varianza condicional ($\omega, \alpha_i, \beta_j$). Para cada valor candidato de θ , la recursión de la ecuación (6.6) genera la trayectoria completa de σ_t^2 , con lo que se evalúa (6.11); un optimizador numérico busca el máximo. Éste es el procedimiento que ejecuta internamente la función `ugarchfit()` del paquete `rugarch` que utilizaremos en los ejemplos.

Dos observaciones prácticas. Primera: si la distribución condicional verdadera no es normal, el estimador anterior se interpreta como de **cuasi-máxima verosimilitud** (QML); sigue siendo consistente, aunque los errores estándar deben corregirse. Segunda: dado que las series financieras suelen exhibir colas pesadas incluso condicionalmente, es común especificar una distribución t de Student para las innovaciones (en `rugarch`, con el argumento `distribution.model = "std"`).

6.2.3 Ejemplo ARCH(1)

Hasta ahora, las distribuciones utilizadas para medir el Valor en Riesgo de un activo (Bitcoin, en este caso) asumen que no existe correlación serial en los retornos diarios del activo. Observemos un par de gráficas de la función de autocorrelación para corroborar este hecho—ver la Figura 6.5—.

```
acf(logret)
```

La idea de clusterización de volatilidad asume que períodos de alta volatilidad serán seguidos por alta volatilidad y viceversa. Por esta razón, la función de autocorrelación útil para saber si existen clústers de volatilidad es utilizando el valor absoluto, ya que lo que importa es saber si la serie está autocorrelacionada en la magnitud de los movimientos. La Figura 6.6 muestra el comportamiento de los rendimientos en valor absoluto y la Figura 6.7 su función de autocorrelación.

```
plot(abs(logret))
```

```
acf(abs(logret))
```




Figura 6.5: Función de autocorrelación de los rendimientos del Bitcoin




Figura 6.6: Evolución de los rendimientos del Bitcoin en valor absoluto




Figura 6.7: Función de autocorrelación de los rendimientos del Bitcoin en valor absoluto

Otra manera de corroborar esta idea es volviendo IID nuestra serie de datos y observar que de este modo se pierde la autocorrelación serial, lo que refuerza la idea de que en esta serie existen clusters de volatilidad.

```
logret_random <- sample(as.vector(logret), size =
  ↪ length(logret), replace = FALSE)

acf(abs(logret_random))
```

```
par(mfrow = c(1,2))
plot(logret)
plot(logret_random, type = 'l')
```

Ahora busquemos una prueba formal. El primer enfoque para comprobar si debemos aceptar o rechazar la hipótesis de que necesitamos estimar un ARCH(q) es realizar una prueba de efectos ARCH. De acuerdo con esta, nuestros datos de Bitcoin muestran que se rechaza la hipótesis de no efectos ARCH. Esta prueba resulta del siguiente código de R:




Figura 6.8: Función de autocorrelación del valor absoluto de los rendimientos del Bitcoin reordenados aleatoriamente

```
logret_mean = dynlm(logret~1)
summary(logret_mean)

##
## Time series regression with "ts" data:
## Start = 1, End = 4311
##
## Call:
## dynlm(formula = logret ~ 1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.46587 -0.01384 -0.00007  0.01459  0.22398
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.0011436  0.0005338   2.142  0.0322 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```





Figura 6.9: Rendimientos del Bitcoin: serie original vs. serie reordenada aleatoriamente


```
##
## Residual standard error: 0.03505 on 4310 degrees of freedom
```

```
ehatsq = ts(resid(logret_mean)^2)
ARCH_m = dynlm(ehatsq~L(ehatsq))
summary(ARCH_m)
```


```
##
## Time series regression with "ts" data:
## Start = 2, End = 4311
##
## Call:
## dynlm(formula = ehatsq ~ L(ehatsq))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.017970 -0.001062 -0.000939 -0.000299  0.215977
##
## Coefficients:
```

```
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) 0.00106096 0.00007146  14.846 <0.0000000000000002
## ***
## L(ehatsq)    0.13523487 0.01509409   8.959 <0.0000000000000002
## ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.004531 on 4308 degrees of freedom
## Multiple R-squared:  0.01829,    Adjusted R-squared:  0.01806
## F-statistic: 80.27 on 1 and 4308 DF,  p-value: <
## 0.00000000000000022
```

```
acf(ARCH_m$residuals)
```



```
acf(abs(ARCH_m$residuals))
```



```
ArchTest(logret, lags = 1, demean = TRUE)
```

```
##
##  ARCH LM-test; Null hypothesis: no ARCH effects
##
## data:  logret
## Chi-squared = 78.84, df = 1, p-value < 0.00000000000000022
```

La prueba puede repetirse para diferentes especificaciones de ARCH, sin embargo, para efectos ilustrativos usaremos un ARCH(1). Estimemos un ARCH(1), considerando la siguiente especificación:

$$\begin{aligned} Y_t &= \mu + \sqrt{h_t} \varepsilon_t \\ h_t &= \omega + \alpha_1 \varepsilon_{t-1}^2 \\ \varepsilon_t &\sim iid(0, 1) \end{aligned}$$

Considerando que la media es una AR(2), los resultados de esta estimación se muestran en el Cuadro 6.1. En la estimación empleamos una distribución t de Student estandarizada para las innovaciones (argumento `distribution.model = "std"` de `rugarch`), en línea con las colas pesadas de los rendimientos que documentamos al inicio del capítulo.

Cuadro 6.1: Estimación del modelo ARCH(1) con media AR(2).

	Estimado	Error Est.	Estad. t	Prob. ($> t $)	Signif.
mu	0.0014	0.0003	4.2651	0.0000	***
ar1	-0.0465	0.0152	-3.0598	0.0022	**
ar2	-0.0042	0.0125	-0.3386	0.7349	
omega	0.0016	0.0003	4.8146	0.0000	***
alpha1	0.6852	0.1717	3.9900	0.0001	***
shape	2.3936	0.1110	21.5583	0.0000	***

```

library(rugarch)

model.spec = ugarchspec(variance.model = list(model = 'sGARCH',
  ↪ garchOrder = c(1, 0)),
                        mean.model      = list(armaOrder = c(2,
  ↪ 0)),
                        distribution.model = "std")

arch.fit = ugarchfit(spec = model.spec, data = logret, solver =
  ↪ 'solnp')

df_arch <- as.data.frame(arch.fit@fit$matcoef)
df_arch$Signif <- ifelse(df_arch[, 4] < 0.001, "***",
                        ifelse(df_arch[, 4] < 0.01, "**",
                        ifelse(df_arch[, 4] < 0.05, "*",
                        ifelse(df_arch[, 4] < 0.1, ".", ""))))

knitr::kable(
  df_arch,
  col.names = c("Estimado", "Error Est.", "Estad. $t$", "Prob.
  ↪ $(>|t|)$", "Signif."),
  caption   = "Estimación del modelo ARCH(1) con media AR(2).",
  align     = c("r", "r", "r", "r", "c"),
  digits    = 4,
  booktabs = TRUE,
  escape    = FALSE
)

```

6.2.4 Ejemplo GARCH(0,1)

Estimemos un GARCH(0,1) usando la siguiente especificación:

$$\begin{aligned} Y_t &= \mu + \sqrt{h_t} \varepsilon_t \\ h_t &= \omega + \beta_1 \sigma_{t-1}^2 \\ \varepsilon_t &\sim iid(0, 1) \end{aligned}$$

Considerando que la media es una AR(2), los resultados de esta estimación se muestran en el Cuadro 6.2.

```
model.spec = ugarchspec(variance.model = list(model = 'sGARCH',
  ↪ garchOrder = c(0, 1)),
  mean.model      = list(armaOrder = c(2,
  ↪ 0)),
  distribution.model = "std")

fit.garch.n = ugarchfit(spec = model.spec, data = logret, solver
  ↪ = "solnp")

df_garch01 <- as.data.frame(fit.garch.n@fit$matcoef)
df_garch01$Signif <- ifelse(df_garch01[, 4] < 0.001, "***",
  ifelse(df_garch01[, 4] < 0.01, "**",
  ifelse(df_garch01[, 4] < 0.05, "*",
  ifelse(df_garch01[, 4] < 0.1, ".", ""))))

knitr::kable(
  df_garch01,
  col.names = c("Estimado", "Error Est.", "Estad. $t$", "Prob.
  ↪ $(>|t|)$", "Signif."),
  caption = "Estimación del modelo GARCH(0,1) con media
  ↪ AR(2).",
  align = c("r", "r", "r", "r", "c"),
  digits = 4,
  booktabs = TRUE,
  escape = FALSE
)
```

6.2.5 Selección GARCH(p,q) óptimo

¿Cómo seleccionamos el orden adecuado para un GARCH(p,q)? Una respuesta la ofrecen los criterios de información, partiendo de la especificación general:

$$Y_t = \mu + \sqrt{h_t} \varepsilon_t$$

Cuadro 6.2: Estimación del modelo GARCH(0,1) con media AR(2).

	Estimado	Error Est.	Estad. t	Prob. ($> t $)	Signif.
mu	0.0014	0.0003	4.1675	0.0000	***
ar1	-0.0572	0.0129	-4.4362	0.0000	***
ar2	-0.0040	0.0124	-0.3197	0.7492	
omega	0.0000	0.0000	59.1393	0.0000	***
beta1	0.9976	0.0000	21619.8572	0.0000	***
shape	2.5751	0.0283	91.0808	0.0000	***

Cuadro 6.3: Criterios de información del modelo GARCH(0,1).

Criterio	Valor
Akaike	-4.164250
Bayes	-4.155385
Shibata	-4.164253
Hannan-Quinn	-4.161119

$$h_t = \omega + \sum_{i=1}^p \beta_i h_{t-i} + \sum_{j=1}^q \alpha_j \varepsilon_{t-j}^2$$

$$\varepsilon_t \sim iid(0,1)$$

6.2.5.1 Criterios de información

```
ic <- infocriteria(fit.garch.n)
knitr::kable(
  data.frame(Criterio = rownames(ic), Valor =
    ↪ round(as.numeric(ic), 6)),
  caption = "Criterios de información del modelo GARCH(0,1).",
  align = c("l", "r"),
  booktabs = TRUE
)
```

6.2.5.2 Selección del modelo óptimo

Podemos hacer una búsqueda del mejor modelo de entre varios que probemos en un espectro de hasta un GARCH(4,4), manteniendo para la media condicional la misma especificación AR(2) empleada en las estimaciones anteriores. Los resultados son los reportados en el siguiente Cuadro.

Cuadro 6.4: Criterios de información AIC en función de p y q para GARCH(p, q).

q	p	AIC	Óptimo
1	1	-4.29787	0
1	2	-4.29896	0
1	3	-4.30017	1
1	4	-4.29971	0
2	1	-4.29741	0
2	2	-4.29849	0
2	3	-4.29989	0
2	4	-4.29937	0
3	1	-4.29672	0
3	2	-4.29780	0
3	3	-4.29943	0
3	4	-4.29890	0
4	1	-4.29633	0
4	2	-4.29762	0
4	3	-4.29882	0
4	4	-4.29844	0

```

source("lag_opt_GARCH.R")
crit_garch <- as.data.frame(Lag_Opt_GARCH(logret, 4, 4, arma =
  ↪ c(2, 0)))
knitr::kable(
  crit_garch,
  col.names = c("$q$", "$p$", "AIC", "Óptimo"),
  caption = "Criterios de información AIC en función de $p$ y
  ↪ $q$ para GARCH($p$, $q$).",
  align = c("c", "c", "r", "c"),
  digits = 5,
  booktabs = TRUE,
  escape = FALSE
)

```

6.2.5.3 Estimación de modelo óptimo

De esta forma, con los datos al corte señalado, el modelo óptimo es un GARCH(3,1). Los resultados de la estimación se muestran en el Cuadro 6.5.

Cuadro 6.5: Estimación del modelo GARCH(3,1) óptimo con media AR(2).

	Estimado	Error Est.	Estad. t	Prob. ($> t $)	Signif.
mu	0.0011	0.0003	3.8379	0.0001	***
ar1	-0.0451	0.0145	-3.1025	0.0019	**
ar2	-0.0031	0.0131	-0.2366	0.8129	
omega	0.0000	0.0000	3.2907	0.0010	***
alpha1	0.1829	0.0228	8.0070	0.0000	***
beta1	0.3148	0.1230	2.5594	0.0105	*
beta2	0.1457	0.1159	1.2572	0.2087	
beta3	0.3556	0.0861	4.1300	0.0000	***
shape	3.2339	0.1473	21.9486	0.0000	***

```

model.spec = ugarchspec(variance.model = list(model = 'sGARCH',
  ↪ garchOrder = c(1, 3)),
                        mean.model      = list(armaOrder = c(2,
  ↪ 0)),
                        distribution.model = "std")

model.fit = ugarchfit(spec = model.spec, data = logret, solver =
  ↪ 'solnp')

df_opt <- as.data.frame(model.fit@fit$matcoef)
df_opt$Signif <- ifelse(df_opt[, 4] < 0.001, "***",
  ifelse(df_opt[, 4] < 0.01, "**",
  ifelse(df_opt[, 4] < 0.05, "*",
  ifelse(df_opt[, 4] < 0.1, ".", ""))))

knitr::kable(
  df_opt,
  col.names = c("Estimado", "Error Est.", "Estad. $t$", "Prob.
  ↪ $(>|t|)$", "Signif."),
  caption = "Estimación del modelo GARCH(3,1) óptimo con media
  ↪ AR(2).",
  align = c("r", "r", "r", "r", "c"),
  digits = 4,
  booktabs = TRUE,
  escape = FALSE
)

```


6.2.5.4 Pronósticos con el modelo GARCH óptimo

Antes de pasar al código, conviene precisar qué pronostica un GARCH. Para un $\text{GARCH}(1,1)$, la varianza condicional esperada a h periodos satisface la recursión $\mathbb{E}_t[\sigma_{t+h}^2] = \omega + (\alpha_1 + \beta_1) \mathbb{E}_t[\sigma_{t+h-1}^2]$, cuya solución es:

$$\mathbb{E}_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha_1 + \beta_1)^{h-1} (\sigma_{t+1}^2 - \bar{\sigma}^2), \quad \text{con} \quad \bar{\sigma}^2 = \frac{\omega}{1 - \alpha_1 - \beta_1}. \quad (6.12)$$

Es decir, el pronóstico de la varianza **revierte geoméricamente** hacia la varianza no condicional $\bar{\sigma}^2$ a una velocidad gobernada por la persistencia $\alpha_1 + \beta_1$: cuanto más cercana a 1 sea la suma, más lentamente se disipa un episodio de alta volatilidad. La misma lógica se extiende al $\text{GARCH}(p, q)$ con persistencia $\sum_i \alpha_i + \sum_j \beta_j$.

Para realizar pronósticos con la estimación de un GARCH, utilizando la librería *rugarch*, es necesario utilizar la función **ugarchforecast()**. Emplearemos el modelo $\text{GARCH}(3,1)$ con media $\text{AR}(2)$ que resultó óptimo en la sección anterior (objeto `model.fit`):

```
spec = getspec(model.fit)

setfixed(spec) <- as.list(coef(model.fit))
```

Esta función precisa como argumentos nuestra estimación del modelo GARCH, con una modificación en la manera en que se presentan los coeficientes, realizada en la última línea del código anterior y que llamamos *spec*. *n.ahead* es el número de periodos que vamos a pronosticar, *n.roll* señala el número de pronósticos móviles que utilizaremos, en caso de que haya más información para realizar el pronóstico. Finalmente damos como input nuestro set de datos y como producto obtendremos el pronóstico de Sigma tanto como de la serie.

```
forecast = ugarchforecast(spec, n.ahead = 12, n.roll = 0, logret)

sigma(forecast)
```

```
##      4311-01-01
## T+1  0.02073343
## T+2  0.02168883
## T+3  0.02195810
## T+4  0.02215006
## T+5  0.02260453
## T+6  0.02294560
## T+7  0.02324236
```

```
## T+8 0.02359079
## T+9 0.02392004
## T+10 0.02423233
## T+11 0.02455141
## T+12 0.02486508
```

```
fitted(forecast)
```

```
##      4311-01-01
## T+1 0.001665495
## T+2 0.001152099
## T+3 0.001136026
## T+4 0.001138346
## T+5 0.001138291
## T+6 0.001138286
## T+7 0.001138287
## T+8 0.001138287
## T+9 0.001138287
## T+10 0.001138287
## T+11 0.001138287
## T+12 0.001138287
```

```
forecast
```

```
##
## *-----*
## *      GARCH Model Forecast      *
## *-----*
## Model: sGARCH
## Horizon: 12
## Roll Steps: 0
## Out of Sample: 0
##
## 0-roll forecast [T0=]:
##      Series  Sigma
## T+1 0.001665 0.02073
## T+2 0.001152 0.02169
## T+3 0.001136 0.02196
## T+4 0.001138 0.02215
## T+5 0.001138 0.02260
## T+6 0.001138 0.02295
## T+7 0.001138 0.02324
## T+8 0.001138 0.02359
## T+9 0.001138 0.02392
```

```
## T+10 0.001138 0.02423
## T+11 0.001138 0.02455
## T+12 0.001138 0.02487
```

6.3 Extensiones: asimetría y GARCH en media

El GARCH(p, q) trata de forma simétrica a los choques: en la ecuación (6.6) solo importa la magnitud U_{t-1}^2 , no su signo. Sin embargo, un hecho estilizado adicional de los mercados financieros es el **efecto apalancamiento** (*leverage effect*): las caídas de precios suelen incrementar la volatilidad más que las alzas de la misma magnitud. Existen dos extensiones clásicas para capturar esta asimetría.

El modelo **TGARCH** o **GJR-GARCH** de Glosten, Jagannathan y Runkle (1993) añade un término que solo se activa cuando el choque es negativo:

$$\sigma_t^2 = \omega + \alpha_1 U_{t-1}^2 + \gamma U_{t-1}^2 \mathbb{I}(U_{t-1} < 0) + \beta_1 \sigma_{t-1}^2, \quad (6.13)$$

donde $\mathbb{I}(\cdot)$ es la función indicadora. Si $\gamma > 0$, un choque negativo incrementa la varianza condicional en $\alpha_1 + \gamma$, mientras que uno positivo solo en α_1 .

El modelo **EGARCH** de Nelson (1991) especifica el logaritmo de la varianza condicional en función de los choques estandarizados $z_t = U_t/\sigma_t$:

$$\ln \sigma_t^2 = \omega + \beta_1 \ln \sigma_{t-1}^2 + \alpha_1 (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1}, \quad (6.14)$$

con dos ventajas: al modelar $\ln \sigma_t^2$, no se requieren restricciones de no negatividad sobre los parámetros, y el término γz_{t-1} captura la asimetría de forma directa (un $\gamma < 0$ implica efecto apalancamiento).

Por último, el modelo **GARCH en media (GARCH-M)** de Engle, Lilien y Robins (1987) permite que la varianza condicional afecte a la media condicional:

$$X_t = \mathbf{Z}_t \beta + \lambda \sigma_t^2 + U_t, \quad (6.15)$$

donde λ se interpreta como el premio al riesgo: si $\lambda > 0$, los periodos de mayor volatilidad esperada se compensan con mayores rendimientos esperados, en línea con la teoría de portafolios. Todas estas variantes están disponibles en `rugarch`: basta cambiar el argumento `variance.model = list(model = "gjrGARCH")` o `"eGARCH"` en `ugarchspec()`, o añadir `archm = TRUE` en la especificación de la media para el GARCH-M.

6.4 Modelos ARCH y GARCH Multivariados

De forma similar a los modelos univariados, los modelos multivariados de heterocedasticidad condicional asumen una estructura de la media condicional. En este caso, descrita por un VAR(p) cuyo proceso estocástico $\mathbf{X}$ es estacionario de dimensión k . De esta forma, la expresión reducida del modelo o el proceso VAR(p) estará dado por:

$$\mathbf{X}_t = \delta + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \mathbf{U}_t \quad (6.16)$$

Donde cada uno de las $\mathbf{A}_i$, $i = 1, 2, \dots, p$, son matrices cuadradas de dimensión k y $\mathbf{U}_t$ representa un vector de dimensión $k \times 1$ con los residuales en el momento del tiempo t que son un proceso puramente aleatorio. También se incorpora un vector de términos constantes denominado como δ , el cual es de dimensión $k \times 1$ —en este caso también es posible incorporar procesos determinísticos adicionales—.

Así, suponemos que el término de error tendrá estructura de vector:

$$\mathbf{U}_t = \begin{bmatrix} U_{1t} \\ U_{2t} \\ \vdots \\ U_{Kt} \end{bmatrix}$$

De forma que diremos que:

$$\mathbf{U}_t | \Omega_{t-1} \sim (0, \Sigma_{t|t-1})$$

Dicho lo anterior, entonces, el modelo ARCH(q) multivariado será descrito por:

$$Vech(\Sigma_{t|t-1}) = \gamma_0 + \Gamma_1 Vech(\mathbf{U}_{t-1} \mathbf{U}_{t-1}') + \dots + \Gamma_q Vech(\mathbf{U}_{t-q} \mathbf{U}_{t-q}') \quad (6.17)$$

Donde $Vech$ es un operador que apila en un vector la parte triangular inferior (incluyendo la diagonal) de la matriz a la cual se le aplique, γ_0 es un vector de constantes, Γ_i , $i = 1, 2, \dots$ son matrices de coeficientes asociados a la estimación.

Para ilustrar la ecuación (6.17), tomemos un ejemplo de $K = 2$, de esta forma tenemos que un M-ARCH(1) será:

$$\Sigma_{t|t-1} = \begin{bmatrix} \sigma_{1,t|t-1}^2 & \sigma_{12,t|t-1} \\ \sigma_{21,t|t-1} & \sigma_{2,t|t-1}^2 \end{bmatrix} = \begin{bmatrix} \sigma_{11,t} & \sigma_{12,t} \\ \sigma_{21,t} & \sigma_{22,t} \end{bmatrix} = \Sigma_t$$

Donde hemos simplificado la notación de las varianzas y la condición de que están en función de $t - 1$. Así,

$$Vech(\Sigma_t) = Vech \begin{bmatrix} \sigma_{11,t} & \sigma_{12,t} \\ \sigma_{21,t} & \sigma_{22,t} \end{bmatrix} = \begin{bmatrix} \sigma_{11,t} \\ \sigma_{12,t} \\ \sigma_{22,t} \end{bmatrix}$$

De esta forma, podemos establecer el modelo M-ARCH(1) con $K = 2$ será de la forma:

$$\begin{bmatrix} \sigma_{11,t} \\ \sigma_{12,t} \\ \sigma_{22,t} \end{bmatrix} = \begin{bmatrix} \gamma_{10} \\ \gamma_{20} \\ \gamma_{30} \end{bmatrix} + \begin{bmatrix} \gamma_{11} & \gamma_{12} & \gamma_{13} \\ \gamma_{21} & \gamma_{22} & \gamma_{23} \\ \gamma_{31} & \gamma_{32} & \gamma_{33} \end{bmatrix} \begin{bmatrix} U_{1,t-1}^2 \\ U_{1,t-1}U_{2,t-1} \\ U_{2,t-1}^2 \end{bmatrix}$$

Como notarán, este tipo de procedimientos implica la estimación de muchos parámetros. En esta circunstancia, se suelen estimar modelos restringidos para reducir el número de coeficientes estimados. Por ejemplo, podríamos querer estimar un caso como:

$$\begin{bmatrix} \sigma_{11,t} \\ \sigma_{12,t} \\ \sigma_{22,t} \end{bmatrix} = \begin{bmatrix} \gamma_{10} \\ \gamma_{20} \\ \gamma_{30} \end{bmatrix} + \begin{bmatrix} \gamma_{11} & 0 & 0 \\ 0 & \gamma_{22} & 0 \\ 0 & 0 & \gamma_{33} \end{bmatrix} \begin{bmatrix} U_{1,t-1}^2 \\ U_{1,t-1}U_{2,t-1} \\ U_{2,t-1}^2 \end{bmatrix}$$

Finalmente y de forma análoga al caso univariado, podemos plantear un modelo M-GARCH(p, q) como:

$$\begin{aligned} Vech(\Sigma_{t|t-1}) &= \gamma_0 + \sum_{j=1}^q \Gamma_j Vech(\mathbf{U}_{t-j} \mathbf{U}_{t-j}') \\ &+ \sum_{m=1}^p \mathbf{G}_m Vech(\Sigma_{t-m|t-m-1}) \end{aligned} \quad (6.18)$$

Donde cada una de las $\mathbf{G}_m$ es una matriz de coeficientes. Para ilustrar este caso, retomemos el ejemplo anterior, pero ahora para un modelo M-GARCH(1, 1) con $K = 2$ de forma que tendríamos:

$$\begin{aligned} \begin{bmatrix} \sigma_{11,t} \\ \sigma_{12,t} \\ \sigma_{22,t} \end{bmatrix} &= \begin{bmatrix} \gamma_{10} \\ \gamma_{20} \\ \gamma_{30} \end{bmatrix} + \begin{bmatrix} \gamma_{11} & \gamma_{12} & \gamma_{13} \\ \gamma_{21} & \gamma_{22} & \gamma_{23} \\ \gamma_{31} & \gamma_{32} & \gamma_{33} \end{bmatrix} \begin{bmatrix} U_{1,t-1}^2 \\ U_{1,t-1}U_{2,t-1} \\ U_{2,t-1}^2 \end{bmatrix} \\ &+ \begin{bmatrix} g_{11} & g_{12} & g_{13} \\ g_{21} & g_{22} & g_{23} \\ g_{31} & g_{32} & g_{33} \end{bmatrix} \begin{bmatrix} \sigma_{11,t-1} \\ \sigma_{12,t-1} \\ \sigma_{22,t-1} \end{bmatrix} \end{aligned}$$

6.5 Pruebas para detectar efectos ARCH

La prueba que mostraremos es conocida como una ARCH-LM, la cual está basada en una regresión de los residuales estimados de un modelo VAR(p) o cualquier otra estimación que deseemos probar, con el objeto de determinar si existen efectos ARCH –esta prueba se puede simplificar para el caso univariado–.

Partamos de plantear:

$$\begin{aligned} Vech(\hat{\mathbf{U}}_t \hat{\mathbf{U}}_t') &= \mathbf{B}_0 + \mathbf{B}_1 Vech(\hat{\mathbf{U}}_{t-1} \hat{\mathbf{U}}_{t-1}') + \dots \\ &+ \mathbf{B}_q Vech(\hat{\mathbf{U}}_{t-q} \hat{\mathbf{U}}_{t-q}') + \varepsilon_t \end{aligned} \quad (6.19)$$

Dada la estimación en la ecuación (6.20), plantearemos la estructura de hipótesis dada por:

$$\begin{aligned} H_0 &: \mathbf{B}_1 = \mathbf{B}_2 = \dots = \mathbf{B}_q = \mathbf{0} \\ H_a &: \text{al menos una } \mathbf{B}_i \neq \mathbf{0} \end{aligned}$$

La estadística de prueba será determinada por:

$$LM_{M-ARCH} = \frac{1}{2}TK(K+1) - T \cdot \text{Traza} \left(\hat{\Sigma}_{ARCH} \hat{\Sigma}_0^{-1} \right) \sim \chi^2_{[qK^2(K+1)^2/4]} \quad (6.20)$$

Donde la matriz $\hat{\Sigma}_{ARCH}$ se calcula de acuerdo con la ecuación (6.20) y la matriz $\hat{\Sigma}_0$ sin considerar una estructura dada para los errores.

6.6 Resumen del capítulo

En este capítulo introdujimos los modelos de heterocedasticidad condicional, diseñados para capturar la variabilidad agrupada (*volatility clustering*) que caracteriza a las series financieras de alta frecuencia.

Motivación. Las series de rendimientos financieros presentan dos hechos estilizados que los modelos ARMA estándar no capturan: (i) períodos de alta volatilidad seguidos de alta volatilidad y períodos de baja volatilidad seguidos de baja volatilidad, y (ii) colas pesadas en la distribución de los rendimientos. La prueba ARCH-LM (Engle, 1982) contrasta formalmente si los residuales al cuadrado presentan autocorrelación, lo que indica efectos ARCH.

Modelos ARCH y GARCH univariados. El modelo ARCH(q) de Engle (1982) especifica la varianza condicional como función de los cuadrados de los errores pasados:

$$h_t = \omega + \alpha_1 U_{t-1}^2 + \dots + \alpha_q U_{t-q}^2$$

El modelo GARCH(p, q) de Bollerslev (1986) añade términos de varianza condicional rezagada, logrando parsimonia frente al ARCH(∞) equivalente:

$$h_t = \omega + \sum_{i=1}^q \alpha_i U_{t-i}^2 + \sum_{j=1}^p \beta_j h_{t-j}$$

La condición de estacionariedad débil requiere $\sum_i \alpha_i + \sum_j \beta_j < 1$; bajo ella el proceso tiene varianza no condicional constante $\bar{\sigma}^2 = \omega / (1 - \sum_i \alpha_i - \sum_j \beta_j)$ y colas más pesadas que la normal, y los pronósticos de varianza reversion geométricamente a $\bar{\sigma}^2$ a la velocidad de la persistencia $\sum_i \alpha_i + \sum_j \beta_j$. La estimación se realiza por máxima verosimilitud (o cuasi-máxima verosimilitud) evaluando recursivamente la varianza condicional. La selección del orden (p, q) se realiza con los criterios AIC, BIC, Shibata y Hannan-Quinn disponibles en la

función `infocriterio()` del paquete `rugarch`. En la práctica, el GARCH(1,1) es suficiente para la mayoría de las series financieras.

Extensiones. El TGARCH/GJR-GARCH y el EGARCH capturan el efecto apalancamiento (los choques negativos elevan la volatilidad más que los positivos), mientras que el GARCH-M incorpora la varianza condicional en la ecuación de la media como premio al riesgo.

Valor en Riesgo (VaR). El VaR al nivel α se obtiene como el cuantil α de la distribución de rendimientos. Los modelos GARCH mejoran la estimación dinámica del VaR al actualizar la varianza condicional periodo a periodo.

Modelos ARCH y GARCH multivariados (M-GARCH). En sistemas de K variables, el M-GARCH extiende el modelo univariado apilando las varianzas y covarianzas condicionales mediante el operador $Vech(\cdot)$. La proliferación de parámetros obliga a trabajar con versiones restringidas (matrices diagonales). La prueba M-ARCH-LM generaliza la prueba univariada y sigue una distribución χ^2 bajo la hipótesis nula de no efectos ARCH.

El capítulo siguiente extiende el análisis a datos en panel, permitiendo explotar tanto la dimensión temporal como la transversal de los datos.

Capítulo 7

Modelos de Datos Panel, Panel VAR y otros Modelos No Lineales

7.1 Modelos de Datos Panel y Panel VAR

7.1.1 Motivación

Los datos panel son una extensión natural del análisis de series de tiempo en el que observamos una misma variable a lo largo del tiempo, pero para múltiples individuos. Denotemos con Y_{it} el componente o individuo i , $i = 1, 2, \dots, N$ en el tiempo t , $t = 1, 2, \dots, T$. Típicamente, las series de tiempo en forma de panel se caracterizan por ser de dimensión de individuos corta y de dimensión temporal larga.

En general, escribiremos:

$$Y_{it} = \alpha_i + \beta_i X_{it} + U_{it} \quad (7.1)$$

Donde α_i es un efecto fijo especificado como:

$$\alpha_i = \beta_0 + \gamma_i Z_i \quad (7.2)$$

7.1.2 Pruebas de Raíces Unitarias en Panel

Las pruebas de raíces unitarias para panel suelen ser usadas principalmente en casos macroeconómicos. De forma similar al caso de series univariadas, asumire-

mos una forma de AR(1) para una serie en panel:

$$\Delta Y_{it} = \mu_i + \rho_i Y_{i,t-1} + \sum_{j=1}^{k_i} \varphi_{ij} \Delta Y_{i,t-j} + \varepsilon_{it} \quad (7.3)$$

Donde $i = 1, \dots, N$, $t = 1, \dots, T$ y ε_{it} es una v.a. iid que cumple con:

$$\begin{aligned} \mathbb{E}[\varepsilon_{it}] &= 0 \\ \mathbb{E}[\varepsilon_{it}^2] &= \sigma_i^2 < \infty \\ \mathbb{E}[\varepsilon_{it}^4] &< \infty \end{aligned}$$

Al igual que en el caso univariado, en este tipo de pruebas buscamos identificar cuándo las series son I(1) y cuándo I(0). Para tal efecto, la prueba de raíz unitaria que utilizaremos está basada en una prueba Dickey-Fuller Aumentada en la cual la hipótesis nula (H_0) es que todas las series en el panel son no estacionarias, es decir, son I(1). Es decir,

$$H_0 : \rho_i = 0 \quad (7.4)$$

Por su parte, en el caso de la hipótesis alternativa tendremos dos: - H_1^A : Todas las series son I(0) – caso homogéneo, o

- H_1^B : Al menos una de las series es I(0) – caso heterogéneo

7.1.3 Ejemplo: Pruebas de Raíces Unitarias en Panel

Dependencias y configuración:

Descarga de datos de la librería plm:

```
data("EmplUK", package="plm")
data("Produc", package="plm")
data("Grunfeld", package="plm")
data("Wages", package="plm")
```

Descripción de los datos: Grunfeld (1958) contiene 20 observaciones anuales de inversión bruta real (invest), valor real de la empresa (value) y valor real del capital (capital) para 10 grandes empresas de EE.UU. durante 1935–1954.

```
names(Grunfeld)
```

```
## [1] "firm"      "year"      "inv"       "value"     "capital"
```

```
head(Grunfeld)
```

```
##   firm year  inv  value capital
## 1    1 1935 317.6 3078.5      2.8
## 2    1 1936 391.8 4661.7     52.6
## 3    1 1937 410.6 5387.1    156.9
## 4    1 1938 257.7 2792.2    209.2
## 5    1 1939 330.8 4313.2    203.4
## 6    1 1940 461.2 4643.9    207.2
```

```
Invest <- data.frame(split( Grunfeld$inv, Grunfeld$firm )) #
  ↪ individuals in columns
```

```
names(Invest)
```

```
## [1] "X1"  "X2"  "X3"  "X4"  "X5"  "X6"  "X7"  "X8"  "X9"
  ↪ "X10"
```

```
names(Invest) <- c( "Firm_1", "Firm_2", "Firm_3", "Firm_4",
                    "Firm_5", "Firm_6", "Firm_7", "Firm_8",
                    "Firm_9", "Firm_10" )
```

```
names(Invest)
```

```
## [1] "Firm_1" "Firm_2" "Firm_3" "Firm_4" "Firm_5"
  ↪ "Firm_6"
## [7] "Firm_7" "Firm_8" "Firm_9" "Firm_10"
```

Gráfica:

```
plot(Invest$Firm_1, type = "l", col = 1, ylim = c(0, 1500), lty =
  ↪ 1,
      xlab = "Tiempo", ylab = "Inversión bruta real")
lines(Invest$Firm_2, type = "l", col = 2, lty = 2)
lines(Invest$Firm_3, type = "l", col = 3, lty = 1)
lines(Invest$Firm_4, type = "l", col = 4, lty = 2)
lines(Invest$Firm_5, type = "l", col = 5, lty = 1)
```

```
lines(Invest$Firm_6, type = "l", col = 6, lty = 2)
lines(Invest$Firm_7, type = "l", col = 7, lty = 1)
lines(Invest$Firm_8, type = "l", col = 8, lty = 2)
lines(Invest$Firm_9, type = "l", col = 9, lty = 1)
lines(Invest$Firm_10, type = "l", col = 10, lty = 2)
legend("topleft", legend=c("Firm_1", "Firm_2", "Firm_3",
↵ "Firm_4", "Firm_5",
                        "Firm_6", "Firm_7", "Firm_8",
↵ "Firm_9", "Firm_10"),
      col = c(1, 2, 3, 4, 5, 6, 7, 8, 9, 10), lty = 1:2)
```




Figura 7.1: Evolución de la inversión por empresa

Prueba de raíz unitaria en panel (Levin et al., 2002; Im et al., 2003; Maddala and Wu, 1999; Hadri, 2000):

Consideremos la prueba de Levin et al. (2002):

```
purtest(log(Invest), test = "levinlin", exo = "intercept",
      lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
  ↪ Intercepts)
##
## data: log(Invest)
## z = -0.63214, p-value = 0.2636
## alternative hypothesis: stationarity
```

Alternativamente:

```
ts_LInvest <- ts(log(Invest), start = 1935, end = 1954, freq = 1)
ts_DLInvest <- diff(ts(log(Invest), start = 1935, end = 1954,
  ↪ freq = 1),
               lag = 1, differences = 1)
```

```
purtest(ts_LInvest, test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
  ↪ Intercepts)
##
## data: ts_LInvest
## z = -0.63214, p-value = 0.2636
## alternative hypothesis: stationarity
```

```
purtest(ts_DLInvest, test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
  ↪ Intercepts)
##
## data: ts_DLInvest
## z = -8.5076, p-value < 0.00000000000000022
## alternative hypothesis: stationarity
```

Consideremos la prueba de raíz unitaria de Im, Pesaran y Shin (2003):

```
purtest(ts_LInvest, test = "ips", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
##
## Im-Pesaran-Shin Unit-Root Test (ex. var.: Individual
## Intercepts)
##
## data: ts_LInvest
## Wtbar = 0.6833, p-value = 0.7528
## alternative hypothesis: stationarity
```

```
purtest(ts_DLInvest, test = "ips", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
##
## Im-Pesaran-Shin Unit-Root Test (ex. var.: Individual
## Intercepts)
##
## data: ts_DLInvest
## Wtbar = -11.14, p-value < 0.00000000000000022
## alternative hypothesis: stationarity
```

7.1.4 Ejemplo: Modelo Dif-in-Dif para el INPC de análisis clínicos (update nov-2022)

Este ejemplo modela el efecto que tiene que una empresa de laboratorios de análisis clínicos compre a sus competidores en diferentes ciudades del país. Para lo cual usaremos información del Índice Nacional de Precios al Consumidor de los servicios de análisis clínicos.

Dependencias y configuración:

Importamos Datos desde un archivo de Excel. Los datos están en formato panel e incluyen: - INPC (Índice Nacional de Precios al Consumidor (2QJul2018 = 100)) para un tipo de servicio. Fuente: <https://www.inegi.org.mx/programas/inpc/2018/#Tabulados>

- Variable dicotómica que indica el momento en que inició el tratamiento
- Variable dicotómica que identifica al grupo expuesto al tratamiento
- Interacción entre el tiempo y el grupo tratado, además de una variable de tendencia

- Otras variables de control

Partamos de la siguiente ecuación:

$$y_{it} = \beta_1 + \beta_2 T_t + \beta_3 D_i + \theta T_t \times D_i + \gamma \mathbf{X}_{it} + \varepsilon_{it} \quad (7.5)$$

Donde y_{it} es la variable sobre la cual queremos evaluar el efecto de un tratamiento, $\mathbf{X}_{it}$ es un conjunto de variables de control, que incluye a las variables de efectos fijos (temporales, de individuos o del tipo que se decida) y, en su caso, una tendencia, entre otras. Finalmente, las variables T_t y D_i son variables dicotómicas que identifican con el valor de 1 el momento a partir del cual se observa el tratamiento y con 0 en cualquier otro caso, y con 1 los individuos que fueron tratados y con 0 en cualquier otro caso, respectivamente.

De esta forma, el producto $T_t \times D_i$ sería una variable dicotómica que indicaría con un 1 a aquellos individuos que fueron tratados a partir del momento en que se implementó el tratamiento y con 0 en cualquier otro caso. Bajo este escenario, θ es un coeficiente que captura el efecto del tratamiento, condicional a que se ha controlado por una serie de factores.

Otra forma de ver lo que se indica en la ecuación (7.5) es como la comparación de la diferencia en diferencia descrita por:

$$\begin{aligned} E &= [(\bar{y}_{exit}|treatment) - (\bar{y}_{baseline}|treatment)] \\ &\quad - [(\bar{y}_{exit}|placebo) - (\bar{y}_{baseline}|placebo)] \end{aligned} \quad (7.6)$$

La expresión (7.6) cuantifica el efecto que tiene el tratamiento como la diferencia de medias de dos grupos: un grupo tratado y otro no tratado. Dentro de los cuales se han comparado las medias respecto de una línea base. Podemos plantear esto desde esta otra perspectiva. Pensemos que solo tenemos dos periodos $t = 1, 2$, en el cual en 1 no ha ocurrido el tratamiento y en 2 ya ha ocurrido. Así, el cambio en la variable de respuesta para los individuos tratados será (suponiendo que omitimos la matriz $\mathbf{X}_{it}$ en la ecuación (7.5)):

$$\begin{aligned} \mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1] &= (\beta_1 + \beta_2 + \beta_3 + \theta) - (\beta_1 + \beta_3) \\ &= \beta_2 + \theta \end{aligned} \quad (7.7)$$

Ahora, sobre los no tratados:

$$\begin{aligned} \mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0] &= (\beta_1 + \beta_2) - (\beta_1) \\ &= \beta_2 \end{aligned} \quad (7.8)$$

Así, la diferencia en diferencia resulta de restar la ecuación (7.8) a la ecuación (7.7):

$$\begin{aligned} &(\mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1]) - (\mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0]) \\ &= \theta \end{aligned} \quad (7.9)$$

En nuestro caso, utilizaremos como tratamiento la entrada al mercado de un laboratorio de análisis clínicos en una ciudad determinada.

```
## [1] 13420      17

## # A tibble: 6 x 17
##   Fecha      Mes Anio Ciudad      INPC Dummy_FIRMA Marca_01
##   <chr>    <dbl> <dbl> <chr>      <chr>      <dbl>    <dbl>
##   <dbl>
## 1 Jul 2002      7 2002 Área Metro~ 68.3~          0          0
##   0
## 2 Ago 2002      8 2002 Área Metro~ 68.3~          0          0
##   0
## 3 Sep 2002      9 2002 Área Metro~ 68.3~          0          0
##   0
## 4 Oct 2002     10 2002 Área Metro~ 68.3~          0          0
##   0
## 5 Nov 2002     11 2002 Área Metro~ 68.3~          0          0
##   0
## 6 Dic 2002     12 2002 Área Metro~ 68.3~          0          0
##   0
## # i 9 more variables: Marca_03 <dbl>, Marca_04 <dbl>, Marca_05
##   <dbl>,
## #   Marca_06 <dbl>, Marca_07 <dbl>, Marca_08 <dbl>, Marca_09
##   <dbl>,
## #   Marca_10 <dbl>, Marca_11 <dbl>
```

Selección de ciudades:

```
Data <- Data[ which( Data$Ciudad != 'Atacomulco, Edo. de Méx.' &
  Data$Ciudad != 'Cancún, Q.R.' &
  Data$Ciudad != 'Coatzacoalcos, Ver.' &
  Data$Ciudad != 'Esperanza, Son.' &
  Data$Ciudad != 'Izúcar de Matamoros, Pue.' &
  Data$Ciudad != 'Pachuca, Hgo.' &
  Data$Ciudad != 'Tuxtla Gutiérrez, Chis.' &
  Data$Ciudad != 'Zacatecas, Zac.' ), ]
```

Transformaciones:

```
# Log de INPC
Data$LINPC <- log( as.numeric(Data$INPC) , base = exp(1))
```



```

# Volvemos factor a la fecha
Data$Periodo <- factor(Data$Fecha, order = TRUE,
  levels = c( "Jul 2002", "Ago 2002", "Sep
    ↪ 2002",
    "Oct 2002", "Nov 2002", "Dic
    ↪ 2002",
    "Ene 2003", "Feb 2003", "Mar
    ↪ 2003",
    "Abr 2003", "May 2003", "Jun
    ↪ 2003",
    "Jul 2003", "Ago 2003", "Sep
    ↪ 2003",
    "Oct 2003", "Nov 2003", "Dic
    ↪ 2003",
    "Ene 2004", "Feb 2004", "Mar
    ↪ 2004",
    "Abr 2004", "May 2004", "Jun
    ↪ 2004",
    "Jul 2004", "Ago 2004", "Sep
    ↪ 2004",
    "Oct 2004", "Nov 2004", "Dic
    ↪ 2004",
    "Ene 2005", "Feb 2005", "Mar
    ↪ 2005",
    "Abr 2005", "May 2005", "Jun
    ↪ 2005",
    "Jul 2005", "Ago 2005", "Sep
    ↪ 2005",
    "Oct 2005", "Nov 2005", "Dic
    ↪ 2005",
    "Ene 2006", "Feb 2006", "Mar
    ↪ 2006",
    "Abr 2006", "May 2006", "Jun
    ↪ 2006",
    "Jul 2006", "Ago 2006", "Sep
    ↪ 2006",
    "Oct 2006", "Nov 2006", "Dic
    ↪ 2006",
    "Ene 2007", "Feb 2007", "Mar
    ↪ 2007",
    "Abr 2007", "May 2007", "Jun
    ↪ 2007",
    "Jul 2007", "Ago 2007", "Sep
    ↪ 2007",
    "Oct 2007", "Nov 2007", "Dic
    ↪ 2007",

```

```
"Ene 2008", "Feb 2008", "Mar
↪ 2008",
"Abr 2008", "May 2008", "Jun
↪ 2008",
"Jul 2008", "Ago 2008", "Sep
↪ 2008",
"Oct 2008", "Nov 2008", "Dic
↪ 2008",
"Ene 2009", "Feb 2009", "Mar
↪ 2009",
"Abr 2009", "May 2009", "Jun
↪ 2009",
"Jul 2009", "Ago 2009", "Sep
↪ 2009",
"Oct 2009", "Nov 2009", "Dic
↪ 2009",
"Ene 2010", "Feb 2010", "Mar
↪ 2010",
"Abr 2010", "May 2010", "Jun
↪ 2010",
"Jul 2010", "Ago 2010", "Sep
↪ 2010",
"Oct 2010", "Nov 2010", "Dic
↪ 2010",
"Ene 2011", "Feb 2011", "Mar
↪ 2011",
"Abr 2011", "May 2011", "Jun
↪ 2011",
"Jul 2011", "Ago 2011", "Sep
↪ 2011",
"Oct 2011", "Nov 2011", "Dic
↪ 2011",
"Ene 2012", "Feb 2012", "Mar
↪ 2012",
"Abr 2012", "May 2012", "Jun
↪ 2012",
"Jul 2012", "Ago 2012", "Sep
↪ 2012",
"Oct 2012", "Nov 2012", "Dic
↪ 2012",
"Ene 2013", "Feb 2013", "Mar
↪ 2013",
"Abr 2013", "May 2013", "Jun
↪ 2013",
"Jul 2013", "Ago 2013", "Sep
↪ 2013",
```

```
"Oct 2013", "Nov 2013", "Dic
↪ 2013",
"Ene 2014", "Feb 2014", "Mar
↪ 2014",
"Abr 2014", "May 2014", "Jun
↪ 2014",
"Jul 2014", "Ago 2014", "Sep
↪ 2014",
"Oct 2014", "Nov 2014", "Dic
↪ 2014",
"Ene 2015", "Feb 2015", "Mar
↪ 2015",
"Abr 2015", "May 2015", "Jun
↪ 2015",
"Jul 2015", "Ago 2015", "Sep
↪ 2015",
"Oct 2015", "Nov 2015", "Dic
↪ 2015",
"Ene 2016", "Feb 2016", "Mar
↪ 2016",
"Abr 2016", "May 2016", "Jun
↪ 2016",
"Jul 2016", "Ago 2016", "Sep
↪ 2016",
"Oct 2016", "Nov 2016", "Dic
↪ 2016",
"Ene 2017", "Feb 2017", "Mar
↪ 2017",
"Abr 2017", "May 2017", "Jun
↪ 2017",
"Jul 2017", "Ago 2017", "Sep
↪ 2017",
"Oct 2017", "Nov 2017", "Dic
↪ 2017",
"Ene 2018", "Feb 2018", "Mar
↪ 2018",
"Abr 2018", "May 2018", "Jun
↪ 2018",
"Jul 2018", "Ago 2018", "Sep
↪ 2018",
"Oct 2018", "Nov 2018", "Dic
↪ 2018",
"Ene 2019", "Feb 2019", "Mar
↪ 2019",
"Abr 2019", "May 2019", "Jun
↪ 2019",
```

```

"Jul 2019", "Ago 2019", "Sep
↪ 2019",
"Oct 2019", "Nov 2019", "Dic
↪ 2019",
"Ene 2020", "Feb 2020", "Mar
↪ 2020",
"Abr 2020", "May 2020", "Jun
↪ 2020",
"Jul 2020", "Ago 2020", "Sep
↪ 2020",
"Oct 2020", "Nov 2020", "Dic
↪ 2020",
"Ene 2021", "Feb 2021", "Mar
↪ 2021",
"Abr 2021", "May 2021", "Jun
↪ 2021",
"Jul 2021", "Ago 2021", "Sep
↪ 2021",
"Oct 2021", "Nov 2021", "Dic
↪ 2021",
"Ene 2022", "Feb 2022", "Mar
↪ 2022",
"Abr 2022", "May 2022", "Jun
↪ 2022",
"Jul 2022", "Ago 2022", "Sep
↪ 2022", "
Oct 2022", "Nov 2022", "Dic
↪ 2022" ))

```

La Figura 7.2 muestra la evolución del logaritmo del INPC de análisis clínicos para las 47 ciudades del panel (líneas grises); la línea roja es el promedio simple entre ciudades. Se aprecia una tendencia común al alza y una dispersión entre ciudades que se reduce hacia el final de la muestra.

```

Data %>%
  ggplot( aes(x = Periodo, y = LINPC, group = Ciudad) ) +
  geom_line(color = "grey70", linewidth = 0.3) +
  stat_summary(aes(group = 1), fun = mean, geom = "line",
    color = "darkred", linewidth = 0.9) +
  scale_x_discrete(breaks = levels(Data$Periodo)[
    seq(1, nlevels(Data$Periodo), by = 12)]) +
  labs(x = NULL, y = "log(INPC) de análisis clínicos") +
  theme(axis.text.x = element_text( size = 8, angle = 90,
    ↪ vjust = 0.5))

```




Figura 7.2: Logaritmo del INPC de análisis clínicos por ciudad (líneas grises) y promedio entre ciudades (línea roja)

Hagamos una prueba de Raíces Unitarias.

Conversión a formato ancho:

```
## # A tibble: 6 x 48
##   Fecha `Acapulco, Gro.` `Aguascalientes, Ags.` Área
##   <chr>      <dbl>      <dbl>
##   <dbl>
## 1 Abr ~      4.39      4.35
##   <dbl>
## 2 Abr ~      4.39      4.36
##   <dbl>
## 3 Abr ~      4.44      4.36
##   <dbl>
## 4 Abr ~      4.47      4.33
##   <dbl>
## 5 Abr ~      4.54      4.38
##   <dbl>
## 6 Abr ~      4.60      4.41
##   <dbl>
## # i abbreviated name: 1: `Área Metropolitana de la Cd. de
##   <dbl>
## # i 44 more variables: `Campeche, Camp.` <dbl>,
## # `Cd. Acuña, Coah.` <dbl>, `Cd. Jiménez, Chih.` <dbl>,
## # `Cd. Juárez, Chih.` <dbl>, `Chetumal, Q.R.` <dbl>,
## # `Chihuahua, Chih.` <dbl>, `Colima, Col.` <dbl>,
## # `Córdoba, Ver.` <dbl>, `Cortazar, Gto.` <dbl>,
## # `Cuernavaca, Mor.` <dbl>, `Culiacán, Sin.` <dbl>, ...
```

Series de tiempo:

```
ts_LINPC <- ts( LINPC[c( 2:48 )],
               start = c(2002, 7),
               freq = 12)

ts_DLINPC <- diff(ts( LINPC[c( 2:48 )],
                    start = c(2002, 7),
                    freq = 12),
                lag = 1,
                differences = 1)
```

Prueba de raíz unitaria en panel:

Rezagos óptimos:

$$\begin{aligned}
 p &= \text{Int}(4 * (T/100)^{(1/4)}) \\
 &= \text{Int}(4 * (244/100)^{(1/4)}) \\
 &= \text{Int}(4.99) \\
 &= 4
 \end{aligned}$$

Prueba de Levin et al. (2002):

```

purtest(ts_LINPC, test = "levinlin", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)

##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual Intercepts
## and Trend)
##
## data: ts_LINPC
## z = -56.022, p-value < 2.2e-16
## alternative hypothesis: stationarity

```

```

purtest(ts_DLINPC, test = "levinlin", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)

##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual Intercepts
## and Trend)
##
## data: ts_DLINPC
## z = -107.84, p-value < 2.2e-16
## alternative hypothesis: stationarity

```

Prueba de Choi (2001):

```

purtest(ts_LINPC, test = "logit", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)

##
## Choi's Logit Unit-Root Test (ex. var.: Individual Intercepts
## and Trend)

```

```
##
## data:  ts_LINPC
## L* = -85.506, df = 239, p-value < 2.2e-16
## alternative hypothesis: stationarity
```

```
purtest(ts_DLINPC, test = "logit", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)
```

```
##
## Choi's Logit Unit-Root Test (ex. var.: Individual Intercepts
## and Trend)
##
## data:  ts_DLINPC
## L* = -278.56, df = 239, p-value < 2.2e-16
## alternative hypothesis: stationarity
```

Prueba de Hadri (2000):

```
purtest(ts_LINPC, test = "hadri", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)
```

```
##
## Hadri Test (ex. var.: Individual Intercepts and Trend)
## (Heterosked. Consistent)
##
## data:  ts_LINPC
## z = -2.7, p-value = 0.9965
## alternative hypothesis: at least one series has a unit root
```

```
purtest(ts_DLINPC, test = "hadri", exo = "trend", # exo =
  ↪ c("none", "intercept", "trend"),
      lags = "AIC", pmax = 4)
```

```
##
## Hadri Test (ex. var.: Individual Intercepts and Trend)
## (Heterosked. Consistent)
##
## data:  ts_DLINPC
## z = -8.9351, p-value = 1
## alternative hypothesis: at least one series has a unit root
```


Estimación PANEL con TREND:

```
# Modelo Final
fixed <- plm( LINPC ~ Dummy_FIRMA + Marca_01 + Marca_02 +
  ↪ Marca_03 + Marca_04 + Marca_05 +
      Marca_06 + Marca_07 + Marca_08 + Marca_09 +
  ↪ Marca_10 + Marca_11 + as.numeric(Periodo),
  data = Data,
  index=c("Ciudad", "Periodo"),
  model = "within")

## Warning in pdata.frame(data, index): at least one NA in at
  ↪ least one index dimension in resulting pdata.frame
## to find out which, use, e.g., table(index(your_pdataframe),
  ↪ useNA = "ifany")

summary(fixed)

## Oneway (individual) effect Within Model
##
## Call:
## plm(formula = LINPC ~ Dummy_FIRMA + Marca_01 + Marca_02 +
  ↪ Marca_03 +
##      Marca_04 + Marca_05 + Marca_06 + Marca_07 + Marca_08 +
  ↪ Marca_09 +
##      Marca_10 + Marca_11 + as.numeric(Periodo), data = Data,
  ↪ model = "within",
##      index = c("Ciudad", "Periodo"))
##
## Balanced Panel: n = 47, T = 243, N = 11421
##
## Residuals:
##      Min.      1st Qu.      Median      3rd Qu.      Max.
## -0.4220510 -0.0416329  0.0026154  0.0471479  0.2275376
##
## Coefficients:
##              Estimate Std. Error t-value Pr(>|t|)
## Dummy_FIRMA    -0.05972092  0.01892851  -3.1551 0.0016087
## ↪ **
## Marca_01         0.04545555  0.02069006   2.1970 0.0280423
## ↪ *
## Marca_02         0.05452288  0.02372909   2.2977 0.0215956
## ↪ *
## Marca_03        -0.02925504  0.02041744  -1.4328 0.1519296
```

```
## Marca_04          -0.07440826  0.02418665  -3.0764  0.0021000
  ↪ **
## Marca_05          0.02633713  0.01045219   2.5198  0.0117567
  ↪ *
## Marca_06          0.12521494  0.01991655   6.2870  3.356e-10
  ↪ ***
## Marca_07          -0.09242328  0.02514895  -3.6750  0.0002389
  ↪ ***
## Marca_08          0.03362324  0.02086579   1.6114  0.1071193
## Marca_09          0.05630828  0.02121641   2.6540  0.0079655
  ↪ **
## Marca_10          -0.04866105  0.02638856  -1.8440  0.0652062
  ↪ .
## Marca_11          -0.03582620  0.03031018  -1.1820  0.2372361
## as.numeric(Periodo) 0.00220384  0.00001018 216.4961 < 2.2e-16
  ↪ ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Total Sum of Squares:    330.79
## Residual Sum of Squares: 60.08
## R-Squared:              0.81838
## Adj. R-Squared:         0.81743
## F-statistic: 3937.79 on 13 and 11361 DF, p-value: < 2.22e-16
```

```
# Modelo Final
fixed <- plm( LINPC ~ Dummy_FIRMA + as.numeric(Periodo),
              data = Data,
              index=c("Ciudad", "Periodo"),
              model = "within")
```

```
## Warning in pdata.frame(data, index): at least one NA in at
  ↪ least one index dimension in resulting pdata.frame
## to find out which, use, e.g., table(index(your_pdataframe),
  ↪ useNA = "ifany")
```

```
summary(fixed)
```

```
## Oneway (individual) effect Within Model
##
## Call:
## plm(formula = LINPC ~ Dummy_FIRMA + as.numeric(Periodo), data
  ↪ = Data,
##      model = "within", index = c("Ciudad", "Periodo"))
```

```
##
## Balanced Panel: n = 47, T = 243, N = 11421
##
## Residuals:
##      Min.      1st Qu.      Median      3rd Qu.      Max.
## -0.4337032 -0.0421466  0.0026796  0.0480377  0.2504866
##
## Coefficients:
##              Estimate Std. Error t-value
##      Pr(>|t|)
## Dummy_FIRMA      -0.02239578  0.00417897  -5.3592
##      0.000000008525
## as.numeric(Periodo) 0.00220318  0.00001032 213.4825    <
##      2.2e-16
##
## Dummy_FIRMA      ***
## as.numeric(Periodo) ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Total Sum of Squares:    330.79
## Residual Sum of Squares: 61.94
## R-Squared:              0.81275
## Adj. R-Squared: 0.81196
## F-statistic: 24680.5 on 2 and 11372 DF, p-value: < 2.22e-16
```

7.1.5 Panel VAR

En esta sección extenderemos el caso del modelo VAR(p) a uno en forma panel. En este caso asumimos que las variables exógenas son los p rezagos de las k variables endógenas. Consideremos el siguiente caso de un modelo panel VAR con efectos fijos –ciertamente es posible hacer estimaciones con efectos aleatorios, no obstante, requiere de supuestos adicionales que no contemplamos en estas notas–, el cual es la forma más común de estimación:

$$\mathbf{Y}_{it} = \mu_i + \sum_{l=1}^p \mathbf{A}_l \mathbf{Y}_{it-l} + \mathbf{B} \mathbf{X}_{it} + \varepsilon_{it} \quad (7.10)$$

Donde $\mathbf{Y}_{it}$ es un vector de variables endógenas estacionarias para la unidad de corte transversal i en el tiempo t , $\mathbf{X}_{it}$ es una matriz que contiene variables exógenas, y ε_{it} es un término de error que cumple con:

$$\begin{aligned} \mathbb{E}[\varepsilon_{it}] &= 0 \\ \text{Var}[\varepsilon_{it}] &= \Sigma_\varepsilon \end{aligned}$$

Donde Σ_ε es una matriz definida positiva.

7.1.5.1 ¿Por qué no estimar por MCO? El sesgo de Nickell

A diferencia del modelo panel estático, en la ecuación (7.10) los regresores incluyen rezagos de la variable dependiente. Esto invalida a los estimadores tradicionales de panel: el estimador *within* (de efectos fijos) elimina μ_i restando la media individual, pero la media de $\mathbf{Y}_{it}$ contiene información de todos los periodos, incluidos los errores pasados, por lo que el regresor transformado queda correlacionado con el error transformado. El sesgo resultante, documentado por Nickell (1981), es de orden $1/T$: resulta despreciable en paneles largos, pero considerable en los paneles macro y microeconómicos típicos, donde T es pequeño ($T \leq 10$, por ejemplo) aunque N sea grande. Por ello, la literatura de paneles dinámicos estima el PVAR por el método generalizado de momentos (GMM) sobre una transformación del modelo que elimine los efectos fijos sin inducir esa correlación.

7.1.5.2 Transformaciones: primeras diferencias y desviaciones ortogonales

La transformación más directa es la de **primeras diferencias** (FD):

$$\Delta \mathbf{Y}_{it} = \sum_{l=1}^p \mathbf{A}_l \Delta \mathbf{Y}_{it-l} + \mathbf{B} \Delta \mathbf{X}_{it} + \Delta \varepsilon_{it} \quad (7.11)$$

que elimina μ_i , pero con dos costos: (i) el nuevo error $\Delta \varepsilon_{it} = \varepsilon_{it} - \varepsilon_{i,t-1}$ sigue por construcción un proceso MA(1), de modo que está correlacionado con $\Delta \mathbf{Y}_{i,t-1}$ y la estimación requiere instrumentos; y (ii) cada hueco en el panel (dato faltante) elimina dos observaciones transformadas.

Una alternativa es la transformación de **desviaciones ortogonales hacia adelante** (FOD, *forward orthogonal deviations*) de Arellano y Bover (1995): a cada observación se le resta el promedio de las observaciones *futuras* disponibles de la misma unidad, reescalando para preservar la varianza:

$$\tilde{\mathbf{Y}}_{it} = c_{it} \left[\mathbf{Y}_{it} - \frac{1}{T-t} (\mathbf{Y}_{i,t+1} + \dots + \mathbf{Y}_{iT}) \right], \quad c_{it} = \sqrt{\frac{T-t}{T-t+1}}. \quad (7.12)$$

Como solo usa información futura, la transformación no introduce autocorrelación en los errores transformados (si ε_{it} no está autocorrelacionado, $\tilde{\varepsilon}_{it}$ tampoco lo está) y solo se pierde la última observación de cada unidad, lo que la hace preferible en paneles cortos o con huecos. En el paquete **panelvar** de R, el argumento **transformation** de la función **pvargmm()** permite elegir entre ambas: "fd" (primeras diferencias) o "fod" (desviaciones ortogonales).

7.1.5.3 Estimación GMM: en diferencias y en sistema

Una vez transformado el modelo, el estimador **GMM en diferencias** de Arellano y Bond (1991) explota como instrumentos los *niveles rezagados* de las variables: bajo el supuesto de que los errores no están autocorrelacionados, los niveles $\mathbf{Y}_{i,t-s}$ con $s \geq 2$ no están correlacionados con $\Delta\epsilon_{it}$, lo que genera las condiciones de momentos

$$\mathbb{E} [\mathbf{Y}_{i,t-s} \Delta\epsilon'_{it}] = 0, \quad s = 2, 3, \dots, t-1. \quad (7.13)$$

Cuando las series son muy persistentes (cercanas a raíz unitaria), los niveles rezagados son instrumentos *débiles* de las diferencias y el GMM en diferencias se comporta mal. El estimador **GMM en sistema** de Blundell y Bond (1998) añade al sistema las ecuaciones en niveles, instrumentadas con las *diferencias rezagadas*, bajo un supuesto adicional sobre las condiciones iniciales del proceso (que las desviaciones iniciales respecto del estado estacionario no estén correlacionadas con los efectos fijos). En `pvargmm()`, esta variante se activa con `system_instruments = TRUE`.

Dos aspectos prácticos completan la especificación:

- **Proliferación de instrumentos.** El número de instrumentos de la ecuación (7.13) crece con T^2 y con el número de variables. Demasiados instrumentos sobreajustan las variables endógenas y debilitan las pruebas de especificación. Roodman (2009) recomienda limitar los rezagos usados como instrumentos (argumentos `max_instr_dependent_vars` y `min_instr_dependent_vars`) o *colapsar* la matriz de instrumentos (`collapse = TRUE`).
- **Una y dos etapas.** El estimador de dos etapas (`steps = "twostep"`) utiliza la matriz de ponderación óptima estimada en la primera etapa y es más eficiente, aunque sus errores estándar deben corregirse en muestras pequeñas (Windmeijer, 2005).

7.1.5.4 Diagnóstico y selección de rezagos

La validez del conjunto de instrumentos se evalúa con la prueba de sobreidentificación de **Hansen** (J), cuya hipótesis nula es que los instrumentos son válidos (no correlacionados con el error); valores p demasiado bajos indican instrumentos inválidos, pero valores p sospechosamente cercanos a 1 suelen ser síntoma de demasiados instrumentos. Adicionalmente, se examina la autocorrelación de los errores en diferencias: se espera autocorrelación de orden 1 (por construcción del MA(1)), pero **no** de orden 2 — si la hubiera, los instrumentos con $s = 2$ dejarían de ser válidos. Finalmente, el orden p del PVAR se selecciona con los criterios de Andrews y Lu (2001) (MMSC-AIC, MMSC-BIC, MMSC-HQIC), que son análogos a los criterios de información tradicionales pero se construyen a partir del estadístico J de Hansen; los calcularemos con la función `Andrews_Lu_MMSC()` en los ejemplos.


```
## 3 -0.4591824 -0.5286502 4.578383 4.561294      0      0      0
  ↪ 1
## 4 -0.3899363 -0.4591824 4.601245 4.578383      0      0      0
  ↪ 0
## 5 -0.4827242 -0.3899363 4.610656 4.601245      0      0      0
  ↪ 0
## 6 -0.6780615 -0.4827242 4.600741 4.610656      0      0      0
  ↪ 0
##   yr1980 yr1981 yr1982 yr1983 yr1984
## 1      0      0      0      0      0
## 2      0      0      0      0      0
## 3      0      0      0      0      0
## 4      1      0      0      0      0
## 5      0      1      0      0      0
## 6      0      0      1      0      0
```

Estimación

```
##?pvargmm

Arellano_Bond_1991_table4b <- pvargmm( dependent_vars = c("n"),
  lags = 2,
  exog_vars = c("w", "wL1",
    ↪ "k", "ys", "ysL1",
    ↪ "yr1979", "yr1980",
    ↪ "yr1981", "yr1982",
      "yr1983",
    ↪ "yr1984"
    ↪ ),
  transformation = "fd",
  ↪ data = abdata,
  ↪ panel_identifier =
  ↪ c("id", "year"),
  steps = c("twostep"),
  system_instruments =
  ↪ FALSE,
  max_instr_dependent_vars =
  ↪ 99,
  min_instr_dependent_vars =
  ↪ 2L,
  collapse = FALSE)
```

```
summary(Arellano_Bond_1991_table4b)
```

Dynamic Panel VAR estimation, two-step GMM

Transformation: First-differences
Group variable: id
Time variable: year
Number of observations = 611
Number of groups = 140
Obs per group: min = 4
Obs per group: avg = 4.36428571428571
Obs per group: max = 6
Number of instruments = 38

n

lag1_n

0.4742*

(0.1854)

lag2_n

-0.0530

(0.0517)

w

-0.5132***

(0.1456)

wL1

0.2246

(0.1419)

k

0.2927***

(0.0626)

ys

0.6098***

(0.1563)

ysL1

-0.4464*

(0.2173)

yr1979

0.0105

(0.0099)

yr1980

0.0247

(0.0158)

yr1981

-0.0158

(0.0267)

yr1982

-0.0374

(0.0300)

yr1983

-0.0393

(0.0347)

yr1984

-0.0495

(0.0349)

***p < 0.001; **p < 0.01; *p < 0.05

Instruments for equation

Standardw, wL1, k, ys, ysL1, yr1979, yr1980, yr1981, yr1982, yr1983, yr1984

GMM-typeDependent vars: L(2,6))Collapse = FALSE

Hansen test of overid. restrictions: chi2(25) = 30.11 Prob > chi2 = 0.22(Robust,
but weakened by many instruments.)

7.2.2 Ejemplo 2:

Se utiliza un conjunto de datos panel de 265 municipios suecos durante 9 años (1979–1987). Las variables incluyen el gasto total (**expenditures**), los ingresos propios (**revenues**) y las transferencias intergubernamentales recibidas por el municipio (**grants**). Fuente: Dahlberg y Johansson (2000). Las transferencias del gobierno central al gobierno local son de tres tipos: apoyo a municipios con baja capacidad fiscal, transferencias para financiar ciertas actividades del gobierno local, y transferencias destinadas a inversiones específicas.

```
data("Dahlberg")
```

```
names(Dahlberg)
```

```
## [1] "id"          "year"         "expenditures" "revenues"
## [5] "grants"
```

```
head(Dahlberg)
```

```
##      id year expenditures revenues grants
## 1 114 1979    0.0229736 0.0181770 0.0054429
## 2 114 1980    0.0266307 0.0209142 0.0057304
## 3 114 1981    0.0273253 0.0210836 0.0056647
## 4 114 1982    0.0288704 0.0234310 0.0058859
## 5 114 1983    0.0226474 0.0179979 0.0055908
## 6 114 1984    0.0215601 0.0179949 0.0047536
```

Estimación:

```
ex1_dahlberg_data <- pvargmm(dependent_vars = c("expenditures",
  ↪ "revenues", "grants"),
  lags = 1,
  transformation = "fod",
  data = Dahlberg,
  panel_identifier=c("id", "year"),
  steps = c("twostep"),
  system_instruments = FALSE,
  max_instr_dependent_vars = 99,
  max_instr_predet_vars = 99,
  min_instr_dependent_vars = 2L,
  min_instr_predet_vars = 1L,
  collapse = FALSE
)
```

```
## Warning in pvargmm(dependent_vars = c("expenditures",
↪ "revenues",
## "grants"), : The matrix D_e is singular, therefore the general
## inverse is used
```

```
summary(ex1_dahlberg_data)
```

Dynamic Panel VAR estimation, two-step GMM

Transformation: Forward orthogonal deviations
Group variable: id
Time variable: year
Number of observations = 1855
Number of groups = 265
Obs per group: min = 7
Obs per group: avg = 7
Obs per group: max = 7
Number of instruments = 252

expenditures

revenues

grants

lag1_expenditures

0.2846***

0.2583**

0.0167

(0.0664)

(0.0795)

(0.0172)

lag1_revenues

-0.0470

0.0588

-0.0405**

(0.0637)

(0.0726)

(0.0151)

lag1_grants

-1.6746***

-2.2367***

0.3204***

(0.2818)

(0.2846)

(0.0521)

***p < 0.001; **p < 0.01; *p < 0.05

Instruments for equation

Standard

GMM-typeDependent vars: L(2,7))Collapse = FALSE

Hansen test of overid. restrictions: chi2(243) = 263.01 Prob > chi2 = 0.18(Robust, but weakened by many instruments.)

Selección de rezagos óptimos mediante el procedimiento de Andrews y Lu (2001):

```
Andrews_Lu_MMSC(ex1_dahlberg_data)
```

```
## $MMSC_BIC
## [1] -1610.877
##
## $MMSC_AIC
## [1] -234.9924
##
## $MMSC_HQIC
## [1] -792.3698
```

```
ex2_dahlberg_data <- pvargmm(dependent_vars = c("expenditures",
↪ "revenues", "grants"),
                             lags = 2,
                             transformation = "fod",
                             data = Dahlberg,
                             panel_identifier=c("id", "year"),
                             steps = c("twostep"),
                             system_instruments = FALSE,
                             max_instr_dependent_vars = 99,
                             max_instr_predet_vars = 99,
                             min_instr_dependent_vars = 2L,
                             min_instr_predet_vars = 1L,
                             collapse = FALSE)
```

```
## Warning in pvargmm(dependent_vars = c("expenditures",
↪  "revenues",
## "grants"), : The matrix D_e is singular, therefore the general
## inverse is used
```

```
summary(ex2_dahlberg_data)
```

Dynamic Panel VAR estimation, two-step GMM

Transformation: Forward orthogonal deviations
 Group variable: id
 Time variable: year
 Number of observations = 1590
 Number of groups = 265
 Obs per group: min = 6
 Obs per group: avg = 6
 Obs per group: max = 6
 Number of instruments = 243

expenditures

revenues

grants

lag1_expenditures

0.2572**

0.2486*

0.0135

(0.0893)

(0.1018)

(0.0178)

lag1_revenues

-0.1219

-0.0634

-0.0293

(0.0879)

(0.0997)

(0.0171)

lag1_grants

-3.0718***

-3.5849***

0.1581*

(0.5941)

(0.6168)

(0.0636)

lag2_expenditures

-0.0247

0.0252

0.0178

(0.0791)

(0.0834)

(0.0157)

lag2_revenues

-0.2584**

-0.2446**

-0.0237

(0.0785)

(0.0800)

(0.0157)

lag2_grants

-1.5265***

-1.6687***

0.0702

(0.1873)

(0.2113)

(0.0586)

***p < 0.001; **p < 0.01; *p < 0.05

Instruments for equation

Standard

GMM-typeDependent vars: L(2,6))Collapse = FALSE

Hansen test of overid. restrictions: $\chi^2(225) = 260.11$ Prob > $\chi^2 = 0.054$ (Robust, but weakened by many instruments.)

```
Andrews_Lu_MMSC(ex2_dahlberg_data)
```

```
## $MMSC_BIC
## [1] -1486.935
##
## $MMSC_AIC
## [1] -213.8917
##
## $MMSC_HQIC
## [1] -734.1071
```

Al igual que en el VAR de series de tiempo (Capítulo 5), la estabilidad del Panel VAR se verifica con los eigenvalores de la matriz compañera del sistema: el proceso es estable si todos los módulos son estrictamente menores que 1, es decir, si todas las raíces se encuentran dentro del círculo unitario. La Figura 7.3 muestra las tres raíces del modelo estimado, todas al interior del círculo, por lo que el PVAR(1) es estable:

```
stab_ex1_dahlberg_data <- stability(ex1_dahlberg_data)
```

```
print(stab_ex1_dahlberg_data)
```

```
## Eigenvalue stability condition:
##
##           Eigenvalue      Modulus
## 1 0.5370657+0.00000000i 0.53706574
## 2 0.0633651+0.06442426i 0.09036383
## 3 0.0633651-0.06442426i 0.09036383
##
## All the eigenvalues lie inside the unit circle.
## PVAR satisfies stability condition.
```

```
plot(stab_ex1_dahlberg_data) +
  coord_fixed() +
  scale_x_continuous(name = "Parte real") +
  scale_y_continuous(name = "Parte imaginaria") +
  labs(title = "Raíces de la matriz compañera")
```




Figura 7.3: Raíces de la matriz compañera del Panel VAR(1) estimado. El proceso es estable porque todos los eigenvalores están dentro del círculo unitario.

Funciones de impulso-respuesta (comentadas; descomentar para ejecutar):

```
# ex1_dahlberg_data_oirf <- oirf(ex1_dahlberg_data, n.ahead = 8)
#
# ex1_dahlberg_data_girf <- girf(ex1_dahlberg_data, n.ahead = 8,
#   ↪   ma_approx_steps= 8)
#
# ex1_dahlberg_data_bs <- bootstrap_irf(ex1_dahlberg_data,
#   ↪   typeof_irf = c("GIRF"),
#                                     n.ahead = 8,
#                                     nof_Nstar_draws = 500,
#                                     confidence.band = 0.95)
#
# plot(ex1_dahlberg_data_girf, ex1_dahlberg_data_bs)
```

7.3 Cointegración

La extensión de los conceptos de cointegración al contexto panel sigue la misma lógica que en el caso univariado: si las series Y_{it} son $I(1)$ pero existe una combinación lineal estacionaria, se dice que cointegran. El procedimiento más utilizado es el propuesto por Pedroni (1999, 2004), que plantea siete estadísticos de prueba bajo la hipótesis nula de no cointegración, permitiendo tanto coeficientes de cointegración homogéneos como heterogéneos entre individuos.

7.3.1 Prueba de Pedroni (1999, 2004)

Para cada individuo $i = 1, \dots, N$ se estima la regresión de cointegración de largo plazo:

$$Y_{it} = \alpha_i + \delta_i t + \beta_i' \mathbf{X}_{it} + e_{it} \quad (7.14)$$

donde $\mathbf{X}_{it}$ es un vector $m \times 1$ de regresores $I(1)$, α_i es un efecto fijo individual y $\delta_i t$ es una tendencia determinista individual (que puede omitirse). La hipótesis nula es que los residuales $\hat{e}_{it}$ tienen raíz unitaria, es decir, no existe cointegración para ningún individuo del panel:

$$H_0 : \hat{e}_{it} = \hat{e}_{i,t-1} + v_{it} \quad \forall i \quad (7.15)$$

Para construir los estadísticos se estima, para cada i , la regresión auxiliar aumentada sobre los residuales:

$$\Delta \hat{e}_{it} = \hat{\rho}_i \hat{e}_{i,t-1} + \sum_{j=1}^{k_i} \hat{\psi}_{ij} \Delta \hat{e}_{i,t-j} + \hat{v}_{it} \quad (7.16)$$

A partir de los residuales $\hat{v}_{it}$ y de las varianzas de largo plazo $\hat{L}_{11i}^2$ (que corrigen la correlación serial), Pedroni (1999) construye siete estadísticos divididos en dos grupos:

Estadísticos de dimensión interna (within-dimension). Imponen un coeficiente autorregresivo $\rho_i = \rho$ común al hacer la suma sobre individuos. Se componen del estadístico Panel- ν (cociente de varianzas, diverge hacia la derecha bajo H_1), el Panel- ρ (análogo al estadístico ρ de Phillips-Perron), el Panel- t no paramétrico y el Panel-ADF paramétrico.

Estadísticos de dimensión entre grupos (between-dimension). Promedian estadísticos individuales sobre los N individuos, permitiendo que ρ_i difiera entre individuos bajo la alternativa. Se componen del Group- ρ , el Group- t no paramétrico y el Group-ADF paramétrico.

Bajo la hipótesis nula de no cointegración, todos los estadísticos estandarizados convergen en distribución a una normal estándar:

$$\frac{\text{Estadístico} - \mu_{NT}}{\sigma_{NT}} \xrightarrow{d} N(0, 1) \quad (7.17)$$

donde μ_{NT} y σ_{NT} son momentos que dependen del número de regresores m y se tabulan en Pedroni (1999). Los estadísticos Panel- ν divergen hacia la derecha bajo la alternativa; los demás seis divergen hacia la izquierda, de modo que valores muy negativos llevan a rechazar H_0 .

La ventaja de los estadísticos between-dimension sobre los within-dimension es que permiten vectores de cointegración heterogéneos entre individuos bajo la hipótesis alternativa, lo que los hace más adecuados en paneles con coeficientes de largo plazo que varían entre individuos.

7.3.2 Prueba de Kao (1999)

Kao (1999) propone pruebas más restrictivas que imponen el mismo vector de cointegración para todos los individuos y no incluyen tendencia determinista individual. Sus estadísticos también se basan en los residuales de la regresión de cointegración y convergen a $N(0, 1)$ bajo la hipótesis nula de no cointegración.

7.3.3 Prueba de Westerlund (2007)

Westerlund (2007) propone cuatro estadísticos basados en la corrección de errores: en lugar de probar raíz unitaria en los residuales, se estima un modelo de corrección de errores para cada individuo y se prueba si el coeficiente de ajuste α_i es significativamente negativo. Este enfoque tiene mayor potencia que las pruebas residuales cuando la dinámica de corto plazo varía entre individuos, y permite controlar la dependencia transversal mediante remuestreo (*bootstrap*).

7.3.4 Ejemplo: inversión y valor de la empresa en el panel de Grunfeld

Ilustremos la mecánica de las pruebas anteriores con el panel de Grunfeld (1958) que hemos utilizado a lo largo del capítulo (10 empresas, 1935–1954). La teoría de la inversión sugiere una relación de largo plazo entre la inversión de la empresa y su valor de mercado —en el espíritu de la q de Tobin (1969)—, de modo que postulamos la regresión de cointegración de la ecuación (7.14) con $Y_{it} = \ln(inv_{it})$ y $X_{it} = \ln(value_{it})$.

Paso 1: verificar que ambas series son $I(1)$. Aplicamos la prueba de Levin-Lin-Chu en niveles y en diferencias:

```
LINV <- ts(data.frame(split(log(Grunfeld$inv), Grunfeld$firm)),
           start = 1935, freq = 1)

LVAL <- ts(data.frame(split(log(Grunfeld$value), Grunfeld$firm)),
           start = 1935, freq = 1)

purtest(LINV, test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
## ↪ Intercepts)
##
## data: LINV
## z = -0.63214, p-value = 0.2636
## alternative hypothesis: stationarity
```

```
purtest(LVAL, test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
## ↪ Intercepts)
##
## data: LVAL
## z = -0.74679, p-value = 0.2276
## alternative hypothesis: stationarity
```

```
purtest(diff(LINV), test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
## ↪ Intercepts)
##
## data: diff(LINV)
## z = -8.5076, p-value < 2.2e-16
## alternative hypothesis: stationarity
```

```
purtest(diff(LVAL), test = "levinlin", exo = "intercept",
        lags = "AIC", pmax = 4)
```

```
## Warning in selectT(1, theTs): the time series is short
```

```
##
## Levin-Lin-Chu Unit-Root Test (ex. var.: Individual
## ↪ Intercepts)
##
## data: diff(LVAL)
## z = -11.944, p-value < 2.2e-16
## alternative hypothesis: stationarity
```

En niveles no se rechaza la hipótesis nula de raíz unitaria para ninguna de las dos variables, mientras que en diferencias se rechaza contundentemente: ambas series son $I(1)$, el escenario donde tiene sentido preguntarse por cointegración. (En paneles tan cortos como éste, $T = 20$, distintas pruebas pueden arrojar conclusiones encontradas —la prueba IPS con tendencia, por ejemplo, rechaza la raíz unitaria en niveles—, por lo que en la práctica conviene contrastar más de una especificación antes de concluir.)

Paso 2: estimar la relación de largo plazo. Estimamos la regresión de cointegración con efectos fijos por empresa:

```
eq_lp <- plm(log(inv) ~ log(value), data = Grunfeld,
             index = c("firm", "year"), model = "within")

coef(summary(eq_lp))
```

```
##              Estimate Std. Error  t-value      Pr(>|t|)
## log(value) 0.9713448  0.0959524 10.12319 1.607934e-19
```

La elasticidad estimada de largo plazo es cercana a uno: en el largo plazo, la inversión crece proporcionalmente con el valor de mercado de la empresa.

Paso 3: prueba residual (idea de Kao). Si existe cointegración, los residuales $\hat{e}_{it}$ de la regresión anterior deben ser estacionarios. Siguiendo la lógica de Kao (1999), estimamos la regresión ADF *agrupada* sobre los residuales, imponiendo el mismo coeficiente ρ para todas las empresas:

```
ehat <- residuals(eq_lp)

adf_pool <- lm(diff(ehat) ~ lag(ehat) - 1)

coef(summary(adf_pool))
```

```
##              Estimate Std. Error  t value      Pr(>|t|)
## lag(ehat) -0.2319281 0.04987178 -4.650488 0.000006207847
```

El coeficiente de $\hat{e}_{i,t-1}$ es negativo y su estadístico t es grande en valor absoluto. Cabe advertir que, al calcularse sobre residuales estimados, este estadístico no sigue la distribución t estándar: la prueba formal de Kao le aplica correcciones que lo llevan a una $N(0, 1)$. Dichas correcciones están implementadas en software especializado (por ejemplo, `xtcointtest` en Stata o las pruebas de panel de EViews); en R, las implementaciones disponibles se encuentran en paquetes archivados, por lo que aquí mostramos la mecánica de la prueba de forma transparente. Con un estadístico de esta magnitud, la evidencia contra la hipótesis nula de no cointegración es clara.

Paso 4: ecuación de corrección de error (idea de Westerlund). Como verificación complementaria, estimamos el mecanismo de corrección de error en panel: si hay cointegración, las desviaciones del equilibrio de largo plazo ($\hat{e}_{i,t-1}$) deben corregirse, es decir, su coeficiente α debe ser negativo y significativo:

```
pGrunfeld <- pdata.frame(Grunfeld, index = c("firm", "year"))

pGrunfeld$ehat <- ehat

mce <- plm(diff(log(inv)) ~ lag(ehat) + lag(diff(log(inv))) +
           diff(log(value)),
           data = pGrunfeld, model = "within")

coef(summary(mce))
```

##	Estimate	Std. Error	t-value
$\hookrightarrow$ Pr(> t)			
## lag(ehat)	-0.2631642	0.05031209	-5.230636
$\hookrightarrow$ 5.005279e-07			
## lag(diff(log(inv)))	0.1455486	0.06613555	2.200762
$\hookrightarrow$ 2.912503e-02			
## diff(log(value))	0.6766472	0.09021746	7.500180
$\hookrightarrow$ 3.582884e-12			

El coeficiente de ajuste estimado es $\hat{\alpha} \approx -0.26$ y altamente significativo: cada año se corrige alrededor de una cuarta parte de la desviación respecto del equilibrio de largo plazo, lo que implica una vida media del desequilibrio de poco más de dos años. Ambos enfoques —el residual y el de corrección de error— apuntan a la misma conclusión: la inversión y el valor de la empresa cointegran en este panel.

7.4 Modelos No Lineales

7.4.1 Modelos de cambio de régimen

En años recientes, los modelos de serie de tiempo han sido incorporados en análisis de la existencia de diferentes estados que son generados por procesos estocásticos subyacentes. En esta sección del curso revisaremos algunos modelos de cambio de régimen. Restringimos nuestra revisión a modelos que asuman que la dinámica de las series puede ser descrita por modelos del tipo AR y dejamos fuera procesos del tipo MA.

En general distinguimos que existen dos tipos de modelos: 1. Modelos caracterizados por una variable observable, por lo que tenemos certeza de los regímenes en cada uno de los momentos.

2. Modelos en los que el régimen no puede ser observado por una variable, pero sí conocemos el proceso estocástico subyacente.

7.4.2 Regímenes determinados por información observable

En estos casos asumimos que el régimen ocurre en un momento t y puede ser determinado por una variable observable. Este modelo es conocido como el modelo autorregresivo con umbral (TAR, Threshold Autoregressive model). En este caso también diremos que cuando el régimen está determinado por la información de la misma serie será llamado Self-Exciting TAR (SETAR).

Veamos un caso particular. Supongamos que existe un umbral, c , para el régimen que está determinado por $q_t = y_{t-1}$ y que el estado de la naturaleza nos permite establecer dos estados o regímenes:

$$y_t = \begin{cases} \phi_{01} + \phi_{11}y_{t-1} + \varepsilon_t & \text{si } y_{t-1} \leq c \\ \phi_{02} + \phi_{12}y_{t-1} + \varepsilon_t & \text{si } y_{t-1} > c \end{cases} \quad (7.18)$$

Donde asumiremos que ε_t es i.i.d y que cumple con:

$$\mathbb{E}[\varepsilon_t | \Omega_{t-1}] = 0$$

Donde $\Omega_{t-1} = \{y_{t-1}, y_{t-2}, \dots\}$. Existe una variante de este modelo que suaviza la transición entre regímenes conocido como Smooth Transition AR (STAR) y puede ser especificada en su modalidad de dos regímenes como:

$$y_t = (\phi_{01} + \phi_{11}y_{t-1})(1 - G(y_{t-1}; \gamma, c)) + (\phi_{02} + \phi_{12}y_{t-1})G(y_{t-1}; \gamma, c) + \varepsilon_t \quad (7.19)$$

Donde $G(y_{t-1}; \gamma, c)$ es una función de distribución de probabilidad que suaviza la transición entre regímenes. La práctica común es suponer que esta tiene una forma logística:

$$G(y_{t-1}; \gamma, c) = \frac{1}{1 + e^{-\gamma(y_{t-1} - c)}} \quad (7.20)$$

Es posible hacer extensiones de lo anterior a modelos de orden superior; dando como resultado:

$$y_t = \begin{cases} \phi_{01} + \phi_{11}y_{t-1} + \phi_{21}y_{t-2} + \dots + \phi_{p_1 1}y_{t-p_1} + \varepsilon_t & \text{si } y_{t-1} \leq c \\ \phi_{02} + \phi_{12}y_{t-1} + \phi_{22}y_{t-2} + \dots + \phi_{p_2 2}y_{t-p_2} + \varepsilon_t & \text{si } y_{t-1} > c \end{cases} \quad (7.21)$$

En el segundo caso:

$$\begin{aligned} y_t = & (\phi_{01} + \phi_{11}y_{t-1} + \phi_{21}y_{t-2} + \dots + \phi_{p_1 1}y_{t-p_1})(1 - G(y_{t-1}; \gamma, c)) \\ & + (\phi_{02} + \phi_{12}y_{t-1} + \phi_{22}y_{t-2} + \dots + \phi_{p_2 2}y_{t-p_2})G(y_{t-1}; \gamma, c) \\ & + \varepsilon_t \end{aligned}$$

De igual forma que en el caso de los modelos ARIMA y VAR, el número de rezagos utilizados es determinado mediante el uso de criterios de información como el de Akaike:

$$AIC(p_1, p_2) = n_1 \ln(\hat{\sigma}_1^2) + n_2 \ln(\hat{\sigma}_2^2) + 2(p_1 + 1) + 2(p_2 + 1) \quad (7.22)$$

Los modelos SETAR y STAR generan procesos estacionarios siempre que cumplan ciertas condiciones. En estas notas nos enfocaremos únicamente en el modelo SETAR, el cual genera un proceso estacionario cuando: 1. $\phi_{11} < 1$, $\phi_{12} < 1$, $\phi_{11} \cdot \phi_{12} < 1$

2. $\phi_{11} = 1, \phi_{12} < 1, \phi_{01} > 0$
3. $\phi_{11} < 1, \phi_{12} = 1, \phi_{02} < 0$
4. $\phi_{11} = 1, \phi_{12} = 1, \phi_{02} < 0 < \phi_{01}$
5. $\phi_{11} \cdot \phi_{12} = 1, \phi_{11} < 0, \phi_{02} + \phi_{12} \cdot \phi_{01} > 0$

Finalmente, en ocasiones podemos estar interesados en modelos donde los regímenes sean más de 2, es decir, digamos m umbrales bajo un modelo SETAR o STAR. Por ejemplo, en el caso de un modelo SETAR podemos verificar que m regímenes implican $m + 1$ umbrales: $c_0, c_1, \dots, c_m$. En cuyo caso:

$$-\infty = c_0 < c_1 < \dots < c_{m-1} < c_m = \infty$$

Así, tendríamos ecuaciones:

$$y_t = \phi_{0j} + \phi_{1j}y_{t-1} + \varepsilon_t \text{ si } c_{j-1} < y_{t-1} < c_j \quad (7.23)$$

Para $j = 1, 2, \dots, m$. De forma similar, podemos recomponer el modelo STAR.

7.4.3 Regímenes determinados por variables no observables

Este tipo de modelos asume que el régimen ocurre en el momento t y que no puede ser observado, ya que este es determinado por un proceso no observable, el cual denotamos como s_t . En el caso de dos regímenes, s_t puede ser asumido como que toma 2 valores: 1 y 2, por ejemplo. Supongamos que el proceso subyacente tiene una forma del tipo AR(1) dado por:

$$y_t = \begin{cases} \phi_{01} + \phi_{11}y_{t-1} + \varepsilon_t & \text{si } s_t = 1 \\ \phi_{02} + \phi_{12}y_{t-1} + \varepsilon_t & \text{si } s_t = 2 \end{cases} \quad (7.24)$$

O en un formato más corto de notación:

$$y_t = \phi_{0s_t} + \phi_{1s_t}y_{t-1} + \varepsilon_t \quad (7.25)$$

Para complementar el modelo, las propiedades del proceso s_t necesitan ser especificadas. El modelo más popular dentro de esta familia es el propuesto por Hamilton (1989), el cual es conocido como Markov Switching Model (MSM), en el cual el proceso s_t se asume como un proceso de Markov de primer orden. Esto implica que el régimen actual s_t sólo depende del período s_{t-1} .

Así, el modelo es completado mediante la definición de las probabilidades de transición para moverse de un estado a otro:

$$\begin{aligned}\mathbb{P}(s_t = 1 | s_{t-1} = 1) &= p_{11} \\ \mathbb{P}(s_t = 2 | s_{t-1} = 1) &= p_{12} \\ \mathbb{P}(s_t = 1 | s_{t-1} = 2) &= p_{21} \\ \mathbb{P}(s_t = 2 | s_{t-1} = 2) &= p_{22}\end{aligned}$$

Así, p_{ij} es igual a la probabilidad de que la cadena de Markov pase del estado i en el momento $t-1$ al estado j en el tiempo t . En todo caso asumiremos que $p_{ij} > 0$ y que:

$$\begin{aligned}p_{11} + p_{12} &= 1 \\ p_{21} + p_{22} &= 1\end{aligned}$$

Otro tipo de probabilidades a analizar son las probabilidades incondicionales de $\mathbb{P}(s_t = i)$, $i = 1, 2$. Usando la teoría ergódica de las cadenas de Markov, estas probabilidades están dadas por:

$$\begin{aligned}\mathbb{P}(s_t = 1) &= \frac{1 - p_{22}}{2 - p_{11} - p_{22}} \\ \mathbb{P}(s_t = 2) &= \frac{1 - p_{11}}{2 - p_{11} - p_{22}}\end{aligned}$$

Un caso más general es el de múltiples regímenes en el cual s_t puede tomar cualquier valor $m > 2$, $m \in \mathbb{N}$. Este modelo se puede escribir como:

$$y_t = \phi_{0j} + \phi_{1j}y_{t-1} + \varepsilon_t \text{ si } s_t = j, \text{ para } j = 1, 2, \dots, m \quad (7.26)$$

Donde las probabilidades de transición estarán dadas por:

$$p_{ij} = \mathbb{P}(s_t = j | s_{t-1} = i) \text{ para } i, j = 1, 2, \dots, m \quad (7.27)$$

Donde la ecuación anterior satisface que $p_{ij} > 0$, $\forall i, j = 1, 2, \dots, m$ y que:

$$\sum_{j=1}^m p_{ij} = 1 \text{ para } i = 1, 2, \dots, m$$

Finalmente, plantearemos el procedimiento empírico seguido para la estimación de este tipo de modelos: 1. Estimar un proceso AR(p)

2. Probar una hipótesis nula de no linealidad de acuerdo con alguno de los modelos SETAR, STAR o MSM
3. Estimar los parámetros
4. Evaluar los resultados del modelo
5. Ajustar, en su caso, la estimación o modelo
6. Pronosticar o realizar análisis impulso-respuesta

7.5 Ejemplo: Modelos de Cambio de Régimen (TAR)

Dependencias y configuración:

Datos: tasas mensuales de muertes por gripe en Estados Unidos (11 años):


```
##      X.8113721
## 1 0.4458291
## 2 0.3415985
## 3 0.2774243
## 4 0.2484958
## 5 0.2525427
## 6 0.2466902
```

Conversión a series de tiempo:


```
flu <- ts(flu)
D_flu = diff(flu, lag = 1)
```

Gráficas:

```
plot(flu, type = "b", col = "darkred", ylab = "",
      main = "Tasas mensuales de muertes por gripe en Estados
      ↪ Unidos")
```

Tasas mensuales de muertes por gripe en Estados Unidos

```
plot(D_flu, type="b", col = "darkred", ylab = "",  
     main = "Diferencias de las tasas mensuales de muertes por  
     ↳ gripe en EE.UU.")
```

Diferencias de las tasas mensuales de muertes por gripe en EE.UU

El paquete `tsDyn` simplifica la estimación en pocos pasos:

```
##?setar

D_flu_tar4_05 <- setar(D_flu, m = 4, thDelay = 0, th = 0.05)

## Warning:
## With the threshold you gave (0.05) there is a regime with less
  ↪ than trim=15% observations (86.51%, 13.49%, )


## Warning: Possible unit root in the high regime. Roots are:
  ↪ 0.6182
## 0.6244 0.6244 0.6182

summary(D_flu_tar4_05)


##
## Non linear autoregressive model
##
## SETAR model ( 2 regimes)
## Coefficients:
## Low regime:
##      const.L      phiL.1      phiL.2      phiL.3
  ↪ phiL.4
## 0.004432028 0.501179574 -0.206693004 0.120140800
  ↪ -0.122254140
##
## High regime:
##      const.H      phiH.1      phiH.2      phiH.3      phiH.4
## 0.4079353 -0.7483325 -1.0323129 -2.0450407 -6.7117769
##
## Threshold:
## -Variable: Z(t) = + (1) X(t)+ (0)X(t-1)+ (0)X(t-2)+ (0)X(t-3)
## -Value: 0.05 (fixed)
## Proportion of points in low regime: 86.51%    High regime:
  ↪ 13.49%
##
## Residuals:
##      Min      1Q      Median      3Q      Max
## -0.1319314 -0.0217073 0.0015801 0.0196093 0.2674245
##
## Fit:
## residuals variance = 0.002166, AIC = -778, MAPE = 412.4%
##
```

```
## Coefficient(s):
##
##           Estimate Std. Error t value Pr(>|t|)
## const.L  0.0044320  0.0051791  0.8558 0.3938357
## phiL.1    0.5011796  0.0833821  6.0106 2.043e-08 ***
## phiL.2   -0.2066930  0.0608839 -3.3949 0.0009313 ***
## phiL.3    0.1201408  0.0576505  2.0839 0.0392868 *
## phiL.4   -0.1222541  0.0522363 -2.3404 0.0209137 *
## const.H   0.4079353  0.0314121 12.9866 < 2.2e-16 ***
## phiH.1   -0.7483325  0.1118329 -6.6915 7.455e-10 ***
## phiH.2   -1.0323129  0.1420203 -7.2688 4.018e-11 ***
## phiH.3   -2.0450407  0.7055163 -2.8986 0.0044573 **
## phiH.4   -6.7117769  0.8367945 -8.0208 7.911e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Threshold
## Variable: Z(t) = + (1) X(t) + (0) X(t-1)+ (0) X(t-2)+ (0)
  ↪ X(t-3)
##
## Value: 0.05 (fixed)
```


```
plot(D_flu_tar4_05)
```




ACF of D_flu




ACF of Residuals








PACF of D_flu




PACF of Residuals











Regime switching plot





Si no se especifica el umbral (`th`), `setar` lo busca automáticamente en una grilla (resultado típico: ~ 0.038):

```
D_flu_tar4 <- setar(D_flu, m = 4, thDelay = 0)
```

```
## Warning: Possible unit root in the high regime. Roots are:
  ↪ 0.6316
## 0.7222 0.7222 0.6316
```

```
summary(D_flu_tar4)
```





```
##
## Non linear autoregressive model
##
## SETAR model ( 2 regimes)
## Coefficients:
## Low regime:
##      const.L      phiL.1      phiL.2      phiL.3
## -0.00006287604  0.44640751264 -0.23158878472  0.10701408961
##      phiL.4
## -0.14406085874
##
## High regime:
```





```



##      const.H      phiH.1      phiH.2      phiH.3      phiH.4
## 0.3486150 -0.5903335 -1.0318488 -2.4053812 -4.8052422
##
## Threshold:
## -Variable: Z(t) = + (1) X(t)+ (0)X(t-1)+ (0)X(t-2)+ (0)X(t-3)
## -Value: 0.03798
## Proportion of points in low regime: 84.92%      High regime:
## ↪ 15.08%
##
## Residuals:
##      Min      1Q      Median      3Q      Max
## -0.277686 -0.020554  0.005116  0.020762  0.119627
##
## Fit:
## residuals variance = 0.002405,  AIC = -762, MAPE = 372.5%
##
## Coefficient(s):
##
##      Estimate  Std. Error  t value  Pr(>|t|)
## const.L -0.000062876  0.005572290  -0.0113  0.9910158
## phiL.1  0.446407513  0.089159422   5.0068  1.921e-06 ***
## phiL.2 -0.231588785  0.064328877  -3.6001  0.0004636 ***
## phiL.3  0.107014090  0.061034049   1.7534  0.0820953 .
## phiL.4 -0.144060859  0.055198346  -2.6099  0.0102109 *
## const.H  0.348615027  0.027460007  12.6954 < 2.2e-16 ***
## phiH.1 -0.590333531  0.109881869  -5.3724  3.869e-07 ***
## phiH.2 -1.031848767  0.149570541  -6.8987  2.641e-10 ***
## phiH.3 -2.405381238  0.691344783  -3.4793  0.0007014 ***
## phiH.4 -4.805242210  0.828241480  -5.8017  5.451e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Threshold
## Variable: Z(t) = + (1) X(t) + (0) X(t-1)+ (0) X(t-2)+ (0)
## ↪ X(t-3)
##
## Value: 0.03798



```

```
plot(D_flu_tar4)
```












Regime switching plot



Threshold variable used



Ordered threshold variable



7.6 Resumen del capítulo

Este capítulo amplió el análisis de series de tiempo a dos dimensiones adicionales: la dimensión transversal (datos panel) y la no linealidad (modelos de cambio de régimen).

Datos panel. Los datos panel combinan series de tiempo para múltiples individuos o unidades (N individuos, T periodos). El modelo básico incluye efectos fijos α_i que capturan heterogeneidad no observada constante en el tiempo. Las pruebas de raíz unitaria en panel (Levin et al. 2002, Im et al. 2003, Maddala y Wu 1999, Hadri 2000) amplían el poder estadístico al explotar la dimensión transversal; plantean hipótesis nulas de no estacionariedad con hipótesis alternativas homogéneas o heterogéneas según la prueba.

Diferencia en diferencias (DiD). El estimador DiD identifica el efecto causal de un tratamiento comparando la variación en el tiempo del grupo tratado con la del grupo de control. Su validez descansa en el supuesto de tendencias paralelas: en ausencia del tratamiento, ambos grupos habrían seguido trayectorias paralelas.

Panel VAR. El Panel VAR (PVAR) combina las ventajas del VAR clásico con la dimensión transversal del panel. Dado que el estimador *within* es sesgado en paneles dinámicos con T pequeño (sesgo de Nickell), se estima mediante GMM con instrumentos basados en los rezagos de las propias variables, controlando por efectos fijos mediante transformación de primeras diferencias o desviaciones ortogonales; la validez de los instrumentos se evalúa con la prueba de Hansen y las pruebas de autocorrelación de orden 1 y 2. La selección del número de rezagos sigue el criterio de Andrews y Lu (2001).

Cointegración en panel. Cuando las series del panel son $I(1)$, las pruebas de Pedroni, Kao y Westerlund permiten contrastar la existencia de relaciones de largo plazo. Las pruebas residuales verifican la estacionariedad de los residuales de la regresión de cointegración, mientras que el enfoque de corrección de errores verifica que las desviaciones del equilibrio se corrijan ($\alpha < 0$); ambos enfoques se ilustraron con el panel de Grunfeld.

Modelos no lineales. Cuando la dinámica de una serie cambia de forma discreta según el estado del sistema, los modelos de cambio de régimen son más apropiados que los modelos lineales.

- *TAR (Threshold Autoregressive)*: el régimen depende de si una variable observable supera un umbral c . En la variante SETAR, el umbral lo determina la propia serie rezagada.
- *STAR (Smooth Transition AR)*: la transición entre regímenes es gradual y está gobernada por una función logística paramétrica $G(y_{t-1}; \gamma, c)$.
- *Markov Switching (MSM)*: el régimen s_t es una variable latente que sigue una cadena de Markov de primer orden. Las probabilidades de transición

$p_{ij} = \mathbb{P}(s_t = j \mid s_{t-1} = i)$ son estimadas junto con los parámetros del modelo AR condicional al régimen.

En todos los casos, el procedimiento empírico incluye: estimar un AR(p) lineal, probar la hipótesis de linealidad, estimar el modelo no lineal seleccionado, evaluar resultados y, finalmente, generar pronósticos o funciones de impulso-respuesta.

Bibliografía

- Allaire, J., Xie, Y., Dervieux, C., McPherson, J., Luraschi, J., Ushey, K., Atkins, A., Wickham, H., Cheng, J., Chang, W., and Iannone, R. (2026). *rmarkdown: Dynamic Documents for R*. R package version 2.31.
- Andrews, D. W. K. and Lu, B. (2001). Consistent model and moment selection procedures for GMM estimation with application to dynamic panel data models. *Journal of Econometrics*, 101(1):123–164.
- Antón Sarabia, A. (2010). El problema al final de la muestra en la estimación de la brecha del producto. *Economía Mexicana. Nueva Época*, XIX(1):5–29.
- Arellano, M. and Bond, S. (1991). Some tests of specification for panel data: Monte Carlo evidence and an application to employment equations. *Review of Economic Studies*, 58(2):277–297.
- Arellano, M. and Bover, O. (1995). Another look at the instrumental variable estimation of error-components models. *Journal of Econometrics*, 68(1):29–51.
- Blanchard, O. J. and Quah, D. (1989). The dynamic effects of aggregate demand and supply disturbances. *American Economic Review*, 79(4):655–673.
- Blundell, R. and Bond, S. (1998). Initial conditions and moment restrictions in dynamic panel data models. *Journal of Econometrics*, 87(1):115–143.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327.
- Box, G. E. P. and Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day, San Francisco.
- Box, G. E. P. and Pierce, D. A. (1970). Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal of the American Statistical Association*, 65(332):1509–1526.
- Breusch, T. S. (1978). Testing for autocorrelation in dynamic linear models. *Australian Economic Papers*, 17(31):334–355.

- Brooks, C. (2019). *Introductory Econometrics for Finance*. Cambridge University Press, Cambridge, 4th edition.
- Choi, I. (2001). Unit root tests for panel data. *Journal of International Money and Finance*, 20(2):249–272.
- Cowpertwait, P. S. P. and Metcalfe, A. V. (2009). *Introductory Time Series with R*. Springer, New York.
- Dahlberg, M. and Johansson, E. (2000). An examination of the dynamic behaviour of local governments using GMM bootstrapping methods. *Journal of Applied Econometrics*, 15(4):401–416.
- Dickey, D. A. and Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366):427–431.
- Dickey, D. A. and Fuller, W. A. (1981). Likelihood ratio statistics for autoregressive time series with a unit root. *Econometrica*, 49(4):1057–1072.
- Enders, W. (2015). *Applied Econometric Time Series*. Wiley, Hoboken, NJ, 4th edition.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4):987–1007.
- Engle, R. F. and Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica*, 55(2):251–276.
- Engle, R. F., Lilien, D. M., and Robins, R. P. (1987). Estimating time varying risk premia in the term structure: The ARCH-M model. *Econometrica*, 55(2):391–407.
- Franses, P. H. and van Dijk, D. (2000). *Non-Linear Time Series Models in Empirical Finance*. Cambridge University Press, Cambridge.
- Glosten, L. R., Jagannathan, R., and Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5):1779–1801.
- Godfrey, L. G. (1978). Testing against general autoregressive and moving average error models when the regressors include lagged dependent variables. *Econometrica*, 46(6):1293–1301.
- Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438.
- Grunfeld, Y. (1958). *The Determinants of Corporate Investment*. PhD thesis, University of Chicago.

- Guerrero, V. M. (2003). *Análisis Estadístico de Series de Tiempo Económicas*. Cengage Learning Editores, México.
- Hadri, K. (2000). Testing for stationarity in heterogeneous panel data. *Econometrics Journal*, 3(2):148–161.
- Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2):357–384.
- Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press, Princeton, NJ.
- Hodrick, R. J. and Prescott, E. C. (1997). Postwar U.S. business cycles: An empirical investigation. *Journal of Money, Credit and Banking*, 29(1):1–16.
- Im, K. S., Pesaran, M. H., and Shin, Y. (2003). Testing for unit roots in heterogeneous panels. *Journal of Econometrics*, 115(1):53–74.
- International Monetary Fund (2020). Monetary policy analysis and forecasting. Curso en línea, plataforma edX.
- Jarque, C. M. and Bera, A. K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3):255–259.
- Johansen, S. (1988). Statistical analysis of cointegration vectors. *Journal of Economic Dynamics and Control*, 12(2–3):231–254.
- Kálmán, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1):35–45.
- Kao, C. (1999). Spurious regression and residual-based tests for cointegration in panel data. *Journal of Econometrics*, 90(1):1–44.
- Kirchgässner, G., Wolters, J., and Hassler, U. (2013). *Introduction to Modern Time Series Analysis*. Springer Texts in Business and Economics. Springer, Berlin, Heidelberg, 2nd edition.
- Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., and Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1–3):159–178.
- Levendis, J. D. (2023). *Time Series Econometrics: Learning Through Replication*. Springer Texts in Business and Economics. Springer, Cham, 2nd edition.
- Levin, A., Lin, C.-F., and Chu, C.-S. J. (2002). Unit root tests in panel data: Asymptotic and finite-sample properties. *Journal of Econometrics*, 108(1):1–24.
- Ljung, G. M. and Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2):297–303.

- Lucas, R. E. (1976). Econometric policy evaluation: A critique. *Carnegie-Rochester Conference Series on Public Policy*, 1:19–46.
- Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer, Berlin.
- MacKinnon, J. G. (1996). Numerical distribution functions for unit root and cointegration tests. *Journal of Applied Econometrics*, 11(6):601–618.
- Maddala, G. S. and Wu, S. (1999). A comparative study of unit root tests with panel data and a new simple test. *Oxford Bulletin of Economics and Statistics*, 61(S1):631–652.
- Marcet, A. and Ravn, M. O. (2004). The HP-filter in cross-country comparisons. CEPR Discussion Paper 4244, Centre for Economic Policy Research, London.
- Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2):347–370.
- Neusser, K. (2025). *Time Series Econometrics*. Springer Texts in Business and Economics. Springer, Cham, 2nd edition.
- Nickell, S. (1981). Biases in dynamic models with fixed effects. *Econometrica*, 49(6):1417–1426.
- Pedroni, P. (1999). Critical values for cointegration tests in heterogeneous panels with multiple regressors. *Oxford Bulletin of Economics and Statistics*, 61(S1):653–670.
- Pedroni, P. (2004). Panel cointegration: Asymptotic and finite sample properties of pooled time series tests with an application to the PPP hypothesis. *Econometric Theory*, 20(3):597–625.
- Pesaran, M. H., Shin, Y., and Smith, R. J. (2001). Bounds testing approaches to the analysis of level relationships. *Journal of Applied Econometrics*, 16(3):289–326.
- Phillips, P. C. B. and Perron, P. (1988). Testing for a unit root in time series regression. *Biometrika*, 75(2):335–346.
- R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Roodman, D. (2009). How to do xtabond2: An introduction to difference and system GMM in Stata. *The Stata Journal*, 9(1):86–136.
- Shrestha, M. B. and Bhatta, G. R. (2018). Selecting appropriate methodological framework for time series data analysis. *The Journal of Finance and Data Science*, 4(2):71–89.
- Sims, C. A. (1980). Macroeconomics and reality. *Econometrica*, 48(1):1–48.

- St-Amant, P. and van Norden, S. (1997). Measurement of the output gap: A discussion of recent research at the Bank of Canada. Technical Report 79, Bank of Canada, Ottawa.
- Stock, J. H. (1987). Asymptotic properties of least squares estimators of cointegrating vectors. *Econometrica*, 55(5):1035–1056.
- Stock, J. H. and Watson, M. W. (1988). Testing for common trends. *Journal of the American Statistical Association*, 83(404):1097–1107.
- Taylor, S. J. (1986). *Modelling Financial Time Series*. Wiley, Chichester.
- Tobin, J. (1969). A general equilibrium approach to monetary theory. *Journal of Money, Credit and Banking*, 1(1):15–29.
- Wei, W. W. S. (2019). *Multivariate Time Series Analysis and Applications*. Wiley, Hoboken, NJ.
- Westerlund, J. (2007). Testing for error correction in panel data. *Oxford Bulletin of Economics and Statistics*, 69(6):709–748.
- Windmeijer, F. (2005). A finite sample correction for the variance of linear efficient two-step GMM estimators. *Journal of Econometrics*, 126(1):25–51.
- Xie, Y. (2014). knitr: A comprehensive tool for reproducible research in R. In Stodden, V., Leisch, F., and Peng, R. D., editors, *Implementing Reproducible Computational Research*. Chapman and Hall/CRC. ISBN 978-1466561595.
- Xie, Y. (2015a). *Dynamic Documents with R and knitr*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition. ISBN 978-1498716963.
- Xie, Y. (2015b). *Dynamic Documents with R and knitr*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition. ISBN 978-1498716963.
- Xie, Y. (2016). *bookdown: Authoring Books and Technical Documents with R Markdown*. Chapman and Hall/CRC, Boca Raton, Florida.
- Xie, Y. (2023a). *bookdown: Authoring Books and Technical Documents with R Markdown*. R package version 0.34.
- Xie, Y. (2023b). *knitr: A General-Purpose Package for Dynamic Report Generation in R*. R package version 1.43.
- Xie, Y., Allaire, J., and Golemund, G. (2018). *R Markdown: The Definitive Guide*. Chapman and Hall/CRC, Boca Raton, Florida.
- Xie, Y., Dervieux, C., and Riederer, E. (2020). *R Markdown Cookbook*. Chapman and Hall/CRC, Boca Raton, Florida.
- Zivot, E. and Andrews, D. W. K. (1992). Further evidence on the great crash, the oil-price shock, and the unit-root hypothesis. *Journal of Business & Economic Statistics*, 10(3):251–270.